



AI 神经网络的数学

用 Python、PyTorch 讲解

线性代数

微积分

概率论

梯度下降

反向传播

CNN

Transformer

大语言模型

涵盖 9 章正文 + 6 个附录 · 1092 个数学公式 · 324 个代码示例

从神经元到 Transformer，用数学理解深度学习

作者：xiefujin · 邮箱：490021684@qq.com

Generated from Markdown source · 2025

目录

- 前言
- 第 1 章 神经网络的思想
- 第 2 章 神经网络的数学基础
- 第 3 章 PyTorch 基础：Tensor 与自动微分
- 第 4 章 神经网络的训练与优化
- 第 5 章 ★ 误差反向传播法
- 第 6 章 卷积神经网络
- 第 7 章 训练技术：优化器、正则化与损失函数
- 第 8 章 现代架构：从 ResNet 到 Transformer
- 第 9 章 大语言模型：训练、采样与推理
- 附录
 - 附录 A：数学公式回顾
 - 附录 B：PyTorch API 速查
 - 附录 C：符号约定
 - 附录 D：常见函数汇总
 - 附录 E：习题参考答案
 - 附录 F：推荐阅读

前言

作者：xiefujin · 邮箱：490021684@qq.com

欢迎！这本书是为那些想真正理解神经网络数学原理、但又不想被形式化推导吓跑的读者准备的。

本书从基础数学概念出发，配合 Python + PyTorch 代码验证，让你看见数学在动。

> © xiefujin · Licensed under CC BY-NC-SA 4.0

本章学习目标

- [] 了解本书的定位和特色
- [] 知道如何高效使用这本书
- [] 准备好 Python 开发环境
- [] 理解本书的核心理念：先直觉，后公式，再代码

0-1 为什么需要这本书？

现有书籍的「缺口」

市面上关于深度学习的书很多，但大多数在数学和代码之间有一个缺口：

书籍类型	优点	不足
纯数学书（如《深度学习的数学》原版）	数学推导严谨	用 Excel 演示，无法处理大规模数据，无法自动求梯度，无法可视化训练过程
工程导向书（如《动手学深度学习》）	代码实战丰富	数学原理讲得不够深，读者容易「知其然而不知其所以然」
学术教材（如《深度学习》Goodfellow）	理论系统完整	数学门槛太高，不适合自学读者

本书填补的「桥梁」

本书在数学原理理解和代码验证之间架起一座桥梁——不求会推导，只求真理解。

核心定位：从基础数学概念出发，手把手帮你理解深度学习背后的数学原理——用 Python + PyTorch 代码来验证和可视化每个概念，而不是做形式化的数学推导。

0-2 本书特色

特色	说明
理解为先	每个数学原理先用直觉和可视化讲清楚，再用代码验证
可视化	Matplotlib 动态展示梯度下降、反向传播过程
PyTorch 原生	手动 NumPy → PyTorch autograd 渐进过渡
透明推导	不隐藏中间步骤，每一层每个权重变化都可见，每一步都有直觉解释
对比实验	每个关键环节都有手动 vs 自动计算对比

每章的标准节奏

每章按照「概念 → 可视化 → 公式 → 代码」的统一节奏展开：

1. **概念直觉** — 30 字说清“它像什么”
2. **可视化** — 让眼睛先“看见”数学
3. **数学公式** — 标注每个符号的含义
4. **代码验证** — “看，数学在这里是这样工作的”
5. **核心洞察** — 一句话总结本节精华

💡 提示：如果你是初学者，建议按顺序阅读；如果你已经有基础，可以直接跳到代码部分，需要理解细节时再回头看公式。

💡 0-3 环境配置

硬件要求

本书的所有代码都可以在普通笔记本电脑上运行：

- 任何能运行 Python 的电脑（无需 GPU）
- 建议 8GB+ 内存（4GB 也可以，但训练稍慢）
- 硬盘空间：约 2GB（包括 PyTorch、MNIST 数据集等）

即使没有 GPU，本书的代码也足够快——我们不会训练 ImageNet 规模的大模型，所有示例都是小规模的数据验证。

软件要求

```
# 推荐使用 conda 或 venv 创建虚拟环境
conda create -n dl_math python=3.10
conda activate dl_math

# 安装核心依赖
pip install torch torchvision # PyTorch 2.0+
pip install numpy matplotlib # 科学计算 + 可视化
pip install jupyter          # (可选) 交互式 notebook
```

版本要求

软件	最低版本	推荐版本
Python	3.8	3.10+
PyTorch	1.13	2.0+
NumPy	1.21	1.24+
Matplotlib	3.5	3.7+

配套代码

- 每章的代码文件在 `code/chNN/` 目录下
- 代码文件命名：`NN{章号}_{功能}.py`
- 推荐在 Jupyter Notebook 中逐节运行

💡 0-4 阅读建议

顺序阅读很重要

本书的章节之间有强依赖关系：

1. 第 1-2 章（基础）→ 第 3 章（工具）

2. 第 3 章 → 第 4-5 章 (核心 ★)
 3. 第 4-5 章 → 第 6 章 (CNN)
 4. 第 7-9 章 — 可按兴趣选读
- 前 4 章是第 5 章 (反向传播法, 全书核心) 的前提
 - 第 5 章是第 6 章 (CNN) 的前提
 - 第 7-9 章可以按兴趣选读

每章的标准结构

每章统一节奏: 概念直觉 → 数学公式 → Python 代码 → PyTorch 验证 → 可视化 → 核心洞察

高效使用方法

1. 先读一遍: 快速通读, 建立整体印象
2. 动手运行: 每一章的 Python 代码都亲手运行
3. 修改参数: 尝试修改学习率、层数、激活函数观察变化
4. 先理解原理, 再看代码: 数学直觉是目标, 代码验证是手段

遇到困难怎么办?

- 数学公式看不懂 → 看公式后面的「人话解释」
- 代码跑不通 → 检查依赖版本, 或回退到 `requirements.txt` 指定版本
- 概念不理解 → 先跳过, 继续往后读, 很多时候后面的内容会帮你理解前面的

💡 0-5 本书的核心理念: 理解数学原理, 而非形式推导

三个信念

1. 数学直觉比公式推导更重要

你不需要会从零推导反向传播公式, 但你需要**直觉上理解**它为什么能工作。

- 每个公式后面都有人话解释: 「这条公式的本质是……」
- 复杂的数学用可视化和类比来理解, 而不是用符号运算

2. 代码是用来验证直觉的, 不是主角

每个数学概念先讲直觉 → 再展示公式 → 最后用代码验证。

- 代码简短、聚焦、可运行——不是展示编程技巧, 而是展示数学在「动」
- 不隐藏中间步骤: 每一层、每个权重的变化都可观察

3. 理解 = 知道「为什么」 > 知道「是什么」

本书的每个子节都优先回答「为什么需要这个概念?」

- 然后用可视化让你「看见」数学
- 最后用代码让你「摸到」数学

三个「不」原则

1. 不作形式化证明: 不需要从公理出发一步步推导, 给直觉即可
2. 不引入多余的数学符号: 能用 w 就不用 θ , 能用 x 就不用 ξ
3. 不假设读者学过: 每个符号第一次出现时, 用括号标注它的含义

🔥 一句话总结: 读完本书, 你不需要成为数学家, 但你会**直觉上理解**神经网络每一步在做什么数学——并且能用代码验证你的理解。

📦 本章配套资源

资源	说明
<code>requirements.txt</code>	依赖列表
代码目录	<code>code/</code> 每章独立文件夹
插图目录	<code>images/chNN/</code> 每章独立文件夹

📖 本章小结

- 本书定位于数学直觉 → 公式 → 代码验证的桥梁
- 前置知识：基础数学概念和线性代数基础
- 核心工具链：Python + NumPy + Matplotlib + PyTorch
- 阅读方法：顺序阅读 + 动手运行 + 修改参数
- 核心理念：理解「为什么」比知道「是什么」更重要

思考题

1. 学习目标：你希望通过这本书学到什么？请写下 3 个具体目标。
2. 数学基础自评：你的数学水平如何？（1-5 分）哪些数学概念你觉得最需要补充？
3. 工具链准备：检查你的开发环境，运行 `python3 -c "import torch; print(torch.__version__)"`。如果遇到问题，尝试通过搜索引擎解决。

← 目录 | 第 1 章 神经网络的思想 →

第 1 章 神经网络的思想

 **目标：**从生物神经元出发，**直观理解**人工神经元如何做数学决策——从输入加权到激活输出，用代码验证每一步。

© xiefujin · Contact: 490021684@qq.com · Licensed under CC BY-NC-SA 4.0

 **代码文件：**code/ch01/ (5 个文件)

插图：images/ch01/ 目录 (3 张可视化图)

📖 本章学习目标

- [] 理解生物神经元与人工神经元的对应关系
- [] 掌握 M-P 神经元模型及其数学表示
- [] 理解为什么需要连续可导的激活函数
- [] 理解 4 种常见激活函数的区别
- [] 理解神经网络的三要素：输入层、隐藏层、输出层
- [] 能用代码搭建一个简单的 2 层网络
- [] 理解「学习 = 参数优化」这个核心思想

1-1 神经网络和深度学习

1-1-1 深度学习的背景

AI 的三次浪潮

人工智能的发展并非一帆风顺，它经历了三次大的浪潮：

时期	浪潮	核心思想	代表作
1950s–1960s	符号主义	逻辑推理、符号运算	逻辑理论机、专家系统
1980s–1990s	统计学习	数据驱动、概率建模	支持向量机、随机森林
2010s–至今	深度学习	端到端学习、表示学习	AlexNet、Transformer、GPT

为什么是现在？

深度学习在 2010 年代爆发，背后有三个驱动力：

1. **数据：**互联网催生了海量标注数据（ImageNet 拥有 1400 万张图片）
2. **算力：**GPU 大规模并行计算让训练深层网络成为可能
3. **算法：**反向传播 + 梯度下降 + ReLU 激活函数三大突破

深度学习的应用全景

领域	典型应用
计算机视觉 (CV)	图像分类、目标检测、人脸识别
自然语言处理 (NLP)	机器翻译、情感分析、对话系统
语音识别	语音转文字、语音合成
推荐系统	短视频推荐、商品推荐

领域	典型应用
强化学习	游戏AI、机器人控制、自动驾驶

1-1-2 从一个简单的例子开始

问题：根据面积预测房价

假设你是一个房产中介，你发现房屋面积和售价之间似乎有关系：

面积（m²）	售价（万元）
50	150
80	230
100	300
120	360

三种解决思路

方法	做法	特点
人工直觉	每平米约 3 万元，直接估算	粗糙，不稳定
数学建模	用线性回归拟合一条直线 $y = wx + b$	精确，但需手动设计
神经网络	让网络自动学习 w 和 b	通用，可扩展到复杂问题

预热：用一行 PyTorch 感受神经网络

```
import torch
import torch.nn as nn

# 一个神经元 = 线性层
neuron = nn.Linear(in_features=1, out_features=1)

# 输入：面积 100 m²
area = torch.tensor([[100.0]], dtype=torch.float32)

# 前向传播
price = neuron(area)
print(f"预测价格：{price.item():.2f} 万元")
```

预测价格：162.34 万元

💡 提示：这个结果不一定准——因为权重是随机初始化的。
本章的最后，你会理解这个「神经元」内部到底在做什么数学运算。

1-2 神经元工作的数学表示

1-2-1 生物神经元的启示

生物神经元的结构

- 1. 树突（接收信号）— 从前一个神经元接收电信号
- 2. 细胞体（整合信号）— 求和 + 判断是否超过阈值
- 3. 轴突（输出信号）— 如果超过阈值，发放脉冲
- 4. 突触（传递给下一个神经元）

关键特性

- 「全或无」法则：超过阈值就激活（发放脉冲），否则保持静默
- 突触可塑性：连接强度（权重）可以随学习改变
- 并行处理：大脑有约 860 亿个神经元，高度并行

数学抽象

输入 $x_1, x_2, \dots \rightarrow$ 加权求和 $\sum w_i x_i \rightarrow$ 激活函数 $f(\cdot) \rightarrow$ 输出 y

1-2-2 McCulloch-Pitts 模型（M-P 模型）

1943 年，Warren McCulloch 和 Walter Pitts 提出了第一个神经元的数学模型。

数学公式

决策函数：当 $\sum w_i x_i \geq \theta$ 时输出 **1**，否则输出 **0**。

符号说明

符号	含义	类比生物神经元
x_i	输入信号（0 或 1）	树突接收的电信号
w_i	突触权重（兴奋为正，抑制为负）	突触的连接强度
θ	阈值	细胞体的激发阈值
y	输出（0 或 1）	轴突是否发放脉冲

1-2-3 用代码验证 M-P 神经元

Python 实现

```
import numpy as np

class MPNeuron:
    """McCulloch-Pitts 神经元模型"""

    def __init__(self, weights, threshold):
        self.w = np.array(weights)
        self.threshold = threshold

    def forward(self, x):
        """前向传播：加权求和 → 阈值判断"""
        u = np.dot(self.w, x)  # 加权求和:  $\sum w_i \times x_i$ 
        return 1 if u >= self.threshold else 0  # 阈值判断
```

核心思路

$$u = w_1 x_1 + w_2 x_2 + \dots + w_n x_n = \sum_{i=1}^n w_i x_i$$

决策函数：当 $u \geq \theta$ 时输出 **1**，当 $u < \theta$ 时输出 **0**。

1-2-4 示例演练：逻辑门 AND / OR

实现 AND 门

AND 门的真值表：只有两个输入都是 1 时，输出才是 1。

x_1	x_2	y_{AND}
0	0	0
0	1	0
1	0	0
1	1	1

```
# 实现 AND 门: 当  $x_1 + x_2 \geq 2$  时输出 1
and_neuron = MPNeuron(weights=[1, 1], threshold=2)

print("AND 门测试: ")
for x1 in [0, 1]:
    for x2 in [0, 1]:
        y = and_neuron.forward([x1, x2])
        print(f" {x1} AND {x2} = {y}")
```

```
AND 门测试:
0 AND 0 = 0
0 AND 1 = 0
1 AND 0 = 0
1 AND 1 = 1
```

实现 OR 门

OR 门的真值表：只要有一个输入是 1，输出就是 1。

```
# 实现 OR 门: 当  $x_1 + x_2 \geq 1$  时输出 1
or_neuron = MPNeuron(weights=[1, 1], threshold=1)

print("OR 门测试: ")
for x1 in [0, 1]:
    for x2 in [0, 1]:
        y = or_neuron.forward([x1, x2])
        print(f" {x1} OR {x2} = {y}")
```

```
OR 门测试:
0 OR 0 = 0
0 OR 1 = 1
1 OR 0 = 1
1 OR 1 = 1
```

为什么解决不了 XOR?

XOR（异或）问题的真值表：两个输入相同时输出 0，不同时输出 1。

x_1	x_2	y_{XOR}
0	0	0
0	1	1
1	0	1
1	1	0

可视化：在二维平面上画出四个点，用颜色表示输出。

点	坐标	XOR 输出
●	(0,0)	0
○	(0,1)	1
○	(1,0)	1

点	坐标	XOR 输出
●	(1,1)	0

为什么一条直线分不开？

试着画一条直线把 ○（应输出 1）和 ●（应输出 0）分开：

- 如果把左上和右下连起来，右上和左下会混在一起
- 如果把左下和右上连起来，左上和右下会混在一起

数学解释：XOR 问题在二维空间中不是线性可分的——不存在一条直线 $w_1x_1 + w_2x_2 = \theta$ 能同时正确分类四个点。

解决思路：需要两层 M-P 神经元！先用 AND、OR、NOT 组合出中间结果：

第 1 层： $h_1 = \text{NAND}(x_1, x_2)$, $h_2 = \text{OR}(x_1, x_2)$

第 2 层： $y = \text{AND}(h_1, h_2) = x_1 \text{ XOR } x_2$

这就是神经网络需要多层结构的根本原因。

💡 核心洞察：XOR 问题是 M-P 神经元的「阿喀琉斯之踵」——它揭示了单层模型的根本局限：只能处理线性可分问题。克服这个局限的唯一方法就是堆叠多层，这就是神经网络诞生的原点。

💡 核心洞察：单一 M-P 神经元只能解决线性可分问题。
XOR 需要多层神经元——这正是神经网络的起点。

1-3 激活函数：将神经元的工作一般化

1-3-1 从阶跃函数到连续函数

阶跃函数

M-P 模型使用的决策函数就是阶跃函数：

$$f(x) = \mathbb{I}(x \geq 0)$$

阶跃函数的问题

阶跃函数在 $x = 0$ 处不可导（导数不存在），而在其他地方导数为 0。

阶跃函数：当 $x \geq 0$ 时 $f(x)=1$ ，当 $x < 0$ 时 $f(x)=0$ 。在 $x=0$ 处跳跃，该点不可导。

为什么「不可导」是个大问题？

我们后面会用梯度下降来训练神经网络——而梯度下降需要计算导数。

如果激活函数不可导，梯度下降就没法工作。

解决方案：寻找「平滑版的阶跃函数」

我们需要一个函数满足：

1. 连续可导（处处有导数）
2. S 形（类似阶跃函数的形状）
3. 值域在 (0, 1)（可解释为概率）

这就是 Sigmoid 函数。

1-3-2 理解 Sigmoid：为什么需要平滑的激活函数？

数学定义

$$\sigma(x) = \frac{1}{1 + e^{-x}}$$

重要导数公式

$$\sigma'(x) = \sigma(x)(1 - \sigma(x))$$

这个导数公式非常重要——以后你在反向传播中会反复用到它。

特点

特性	说明
值域	(0, 1), 可解释为概率
单调性	单调递增
连续可导	处处可导
饱和区	当 $ x $ 很大时, 梯度接近 0 (梯度消失问题)

直觉理解

Sigmoid 就像一个「软化的开关」:

- 当输入很大时 → 输出接近 1 (开关打开)
- 当输入很小时 → 输出接近 0 (开关关闭)
- 在中间区域 → 输出平滑过渡

1-3-3 理解 ReLU：为什么它比 Sigmoid 更常用？

ReLU (Rectified Linear Unit, 修正线性单元) 是目前最常用的激活函数。

数学定义

$$\text{ReLU}(x) = \max(0, x)$$

导数

ReLU 导数：当 $x > 0$ 时导数为 1, 当 $x \leq 0$ 时导数为 0。

为什么 ReLU 比 Sigmoid 更受欢迎？

对比项	Sigmoid	ReLU
计算复杂度	需要指数运算	只需 max 操作
梯度消失	两端饱和 (梯度趋近 0)	正半轴梯度恒为 1
收敛速度	慢	快 (约 6 倍)
输出范围	(0, 1)	$[0, +\infty)$

Leaky ReLU 变体

为了解决 ReLU 在负半轴「死掉」的问题 (神经元死亡), Leaky ReLU 给负半轴一个很小的斜率:

$$\text{LeakyReLU}(x) = \max(0.01x, x)$$

1-3-4 理解 Tanh：中心对称的激活有什么好处？

数学定义

$$\tanh(x) = \frac{e^x - e^{-x}}{e^x + e^{-x}}$$

与 Sigmoid 的关系

$$\tanh(x) = 2\sigma(2x) - 1$$

特点

特性	说明
值域	(-1, 1)，零中心化
优点	输出均值为 0，有利于下一层学习
缺点	同样有饱和区（梯度消失）

🌟 小精灵说：Tanh 就像 Sigmoid 的「升级版」——它不仅告诉你信号有多强（正/负），还把信号中心化到 0 附近，让下一层的小精灵们接收到的信号更均衡。

1-3-5 代码验证：用 Python 观察四种激活函数的形状

```
import numpy as np
import matplotlib.pyplot as plt

def sigmoid(x):
    return 1 / (1 + np.exp(-x))

def sigmoid_derivative(x):
    s = sigmoid(x)
    return s * (1 - s)

def relu(x):
    return np.maximum(0, x)

def relu_derivative(x):
    return (x > 0).astype(float)

def tanh(x):
    return np.tanh(x)

def tanh_derivative(x):
    return 1 - np.tanh(x) ** 2

def step(x):
    return (x >= 0).astype(float)

# 生成数据
x = np.linspace(-5, 5, 1000)

# 四种激活函数及其导数
activations = {
    '阶跃函数 (Step)': (step, None),
    'Sigmoid': (sigmoid, sigmoid_derivative),
    'Tanh': (tanh, tanh_derivative),
    'ReLU': (relu, relu_derivative),
}
```

```

}

# 可视化
fig, axes = plt.subplots(2, 2, figsize=(12, 8))
for ax, (name, (func, deriv)) in zip(axes.flat, activations.items()):
    ax.plot(x, func(x), 'b-', linewidth=2, label=name)
    if deriv is not None:
        ax.plot(x, deriv(x), 'r--', linewidth=1.5, label='导数')
    ax.axhline(y=0, color='gray', linestyle=':', alpha=0.5)
    ax.axvline(x=0, color='gray', linestyle=':', alpha=0.5)
    ax.set_xlim(-5, 5)
    ax.set_ylim(-1.5, 1.5)
    ax.set_xlabel('x')
    ax.set_ylabel('f(x)')
    ax.set_title(name)
    ax.legend()
    ax.grid(True, alpha=0.3)

plt.tight_layout()
plt.savefig('images/ch01/NN01_activation_functions.png', dpi=150)
plt.show()

```




图 1-1: 四种激活函数及其导数对比。蓝色为函数本身，红色为导数（阶跃函数不可导）。

💡 **核心洞察**：激活函数的选择决定了网络的表达能力。

经验法则：隐藏层用 ReLU，输出层用 Sigmoid（二分类） / Softmax（多分类）。

1-4 什么是神经网络

1-4-1 网络结构三要素

一个标准的神经网络由三部分组成：

输入层 (Input Layer)

- 接收原始数据（特征向量）
- 不做任何计算，只是「传递信号」
- 节点数 = 特征维度

隐藏层 (Hidden Layer)

- 特征提取与变换
- 可以有一层或多层（这就是「深度」的来源）
- 每一层都进行：加权求和 → 激活函数

输出层 (Output Layer)

- 最终预测结果
- 节点数取决于任务类型
 - 二分类: 1 个节点 (Sigmoid)
 - 多分类: K 个节点 (Softmax)
 - 回归: 1 个节点 (无激活函数)

层	节点	作用
输入层	○ ○ ○	接收原始数据, 不做计算
隐藏层	○ ○ ○ ...	特征提取与变换 (可多层堆叠 = 深度)
输出层	○	最终预测结果

1-4-2 全连接 (Dense) 的含义

什么是「全连接」?

每一层的每个神经元都连接到上一层的所有神经元。例如输入 x_1, x_2 全连接到隐藏层 h_1, h_2, h_3 :

x_1 连接所有隐藏神经元 (通过 w_{11}, w_{12}, w_{13})

x_2 连接所有隐藏神经元 (通过 w_{21}, w_{22}, w_{23})

每个隐藏神经元 h_j 收到的信号: $u_j = w_{1j}x_1 + w_{2j}x_2 + b_j$

数学表达

$$\mathbf{z}^{(l+1)} = f(\mathbf{W}^{(l)}\mathbf{z}^{(l)} + \mathbf{b}^{(l)})$$

符号	含义	形状
$\mathbf{z}^{(l)}$	第 l 层的输出	$(n_{in},)$
$\mathbf{W}^{(l)}$	权重矩阵	(n_{in}, n_{out})
$\mathbf{b}^{(l)}$	偏置向量	$(n_{out},)$
f	激活函数	逐元素运算

参数量计算

对于一个全连接层:

$$\text{参数量} = (n_{in} \times n_{out}) + n_{out}$$

- $n_{in} \times n_{out}$ 个权重参数
- n_{out} 个偏置参数

1-4-3 从单个神经元到神经网络

单个神经元

$$y = f\left(\sum_{i=1}^n w_i x_i + b\right)$$

一层神经元（向量形式）

$$\mathbf{y} = f(\mathbf{x}\mathbf{W} + \mathbf{b})$$

其中：

- $\mathbf{x} = [x_1, x_2, \dots, x_n]$ 是 $1 \times n$ 的输入行向量
- $\mathbf{W}$ 是 $n \times m$ 的权重矩阵
- $\mathbf{b} = [b_1, b_2, \dots, b_m]$ 是偏置行向量
- $\mathbf{y} = [y_1, y_2, \dots, y_m]$ 是 m 个神经元的输出

💡 核心洞察：一层神经元 = 一个矩阵乘法 + 一个逐元素激活函数。

多层堆叠（深度）

每一层的变换： $h_i = f_i(h_{i-1} \mathbf{W}_i + \mathbf{b}_i)$

堆叠三层： $x \rightarrow W_1, b_1 \rightarrow h_1 \rightarrow W_2, b_2 \rightarrow h_2 \rightarrow W_3, b_3 \rightarrow y$

深度的来源：每一层都在进行特征变换，多层堆叠可以学习到更抽象的特征。

1-4-4 理解 2 层网络：从数学公式到 Python 代码

数学表达

$$\mathbf{h} = \sigma(\mathbf{x}\mathbf{W}_1 + \mathbf{b}_1)$$

$$\mathbf{y} = \sigma(\mathbf{h}\mathbf{W}_2 + \mathbf{b}_2)$$

Python 实现

```
import numpy as np

def sigmoid(x):
    return 1 / (1 + np.exp(-x))

class TwoLayerNetwork:
    """手动实现 2 层全连接网络"""

    def __init__(self, input_size, hidden_size, output_size):
        # 初始化权重 (小随机数)
        self.W1 = np.random.randn(input_size, hidden_size) * 0.1
        self.b1 = np.zeros(hidden_size)
        self.W2 = np.random.randn(hidden_size, output_size) * 0.1
        self.b2 = np.zeros(output_size)

    def forward(self, x):
        """前向传播"""
        # 第 1 层: 输入 → 隐藏
        self.z1 = sigmoid(np.dot(x, self.W1) + self.b1)
        # 第 2 层: 隐藏 → 输出
        self.y = sigmoid(np.dot(self.z1, self.W2) + self.b2)
        return self.y

    def predict(self, x):
        """预测 (二分类)"""
        prob = self.forward(x)
        return 1 if prob >= 0.5 else 0

# 测试网络
np.random.seed(42)
net = TwoLayerNetwork(input_size=3, hidden_size=4, output_size=1)
```

```
# 随机输入
x = np.array([0.5, 0.3, 0.8])
output = net.forward(x)
print(f"网络输出: {output[0]:.4f}")
```

🌟 小精灵说：我就是那个站在两层神经元中间的小信使！
我左手接着上一层的信号，右手把它们加权求和再激活，传给下一层。

1-5 用小精灵来讲解神经网络的结构 🌟

1-5-1 小精灵的角色设定

每个连接线都是一个小精灵

在一个全连接网络中，每一条连接线都由一个小精灵负责。以隐藏层的某个神经元 j 为例，它同时接收来自所有输入神经元的信号：

- 🌟 小精灵 A 举着 $w_{1j} = 0.5$ 的号码牌，把 x_1 放大 0.5 倍传给神经元 j
- 🌟 小精灵 B 举着 $w_{2j} = -0.3$ 的号码牌，把 x_2 取反后传给神经元 j
- 🌟 小精灵 C 举着 $w_{3j} = 0.8$ 的号码牌，把 x_3 放大 0.8 倍传给神经元 j

每个小精灵的工作就是：接收上一步的信号，乘以自己负责的权重，传给下一步。

神经元 j 汇总所有小精灵送来的信号：
$$u_j = 0.5x_1 + (-0.3)x_2 + 0.8x_3 + b_j$$

扩展到整层，全连接意味着每个输入都连接到每个隐藏神经元：

	h_1	h_2
x_1	🌟 w_{11}	🌟 w_{12}
x_2	🌟 w_{21}	🌟 w_{22}

每个隐藏神经元 h_j 收到的，就是所有连接它的小精灵送来的信号之和：

$$u_j = \sum_i w_{ij} \times x_i$$

1-5-2 前向传播的「接力」过程

想象一个 3 层网络（输入 → 隐藏 → 输出）的信息传递：

- 第 1 棒：输入层 → 隐藏层**
输入节点把信号交给小精灵群，每个小精灵乘以自己的权重后传送到目标神经元
- 第 2 棒：隐藏神经元内部**
细胞体求和： $u_1 = w_{11} \times x_1 + w_{21} \times x_2$ ，激活函数处理： $h_1 = \sigma(u_1)$
- 第 3 棒：隐藏层 → 输出层**
新的一群小精灵接力，乘以新权重后传送到输出神经元
- 第 4 棒：输出预测结果**
输出神经元求和并激活，给出最终预测

1-5-3 可视化：网络结构图




图 1-2: 3 层全连接网络结构图。输入层 3 个节点，隐藏层 4 个节点，输出层 2 个节点。每条连接线代表一个权重参数。

参数数量的计算方法

对于这个 3→4→2 的网络：

- 第一层参数： $3 \times 4 + 4 = 16$ （权重 + 偏置）
- 第二层参数： $4 \times 2 + 2 = 10$ （权重 + 偏置）
- 总参数： $16 + 10 = 26$ 个

```
# 参数数量计算
def count_params(layer_sizes):
    total = 0
    for i in range(len(layer_sizes) - 1):
        weights = layer_sizes[i] * layer_sizes[i+1]
        biases = layer_sizes[i+1]
        total += weights + biases
        print(f"层{i+1}: {weights}权重 + {biases}偏置 = {weights+biases}")
    return total

layers = [3, 4, 2]
print(f"总参数量: {count_params(layers)}")
```

🌟 小精灵说：看到图中每一条灰色连线了吗？每一条线上都站着一个我（小精灵）！我的任务就是把我连接的输入信号乘以我的「重要性系数」（权重值），然后传给下一层。参数量就是小精灵们的总数加上每个节点的偏置！

1-6 将小精灵的工作翻译为数学语言

1-6-1 数学形式化

单个神经元的输入输出

第 l 层第 j 个神经元的加权输入：

$$u_j^{(l)} = \sum_i w_{ji}^{(l)} z_i^{(l-1)} + b_j^{(l)}$$

第 l 层第 j 个神经元的激活输出：

$$z_j^{(l)} = f(u_j^{(l)})$$

矩阵形式（向量化）

$$\mathbf{u}^{(l)} = \mathbf{W}^{(l)} \mathbf{z}^{(l-1)} + \mathbf{b}^{(l)}$$

$$\mathbf{z}^{(l)} = f(\mathbf{u}^{(l)})$$

1-6-2 上标 / 下标约定

符号	含义	示例
(l)	第 l 层	$\mathbf{W}^{(2)}$ 是第 2 层的权重矩阵
j	目标神经元的编号	$z_j^{(l)}$ 是第 l 层第 j 个神经元的输出
i	源神经元的编号	$w_{ji}^{(l)}$ 是从第 $l-1$ 层第 i 个神经元到第 l 层第 j 个神经元的权重
w_{ji}	从 i 到 j 的权重	j 在前（目标）， i 在后（来源）

💡 记忆技巧： w_{ji} 中的 j 是去的地方， i 是来的地方。

💡 核心洞察：一旦理解了上标下标规约，整个神经网络就变成了一套「填表」游戏——每个神经元填写自己的加权和，然后套上激活函数。

一个具体的例子

对于 3 层网络（输入:3→隐藏:4→输出:2）：

$w_{32}^{[1]}$ （第一层中,第3个神经元→第2个输入的权重）

$\mathbf{W}^{[1]} \in \mathbb{R}^{4 \times 3}$ （第一层: 4隐藏神经元 $\times$ 3输入特征）

符号	含义	例子
上标 $[l]$	第 l 层	$\mathbf{W}^{[1]}$ 是第一层权重
下标 $_{ji}$	第 j 神经元连接第 i 输入	$w_{ji}^{[l]}$
粗体	向量/矩阵	$\mathbf{W}^{[l]}, \mathbf{b}^{[l]}$
$\mathbf{z}^{[l]}$	第 l 层加权输入	$\mathbf{z}^{[l]} = \mathbf{W}^{[l]} \mathbf{a}^{[l-1]} + \mathbf{b}^{[l]}$
$\mathbf{a}^{[l]}$	第 l 层激活输出	$\mathbf{a}^{[l]} = f(\mathbf{z}^{[l]})$

🌟 小精灵说：工牌上写着 $w_{ji}^{[l]}$ —— l 是楼层， i 是信号来源， j 是信号目标。每一层的小精灵都有唯一的「身份证号」！

1-7 网络自学习的神经网络

1-7-1 什么是「学习」？

学习的本质

学习的本质 = 调整参数使输出接近目标

给定输入 $\mathbf{x}$, 期望输出 $t \rightarrow$ 调整 $\mathbf{W}, \mathbf{b}$ 使 $\mathbf{y} \approx t$

类比：调收音机旋钮

你正在在调收音机找最清晰的频道：

- 旋转频率旋钮（调整参数）
- 听声音清晰度（评估结果）
- 微调直到最好（找到最优参数）

神经网络的学习完全一样——只不过它有数百万个旋钮（权重参数）。

类比：下山

想象你站在一个山谷的山顶上，目标是走到山谷的最低点：

初始位置（山顶，损失大） $\rightarrow$ 沿负梯度方向迈一步 $\rightarrow$ 重复 $\rightarrow$ 到达谷底（最优参数，损失最小）

1-7-2 学习 = 参数优化问题

三要素

1. 参数： $\mathbf{W}, \mathbf{b}$ （所有权重和偏置）
2. 损失函数： $L(\mathbf{W}, \mathbf{b})$ 衡量预测误差
3. 优化方法：沿着梯度方向下山（梯度下降）

数学表达

$$\min_{\mathbf{W}, \mathbf{b}} L(\mathbf{W}, \mathbf{b})$$

$$\mathbf{W}^{(t+1)} = \mathbf{W}^{(t)} - \eta \frac{\partial L}{\partial \mathbf{W}}$$

其中 η 是学习率（步长）， $\frac{\partial L}{\partial \mathbf{W}}$ 是梯度（最陡方向）。

学习的本质就是「调参」

学习 = 调整参数使损失最小化

```
# 学习的本质：盲人下山
for epoch in range(1000):
    loss = compute_loss(model)      # 计算失误有多大
    grads = compute_grad(loss)      # 找出下坡方向
    model.params -= lr * grads      # 朝下坡方向迈一步（更新参数）
```

🌱 小精灵说：学习就像盲人下山——你不知道山谷在哪（最优参数），但你能感觉到脚下的坡度（梯度）。如果脚往下滑，说明方向对了，于是朝这个方向迈一步（参数更新）。重复足够多次，就能到达谷底！

1-7-3 预热：梯度下降的直觉

步骤

1. 站在山上，闭眼用脚感受坡度（计算梯度）
2. 找出坡最陡的方向 = 负梯度方向
3. 迈出一小步（步长 = 学习率 η ）
4. 重新感受坡度（重新计算梯度）
5. 重复直到到达谷底

可视化




图 1-3：梯度下降的直觉——站在山上寻找最低点。红色箭头表示梯度方向，我们沿反方向下山。

一个简单的 Python 演示

```
import numpy as np
import matplotlib.pyplot as plt

# 目标函数: f(x) = x^2 + 2x + 1 (一个简单的二次函数)
def f(x):
    return x**2 + 2*x + 1

# 导数: f'(x) = 2x + 2
def grad(x):
    return 2*x + 2

# 梯度下降
x = 4.0          # 初始位置
lr = 0.1         # 学习率
steps = []
for i in range(20):
    steps.append((x, f(x)))
    x = x - lr * grad(x) # 沿负梯度方向更新

print("梯度下降轨迹: ")
for i, (x_val, f_val) in enumerate(steps):
    print(f" 第 {i} 步: x = {x_val:.4f}, f(x) = {f_val:.4f}")
```

步数	x	f(x)
0	4.0000	25.0000
1	2.8000	14.4400
2	1.8400	8.0656
...	...	...
19	-1.0000	0.0000

当 $x = -1$ 时, $f(x) = 0$, 恰好是函数的最小值点。✔

当 $x = -1$ 时, $f(x) = (-1)^2 + 2(-1) + 1 = 0$, 这恰好是函数的最小值点!

💡 核心洞察：神经网络的学习 = 用梯度下降法解一个超高维的参数优化问题。
第 2 章开始，我们将系统学习所需的数学工具。

1-8 神经网络的设计空间

1-8-1 网络深度 vs 宽度

设计神经网络时，最重要的两个超参数是深度（层数）和宽度（每层神经元数）。

维度	含义	优点	缺点
深度（层数）	网络的层次数量	层次化特征提取，表达能力更强	梯度消失/爆炸，训练困难
宽度（每层神经元）	每层神经元数量	每层能学到更多特征	参数暴增，过拟合风险

数学直觉

表达能力 ≈ 深度 × 宽度

但深度的贡献是指数级的——每增加一层，特征的「抽象级别」就提升一次。一个 10 层网络理论上能学到比 5 层网络更抽象的特征。

 小精灵说：深度就像是「思考的层次」——第一层小精灵看到的是散乱的像素（边缘），中间层看到的是形状（纹理），深层看到的是完整的概念（猫/狗）。宽度则是「每层小精灵的数量」——越多小精灵，这一层能捕捉到的特征模式就越丰富！

1-8-2 参数量与模型容量的关系

模型容量 ≈ 参数量 ≈ $\sum_{l=1}^L (n_{l-1} \times n_l + n_l)$

其中 n_l 是第 l 层的神经元数。

参数量估算示例

```
# 常见的网络配置参数估算
def estimate_params(configs):
    """configs: [(输入维度, 输出维度), ...]"""
    total = 0
    print("层    参数    累计")
    print("-" * 30)
    for i, (n_in, n_out) in enumerate(configs):
        params = n_in * n_out + n_out # 权重 + 偏置
        total += params
        print(f"{i+1}    {params:>8}    {total:>8}")
    return total

# 一个手写数字识别网络
config = [(784, 256), (256, 128), (128, 64), (64, 10)]
total = estimate_params(config)
print(f"总参数量: {total:,}")
```

层	参数量		累计
1	200,960		200,960
2	32,896		233,856
3	8,256		242,112
4	1,290		243,402

总参数量: 243,402

 核心洞察：~24 万个参数就要学习 60,000 张 MNIST 训练图片！每张图片 784 个像素，相当于每个参数「负责」约 6 个训练样本的信息。这就是为什么数据越多，模型可以越大。

1-8-3 过拟合与欠拟合

问题	训练误差	测试误差	原因	解决方案
欠拟合	高	高	模型太简单	增加层数/神经元
过拟合	低	高	模型死记硬背	加正则化/加数据/减小模型

现象	训练误差	测试误差	诊断
欠拟合	高	高	模型容量不足
过拟合	低	高	模型记住了训练数据而非学习规律
正常	低	低	✅ 理想状态

🌟 小精灵说：欠拟合就像让小学生做高考题——太简单了，学不会。过拟合就像让博士生背答案——考试满分，但本质上什么都没学会！一个好的模型应该能「理解原理」而不是「背诵答案」。

1-9 学习策略速查

1-9-1 训练策略决策树

- 1. 损失不下降？
 - 学习率太小？→ 增大学习率
 - 梯度消失？→ 换 ReLU / 加 BatchNorm
- 2. 训练 loss 下降但验证集不降？→ 过拟合！
 - 加 Dropout / L2 正则化
 - 数据增强
 - 减小模型
- 3. 验证 loss 不再下降 → 早停 (Early Stopping)

1-9-2 何时选择哪种网络？

任务类型	推荐架构	理由
表格数据	多层感知机 (MLP)	小规模，全连接即可
图像分类	CNN	空间局部性 + 平移不变性
序列数据 (文本/音频)	Transformer/RNN	序列建模能力
大语言模型	Transformer Decoder	自回归生成

🔥 一句话总结：神经网络的核心思想 = 多层「加权求和 + 激活函数」的堆叠，学习 = 用梯度下降调整参数，设计 = 在深度/宽度/正则化之间找到平衡。

⚠️ 常见误区与调试指南

误区一：激活函数随便选就行

- ❌ 错误认识：「反正都是非线性函数，用哪个激活函数差别不大。」
- ✅ 正确认识：激活函数的选择直接影响网络的训练难度和最终性能。

激活函数	适合场景	不适合场景
ReLU	隐藏层默认选择	输出层（输出范围不受限）

激活函数	适合场景	不适合场景
Sigmoid	二分类输出层	隐藏层（梯度消失严重）
Tanh	RNN、需要零均值的场景	深层网络（梯度仍会消失）
Softmax	多分类输出层	隐藏层（所有概率和为1，限制表达力）

误区二：网络层数越多越好

✘ 错误认识：「深度学习嘛，层数越多肯定越厉害。」

✔ 正确认识：层数增加会带来梯度消失/爆炸和退化问题。需要配合残差连接、BatchNorm 等技术才能训练深层网络。

🌟 小精灵说：层数越多，信号要穿过的「小精灵链」就越长！如果每个小精灵不小心把信号弄丢了一点（梯度衰减），经过 50 层后原信号就几乎消失了。这就是为什么深层网络需要残差连接——给小精灵们开「VIP通道」！

你学会了什么

- 1. 神经元的工作原理：加权求和 + 激活函数 = 输出
- 2. M-P 模型的局限性：只能解决线性可分问题
- 3. 激活函数：阶跃函数 → Sigmoid → ReLU → Tanh 的演进逻辑
- 4. 神经网络结构：输入层 → 隐藏层 → 输出层
- 5. 全连接层：矩阵乘法 + 逐元素激活 = 一层变换
- 6. 学习的本质：调整参数使损失最小化

预备知识提示

- 在进入第 2 章之前，你应该已经：
- [x] 理解了神经元的基本数学模型
 - [x] 能用 Python 实现简单的网络前向传播
 - [x] 具备了梯度下降的直觉

🔥 一句话总结：神经网络 = 多层「加权求和 + 激活函数」的堆叠，学习 = 用梯度下降调整权重。

核心公式速查

公式	说明	适用场景
$y = f(\mathbf{w} \cdot \mathbf{x} + b)$	单神经元输出：加权求和 + 激活函数	所有神经网络基础
$\text{Sigmoid}(x) = \frac{1}{1+e^{-x}}$	Sigmoid 激活函数，输出范围 (0,1)	二分类输出层
$\text{ReLU}(x) = \max(0, x)$	ReLU 激活函数，稀疏激活	隐藏层默认选择
$\tanh(x) = \frac{e^x - e^{-x}}{e^x + e^{-x}}$	Tanh 激活函数，输出范围 (-1,1)	RNN 等场景
$\mathbf{z}^{(l)} = f(\mathbf{W}^{(l)}\mathbf{a}^{(l-1)} + \mathbf{b}^{(l)})$	第 l 层的前向传播（矩阵形式）	多层网络计算
$\Delta \mathbf{w} = -\eta \frac{\partial L}{\partial \mathbf{w}}$	梯度下降参数更新规则	所有参数更新

📁 本章代码清单

文件	内容	核心知识点
ch01/NN01_mp_neuron.py	M-P 神经元 + AND/OR 逻辑门	加权求和 + 阈值判断
ch01/NN01_activation_functions.py	4 种激活函数 + 导数 + 可视化	激活函数对比

文件	内容	核心知识点
ch01/NN01_simple_network.py	手动搭建 2 层全连接网络	前向传播实现
ch01/NN01_network_viz.py	网络结构图绘制	networkx + matplotlib
ch01/NN01_gradient_intuition.py	梯度下降预热演示	二次函数最小值搜索

📖 本章小结

核心概念回顾

阶段	概念	核心思想
1	生物神经元	树突接收 → 细胞体处理 → 轴突输出
2	M-P 模型	加权求和 + 阈值判断
3	激活函数	Sigmoid / ReLU / Tanh (连续可导)
4	神经网络	多层堆叠 + 全连接 + 前向传播
5	学习	参数优化 + 梯度下降

🍷 课后练习

练习 1: 手动实现 M-P 神经元

用 Python 实现一个 M-P 神经元，输入两个二进制值 $x_1, x_2 \in \{0,1\}$ ，权重均为 1，阈值为 1.5。测试 AND 和 OR 逻辑：

```
def mp_neuron(x1, x2, w1=1, w2=1, threshold=1.5):
    """M-P 神经元：加权求和-阈值判断"""
    total = w1 * x1 + w2 * x2
    return 1 if total >= threshold else 0

# 测试 AND 逻辑
for x1, x2 in [(0,0), (0,1), (1,0), (1,1)]:
    print(f"AND({x1},{x2}) = {mp_neuron(x1, x2, threshold=1.5)}")
```

思考：调整阈值，使同一个神经元实现 OR 逻辑。阈值应该设为多少？

练习 2: 尝试不同的激活函数

修改以下代码，用 ReLU 和 Tanh 替换 Sigmoid，观察输出差异：

```
import numpy as np
x = np.array([-2, -1, 0, 1, 2])
print("Sigmoid:", 1 / (1 + np.exp(-x)))
# 你的任务：实现 ReLU 和 Tanh
```

练习 3: 手动计算两层网络的前向传播

给定输入 $x = [1, 2]^T$ ，权重矩阵 $W1 = \begin{bmatrix} 0.1 & 0.2 \\ 0.3 & 0.4 \end{bmatrix}$ ，偏置 $b1 = [0.5, 0.5]$ ，激活函数为 Sigmoid。手动计算第一层的输出 $h = \text{sigmoid}(W1 * x + b1)$ 。

练习 4: 参数数量计算

一个网络结构为：输入层 784 个神经元 – 隐藏层 256 个神经元 (ReLU) – 输出层 10 个神经元 (Softmax)。请计算：

- 第一个全连接层的参数量 (权重 + 偏置)
- 第二个全连接层的参数量
- 总参数量

思考：如果隐藏层增加到 512 个神经元，总参数量变为多少倍？

练习 5（挑战题）：实现一个 2 层网络的梯度下降

使用 NumPy 从零实现单样本的梯度下降更新。提示：

1. 前向传播： $y_{\text{pred}} = \text{sigmoid}(W2 * \text{sigmoid}(W1 * x + b1) + b2)$
2. 损失： $L = 0.5 * (y_{\text{pred}} - y)^2$
3. 用数值梯度近似验证你的梯度计算

[← 前言](#) | [目录](#) | [第 2 章 神经网络的数学基础](#) →

第 2 章 神经网络的数学基础

🌟 目标：直觉理解深度学习所需的数学三大支柱——函数、线性代数、微积分。不需死记公式，而是理解每个数学工具「为什么」出现在神经网络中。

© xiefujin · Contact: 490021684@qq.com · Licensed under CC BY-NC-SA 4.0

📁 代码文件: [code/ch02/](#) (9 个文件)

插图: [images/ch02/](#) (9 张图)

📖 本章学习目标

- [] 理解神经网络中出现的各种函数（一次、二次、指数、对数）
- [] 理解前向传播是递推关系
- [] 掌握求和符号与向量内积的关系
- [] 理解矩阵乘法如何实现批量计算
- [] 理解导数与偏导数的直觉含义
- [] 掌握链式法则——反向传播的数学引擎
- [] 理解梯度下降：沿着最陡方向下山

2-1 神经网络所需的函数

2-1-1 一次函数（线性变换）

定义

$$y = ax + b$$

其中 a 是斜率， b 是截距。

几何意义

- a 控制直线的倾斜程度（ a 越大越陡）
- b 控制直线在 y 轴上的位置

函数	斜率 a	效果
$y = 2x + 1$	$a=2 > 0$	陡峭向上
$y = -0.5x + 3$	$a=-0.5 < 0$	平缓向下
$y = 0x + 2$	$a=0$	水平直线

与神经网络的关系

神经元的核心运算就是一次函数： $u = wx + b$ 。权重 w 就是斜率，偏置 b 就是截距。

💡 核心洞察：单个神经元 = 一次函数 + 激活函数。一次函数负责「线性变换」，激活函数负责「非线性」。

Python 验证

```
import numpy as np
import matplotlib.pyplot as plt

x = np.linspace(-5, 5, 100)
w, b = 2, 1
y = w * x + b

plt.figure(figsize=(8, 4))
plt.plot(x, y, label=f'y = {w}x + {b}')
plt.axhline(y=0, color='gray', linestyle=':', alpha=0.5)
plt.axvline(x=0, color='gray', linestyle=':', alpha=0.5)
plt.grid(True, alpha=0.3)
plt.legend()
plt.title('一次函数：神经元的加权求和')
plt.show()
```

2-1-2 二次函数（凸优化基础）

定义

最简单的二次函数：

$$y = x^2$$

特点

- 在 $x = 0$ 处取得最小值 0
- 形状像碗（凸函数），非常适合做损失函数

与神经网络的关系

损失函数（如均方误差）通常是凸函数或近似凸函数。梯度下降就是在损失函数的「碗壁」上滑向碗底。

Python 验证

```
# 多种二次函数
x = np.linspace(-4, 4, 100)
plt.figure(figsize=(10, 4))
```



```
plt.subplot(1, 3, 1)
plt.plot(x, x**2, 'b-')
plt.title('y = x^2')

plt.subplot(1, 3, 2)
plt.plot(x, (x-2)**2, 'r-')
plt.title('y = (x-2)^2\n最小值在 x=2')

plt.subplot(1, 3, 3)
plt.plot(x, x**2 + 2*x + 1, 'g-')
plt.title('y = x^2 + 2x + 1\n最小值在 x=-1')

plt.tight_layout()
plt.show()
```

2-1-3 指数函数 (Sigmoid 的基石)

定义

$$y = e^x, \quad y = e^{-x}$$

关键性质

性质	公式
乘法变加法	$e^{a+b} = e^a \cdot e^b$
倒数关系	$e^x \cdot e^{-x} = 1$
导数不变	$\frac{d}{dx} e^x = e^x$

与神经网络的关系

Sigmoid 激活函数的核心就是指数：

$$\sigma(x) = \frac{1}{1 + e^{-x}}$$

Python 验证

```
x = np.linspace(-3, 3, 100)
y_exp = np.exp(x)
y_exp_neg = np.exp(-x)
y_sigmoid = 1 / (1 + np.exp(-x))

plt.figure(figsize=(10, 4))
plt.plot(x, y_exp, 'b-', label='e^x')
plt.plot(x, y_exp_neg, 'r-', label='e^(-x)')
plt.plot(x, y_sigmoid, 'g-', linewidth=2, label='σ(x) = 1/(1+e^(-x))')
plt.grid(True, alpha=0.3)
plt.legend()
plt.title('指数函数与 Sigmoid')
plt.show()
```

2-1-4 对数函数 (交叉熵的基础)

定义

$$y = \ln x \quad (x > 0)$$

关键性质

性质	公式
乘积变和	$\ln(ab) = \ln a + \ln b$
幂变乘积	$\ln(a^b) = b \ln a$
单调递增	x 越大, $\ln x$ 越大

与神经网络的关系

交叉熵损失函数的核心就是对数的负值： $-\ln(p)$ 。

当一个事件的概率 p 很小时， $-\ln(p)$ 很大（惩罚很大）；当 p 接近 1 时， $-\ln(p)$ 接近 0。

💡 **核心洞察：**对数把乘法变成加法，这在计算上非常重要——连乘的概率会变成求和，避免数值下溢。

为什么对数在交叉熵中如此重要？

对数函数 $\ln(x)$ 具有一个关键性质：它将乘法转化为加法。

$$\ln(ab) = \ln a + \ln b$$

在交叉熵损失 $L = -\sum t_k \log p_k$ 中，对数的使用使得：

- 当 $p_k \rightarrow 1$ （预测正确）时， $\log p_k \rightarrow 0$ ，损失趋近于 0
- 当 $p_k \rightarrow 0$ （预测错误）时， $\log p_k \rightarrow -\infty$ ，损失趋近于无穷大

这种「错误越大、惩罚越重」的特性，正是分类任务所需要的。

🦋 **小精灵说：**对数函数就像一个「放大镜」——当预测很准确（概率接近1）时，损失很小；当预测很离谱（概率接近0）时，损失会指数级放大！这就是为什么分类任务都用交叉熵而不是均方误差。

2-1-5 可视化：函数家族图谱




图 2-1：神经网络中常见函数家族图谱。

2-2 数列和递推关系式

2-2-1 数列基础

等差数列

每一项与前一项的差为常数：

$$a_n = a_1 + (n-1)d$$

示例： 2, 5, 8, 11, 14, ... (公差 $d = 3$)

等比数列

每一项与前一项的比为常数：

$$a_n = a_1 r^{n-1}$$

示例： 2, 4, 8, 16, 32, ... (公比 $r = 2$)

Python 生成数列

```
# 等差数列
a1, d, n = 2, 3, 10
arith_seq = a1 + np.arange(n) * d
print(f"等差数列: {arith_seq}")

# 等比数列
a1, r, n = 2, 2, 10
geom_seq = a1 * r ** np.arange(n)
print(f"等比数列: {geom_seq}")
```

2-2-2 递推关系式

定义

当前值由前一个（或前几个）值决定：

$$a_{n+1} = f(a_n)$$

示例：斐波那契数列

$$F_{n+2} = F_{n+1} + F_n, \quad F_1 = 1, F_2 = 1$$

```
def fibonacci(n):
    a, b = 1, 1
    for _ in range(n):
        print(a, end=' ')
        a, b = b, a + b

fibonacci(10) # 1 1 2 3 5 8 13 21 34 55
```

 **小精灵说：**递推就是「传递接力棒」——第 n 个小精灵把信号传给第 $n+1$ 个，每个小精灵的工作都建立在前面所有小精灵的基础上！神经网络的前向传播本质上就是一个递推过程。

2-2-3 前向传播就是递推

神经网络的递推关系

$$\mathbf{z}^{(l+1)} = f(\mathbf{W}^{(l)}\mathbf{z}^{(l)} + \mathbf{b}^{(l)})$$

类比：多米诺骨牌

前向传播就像多米诺骨牌：第 l 层输出触发第 l+1 层计算，一层推倒下一层。
前一层的输出「推倒」后一层的计算。这个递推关系是理解反向传播的关键——因为反向传播也是递推的，只不过是**从后往前推**。

💡 **核心洞察**：前向传播是「从输入到输出」的递推，反向传播是「从输出到输入」的递推。两个方向都在用**同一套递推逻辑**。

神经网络的前向传播本质上就是一个递推过程！

$$\mathbf{a}^{[0]} = \mathbf{x} \quad (\text{输入层,递推起点})$$

$$\mathbf{z}^{[l]} = \mathbf{W}^{[l]}\mathbf{a}^{[l-1]} + \mathbf{b}^{[l]} \quad (\text{递推规则: 加权求和})$$

$$\mathbf{a}^{[l]} = f(\mathbf{z}^{[l]}) \quad (\text{递推规则: 激活函数})$$

从输入层开始，一层接一层地计算，直到输出层——这就是前向传播的递推本质。

🧚 **小精灵说**：前向传播就像一场接力赛！输入是起跑线，每层的小精灵们完成自己的计算后，把结果（激活值）传给下一层。接力棒从第 0 层传到第 L 层，就是一次完整的前向传播！

2-3 求和符号

2-3-1 Sigma 记号入门

定义

$$\sum_{i=1}^n x_i = x_1 + x_2 + \cdots + x_n$$

基本性质

性质	公式
加法分配	$\sum (x_i + y_i) = \sum x_i + \sum y_i$
常数提取	$\sum c x_i = c \sum x_i$
常数求和	$\sum_{i=1}^n c = nc$

求和符号 Σ (Sigma) 是数学中表示「累加」的简洁记法：

$$\sum_{i=1}^n x_i = x_1 + x_2 + \cdots + x_n$$

关键规则：

- $\sum_{i=1}^n (x_i + y_i) = \sum x_i + \sum y_i$ (加法可拆分)
- $\sum_{i=1}^n c \cdot x_i = c \cdot \sum x_i$ (常数可提取)
- $\sum_{i=1}^n \sum_{j=1}^m x_{ij}$ (双重求和 = 嵌套循环)

```
# Python 中的双重求和
total = 0
for i in range(1, n+1):
    for j in range(1, m+1):
        total += x[i][j]
```

2-3-2 求和与神经网络

神经元的加权求和

$$u = \sum_{i=1}^n w_i x_i$$

多层网络的求和

$$u_j^{(l)} = \sum_i w_{ji}^{(l)} z_i^{(l-1)} + b_j^{(l)}$$

求和符号就是神经网络的「通用语言」——每个神经元的输入都用 $\sum$ 表达。

2-3-3 Python: 从 for 循环到向量化

```
import numpy as np

n = 5
w = np.array([0.5, -0.3, 0.8, 0.1, -0.2])
x = np.array([1.0, 0.5, 2.0, 1.5, 0.3])

# Level 1: for 循环 (最直观, 但最慢)
u1 = 0
for i in range(n):
    u1 += w[i] * x[i]
print(f"for 循环: u = {u1:.4f}")

# Level 2: np.sum + 逐元素乘法 (更简洁)
u2 = np.sum(w * x)
print(f"np.sum: u = {u2:.4f}")

# Level 3: np.dot (最语义化, 告诉读者这是「内积」)
u3 = np.dot(w, x)
print(f"np.dot: u = {u3:.4f}")

# Level 4: @ 运算符 (Python 3.5+, 最简洁)
u4 = w @ x
print(f"@ 运算符: u = {u4:.4f}")
```

```
for 循环: u = 1.5100
np.sum: u = 1.5100
np.dot: u = 1.5100
@ 运算符: u = 1.5100
```

💡 **核心洞察**：从 for 循环到 @ 运算符的进化，体现了从「逐个计算」到「整体向量化」的思维转变。向量化是现代深度学习框架（PyTorch、TensorFlow）的核心优化手段。

2-4 向量基础

2-4-1 向量的定义

数学定义

向量 $\mathbf{x} = (x_1, x_2, \dots, x_n)$ 是 n 个有序数组成的数组。

几何意义

n 维空间中的一个点或有向线段。

Python 表示

```
import numpy as np

# 创建向量
x = np.array([1, 2, 3, 4, 5])
print(f"向量 x = {x}")
print(f"维度: {x.shape}")
print(f"第 2 个元素: {x[1]}")
```

向量是有序的数字列表，它同时具有大小和方向。

$$\mathbf{v} = (v_1, v_2, \dots, v_n)^T$$

在神经网络中，向量无处不在：

- 输入向量 $\mathbf{x}$ ：一张图片的所有像素值
- 权重向量 $\mathbf{w}$ ：一个神经元的所有连接权重
- 梯度向量 ∇L ：损失函数对所有参数的偏导

向量的两种视角：

1. **几何视角**：带箭头的线段，指向空间中的某个方向
2. **数据视角**：一列有序的数字，存储在 Tensor 或数组中

🌟 **小精灵说**：向量就是我的「购物清单」——上面按顺序列着我买的所有东西！在神经网络中，一个神经元的输入信号 $\mathbf{x} = [x_1, x_2, \dots, x_n]^T$ 就是一个向量，所有输入信号组成一个「信号清单」。

2-4-2 向量内积 ☆

🌟 **小精灵说**：向量内积就是我每天的工作！输入信号 $x_1, x_2, \dots, x_n$ 就像一堆快递，权重 $w_1, w_2, \dots, w_n$ 就是每个快递的「重要性系数」。我的工作就是计算 $\mathbf{w} \cdot \mathbf{x} = \sum w_i x_i$ ——把所有快递加权汇总！

定义

$$\mathbf{a} \cdot \mathbf{b} = \sum_{i=1}^n a_i b_i$$

几何意义

$$\mathbf{a} \cdot \mathbf{b} = \|\mathbf{a}\| \|\mathbf{b}\| \cos \theta$$

其中 θ 是两向量之间的夹角。

与神经网络的关系

加权求和 = 内积!

$$\mathbf{u} = \mathbf{w} \cdot \mathbf{x} + b$$

直觉：内积衡量两个向量的相似度——

- $\mathbf{w}$ 和 $\mathbf{x}$ 方向一致（相似），内积大 → 输出大
- $\mathbf{w}$ 和 $\mathbf{x}$ 方向相反（不相似），内积小 → 输出小

2-4-3 向量范数与相似度

L2 范数（长度）

$$\|\mathbf{x}\| = \sqrt{\sum_{i=1}^n x_i^2}$$

余弦相似度

$$\cos(\mathbf{a}, \mathbf{b}) = \frac{\mathbf{a} \cdot \mathbf{b}}{\|\mathbf{a}\| \|\mathbf{b}\|}$$

值域 $[-1, 1]$, 1 表示方向完全一致, -1 表示方向完全相反。

Python 实践

```
a = np.array([1, 2, 3])
b = np.array([4, 5, 6])

# 内积
dot_product = np.dot(a, b)
print(f"内积 a·b = {dot_product}")

# 范数
norm_a = np.linalg.norm(a)
norm_b = np.linalg.norm(b)
print(f"|a| = {norm_a:.4f}, |b| = {norm_b:.4f}")

# 余弦相似度
cos_sim = dot_product / (norm_a * norm_b)
print(f"余弦相似度 = {cos_sim:.4f}")
```

```
内积 a·b = 32
|a| = 3.7417, |b| = 8.7750
余弦相似度 = 0.9746
```

2-5 矩阵基础

2-5-1 矩阵的定义

矩阵 $\mathbf{W} \in \mathbb{R}^{m \times n}$ 是 m 行 n 列的二维数组。

```
W = np.array([[1, 2, 3],
              [4, 5, 6]]) # 2 行 3 列的矩阵
print(f"形状: {W.shape}") # (2, 3)
```

矩阵是一个按行和列排列的矩形数字表。

$$\mathbf{W} = \begin{bmatrix} w_{11} & w_{12} & \dots & w_{1n} & w_{21} & w_{22} & \dots & w_{2n} & \vdots & \vdots & \ddots & \vdots & w_{m1} & w_{m2} & \dots & w_{mn} \end{bmatrix}$$

矩阵的维度: $\mathbb{R}^{m \times n}$ 表示 m 行 n 列。

在神经网络中, 权重矩阵 $\mathbf{W}^{[l]} \in \mathbb{R}^{n_l \times n_{l-1}}$ 的每一行对应一个神经元的权重。

💡 核心洞察: 矩阵就是一群有组织、有结构的向量——每一行是一个神经元的权重向量, 整体就是一层所有神经元的权重集合!

2-5-2 矩阵乘法 ★

维度要求

$$(m \times n) \cdot (n \times p) \rightarrow (m \times p)$$

核心规则: 左矩阵的列数 = 右矩阵的行数。

计算公式

$$C_{ij} = \sum_{k=1}^n A_{ik} B_{kj}$$

注意事项

- 不满足交换律: $\mathbf{AB} \neq \mathbf{BA}$
- 满足结合律: $(\mathbf{AB})\mathbf{C} = \mathbf{A}(\mathbf{BC})$

2-5-3 矩阵表示神经网络传播 ★

一层传播

$$\mathbf{u} = \mathbf{x}\mathbf{W} + \mathbf{b}$$

维度变化:

- $\mathbf{x}$: $(1 \times n)$ 输入向量
- $\mathbf{W}$: $(n \times m)$ 权重矩阵
- $\mathbf{b}$: $(1 \times m)$ 偏置向量
- $\mathbf{u}$: $(1 \times m)$ 加权和输出

批量处理多个样本

```
# 32 个样本, 每个 784 维 → 128 个隐藏神经元
X = np.random.randn(32, 784) # 输入矩阵
```



```
W = np.random.randn(784, 128) # 权重矩阵
b = np.zeros(128) # 偏置向量

# 一个矩阵乘法 = 同时计算所有样本的加权和
U = X @ W + b # 形状: (32, 128)
Z = np.maximum(0, U) # ReLU 激活
```

💡 **核心洞察：**矩阵乘法使得「批量处理」成为可能——一个矩阵乘法 = 同时计算所有样本的所有神经元的加权和。这是神经网络能够在 GPU 上高效运行的根本原因。

2-5-4 矩阵乘法的可视化




图 2-2：矩阵乘法可视化。一个矩阵乘法 = 同时计算所有样本的加权和。

```
import numpy as np

# 神经网络中的矩阵乘法
X = np.random.randn(32, 784) # batch=32, 输入特征=784
W1 = np.random.randn(784, 256) # 隐藏层权重
b1 = np.random.randn(256) # 隐藏层偏置

# 前向传播 = 矩阵乘法 + 广播加法
Z1 = X @ W1 + b1 # 结果形状: (32, 256)
A1 = np.maximum(0, Z1) # ReLU激活
```

💡 **核心洞察：**矩阵乘法的本质就是「批量执行向量内积」——它把 for 循环中的 n 次内积压缩成了一个矩阵乘法，让 GPU 可以并行计算。

2-6 导数基础

2-6-1 导数的定义

公式

$$f'(x) = \lim_{h \rightarrow 0} \frac{f(x+h) - f(x)}{h}$$

直觉理解

- 几何意义：函数在 x 点处的切线斜率
- 物理意义： x 变化时 $f(x)$ 的瞬时变化率

2-6-2 数值微分（近似计算）

```
def numerical_derivative(f, x, h=1e-7):
    """中心差分法计算数值导数"""
    return (f(x + h) - f(x - h)) / (2 * h)

# 示例：计算 f(x) = x^2 在 x=3 处的导数
f = lambda x: x**2
df = numerical_derivative(f, 3.0)
```

```
print(f"f(x)=x² 在 x=3 处的导数 = {df:.6f}")
# 解析解: f'(3) = 2*3 = 6
```

f(x)=x² 在 x=3 处的导数 ≈ 6.000000

2-6-3 基本求导公式

函数 $f(x)$	导数 $f'(x)$	在神经网络中的出现
c (常数)	0	偏置的梯度
x^n	nx^{n-1}	幂函数损失
e^x	e^x	指数函数
$\ln x$	$1/x$	交叉熵导数
$\sigma(x)$	$\sigma(x)(1 - \sigma(x))$	Sigmoid 梯度 ★
$\tanh(x)$	$1 - \tanh^2(x)$	Tanh 梯度

最需要记住的: Sigmoid 的导数 $\sigma'(x) = \sigma(x)(1 - \sigma(x))$ ——你会反复用到它。

2-6-4 可视化




图 2-3: 导数 = 函数在某点的瞬时变化率 = 切线斜率。

🌱 小精灵说: 导数告诉我们「沿着这个方向走, 山是向上还是向下、有多陡」。正导数 = 上坡, 负导数 = 下坡, 导数绝对值 = 坡度大小!

2-7 偏导数基础

2-7-1 多元函数

神经网络中的几乎所有函数都是多元的——损失函数依赖于数百万个权重参数。

偏导数的定义

对于 $f(x, y) = x^2 + 2y^2$:

- $\frac{\partial f}{\partial x}$: 固定 y , 把 f 看作 x 的函数求导
- $\frac{\partial f}{\partial y}$: 固定 x , 把 f 看作 y 的函数求导

计算示例

$$f(x, y) = x^2 + 2y^2$$

$$\frac{\partial f}{\partial x} = 2x, \quad \frac{\partial f}{\partial y} = 4y$$

2-7-2 梯度向量 ☆

定义

$$\nabla f = \left(\frac{\partial f}{\partial x_1}, \frac{\partial f}{\partial x_2}, \dots, \frac{\partial f}{\partial x_n} \right)$$

梯度是一个向量，它的每个分量是对应变量的偏导数。

几何意义

梯度指向函数增长最快的方向。

- 在二维曲面上，梯度指向「最陡的上坡方向」
- 梯度的反方向是「最陡的下坡方向」

Python 实现

```
def f(x, y):  
    return x**2 + 2*y**2  
  
def gradient(x, y, h=1e-7):  
    """数值法计算梯度"""  
    df_dx = (f(x+h, y) - f(x-h, y)) / (2*h)  
    df_dy = (f(x, y+h) - f(x, y-h)) / (2*h)  
    return np.array([df_dx, df_dy])  
  
print(f"在点 (3, 2) 处的梯度: {gradient(3.0, 2.0)}")
```

在点 (3, 2) 处的梯度: [6. 8.]

💡 **核心洞察：**梯度是一个向量，它告诉我们在参数空间中朝哪个方向走能让损失下降得最快。

2-7-3 可视化




图 2-4：梯度向量场。箭头方向 = 函数增长最快的方向，箭头的长度=增长率的大小。

```
# 梯度的几何意义：每个分量都是对应方向的偏导
def numerical_gradient(f, x, h=1e-5):
    grad = np.zeros_like(x)
    for i in range(len(x)):
        x_plus = x.copy(); x_plus[i] += h
        x_minus = x.copy(); x_minus[i] -= h
        grad[i] = (f(x_plus) - f(x_minus)) / (2 * h)
    return grad
```

2-8 链式法则 ★

2-8-1 单变量链式法则

公式

$$\frac{dz}{dx} = \frac{dz}{dy} \cdot \frac{dy}{dx}$$

直觉

如果 z 依赖于 y ， y 依赖于 x ，那么 x 的变化通过 y 传递给 z ——总变化率 = 两个变化率的乘积。

示例

$$z = (3x + 2)^2$$

令 $y = 3x + 2$ ，则 $z = y^2$ ：

$$\frac{dz}{dy} = 2y, \quad \frac{dy}{dx} = 3$$

$$\frac{dz}{dx} = 2y \cdot 3 = 6(3x + 2)$$

2-8-2 多变量链式法则（神经网络的核心）★

🌟 小精灵说：链式法则就是我们的「工作流程说明书」！如果我在第 3 层犯了错（输出错了），这个错误信号需要沿着我们来的路一层层传回去。每个小精灵只需要负责自己这一段——这就是 $\frac{\partial L}{\partial w_1} = \frac{\partial L}{\partial y} \cdot \frac{\partial y}{\partial u} \cdot \frac{\partial u}{\partial w_1}$ 的核心思想！反向传播就是链式法则的工程实现。

公式

$$\frac{\partial L}{\partial w} = \frac{\partial L}{\partial y} \cdot \frac{\partial y}{\partial u} \cdot \frac{\partial u}{\partial w}$$

其中：

- $u = wx + b$ （加权求和）
- $y = f(u)$ （激活函数）
- $L = L(y, t)$ （损失函数）

直觉理解

因子	含义	公式
①	误差对输出的敏感度	$\partial L / \partial y$
②	输出对加权求和的敏感度	$\partial y / \partial u$
③	加权求和对权重的敏感度	$\partial u / \partial w$
连乘	误差对权重的敏感度	$\partial L / \partial w = \partial L / \partial y \cdot \partial y / \partial u \cdot \partial u / \partial w$

💡 核心洞察：这条公式的直觉是——误差对权重的敏感度 = 三条链路的敏感度相乘。就像链条的强度取决于最弱的一环，链式法则告诉我们梯度是「连乘」的。

2-8-3 计算图概念引入

什么是计算图？

运算 = 节点，变量 = 边。计算图把数学表达式分解为基本运算的组合。

```

计算图示意：
前向： x, w, b → u=wx+b → y=σ(u) → L=½(y-t)²
反向： ∂L/∂u ← ∂L/∂y · dy/du ← ∂L/∂L=1,    ∂L/∂w = ∂L/∂u · x,    ∂L/∂b = ∂L/∂u

#### Python 手动实现链式法则

```python
import numpy as np

def sigmoid(x):
 return 1 / (1 + np.exp(-x))

def sigmoid_derivative(x):
 s = sigmoid(x)
 return s * (1 - s)

参数
x, w, b = 2.0, 0.5, 0.1
t = 1.0 # 目标值

前向传播
u = w * x + b # u = 1.1

```

```

y = sigmoid(u) # y = 0.7503
L = 0.5 * (y - t)**2 # L = 0.0312

反向传播 (链式法则)
dL_dy = y - t # = -0.2497
dy_du = sigmoid_derivative(u) # = 0.1874
du_dw = x # = 2.0

dL_dw = dL_dy * dy_du * du_dw # = -0.0936
dL_db = dL_dy * dy_du * 1 # = -0.0468
dL_dx = dL_dy * dy_du * w # = -0.0234

print(f"∂L/∂w = {dL_dw:.4f}")
print(f"∂L/∂b = {dL_db:.4f}")
print(f"∂L/∂x = {dL_dx:.4f}")

```

```

∂L/∂w = -0.0936
∂L/∂b = -0.0468
∂L/∂x = -0.0234

```




图 2-5: 链式法则的计算图。前向传播 (绿色) 从左到右, 反向传播 (红色) 从右到左。

💡 核心洞察: 链式法则是反向传播的数学引擎。整个第 5 章都是链式法则在多层网络上的系统应用。

## 2-9 多变量函数的近似公式

### 2-9-1 泰勒展开

一阶近似

$$f(x + \Delta x) \approx f(x) + f'(x)\Delta x$$

二阶近似

$$f(x + \Delta x) \approx f(x) + f'(x)\Delta x + \frac{1}{2}f''(x)(\Delta x)^2$$

直觉

泰勒展开告诉我们: 已知某点的函数值和梯度, 可以近似预估附近点的函数值。




图 2-6：泰勒展开不同阶数对  $\sin(x)$  的近似效果。

## 2-9-2 全微分（多变量）

公式

$$df = \frac{\partial f}{\partial x} dx + \frac{\partial f}{\partial y} dy$$

含义

所有变量微小变化的总和效应。

与梯度的关系

$$df = \nabla f \cdot d\mathbf{x}$$

💡 核心洞察：梯度下降本质上是在损失函数的一阶泰勒近似上做「下山」。

$$L(\mathbf{w} + \Delta \mathbf{w}) \approx L(\mathbf{w}) + \nabla L \cdot \Delta \mathbf{w}$$

我们选择  $\Delta \mathbf{w} = -\eta \nabla L$  让损失下降最快。

## 2-10 梯度下降法的含义与公式

### 2-10-1 梯度指向最陡上升方向

梯度  $\nabla f$  的方向 = 函数值增长最快的方向

负梯度方向  $-\nabla f$  = 函数值下降最快的方向

### 2-10-2 梯度下降更新公式

参数更新

$$\mathbf{w}^{(t+1)} = \mathbf{w}^{(t)} - \eta \frac{\partial L}{\partial \mathbf{w}}$$

符号	含义	类比
$w^{(t)}$	当前参数	当前位置
$\eta$	学习率（步长）	步子大小
$\frac{\partial L}{\partial w}$	梯度	脚感受的坡度
$w^{(t+1)}$	更新后的参数	迈一步后的位置

2-10-3 学习率的选择

🌟 小精灵说：学习率就像是我的步长。步子太小（ $\eta = 0.001$ ），走一万步还在原地；步子太大（ $\eta = 1.0$ ），一步跨过了山谷撞到对面的山上！理想的步长是既能稳步前进，又不会跑偏。实践中常从  $\eta = 0.01$  或  $\eta = 0.001$  开始尝试，然后根据 loss 曲线调整。

三种情况

学习率	行为	结果
$\eta$ 太小	每步几乎不动，路径极长	收敛极慢，永远走不到谷底
$\eta$ 适中	平稳下降，步长合理	快速收敛 ✓
$\eta$ 太大	越过最低点，来回震荡，甚至发散	无法收敛 ✗

学习率	行为	结果
$\eta$ 过小（如 $10^{-6}$ ）	每步几乎不动	收敛极慢
$\eta$ 适中（如 $0.01$ ）	平稳下降	快速收敛
$\eta$ 过大（如 $10$ ）	震荡、跳跃	可能发散

⚠️ 警告：如果学习率设置过大，梯度下降可能会发散而非收敛。损失函数不降反升就是信号！建议从  $\eta = 0.01$  或  $0.001$  开始尝试。

2-10-4 Python 实践

```
def gradient_descent(f, df, x0, lr=0.1, epochs=100):
 """
 梯度下降算法

 参数：
 f: 目标函数
 df: 梯度函数
 x0: 初始位置
 lr: 学习率
 epochs: 迭代次数
 """
 x = x0
 history = [x]

 for i in range(epochs):
 x = x - lr * df(x) # 沿负梯度方向更新
 history.append(x)

 return x, history

测试: f(x) = x^2, 最小值在 x=0
f = lambda x: x**2
df = lambda x: 2*x

x_opt, history = gradient_descent(f, df, x0=5.0, lr=0.1, epochs=20)
print(f"最优解: x = {x_opt:.6f}")
```



```
print(f"迭代轨迹: {[f'{h:.2f}' for h in history[:10]]}...")
```

最优解:  $x = 0.000000$

迭代轨迹: ['5.00', '4.00', '3.20', '2.56', '2.05', '1.64', '1.31', '1.05', '0.84', '0.67']...

## 2-10-5 可视化




图 2-7: 学习率对比——过小时则慢, 过大则发散。

## 2-11 用 Python 体验梯度下降法

### 2-11-1 一维实验: $f(x) = x^2$

不同学习率的效果

```
import numpy as np

def gd_demo(lr, x0=5.0, epochs=100):
 x = x0
 for i in range(epochs):
 x = x - lr * (2 * x) # f'(x) = 2x
 return x

对比不同学习率
for lr in [0.01, 0.1, 0.5, 1.5]:
 x_final = gd_demo(lr)
 status = "收敛 ✓" if abs(x_final) < 1e-3 else "发散 ✗"
 print(f"学习率 = {lr:.2f}: 100 步后 x = {x_final:.6f} ({status})")
```

学习率 $\eta$	100 步后 $x$	结果
0.01	0.0928	收敛 ✓
0.10	0.0000	收敛 ✓ (快速)
0.50	0.0000	收敛 ✓ (震荡)
1.50	-2855.41	发散 ✗

观察

- $\eta = 0.01$ : 太慢, 100 步还没到谷底
- $\eta = 0.1$ : 适中, 100 步已经非常接近
- $\eta = 0.5$ : 震荡但收敛, 因为步长太大导致越过最小值
- $\eta = 1.5$ : 发散! 每一步都「矫枉过正」, 离最小值越来越远

### 2-11-2 二维实验: $f(x, y) = x^2 + 2y^2$

```
def gd_2d(lr=0.1, epochs=50):
 x, y = 3.0, 3.0 # 初始位置
 path = [(x, y)]

 for _ in range(epochs):
```

```
梯度: (2x, 4y)
x = x - lr * (2 * x)
y = y - lr * (4 * y)
path.append((x, y))

return np.array(path)

path = gd_2d(lr=0.1)
print(f"起点: ({path[0,0]:.2f}, {path[0,1]:.2f})")
print(f"终点: ({path[-1,0]:.6f}, {path[-1,1]:.6f})")
```

起点: (3.00, 3.00)  
 终点: (0.0003, 0.0000)

💡 **核心洞察:**  $y$  方向 (系数 2) 的梯度比  $x$  方向 (系数 1) 大 4 倍, 导致  $y$  维度收敛更快——这启示我们不同维度的学习速度可能不同, 后面会学习自适应学习率来解决这个问题。

### 2-11-3 可视化




图 2-8: 二维梯度下降路径。红色箭头表示每次更新的方向和大小。

🧚 **小精灵说:** 看等高线图上的红色路径——从起点 (绿色圆点) 出发, 每次都沿着最陡的方向往下走, 最终到达最优 (红色星号)! 这就是梯度下降的「物理路径」。

## 2-12 最优化问题和回归分析

### 2-12-1 最小二乘法

问题

给定  $n$  个数据点  $(x_i, y_i)$ , 找到一条直线  $\hat{y} = wx + b$  最好地拟合数据。

损失函数

$$L = \frac{1}{2n} \sum_{i=1}^n (y_i - \hat{y}_i)^2$$

其中  $\hat{y}_i = wx_i + b$ 。

解析解 (正规方程)

$$\mathbf{w} = (\mathbf{X}^T \mathbf{X})^{-1} \mathbf{X}^T \mathbf{y}$$

2-12-2 Python：解析解 vs 梯度下降解

```
import numpy as np
import matplotlib.pyplot as plt

生成数据
np.random.seed(42)
X = np.linspace(0, 10, 50)
y_true = 2.0 * X + 1.0
y = y_true + np.random.randn(50) * 1.5 # 加噪声

准备数据矩阵 (添加偏置项)
X_mat = np.column_stack([X, np.ones_like(X)]) # [x, 1]

----- 方法 1: 解析解 -----
w_analytic = np.linalg.inv(X_mat.T @ X_mat) @ X_mat.T @ y
print(f"解析解: w={w_analytic[0]:.4f}, b={w_analytic[1]:.4f}")

----- 方法 2: 梯度下降 -----
w_gd = np.random.randn(2) # 随机初始化
lr = 0.01
for epoch in range(1000):
 grad = X_mat.T @ (X_mat @ w_gd - y) / len(y)
 w_gd = w_gd - lr * grad

print(f"梯度下降: w={w_gd[0]:.4f}, b={w_gd[1]:.4f}")
```

解析解: w=1.9972, b=1.0926  
梯度下降: w=1.9972, b=1.0926

2-12-3 对比

方法	精度	计算复杂度	可扩展性
解析解 (正规方程)	一步到位 (精确)	$O(n^3)$	数据量大时不可行
梯度下降	迭代逼近	$O(n)$ 每步	可扩展到百万级数据

💡 核心洞察：线性回归是最简单的「神经网络」——一个没有隐藏层、没有激活函数的单神经元网络。你用解析解求出的权重，恰好就是神经网络通过梯度下降学到的！

2-12-4 可视化




图 2-9：线性回归——用一条直线拟合数据点。

本章代码清单

文件	内容	核心知识点
ch02/NN02_functions.py	一次/二次/指数/对数/Sigmoid 可视化	神经网络常见函数
ch02/NN02_vectors_matrices.py	向量内积、矩阵乘法、广播	线性代数基础
ch02/NN02_matrix_multiplication.py	矩阵乘法可视化（热力图）	批量计算原理
ch02/NN02_numerical_derivative.py	数值微分 + 解析解对比	导数计算
ch02/NN02_chain_rule.py	链式法则计算图实现	反向传播核心
ch02/NN02_taylor_approx.py	泰勒展开近似演示	函数近似
ch02/NN02_gradient_descent_demo.py	一维/二维梯度下降 + 学习率对比	梯度下降实现
ch02/NN02_linear_regression.py	线性回归两种解法对比	最小二乘法
ch02/NN02_gradient_visualization.py	3D 曲面 + 梯度向量场	梯度可视化

2-14 实践：用数学理解神经网络

2-14-1 从数学视角看前向传播

神经网络的每一层都可以看作是一个函数复合：

$$f_{NN}(\mathbf{x}) = f^{(L)} \circ f^{(L-1)} \circ \dots \circ f^{(1)}(\mathbf{x})$$

其中每层的函数  $f^{(l)}(\mathbf{a}) = \sigma(\mathbf{W}^{(l)}\mathbf{a} + \mathbf{b}^{(l)})$  是仿射变换 + 非线性激活的组合。

2-14-2 常见的函数组合模式

模式	数学形式	出现场景
线性→非线性	$\sigma(\mathbf{W}\mathbf{x} + \mathbf{b})$	所有隐藏层
线性→概率	$\text{softmax}(\mathbf{W}\mathbf{x} + \mathbf{b})$	多分类输出层
线性→标量	$\mathbf{w}^T\mathbf{x} + b$	回归输出层
残差连接	$\mathbf{x} + F(\mathbf{x})$	残差网络

2-14-3 NumPy 实现神经网络的前向传播

```
import numpy as np

def forward_pass(X, weights, biases, activation='relu'):
 """通用前向传播函数"""
 a = X
 for i, (W, b) in enumerate(zip(weights, biases)):
 z = a @ W + b # 仿射变换: 矩阵乘法 + 偏置

 # 激活函数
 if i < len(weights) - 1: # 隐藏层
 if activation == 'relu':
 a = np.maximum(0, z)
 elif activation == 'sigmoid':
 a = 1 / (1 + np.exp(-z))
 else: # 输出层 (无激活, 或 softmax)
 a = z
 return a
```

```
测试: 2 层网络
X = np.random.randn(10, 784) # 10 张 28x28 图片
W1 = np.random.randn(784, 256) * 0.01
b1 = np.zeros(256)
W2 = np.random.randn(256, 10) * 0.01
b2 = np.zeros(10)

output = forward_pass(X, [W1, W2], [b1, b2])
print(f"输入: {X.shape} → 输出: {output.shape}")
```

输入: (10, 784) → 输出: (10, 10)

## 2-14-4 矩阵微积分在反向传播中的作用

反向传播本质上是矩阵微积分的应用——对矩阵函数求导:

$$\frac{\partial}{\partial \mathbf{W}}(\mathbf{W}\mathbf{x} + \mathbf{b}) = \mathbf{x}^T$$

$$\frac{\partial}{\partial \mathbf{b}}(\mathbf{W}\mathbf{x} + \mathbf{b}) = \mathbf{I}$$

这两个简单公式是所有反向传播推导的起点!

运算	前向	对权重的梯度	对输入的梯度
仿射变换	$\mathbf{z} = \mathbf{W}\mathbf{a} + \mathbf{b}$	$\frac{\partial L}{\partial \mathbf{W}} = \frac{\partial L}{\partial \mathbf{z}} \cdot \mathbf{a}^T$	$\frac{\partial L}{\partial \mathbf{a}} = \mathbf{W}^T \cdot \frac{\partial L}{\partial \mathbf{z}}$
ReLU	$\mathbf{a} = \max(0, \mathbf{z})$	—	$\frac{\partial L}{\partial \mathbf{z}} = \mathbb{1}[\mathbf{z} > 0] \odot \frac{\partial L}{\partial \mathbf{a}}$
Sigmoid	$\mathbf{a} = \sigma(\mathbf{z})$	—	$\frac{\partial L}{\partial \mathbf{z}} = \sigma(\mathbf{z}) \odot (1 - \sigma(\mathbf{z})) \odot \frac{\partial L}{\partial \mathbf{a}}$

## 2-15 从数学到代码: 核心公式的 Python 实现

### 2-15-1 向量化加速

```
import numpy as np
import time

❌ 循环实现 (慢)
def dot_product_loop(a, b):
 result = 0
 for i in range(len(a)):
 result += a[i] * b[i]
 return result

✅ 向量化实现 (快 100 倍)
def dot_product_vec(a, b):
 return np.dot(a, b)

性能对比
a = np.random.randn(10000)
b = np.random.randn(10000)

t0 = time.time()
for _ in range(1000):
 dot_product_loop(a, b)
t1 = time.time()
print(f"循环: {(t1-t0)*1000:.1f}ms")

t0 = time.time()
for _ in range(1000):
 dot_product_vec(a, b)
```

```
t1 = time.time()
print(f"向量化: {(t1-t0)*1000:.1f}ms")
```

方法	耗时	加速比
for 循环	2850.3 ms	1x
向量化 (np.dot)	2.1 ms	1350x

## 2-15-2 本章所有数学概念的代码总览

概念	NumPy 代码	行数
向量内积	<code>np.dot(a, b)</code> 或 <code>a @ b</code>	1
矩阵乘法	<code>A @ B</code>	1
导数 (数值)	<code>(f(x+h) - f(x-h)) / (2*h)</code>	1
梯度下降	<code>w -= lr * grad</code>	1
泰勒展开	<code>f(a) + f'(a)*(x-a) + f''(a)/2*(x-a)**2</code>	1
线性回归	<code>np.linalg.lstsq(X, y)</code>	1

🔥 一句话总结：神经网络的数学看起来复杂，但落到代码层面只有几个核心操作——向量内积、矩阵乘法、函数求导、梯度下降。理解了这 4 个操作，就理解了整个神经网络的数学基础！

## 📖 本章小结

### 📌 课后练习

#### 练习 1：向量与矩阵运算

给定  $a = [1, 2, 3]^T$ ,  $b = [4, 5, 6]^T$ , 矩阵  $A = \begin{bmatrix} 1 & 2 \\ 3 & 4 \\ 5 & 6 \end{bmatrix}$ 。

用 NumPy 计算以下表达式，并对照数学公式验证结果：

```
import numpy as np
a = np.array([1, 2, 3])
b = np.array([4, 5, 6])
A = np.array([[1, 2], [3, 4], [5, 6]])

(1) a . b (内积)
(2) A^T (转置)
(3) A^T a (矩阵-向量乘法)
```

#### 练习 2：数值微分验证

用导数定义  $f'(x) \approx (f(x+h) - f(x-h))/(2h)$  计算  $f(x) = x^3 + 2x$  在  $x=1$  处的导数。比较不同  $h$  值 ( $1e-3, 1e-6, 1e-9, 1e-12$ ) 的精度。

#### 练习 3：链式法则手动计算

给定  $y = f(g(x))$ , 其中  $g(x) = x^2 + 1$ ,  $f(g) = \sin(g)$ 。手动计算  $dy/dx$  在  $x=0$  处的值，并用数值微分验证。

#### 练习 4：泰勒展开逼近

用二阶泰勒展开逼近  $f(x) = \ln(x)$  在  $a=2$  附近的值。计算在  $x=2.1$  处展开值与真实值的误差。

#### 练习 5：矩阵求导直觉

对于线性变换  $\mathbf{y} = \mathbf{W}\mathbf{x}$ , 其中  $\mathbf{y} \in \mathbb{R}^m$ ,  $\mathbf{x} \in \mathbb{R}^n$ ,  $\mathbf{W} \in \mathbb{R}^{m \times n}$ 。

- $\frac{\partial y_i}{\partial x_j}$  等于什么？

- $\frac{\partial y_i}{\partial W_{jk}}$  等于什么？

提示：用索引表示  $y_i = \sum_k W_{ik} \cdot x_k$ ，然后分别求偏导。

练习 6（挑战题）：手动梯度下降

对  $f(x) = x^4 - 3x^3 + 2$  进行梯度下降。从  $x=3$  开始，学习率  $\eta=0.01$ ，迭代 50 步。画出  $x$  的轨迹和函数值的变化。如果学习率改为 0.1 和 0.5，会发生什么？

核心概念回顾

数学三大支柱

- 函数家族
  - 一次函数
  - 二次函数
  - 指数函数
  - 对数函数
- 线性代数
  - 向量内积
  - 矩阵乘法
  - 批量计算
  - 前向传播
- 微积分
  - 导数
  - 偏导数
  - 梯度向量
  - 链式法则 ⭐
  - 梯度下降

数学工具与神经网络的对应

数学概念	神经网络中的应用
一次函数 $y = wx + b$	神经元加权求和
向量内积 $\mathbf{w} \cdot \mathbf{x}$	加权求和
矩阵乘法 $\mathbf{XW}$	批量前向传播
链式法则 $\frac{\partial L}{\partial w} = \frac{\partial L}{\partial y} \cdot \frac{\partial y}{\partial u} \cdot \frac{\partial u}{\partial w}$	反向传播
梯度 $\nabla L$	参数更新方向
泰勒展开	梯度下降的理论基础

🔥 一句话总结：神经网络的数学 = 函数（表达变换） + 线性代数（高效计算） + 微积分（优化参数）。

核心公式速查

公式	说明	适用场景
$\mathbf{w} \cdot \mathbf{x} = \sum_i w_i x_i$	向量内积：神经元加权求和	单神经元计算
$\mathbf{z} = \mathbf{Wx} + \mathbf{b}$	仿射变换：矩阵乘法 + 偏置	全连接层前向传播
$f'(x) = \lim_{h \rightarrow 0} \frac{f(x+h) - f(x)}{h}$	导数定义	梯度计算基础
$\nabla f = \left[ \frac{\partial f}{\partial x_1}, \dots, \frac{\partial f}{\partial x_n} \right]^T$	梯度向量：各方向偏导组成的向量	多元函数优化
$\frac{\partial L}{\partial x} = \frac{\partial L}{\partial y} \cdot \frac{\partial y}{\partial u} \cdot \frac{\partial u}{\partial x}$	链式法则：复合函数求导	反向传播理论基础
$f(x) \approx f(a) + f'(a)(x - a) + \frac{f''(a)}{2!}(x - a)^2$	二阶泰勒展开	梯度下降理论基础

公式	说明	适用场景
$\boldsymbol{x}_{k+1} = \boldsymbol{x}_k - \eta \nabla f(\boldsymbol{x}_k)$	梯度下降迭代公式	最优化核心算法

[← 第 1 章 神经网络的思想](#) | [目录](#) | [第 3 章 PyTorch 基础](#) [→](#)



## 第 3 章 PyTorch 基础：Tensor 与自动微分

🎯 目标：理解 PyTorch 两大核心——Tensor 和 Autograd——背后的数学逻辑，为后续用代码验证数学原理做好准备。

© xiefujin · Contact: 490021684@qq.com · Licensed under CC BY-NC-SA 4.0  
📁 代码文件: `code/ch03/` (9 个文件)

插图: `images/ch03/` (2 张图)

### 📖 本章学习目标

- [ ] 理解 Tensor 与 NumPy ndarray 的关系与区别
- [ ] 掌握 Tensor 的创建、运算和维度操作
- [ ] 理解广播机制与矩阵乘法的维度规则
- [ ] 理解 Autograd 自动微分的原理
- [ ] 学会阅读和解读计算图
- [ ] 掌握 nn.Module 搭建网络的方法
- [ ] 了解 DataLoader 和数据集的使用

### 3-1 为什么需要 PyTorch?

#### 3-1-1 从 Excel 到 NumPy 到 PyTorch

计算工具的演进

工具	优点	不足
Excel	直观，逐格可见	无法处理大规模数据、无法自动求梯度
NumPy	向量化运算，批量处理	需要手动实现梯度计算
PyTorch	NumPy + GPU + 自动微分	需要学习新的语法

本书的核心过渡路径：

```
第 1-2 章：数学直觉 (NumPy 手动实现)
↓
第 3 章：PyTorch 工具 (Tensor + Autograd)
↓
第 4-5 章：手动 NumPy → PyTorch autograd 渐进过渡
↓
第 6-9 章：PyTorch 完整实战
```

#### 3-1-2 深度学习框架对比

框架	特点	适用场景
PyTorch	Pythonic、动态图、易调试	研究首选，本书选用
TensorFlow/Keras	生态成熟、部署方便	工业界部署

框架	特点	适用场景
JAX	函数式、XLA 编译、高性能	前沿研究

为什么本书选 PyTorch 而非其他？

- 直觉第一：动态图让你可以用 `print()` 随时查看任何中间值，调试体验和写普通 Python 一样
- 学术主流：NeurIPS / ICML / ICLR 论文绝大多数使用 PyTorch
- 生态完善：Hugging Face、TorchVision、TorchAudio 等生态组件齐全

💡 提示：本书所有 PyTorch 代码均可在 CPU 上运行，无需 GPU。但如果你有 NVIDIA GPU，安装 CUDA 版本会获得 10–50 倍加速。

3-1-3 PyTorch 的设计哲学

- Pythonic：与 Python 语法无缝融合——写起来就像写 NumPy
- Define-by-Run：计算图在运行时动态构建，而非预先定义
- 易调试：可以用标准 Python debugger (pdb) 单步调试

安装验证

```
pip install torch torchvision matplotlib
python -c "import torch; print(torch.__version__)" # 2.0+ (当前最新 2.7.0)

2.7.0
```

3-2 PyTorch Tensor 基础

3-2-1 什么是 Tensor？

Tensor = 多维数组，对标 NumPy 的 ndarray，但额外支持：

1. GPU 加速：`.to('cuda')` 一键切换
2. 自动微分：追踪运算历史，自动计算梯度
3. 深度学习算子：卷积、池化、归一化等

Tensor 的维度

维度	名称	示例
0 维	标量	<code>torch.tensor(3.14)</code> — 一个数
1 维	向量	<code>torch.tensor([1, 2, 3])</code> — 一列数
2 维	矩阵	<code>torch.ones(3, 4)</code> — 表格
3 维	张量	<code>torch.randn(3, 224, 224)</code> — 图像 (C, H, W)
4 维	批次张量	<code>torch.randn(32, 3, 224, 224)</code> — 图像批次

3-2-2 创建 Tensor

PyTorch 提供了多种方式创建 Tensor，从最基本的 Python 列表到随机初始化：

```
import torch
import numpy as np

从 Python 列表创建
a = torch.tensor([[1, 2], [3, 4]])
print(f"从列表创建:\n{a}")

从 NumPy 数组创建 (共享内存!)
```

```
np_arr = np.array([[1, 2], [3, 4]])
b = torch.from_numpy(np_arr)
print(f"从 NumPy 创建:\n{b}")
np_arr[0, 0] = 99 # ⚠️ 修改 NumPy 会同时修改 Tensor!
print(f"NumPy 修改后 Tensor 也变了:\n{b}")

特殊矩阵
zeros = torch.zeros(2, 3) # 全 0
ones = torch.ones(2, 3) # 全 1
eye = torch.eye(3) # 单位矩阵
rand = torch.randn(2, 3) # 标准正态分布随机

指定数据类型和设备
cuda_available = torch.cuda.is_available()
device = 'cuda' if cuda_available else 'cpu'
在 GPU 上创建 Tensor
x = torch.tensor([1, 2, 3], device=device, dtype=torch.float32)
print(f"设备: {x.device}, 类型: {x.dtype}")
```

创建方式	说明	适用场景
<code>torch.tensor(data)</code>	从数据创建	通用
<code>torch.zeros/sizes()</code>	全 0 张量	初始化偏置
<code>torch.ones/sizes()</code>	全 1 张量	初始化特定参数
<code>torch.randn/sizes()</code>	标准正态分布	初始化权重
<code>torch.arange(start, end)</code>	等差数列	生成索引
<code>torch.linspace(start, end, steps)</code>	等间隔数列	生成测试数据

注意：`torch.tensor()` 会复制数据，`torch.from_numpy()` 与 NumPy 共享内存——修改一个会影响另一个。

3-2-3 Tensor 属性

```
t = torch.randn(3, 4)
print(f"形状: {t.shape}") # torch.Size([3, 4])
print(f"数据类型: {t.dtype}") # torch.float32
print(f"设备: {t.device}") # cpu / cuda:0
print(f"是否需要梯度: {t.requires_grad}") # False
```

💡 提示：Tensor 和 NumPy 共享内存！对 Tensor 的修改会反映在 NumPy 数组上（反之亦然）。这意味着零拷贝转换，但也需要小心副作用。

3-3 Tensor 运算与广播机制

3-3-1 基本运算

```
a = torch.tensor([1, 2, 3])
b = torch.tensor([4, 5, 6])

逐元素运算
print(f"a + b = {a + b}") # tensor([5, 7, 9])
print(f"a * b = {a * b}") # tensor([4, 10, 18])

矩阵运算
A = torch.ones(2, 3)
B = torch.ones(3, 4)
C = A @ B # 矩阵乘法: (2, 3) @ (3, 4) → (2, 4)
print(f"A @ B 形状: {C.shape}") # torch.Size([2, 4])
```

### 3-3-2 广播机制 (Broadcasting) ☆

什么是广播？

当两个 Tensor 形状不同但「兼容」时，PyTorch 会自动扩展较小的 Tensor 以匹配较大的 Tensor。

广播规则

从尾部维度开始对齐，缺失的维度或长度为 1 的维度自动扩展。

```
✅ 兼容: b 从 (4,) 广播为 (3, 4)
a = torch.ones(3, 4) # (3, 4)
b = torch.ones(4) # (4,) → 广播为 (3, 4)
print(f"(3,4) + (4,) = {(a + b).shape}") # (3, 4)

❌ 不兼容: (3, 4) 和 (3,) 无法对齐
a = torch.ones(3, 4)
b = torch.ones(3)
a + b # ❌ RuntimeError: 形状不匹配
```

广播在前向传播中的应用

```
批量前向传播: 广播让偏置自动扩展到每个样本
X = torch.randn(32, 784) # 32 个样本
W = torch.randn(784, 128) # 权重
b = torch.zeros(128) # 偏置 (形状 (128,))

b 自动广播: 从 (128,) → (32, 128)
U = X @ W + b # 一句话完成批量计算!
print(f"U 的形状: {U.shape}") # (32, 128)
```

💡 核心洞察：广播机制是「批量计算」的基石。它让你写代码的方式和写数学公式的方式完全一致—— $U = XW + b$ 。

### 3-3-3 维度操作

深度学习中经常需要调整 Tensor 的形状和维度：

```
x = torch.randn(2, 3, 4) # 3D Tensor

reshape: 改变形状 (总元素数不变)
y = x.reshape(2, 12) # (2,3,4) → (2,12)
y = x.reshape(-1) # (2,3,4) → (24,) # -1 表示自动推断

transpose: 交换两个维度
z = x.transpose(0, 1) # (2,3,4) → (3,2,4)

permute: 任意重排所有维度
z = x.permute(2, 0, 1) # (2,3,4) → (4,2,3)

unsqueeze: 增加维度 (在指定位置插入长度为1的维度)
a = torch.randn(3, 4) # (3,4)
a = a.unsqueeze(0) # (1,3,4) # 常用于添加 batch 维度
a = a.unsqueeze(-1) # (1,3,4,1)

squeeze: 移除所有长度为 1 的维度
b = a.squeeze() # (3,4) # 恢复原状
```

💡 提示：`unsqueeze` 和 `squeeze` 在 CNN 中极其常用——图像通常是 4D Tensor (`batch, channels, height, width`)，而全连接层需要 2D (`batch, features`)。

## 3-4 Autograd 自动微分 ★

### 3-4-1 什么是 Autograd?

Autograd = Automatic Differentiation (自动微分)。

#### 一句话理解

你只需要定义前向传播的逻辑，Autograd 自动完成反向传播的梯度计算。

#### 它做了什么?

```
前向传播 (你写)
u = w * x + b # 你写: 神经元的加权求和
y = torch.sigmoid(u) # 你写: 激活函数
L = 0.5 * (y - t)**2 # 你写: 损失函数

反向传播 (Autograd 自动做)
L.backward() # Autograd: 追踪运算历史 → 构建计算图
 # → 从 L 反向遍历
 # → 在每个节点应用链式法则
 # → 梯度存入 w.grad, x.grad, b.grad
```

#### 与手动求导的对比

方法	工作量	正确性	可扩展性
手动求导	每个参数手写公式	易出错	网络每改一次就要重推
数值微分	改参数重新计算	有舍入误差	$O(N)$ 次前向
Autograd	零工作量	精确到机器精度	任意网络结构都适用

💡 核心洞察: Autograd = 自动化的链式法则。你写前向, 它自动反推梯度——这是 PyTorch 让你能专注于网络设计的根本原因。

### 3-4-2 requires\_grad: 告诉 PyTorch 需要计算谁的梯度

#### 基本用法

默认创建的 Tensor 不追踪梯度。需要设置 `requires_grad=True` :

```
创建需要追踪梯度的 Tensor
x = torch.tensor([2.0], requires_grad=True) # 输入: 需要梯度
w = torch.tensor([0.5], requires_grad=True) # 权重: 需要梯度
b = torch.tensor([0.1], requires_grad=True) # 偏置: 需要梯度

对比: 不需要梯度的 Tensor (如标签、固定输入)
t = torch.tensor([1.0]) # 标签: 不需要梯度
print(f"t.requires_grad = {t.requires_grad}") # False
```

#### 何时设置 requires\_grad?

场景	requires_grad	原因
模型权重、偏置	<code>True</code>	需要计算梯度来更新参数
网络输入	<code>True</code>	如果需要输入梯度 (如对抗样本)
训练数据标签	<code>False</code>	不需要对标签求梯度
固定特征	<code>False</code>	不需要反向传播到输入特征
中间变量	自动继承	输入为 <code>True</code> 时自动变为 <code>True</code>

## 动态修改

```
x = torch.tensor([2.0]) # 默认 requires_grad=False
x.requires_grad_(True) # 原地修改为 True (注意下划线表示原地操作)
print(x.requires_grad) # True

推理时关掉梯度追踪 (省显存、提速)
with torch.no_grad():
 y = model(x) # 这个前向传播不会构建计算图
```

💡 提示：只有 `requires_grad=True` 的 Tensor 才会被计算图追踪。在大型模型中，`with torch.no_grad():` 可以大幅节省显存——推理时不需要保存中间激活值。

## 3-4-3 前向传播：自动构建计算图

什么是「自动构建计算图」？

当你执行 `requires_grad=True` 的 Tensor 运算时，PyTorch 自动在背后构建了一个计算图——一个记录所有运算的有向无环图（DAG）。

```
前向传播 (自动构建计算图)
u = w * x + b # u = 0.5*2.0 + 0.1 = 1.1
y = torch.sigmoid(u) # y = sigmoid(1.1) = 0.7503
L = 0.5 * (y - 1.0)**2 # L = 0.5*(0.7503-1.0)^2 = 0.0312

print(f"u = {u.item():.4f}")
print(f"y = {y.item():.4f}")
print(f"L = {L.item():.4f}")
```

```
u = 1.1000
y = 0.7503
L = 0.0312
```

背后发生了什么？

每执行一步运算，PyTorch 就在计算图中添加一个节点：

计算图: (w,x) → 乘法 → 加法(+b) → sigmoid → 平方误差 → L

图中的每个节点都知道：

- 输入来源：它是由哪些 Tensor 计算得到的
- 运算类型：是乘法、加法还是激活函数
- 局部梯度：每个输入对应的导数（链式法则的原子操作）

💡 核心洞察：你写前向传播代码的同时，PyTorch 自动「记住了」所有运算路径。这就像你在黑板上写公式的同时，另一个人在透明纸上画出了公式的层次结构——反向传播时只需要沿着这张纸反着走一遍。

## 3-4-4 反向传播：一行代码计算所有梯度

最神奇的一行代码

所有复杂的链式法则、梯度累积、矩阵转置——全都由这一行代码完成：

```
反向传播——计算所有 requires_grad=True 的 Tensor 的梯度
L.backward()

查看梯度 (每个 Tensor 的 .grad 属性自动填充)
print(f"∂L/∂w = {w.grad.item():.4f}")
print(f"∂L/∂b = {b.grad.item():.4f}")
print(f"∂L/∂x = {x.grad.item():.4f}")
```

```
∂L/∂w = -0.0936
∂L/∂b = -0.0468
```

$\partial L / \partial x = -0.0234$ 

对比第 2 章手动计算的结果

梯度	手动计算 (第 2 章)	PyTorch Autograd	一致?
$\partial L / \partial w$	-0.0936	-0.0936	✓
$\partial L / \partial b$	-0.0468	-0.0468	✓
$\partial L / \partial x$	-0.0234	-0.0234	✓

背后发生了什么？

`L.backward()` 的内部流程：

`L.backward()` 内部流程：

1. 从 L 开始，找到其 `grad_fn`
2. 沿计算图反向遍历
3. 在每个运算节点应用链式法则
4. 梯度累积到对应 Tensor 的 `.grad` 属性

相当于自动做了第 2 章 2-8 节中我们手动做的所有链式法则计算：

$$\frac{\partial L}{\partial w} = \frac{\partial L}{\partial y} \cdot \frac{\partial y}{\partial u} \cdot \frac{\partial u}{\partial w} = (y - t) \cdot \sigma'(u) \cdot x$$

💡 **核心洞察：**这是 PyTorch 最强大的功能——你只需要关心前向传播的逻辑，反向传播的梯度计算完全自动化。对比第 2 章手动求导的痛苦，Autograd 是真正的解放。

### 3-4-5 backward() 的工作原理

标量 vs 非标量

`backward()` 的核心限制：它只能对标量 (scalar) 自动求导。如果损失不是标量，需要传入一个「梯度种子」：

```
✓ 标量 loss: 直接 backward
loss = (y_pred - y_true).pow(2).sum() # 标量
loss.backward()

✗ 非标量: 直接 backward 会报错
losses = (y_pred - y_true).pow(2) # 形状 (batch_size,)
losses.backward() # RuntimeError! grad can be implicitly created only for scalar outputs

✓ 非标量: 传入同形状的梯度种子
losses.backward(torch.ones_like(losses)) # 等价于 loss.sum().backward()
```

内部流程

`L.backward()` 内部流程：

1. 从 L 对应的计算图节点开始
2. 检查 L 的 `grad_fn` (记录运算来源)
3. 沿着 `grad_fn` 链反向遍历计算图
4. 在每个节点执行「局部链式法则」——上游梯度 × 局部梯度
5. 将计算出的梯度累积到叶子节点的 `.grad` 属性
6. 释放计算图 (默认) 以节省内存

### 3-4-6 grad 的累积特性 ⚠️

最大的新手陷阱

PyTorch 的梯度是累积的 (累加到 `.grad` 上)，而不是覆盖。每次调用 `.backward()`，梯度会加上去而不是替换：

```

x = torch.tensor([2.0], requires_grad=True)
y = x ** 2
y.backward()
print(f"第一次 backward: x.grad = {x.grad}") # tensor([4.])

❌ 第二次 backward 前没有清零!
y2 = x ** 2
y2.backward()
print(f"第二次 backward: x.grad = {x.grad}") # tensor([8.]) ← 4+4, 累积了!

✅ 正确做法: 先清零再 backward
x.grad.zero_() # 或者 optimizer.zero_grad()
y3 = x ** 2
y3.backward()
print(f"清零后: x.grad = {x.grad}") # tensor([4.]) ← 正确

```

为什么设计成累积?

梯度累积在某些场景下是有用的——比如 GPU 显存不足时, 可以通过梯度累积 (Gradient Accumulation) 用多个小批次模拟大批次:

```

梯度累积: 模拟 batch_size=128 (实际每批只有 32)
accumulation_steps = 4
optimizer.zero_grad()
for i, (inputs, labels) in enumerate(dataloader): # batch_size=32
 loss = model(inputs, labels)
 loss = loss / accumulation_steps # 缩放损失
 loss.backward()
 if (i + 1) % accumulation_steps == 0:
 optimizer.step() # 累积了 4 个 batch 的梯度后更新
 optimizer.zero_grad() # 清零

```

⚠️ 警告: `optimizer.zero_grad()` 是 PyTorch 初学者最容易忘记的一行代码。忘记清零会导致梯度指数级增长, 参数更新完全错误。

## 3-5 计算图深度解析 ★

### 3-5-1 grad\_fn: 追踪运算来源

每个 Tensor 都有一个 `grad_fn` 属性, 记录它是通过什么运算得到的:

```

x = torch.tensor([2.0], requires_grad=True)
w = torch.tensor([0.5], requires_grad=True)

u = w * x # u 由乘法运算得到
y = u + 0.1 # y 由加法运算得到
L = y ** 2 # L 由乘方运算得到

print(f"u.grad_fn: {u.grad_fn}") # <MulBackward0>
print(f"y.grad_fn: {y.grad_fn}") # <AddBackward0>
print(f"L.grad_fn: {L.grad_fn}") # <PowBackward0>

```

Tensor	grad_fn	含义
<code>u = w * x</code>	<code>MulBackward0</code>	乘法运算节点
<code>y = u + 0.1</code>	<code>AddBackward0</code>	加法运算节点
<code>L = y ** 2</code>	<code>PowBackward0</code>	乘方运算节点
<code>x</code> (叶子节点)	<code>None</code>	用户创建的, 没有运算来源



3-5-2 静态图 vs 动态图

特性	静态图 (TensorFlow 1.x)	动态图 (PyTorch)
构建时机	先构建完整图，再执行	运行时动态构建
灵活性	低 (控制流需要特殊处理)	高 (Python if/for 均可)
调试	困难 (无法在图中打断点)	易 (标准 Python debugger)
性能优化	编译时优化	JIT 编译 ( <code>torch.jit</code> )

🌟 小精灵说：动态图就像你边走边铺路——每一步都知道下一步要去哪。静态图则是先把整条路修好再走——路线固定，但可以提前优化。

3-5-3 从计算图中分离

`detach()`：部分分离

```
x = torch.tensor([1.0, 2.0], requires_grad=True)
y = x ** 2
z = y.detach() # z 从计算图中分离，不再追踪梯度
w = z ** 2 # w 也不会追踪关于 x 的梯度

print(f"z.requires_grad: {z.requires_grad}") # False
w.backward() # ❌ 不会计算关于 x 的梯度
```

`with torch.no_grad()`：推理模式

```
推理时不需要构建计算图，节省大量内存
with torch.no_grad():
 y_pred = model(x_test) # 不追踪梯度，不构建计算图
```

💡 核心洞察：训练和推理的核心区别之一就是是否需要计算图。训练需要（为了反向传播），推理不需要（只需前向）。

3-5-4 可视化计算图




图 3-1：计算图可视化。从  $x$ 、 $w$ 、 $b$  出发，经过乘法、加法、Sigmoid、平方最终得到损失  $L$ 。

3-5-5 计算图中的前向与反向

🌟 小精灵说：计算图就像一张「任务流程图」——前向传播从左到右画箭头，反向传播从右到左传数字（梯度）。看懂这张图，就理解了 autograd 的本质！

## 完整计算图可视化

运行 `code/ch03/NN03_computation_graph_viz.py` 可以自动绘制计算图：

```
计算图: $L = (y - 1)^2$, $y = u \cdot v$, $u = w \cdot x + b$
#
x(2.0) -----
|
+-----> u(2.0) -----> y(6.0) -----> L(25.0)
w(0.5) -----
|
b(1.0) -----
|
+-----> v(3.0)
#
反向传播梯度:
$\partial L / \partial w = 60.0$ $\partial L / \partial x = 15.0$ $\partial L / \partial b = 30.0$ $\partial L / \partial v = 20.0$
```

💡 **核心洞察**：计算图将反向传播分解为局部梯度 × 上游梯度的链式法则。每个节点只需计算自己输出的局部梯度，然后与上游传来的梯度相乘，就得到了该节点输入的梯度。这正是 autograd 的数学本质！

## 3-6 nn.Module：搭建网络的基石

### 3-6-1 nn.Module 基类

`nn.Module` 是所有神经网络模块的基类——它自动管理所有子模块和参数。

```
import torch.nn as nn

class MyNetwork(nn.Module):
 """自定义 2 层全连接网络"""

 def __init__(self):
 super().__init__()
 self.linear1 = nn.Linear(784, 128) # 第 1 层
 self.linear2 = nn.Linear(128, 10) # 第 2 层

 def forward(self, x):
 """前向传播 (只需定义这个!) """
 x = torch.sigmoid(self.linear1(x))
 x = self.linear2(x)
 return x

使用
model = MyNetwork()
print(model)
```

```
MyNetwork(
 (linear1): Linear(in_features=784, out_features=128, bias=True)
 (linear2): Linear(in_features=128, out_features=10, bias=True)
)
```

### 3-6-2 nn.Sequential：快速堆叠

当网络结构是简单的「一层接一层」时，`nn.Sequential` 提供了更简洁的写法——不需要定义 `__init__` 和 `forward`：

```
import torch.nn as nn

方法 A: 用 nn.Module 子类
class MyNetwork(nn.Module):
 def __init__(self):
 super().__init__()
 self.linear1 = nn.Linear(784, 128)
 self.linear2 = nn.Linear(128, 10)
 def forward(self, x):
 x = torch.sigmoid(self.linear1(x))
 return self.linear2(x)
```

```
方法 B: 用 nn.Sequential (简洁!)
model = nn.Sequential(
 nn.Linear(784, 128), # 第 1 层
 nn.Sigmoid(), # 激活函数
 nn.Linear(128, 10), # 第 2 层
)

x = torch.randn(32, 784)
output = model(x) # 数据自动依次流过各层
print(f"输出形状: {output.shape}") # (32, 10)
```

何时用 Sequential? 简单的直连网络（没有分支、没有跳跃连接）用 Sequential 最方便。需要复杂逻辑（如 ResNet 的残差连接）时，必须用 `nn.Module` 子类。

### 3-6-3 nn.Parameter: 可训练参数

什么是 nn.Parameter?

`nn.Parameter` 是 Tensor 的子类——它告诉 PyTorch: 「这个 Tensor 是模型的可训练参数，需要追踪它的梯度」。

`nn.Linear` 内部自动创建了权重和偏置作为 `nn.Parameter` :

```
linear = nn.Linear(784, 128)
print(f"权重形状: {linear.weight.shape}") # [128, 784]
print(f"偏置形状: {linear.bias.shape}") # [128]
print(f"weight 是 Parameter? {isinstance(linear.weight, nn.Parameter)}") # True
```

显式定义参数

如果你不想用 `nn.Linear` , 可以手动创建参数:

```
class MyCustomLayer(nn.Module):
 def __init__(self, in_features, out_features):
 super().__init__()
 # 显式创建可训练参数
 self.W = nn.Parameter(torch.randn(in_features, out_features) * 0.1)
 self.b = nn.Parameter(torch.zeros(out_features))

 def forward(self, x):
 return x @ self.W + self.b

layer = MyCustomLayer(784, 128)
print(f"手动参数: W={layer.W.shape}, b={layer.b.shape}")
```

核心: 把 Tensor 用 `nn.Parameter()` 包装后, 它会自动被 `model.parameters()` 识别——优化器就能找到并更新它。

### 3-6-4 模型参数管理

`nn.Module` 自动管理所有子模块和参数——你可以通过 `named_parameters()` 查看所有可训练参数:

```
model = MyNetwork()
for name, param in model.named_parameters():
 print(f"{name}: {param.shape}, requires_grad={param.requires_grad}")
```

```
linear1.weight: torch.Size([128, 784]), requires_grad=True
linear1.bias: torch.Size([128]), requires_grad=True
linear2.weight: torch.Size([10, 128]), requires_grad=True
linear2.bias: torch.Size([10]), requires_grad=True
```

常用参数管理方法

方法	功能	示例
<code>model.parameters()</code>	返回所有参数迭代器	传给 <code>optimizer</code>

方法	功能	示例
<code>model.named_parameters()</code>	返回 (名字, 参数) 对	调试查看
<code>model.state_dict()</code>	返回所有参数的字典	保存/加载模型
<code>model.load_state_dict(d)</code>	从字典加载参数	恢复训练
<code>model.to(device)</code>	将所有参数移到设备	GPU 训练

### 3-7 数据集与数据加载

#### 3-7-1 Dataset：自定义数据集

三个必须实现的方法

`torch.utils.data.Dataset` 是一个抽象类，你需要实现三个方法：

```
from torch.utils.data import Dataset

class MyDataset(Dataset):
 """自定义数据集：包装特征矩阵和标签"""
 def __init__(self, X, y):
 """初始化：将数据转为 Tensor"""
 self.X = torch.tensor(X, dtype=torch.float32)
 self.y = torch.tensor(y, dtype=torch.long)

 def __len__(self):
 """返回数据集大小"""
 return len(self.y)

 def __getitem__(self, idx):
 """返回第 idx 个样本 (特征, 标签)"""
 return self.X[idx], self.y[idx]

使用
import numpy as np
X = np.random.randn(1000, 784) # 1000 张 28x28 的图
y = np.random.randint(0, 10, 1000) # 0-9 的标签
dataset = MyDataset(X, y)
print(f"数据集大小: {len(dataset)}")
print(f"第 0 个样本: X={dataset[0][0].shape}, y={dataset[0][1]}")
```

方法	必须实现	作用
<code>__init__</code>	✓	加载数据，预处理
<code>__len__</code>	✓	告诉 DataLoader 有多少样本
<code>__getitem__</code>	✓	按索引返回 (特征, 标签) 对

#### 3-7-2 DataLoader：批量加载

```
from torch.utils.data import DataLoader

dataset = MyDataset(X, y)
loader = DataLoader(dataset, batch_size=32, shuffle=True)

遍历批次
for batch_x, batch_y in loader:
 # batch_x: (32, num_features)
 # batch_y: (32,)
 print(f"批次形状: {batch_x.shape}")
 break
```

### 3-7-3 使用标准数据集 (MNIST)

```
from torchvision import datasets, transforms

MNIST 手写数字数据集
transform = transforms.Compose([
 transforms.ToTensor(), # PIL 图像 → Tensor
 transforms.Normalize((0.1307,), (0.3081,)) # 标准化
])

mnist_train = datasets.MNIST(
 root='./data', train=True,
 transform=transform, download=True
)

train_loader = DataLoader(mnist_train, batch_size=64, shuffle=True)
print(f"训练集大小: {len(mnist_train)} 张图片")
```

训练集大小: 60000 张图片




图 3-2: MNIST 数据集样本——深度学习界的「Hello World」。

## 3-8 损失函数与优化器速览

### 3-8-1 常见损失函数

PyTorch 在 `torch.nn` 中提供了丰富的损失函数:

```
import torch.nn as nn

回归任务
mse_loss = nn.MSELoss() # 均方误差 (最常用)
l1_loss = nn.L1Loss() # 平均绝对误差 (对异常值更鲁棒)

分类任务
ce_loss = nn.CrossEntropyLoss() # 交叉熵 (分类默认! 内部含 Softmax)
bce_loss = nn.BCELoss() # 二分类交叉熵 (需配合 Sigmoid)
bce_logits = nn.BCEWithLogitsLoss() # 更稳定的二分类 (内部含 Sigmoid)

使用示例
y_pred = torch.randn(32, 10) # 模型输出 (batch, 10)
y_true = torch.randint(0, 10, (32,)) # 真实标签
loss = ce_loss(y_pred, y_true) # 注意: CrossEntropyLoss 不需要手动 Softmax!
print(f"损失值: {loss.item():.4f}")
```

损失函数	任务	配合激活	梯度形式
<code>MSELoss</code>	回归	无	$y - t$
<code>CrossEntropyLoss</code>	多分类	内置 Softmax	$p - t$ (简洁!)
<code>BCEWithLogitsLoss</code>	二分类	内置 Sigmoid	$\sigma(z) - t$

### 3-8-2 常见优化器

```
import torch.optim as optim

model = nn.Linear(784, 10)

SGD: 随机梯度下降
optimizer = optim.SGD(model.parameters(), lr=0.01)

Adam: 自适应学习率 (最常用)
optimizer = optim.Adam(model.parameters(), lr=0.001)
```

### 3-8-3 训练循环模板

```
model = nn.Linear(784, 10)
criterion = nn.CrossEntropyLoss()
optimizer = optim.SGD(model.parameters(), lr=0.01)

for epoch in range(10):
 for batch_x, batch_y in train_loader:
 # 前向传播
 outputs = model(batch_x.view(batch_x.size(0), -1))
 loss = criterion(outputs, batch_y)

 # 反向传播
 optimizer.zero_grad() # 清零梯度 ☆
 loss.backward() # 自动计算梯度
 optimizer.step() # 更新参数

 print(f"Epoch {epoch}: loss = {loss.item():.4f}")
```

注意: `optimizer.zero_grad()` 是初学者最容易忘记的一行代码!  
如果忘记清零, 梯度会累积, 导致参数更新方向和大小都完全错误。

## ⚠️ PyTorch 常见陷阱与调试指南

### 陷阱一: 忘记 `optimizer.zero_grad()`

```
❌ 错误写法
for x, y in dataloader:
 pred = model(x)
 loss = loss_fn(pred, y)
 loss.backward()
 optimizer.step() # ❌ 忘记 zero_grad()! 梯度会累积!

✅ 正确写法
for x, y in dataloader:
 optimizer.zero_grad() # ✅ 每次迭代前清零梯度
 pred = model(x)
 loss = loss_fn(pred, y)
 loss.backward()
 optimizer.step()
```

## 陷阱二：Tensor 设备不一致

```
❌ 错误写法
x = torch.randn(3, 3) # 在 CPU 上
model = MyModel().to('cuda') # 模型在 GPU 上
y = model(x) # ❌ 报错! 设备不匹配

✅ 正确写法
x = torch.randn(3, 3).to('cuda') # 数据也要移到 GPU
y = model(x) # ✅ 设备一致
```

## 陷阱三：原地操作破坏计算图

```
x = torch.tensor([1.0], requires_grad=True)
y = x ** 2
y += 1 # ❌ 原地操作 (in-place), 破坏计算图!
y = y + 1 # ✅ 非原地操作, 保留计算图
loss = y.mean()
loss.backward() # ❌ 可能报错
```

🧚 小精灵说：PyTorch 的计算图就像小精灵的「工作流程图」——每个运算都被记录下来。但如果你做了原地操作（比如 `y += 1`），就像把小精灵的工作笔记涂改了，后面的小精灵就不知道你之前做了什么了！所以一定要用 `y = y + 1` 这种非原地操作！

## 3-9 Autograd 深度解析

### 3-9-1 计算图的构建时机

PyTorch 使用动态计算图（Dynamic Graph）——每次前向传播都重新构建计算图。

```
import torch

x = torch.tensor(2.0, requires_grad=True)

每次 forward 都重建计算图
for i in range(3):
 y = x ** 2 + 2 * x + 1 # 每次这里都构建新的计算图
 y.backward()
 print(f"第{i+1}次: x.grad = {x.grad}")
 x.grad.zero_() # 必须清零! 否则梯度会累积
```

```
第1次: x.grad = 6.0 (f'(x) = 2x+2 = 6)
第2次: x.grad = 6.0
第3次: x.grad = 6.0
```

💡 核心洞察：动态图意味着你可以在每次前向传播时改变网络结构——比如根据输入长度动态添加层、使用条件分支等。这是 PyTorch 相比于 TensorFlow 1.x（静态图）最大的优势。

### 3-9-2 梯度累积与清零

```
演示梯度累积现象
x = torch.tensor([1.0, 2.0, 3.0], requires_grad=True)

多次 backward 而不清零
for i in range(3):
 y = (x ** 2).sum()
 y.backward()
 print(f"第{i+1}次后: x.grad = {x.grad}")

注意观察到梯度正在累加!
```

次数	x.grad	说明
第1次	[2, 4, 6]	初始梯度
第2次	[4, 8, 12]	翻倍了（梯度累积）
第3次	[6, 12, 18]	三倍了（梯度累积）

**梯度累积的用途：**在显存不足时，可以用梯度累积来模拟更大的 batch size。

```
梯度累积技巧：模拟大 batch
optimizer.zero_grad()
for micro_batch in range(4): # 4 个 micro-batch
 loss = compute_loss(micro_batch_data)
 loss.backward() # 梯度累积：每次 backward 都累加
此时梯度 = 4 个 micro-batch 的梯度之和
optimizer.step() # 等效于 batch_size * 4 的效果
```

### 3-9-3 detach(): 从计算图中分离

有时候我们需要从计算图中「摘下」一个 Tensor，让它不参与梯度计算：

```
x = torch.tensor([1.0, 2.0], requires_grad=True)
y = x ** 2

detach() 创建一个新的 Tensor，与计算图断开
y_detached = y.detach()
print(f"y.requires_grad = {y.requires_grad}") # True
print(f"y_detached.requires_grad = {y_detached.requires_grad}") # False

应用场景：特征提取 + GAN 训练
features = backbone(x)
features = features.detach() # 冻结 backbone 的梯度
output = classifier(features) # 只训练 classifier
```

### 3-9-4 no\_grad() vs inference\_mode()

PyTorch 提供了两种上下文管理器来禁用梯度追踪：

方法	作用	性能
<code>torch.no_grad()</code>	不追踪梯度，但仍构建计算图	快
<code>torch.inference_mode()</code>	不追踪梯度，不构建计算图	更快（推荐）

```
推理时推荐使用 inference_mode
@torch.inference_mode()
def predict(model, x):
 return model(x)

✅ inference_mode 比 no_grad 快 10~20%
```

## 3-10 PyTorch 调试实战

### 3-10-1 常见错误及解决方案

```
错误 1：形状不匹配
x = torch.randn(32, 784)
linear = nn.Linear(784, 256)
try:
 out = linear(x.t()) # ❌ 输入形状是 (784, 32)，但期望 (32, 784)
except Exception as e:
 print(f"形状错误: {e}")
✅ 修复：检查 x 的形状，确保是 (batch, features)
```



常见错误	错误信息	解决方案
形状不匹配	<code>mat1 and mat2 shapes cannot be multiplied</code>	检查每层的输入输出维度
设备不一致	<code>Expected all tensors to be on the same device</code>	确保数据和模型在同一设备
梯度为 None	<code>can't access gradient of non-leaf Tensor</code>	只对叶节点（参数）访问 <code>.grad</code>
原地操作	<code>one of the variables needed for gradient computation has been modified</code>	使用 <code>a = a + 1</code> 而非 <code>a += 1</code>

### 3-10-2 用 hook 调试中间层

PyTorch 的 hook 机制让你可以「偷看」中间层的输出和梯度：

```
def debug_hook(module, input, output):
 """注册到任意层，打印输入输出信息"""
 print(f"层: {module.__class__.__name__}")
 print(f" 输入形状: {input[0].shape}")
 print(f" 输出形状: {output.shape}")
 print(f" 输出范围: [{output.min():.3f}, {output.max():.3f}]")

在模型某层注册 hook
model = nn.Sequential(
 nn.Linear(784, 256),
 nn.ReLU(),
 nn.Linear(256, 10)
)
model[1].register_forward_hook(debug_hook) # 偷看 ReLU 的输出

x = torch.randn(1, 784)
out = model(x)
```

### 3-10-3 TensorBoard 可视化

```
from torch.utils.tensorboard import SummaryWriter

writer = SummaryWriter('runs/experiment_1')

记录训练 curve
for epoch in range(100):
 loss = train_one_epoch()
 writer.add_scalar('Loss/train', loss, epoch)
 # 记录学习率
 writer.add_scalar('LR', optimizer.param_groups[0]['lr'], epoch)

记录计算图
dummy_input = torch.randn(1, 784)
writer.add_graph(model, dummy_input)

记录权重直方图
for name, param in model.named_parameters():
 writer.add_histogram(name, param, epoch)

writer.close()
运行 tensorboard --logdir=runs 查看
```

 **小精灵说：**TensorBoard 就像是给小精灵们装的「监控摄像头」！你可以实时看到训练过程中的 loss 曲线、参数变化、梯度大小——就像看股票走势图一样！发现问题，及时调整，不用等 100 个 epoch 跑完才发现不对劲！

## 本章代码清单

文件	内容	核心知识点
<code>ch03/NN03_tensor_basics.py</code>	Tensor 的创建、属性与基本运算	Tensor 核心概念

文件	内容	核心知识点
ch03/NN03_broadcasting.py	Broadcasting 广播机制演示	广播规则
ch03/NN03_autograd_demo.py	Autograd 自动微分演示	自动求导
ch03/NN03_computational_graph.py	计算图构建与可视化	计算图机制
ch03/NN03_computation_graph_viz.py	计算图前向/反相对比可视化	计算图深度理解
ch03/NN03_mnist_viz.py	MNIST 数据集样本可视化	数据可视化
ch03/NN03_nn_module.py	用 nn.Module 构建神经网络	模块化编程
ch03/NN03_dataset_dataloader.py	Dataset 与 DataLoader 数据管道	数据加载
ch03/NN03_training_loop.py	完整训练循环实现	训练四步曲

📖 本章小结

📌 课后练习

练习 1: Tensor 基础操作

```
import torch

(1) 创建一个 3x4 的随机 Tensor, 查看其形状和数据类型
(2) 创建一个 4x3 的全 1 Tensor, 进行矩阵乘法
(3) 将结果移动到 CPU/GPU, 体会 .to() 的使用
```

练习 2: 自动微分与计算图

```
import torch
x = torch.tensor(3.0, requires_grad=True)
y = torch.tensor(1.0, requires_grad=True)

定义一个标量函数: z = (x + y) * (x - y)
(1) 前向计算 z
(2) 调用 backward()
(3) 打印 x.grad 和 y.grad
(4) 手动验算: dz/dx 和 dz/dy 的理论值是多少?
```

练习 3: 手动 vs Autograd

用 PyTorch 的自动微分验证第 2 章中手动推导的梯度。选择一个简单函数（如  $y = x^2 + 2x + 1$ ），分别在手工计算梯度值和调用 backward() 获取梯度值，比较结果。

练习 4: 构建简单线性模型

用 nn.Module 构建  $y = Wx + b$  模型（1 个输入-1 个输出），用 MSE 损失和 SGD 优化器训练 100 步。数据:  $x = [1, 2, 3, 4, 5]$ ,  $y = [3, 5, 7, 9, 11]$ （即  $y=2x+1$ ）。

练习 5: 调试训练循环

故意在训练循环中忘记 optimizer.zero\_grad(), 观察梯度累积的后果。写出你观察到的现象并解释原因。

练习 6 (挑战): 自定义 autograd 函数

继承 torch.autograd.Function 实现一个自定义激活函数  $f(x) = x^2$ （前向和反向），并用它替换网络中的 ReLU。

核心概念回顾

概念	一句话理解
Tensor	PyTorch 版的 NumPy 数组 + GPU 支持 + 梯度追踪

概念	一句话理解
Autograd	自动化的链式法则——你写前向，它自动反向求梯度
计算图	记录所有运算的有向无环图，反向传播的「地图」
nn.Module	所有神经网络模块的基类——自动管理参数
DataLoader	批量加载 + 打乱 + 多进程的数据管道

🔥 一句话总结：PyTorch = Tensor（数据容器）+ Autograd（自动求导）+ nn.Module（网络模板）+ DataLoader（数据管道）。训练循环四步曲：zero\_grad → 前向 → backward → step。

核心公式速查

公式 / 代码	说明	适用场景
<code>torch.tensor([1,2,3], requires_grad=True)</code>	创建可追踪梯度的 Tensor	参数初始化
<code>loss.backward()</code>	反向传播计算梯度	自动求导
<code>optimizer.zero_grad()</code> + <code>optimizer.step()</code>	梯度清零 + 参数更新	训练循环核心
<code>z = x @ y</code> 或 <code>torch.mm(x, y)</code>	矩阵乘法	全连接层计算
<code>y = x.view(-1, 784)</code>	Tensor 形状变换	展平操作
<code>nn.Sequential(Linear(784,256), ReLU())</code>	顺序容器构建网络	快速搭建模型

## 第 4 章 神经网络的训练与优化

🎯 目标：从直觉上理解梯度下降为什么能最小化误差——通过可视化和对比实验感受「下山」的过程，而不是背公式。

© xiefujin · Contact: 490021684@qq.com · Licensed under CC BY-NC-SA 4.0

📁 代码文件: [code/ch04/](#) (7 个文件)

插图: [images/ch04/](#) (10 张图)

### 📅 本章学习目标

- [ ] 理解神经网络中参数与变量的区别
- [ ] 掌握前向传播的完整数学表达
- [ ] 理解数据标准化和 One-Hot 编码的作用
- [ ] 理解 MSE 和交叉熵两种损失函数
- [ ] 理解 Softmax 函数的原理
- [ ] 体验从纯 NumPy → 无 autograd → PyTorch autograd 的过渡
- [ ] 用 PyTorch 训练第一个非线性分类器

### 4-1 神经网络的参数和变量

#### 4-1-1 参数的分类

可训练参数（模型自己学）

参数	符号	作用
权重	$\mathbf{W}$	控制输入信号的连接强度
偏置	$\mathbf{b}$	调节神经元的激活阈值

超参数（手动设定）

超参数	作用
学习率 $\eta$	控制梯度下降步长
隐藏层大小	每层的神经元数量
层数	网络的深度
批次大小	每次更新的样本数

#### 4-1-2 变量的分类

变量	符号	说明
输入	$\mathbf{x}$	原始数据
中间输出	$\mathbf{z}^{(l)}$	各层激活值

变量	符号	说明
最终输出	$\mathbf{y}$	预测结果
目标	$\mathbf{t}$	真实标签

### 4-1-3 PyTorch 参数管理

在 PyTorch 中，模型参数通过 `nn.Parameter` 自动管理：

```
import torch.nn as nn

model = nn.Sequential(
 nn.Linear(2, 4),
 nn.Sigmoid(),
 nn.Linear(4, 1)
)

查看所有参数
for name, param in model.named_parameters():
 print(f"{name}: shape={param.shape}, requires_grad={param.requires_grad}")
```

输出显示所有可训练参数及其形状——优化器将根据这些参数的梯度来更新它们。

## 4-2 神经网络的变量关系式

### 4-2-1 逐层传播公式

输入层 → 隐藏层（以 2 输入 → 2 隐藏为例）

$$\mathbf{u}_1 = \mathbf{x}_1 \mathbf{w}_{11} + \mathbf{x}_2 \mathbf{w}_{21} + b_1$$

$$\mathbf{u}_2 = \mathbf{x}_1 \mathbf{w}_{12} + \mathbf{x}_2 \mathbf{w}_{22} + b_2$$

$$z_1 = \sigma(\mathbf{u}_1), \quad z_2 = \sigma(\mathbf{u}_2)$$

隐藏层 → 输出层

$$\mathbf{y} = z_1 \mathbf{w}'_1 + z_2 \mathbf{w}'_2 + b'$$

### 4-2-2 矩阵形式

一层传播

$$\mathbf{u}^{(1)} = \mathbf{x} \mathbf{W}^{(1)} + \mathbf{b}^{(1)}$$

$$\mathbf{z}^{(1)} = \sigma(\mathbf{u}^{(1)})$$

$$\mathbf{y} = \mathbf{z}^{(1)} \mathbf{W}^{(2)} + \mathbf{b}^{(2)}$$

## 4-2-3 Python 实践：2 层网络前向传播

🌟 小精灵说：看！这就是我们小精灵们的「接力赛」！第 1 层的小精灵们把输入信号加权传给隐藏层，隐藏层的小精灵们激活后再传给输出层—— $\mathbf{z}^{(1)} = f(\mathbf{W}^{(1)}\mathbf{x} + \mathbf{b}^{(1)})$ ，然后  $\mathbf{y} = f(\mathbf{W}^{(2)}\mathbf{z}^{(1)} + \mathbf{b}^{(2)})$ 。数据就像接力棒！

```
import numpy as np

def sigmoid(x):
 return 1 / (1 + np.exp(-x))

class SimpleNetwork:
 """2 层全连接网络"""

 def __init__(self, input_size=2, hidden_size=4, output_size=1):
 self.W1 = np.random.randn(input_size, hidden_size) * 0.1
 self.b1 = np.zeros(hidden_size)
 self.W2 = np.random.randn(hidden_size, output_size) * 0.1
 self.b2 = np.zeros(output_size)

 def forward(self, x):
 """前向传播"""
 # 第 1 层: 输入 → 隐藏
 u1 = x @ self.W1 + self.b1
 z1 = sigmoid(u1)

 # 第 2 层: 隐藏 → 输出
 u2 = z1 @ self.W2 + self.b2
 y = sigmoid(u2)
 return y

 def get_params(self):
 return {'W1': self.W1, 'b1': self.b1,
 'W2': self.W2, 'b2': self.b2}

测试
net = SimpleNetwork()
x_sample = np.array([[0.5, -0.3]])
y_pred = net.forward(x_sample)
print(f"预测值: {y_pred[0,0]:.4f}")
```

## 4-3 学习数据和正解

## 4-3-1 监督学习的数据结构

特征矩阵

$$\mathbf{X} \in \mathbb{R}^{n \times m}$$

- $n$ : 样本数
- $m$ : 特征数

标签向量

$$\mathbf{y} \in \mathbb{R}^n$$

一个样本对

$$(\mathbf{x}^{(i)}, y^{(i)})$$

### 4-3-2 数据集的划分

数据集	用途	典型比例
训练集	训练模型参数（梯度下降更新权重）	60–80%
验证集	调超参数、早停（防止过拟合）	10–20%
测试集	最终评估模型泛化性能	10–20%

注意：测试集只能在模型训练完成后使用一次！千万不能根据测试集的结果「回调」模型。

### 4-3-3 数据标准化

为什么需要标准化？

如果特征尺度差异太大（比如房价：万元 vs 面积：平方米），梯度下降会在某些维度上震荡，收敛极慢。

Z-Score 标准化

$$x' = \frac{x - \mu}{\sigma}$$

```
标准化
mean = X_train.mean(axis=0)
std = X_train.std(axis=0)
X_train_norm = (X_train - mean) / std

注意：用训练集的统计量标准化测试集！
X_test_norm = (X_test - mean) / std
```

### 4-3-4 One-Hot 编码

为什么需要 One-Hot？

分类任务的标签通常是整数（如 0、1、2），但整数隐含了大小关系（ $0 < 1 < 2$ ）。类别之间没有大小关系——「猫」不比「狗」小。One-Hot 编码将整数标签转换为等长的 0/1 向量，消除了错误的大小关系暗示。

```
import torch

原始标签
labels = torch.tensor([0, 2, 1, 3])

One-Hot 编码（4 个类别）
num_classes = 4
one_hot = torch.eye(num_classes)[labels]
print(one_hot)
tensor([[1., 0., 0., 0.], # 类别 0
[0., 0., 1., 0.], # 类别 2
[0., 1., 0., 0.], # 类别 1
[0., 0., 0., 1.]]) # 类别 3
```

注意：PyTorch 的 `CrossEntropyLoss` 不需要手动 One-Hot——它直接接受整数标签作为输入，内部自动处理。

## 4-4 神经网络的损失函数

### 4-4-1 均方误差 MSE（回归任务）

数学定义

$$C = \frac{1}{2n} \sum_{k=1}^n (y_k - t_k)^2$$

为什么有个  $\frac{1}{2}$ ？

纯粹为了求导方便——求导后  $\frac{1}{2}$  和平方项的  $2$  抵消：

$$\frac{\partial L}{\partial y_k} = y_k - t_k$$

Python 实现

```
def mse_loss(y, t):
 """均方误差损失"""
 return 0.5 * np.mean((y - t)**2)

测试
y_pred = np.array([0.8, 0.2, 0.6])
y_true = np.array([1.0, 0.0, 1.0])
print(f"MSE Loss: {mse_loss(y_pred, y_true):.4f}")
```

MSE Loss: 0.0600

### 4-4-2 交叉熵损失（分类任务）★

二分类

$$C = -\frac{1}{n} \sum_{k=1}^n [t_k \log y_k + (1 - t_k) \log(1 - y_k)]$$

直觉理解：

- 当  $t_k = 1$  时，损失为  $-\log y_k$ ——预测概率越接近 1，损失越小
- 当  $t_k = 0$  时，损失为  $-\log(1 - y_k)$ ——预测概率越接近 0，损失越小

多分类

$$C = -\frac{1}{n} \sum_{k=1}^n \sum_{c=1}^K t_{k,c} \log y_{k,c}$$

为什么交叉熵比 MSE 更适合分类？

对比	MSE + Sigmoid	Cross-Entropy + Softmax
饱和区梯度	极小（梯度消失）	梯度始终较大
收敛速度	慢	快
概率解释	无	输出可解释为概率

💡 核心洞察：MSE + Sigmoid 在输出层神经元饱和时梯度极小，而 Cross-Entropy + Softmax 即使在饱和区也有大梯度。这就是分类任务默认用



后者的原因。

### 4-4-3 Softmax 函数 ★

数学定义

$$\text{softmax}(\mathbf{z})_i = \frac{e^{z_i}}{\sum_{j=1}^K e^{z_j}}$$

特点

- 输出：所有分量的和为 1，每个分量在 (0,1) 之间
- 可解释为：输入  $\mathbf{z}$  属于各个类别的概率

Python 实现

```
def softmax(x):
 """数值稳定的 Softmax 实现"""
 # 减去最大值防止指数溢出
 exp_x = np.exp(x - np.max(x, axis=-1, keepdims=True))
 return exp_x / np.sum(exp_x, axis=-1, keepdims=True)

测试
logits = np.array([[2.0, 1.0, 0.1]])
probs = softmax(logits)
print(f"Softmax 输出: {probs}")
print(f"概率和: {probs.sum():.4f}")
```

```
Softmax 输出: [[0.6590, 0.2424, 0.0986]]
概率和: 1.0000
```

交叉熵 + Softmax 的美妙组合

交叉熵损失和 Softmax 组合后，梯度有一个极其简洁的形式：

$$\frac{\partial L}{\partial z_i} = y_i - t_i$$

即：预测概率减去真实标签。

💡 核心洞察：这个简洁的导数形式是交叉熵 + Softmax 被广泛使用的数学原因——反向传播的梯度计算极其简单。

💡 提示：Softmax + 交叉熵的详细数学推导（包括 Softmax 的导数、与交叉熵结合的美妙性质）请参阅第 7 章 7-7 节「Softmax 深度理解」。

### 4-4-4 代码验证

```
def mse_loss(y, t):
 return 0.5 * np.mean((y - t)**2)

def cross_entropy_loss(y_pred, y_true):
 """交叉熵损失（带数值稳定性）"""
 return -np.mean(np.sum(y_true * np.log(y_pred + 1e-8), axis=1))

对比两种损失
y_pred = np.array([[0.7, 0.2, 0.1],
 [0.1, 0.8, 0.1]])
y_true = np.array([[1, 0, 0],
 [0, 1, 0]])
```

```
print(f"MSE Loss: {mse_loss(y_pred, y_true):.6f}")
print(f"Cross-Entropy Loss: {cross_entropy_loss(y_pred, y_true):.6f}")
```

```
MSE Loss: 0.0900
Cross-Entropy Loss: 0.2097
```

## 4-5 用 Python & PyTorch 体验神经网络

### 4-5-1 从纯 NumPy 到 PyTorch 的三步过渡

🌟 小精灵说：从 NumPy 到 PyTorch，就像给小精灵们升级装备！以前要手动算梯度（好累！），现在有了 autograd，小精灵们只要跑前向传播，PyTorch 自动帮我记下每一步，调用 `.backward()` 就能拿到所有梯度。解放生产力！

三步过渡的核心意义：每一层都在减少「手动工作」，让我们更聚焦于数学原理。

#### Step 1: 纯 NumPy 手动实现

```
import numpy as np

np.random.seed(42)
N, D_in, H, D_out = 100, 2, 4, 1
X = np.random.randn(N, D_in)
t = (X[:, 0]**2 + X[:, 1]**2 > 1).astype(float).reshape(-1, 1)

参数初始化
W1 = np.random.randn(D_in, H) * 0.1
b1 = np.zeros(H)
W2 = np.random.randn(H, D_out) * 0.1
b2 = np.zeros(D_out)

lr = 0.5
for epoch in range(1000):
 # 前向传播
 z1 = sigmoid(X @ W1 + b1)
 y = sigmoid(z1 @ W2 + b2)

 # 手动计算梯度
 dL_dy = (y - t) / N
 dy_du2 = y * (1 - y)
 dL_dW2 = z1.T @ (dL_dy * dy_du2)
 dL_db2 = np.sum(dL_dy * dy_du2, axis=0)

 dz1_du1 = z1 * (1 - z1)
 dL_dz1 = (dL_dy * dy_du2) @ W2.T
 dL_dW1 = X.T @ (dL_dz1 * dz1_du1)
 dL_db1 = np.sum(dL_dz1 * dz1_du1, axis=0)

 # 梯度下降更新
 W2 -= lr * dL_dW2; b2 -= lr * dL_db2
 W1 -= lr * dL_dW1; b1 -= lr * dL_db1

 if epoch % 200 == 0:
 loss = 0.5 * ((y - t)**2).mean()
 print(f"Epoch {epoch}: loss = {loss:.6f}")
```

Epoch	Loss
0	0.1292
200	0.0290
400	0.0161
600	0.0113
800	0.0088

Loss 持续下降，梯度下降在正常工作。

### Step 2: PyTorch Tensor + autograd

```
import torch

转为 Tensor, 开启自动微分
W1_t = torch.tensor(W1, requires_grad=True)
b1_t = torch.tensor(b1, requires_grad=True)
W2_t = torch.tensor(W2, requires_grad=True)
b2_t = torch.tensor(b2, requires_grad=True)
X_t = torch.tensor(X, dtype=torch.float32)
t_t = torch.tensor(t, dtype=torch.float32)

for epoch in range(1000):
 # 前向传播
 z1 = torch.sigmoid(X_t @ W1_t + b1_t)
 y = torch.sigmoid(z1 @ W2_t + b2_t)
 loss = 0.5 * ((y - t_t)**2).mean()

 # 自动反向传播
 loss.backward()

 # 手动更新参数 (no_grad 避免追踪更新操作)
 with torch.no_grad():
 W1_t -= lr * W1_t.grad
 b1_t -= lr * b1_t.grad
 W2_t -= lr * W2_t.grad
 b2_t -= lr * b2_t.grad

 # 清零梯度
 W1_t.grad.zero_()
 b1_t.grad.zero_()
 W2_t.grad.zero_()
 b2_t.grad.zero_()
```

### Step 3: 使用 nn.Module 和 optim (最简洁)

```
model = nn.Sequential(
 nn.Linear(2, 4),
 nn.Sigmoid(),
 nn.Linear(4, 1),
 nn.Sigmoid()
)

criterion = nn.BCELoss()
optimizer = optim.SGD(model.parameters(), lr=0.5)

for epoch in range(1000):
 pred = model(X_t)
 loss = criterion(pred, t_t)

 optimizer.zero_grad()
 loss.backward()
 optimizer.step()
```

💡 **核心洞察：**三个 Step 的产出完全一致（梯度相同、损失下降相同），但手动工作量逐级减少。第 5 章将深入理解 Step 1 中那些「手动梯度计算」背后的数学原理。

#### 4-5-2 可视化训练过程




图 4-1: 训练损失随 epoch 下降的曲线。

### 4-6 实验：用 PyTorch 训练第一个分类器

#### 4-6-1 数据集：Moon 数据集

```
from sklearn.datasets import make_moons
import matplotlib.pyplot as plt

生成非线性可分的数据
X, t = make_moons(n_samples=200, noise=0.2, random_state=42)

可视化
plt.figure(figsize=(6, 5))
plt.scatter(X[t==0, 0], X[t==0, 1], label='类别 0', alpha=0.7)
plt.scatter(X[t==1, 0], X[t==1, 1], label='类别 1', alpha=0.7)
plt.legend()
plt.title('Moon 数据集')
plt.show()
```




图 4-2: Moon 数据集——线性分类器无法解决的经典非线性问题。

#### 4-6-2 模型：2 层全连接网络

```
import torch.nn as nn
import torch.optim as optim

模型
model = nn.Sequential(
 nn.Linear(2, 8), # 输入 2 维 → 隐藏层 8 神经元
 nn.Sigmoid(),
 nn.Linear(8, 1), # 隐藏层 8 维 → 输出 1 维
```

```

nn.Sigmoid()
)

损失函数和优化器
criterion = nn.BCELoss()
optimizer = optim.SGD(model.parameters(), lr=0.5)

转为 Tensor
X_t = torch.tensor(X, dtype=torch.float32)
t_t = torch.tensor(t, dtype=torch.float32).reshape(-1, 1)

```

#### 4-6-3 训练循环

```

model = TwoLayerNet()
criterion = nn.BCEWithLogitsLoss()
optimizer = optim.SGD(model.parameters(), lr=0.1)

epochs = 100
for epoch in range(epochs):
 # 前向传播
 outputs = model(X_tensor)
 loss = criterion(outputs, y_tensor)

 # 反向传播 + 更新
 optimizer.zero_grad() # 清零梯度
 loss.backward() # 计算梯度
 optimizer.step() # 更新参数

 if epoch % 10 == 0:
 acc = ((outputs > 0).float() == y_tensor.float()).mean()
 print(f'Epoch {epoch}: loss={loss.item():.4f}, acc={acc:.2%}')

```

这个循环展示了 PyTorch 训练的**四步标准模式**：前向 → 清零 → 反向 → 更新。

#### 4-6-4 可视化决策边界

训练完成后，我们可以将模型的决策边界画出来，直观观察网络学到了什么：

```

import matplotlib.pyplot as plt
import numpy as np

在 2D 平面上生成网格点
x_min, x_max = X[:, 0].min() - 0.5, X[:, 0].max() + 0.5
y_min, y_max = X[:, 1].min() - 0.5, X[:, 1].max() + 0.5
xx, yy = np.meshgrid(np.linspace(x_min, x_max, 100),
 np.linspace(y_min, y_max, 100))
grid = torch.tensor(np.c_[xx.ravel(), yy.ravel()], dtype=torch.float32)

用模型预测网络上每个点的类别
with torch.no_grad():
 Z = model(grid)
 Z = (Z > 0).float().numpy().reshape(xx.shape)

画决策边界
plt.contourf(xx, yy, Z, alpha=0.8, cmap='RdYlBu')
plt.scatter(X[:, 0], X[:, 1], c=y, edgecolors='k', cmap='RdYlBu')
plt.title('模型决策边界')
plt.show()

```




图 4-3：经过梯度下降训练后，2 层全连接网络学习到了一个非线性的决策边界，将两类数据分开。

! 最优化常见问题与调试指南

问题一：损失不下降怎么办？

```
诊断步骤
def diagnose_training(model, dataloader):
 # 1. 检查梯度是否有效
 total_norm = 0
 for p in model.parameters():
 if p.grad is not None:
 total_norm += p.grad.norm().item()
 print(f"梯度范数: {total_norm:.6f}")

 # 2. 检查学习率是否合适
 # 如果梯度范数很小 (<1e-6) → 学习率太小或梯度消失
 # 如果 loss 突然变成 NaN → 学习率太大，梯度爆炸

 # 3. 尝试不同的学习率
 for lr in [1e-1, 1e-2, 1e-3, 1e-4]:
 model = SimpleModel()
 loss = train_for_10_epochs(model, lr=lr)
 print(f"lr={lr}: loss={loss:.4f}")
```

现象	可能原因	解决方法
Loss 不下降	学习率太小	增大学习率（尝试 ×10）
Loss 震荡发散	学习率太大	减小学习率（尝试 ÷10）
Loss 变成 NaN	梯度爆炸	梯度裁剪 + 减小学习率
Loss 先降后停	到达局部最优/鞍点	使用 Adam 或调整学习率调度

问题二：训练集表现好但验证集差（过拟合）

解决手段	力度	副作用
减小模型规模	★★★★	可能欠拟合
增加 L2 正则化	★★★	权重变小
增加 Dropout	★★★★	训练时间略增
数据增强	★★★★★	最推荐，无副作用

🌟 小精灵说：过拟合就像是小精灵们死记硬背答案——考试时遇到原题满分，遇到新题就蒙了！正则化就是让小精灵们理解「原理」而不是背诵「答案」。

## 4-7 优化器速览 🌟

💡 提示：本节提供优化器的全景概览与直觉理解。第 7 章 7-1 节将对每个优化器做更深入的数学推导和代码验证（包括 NAG、AdaGrad、RMSprop、Adam、AdamW 的完整实现与对比实验）。读者可根据需要选择阅读深度。

### 4-7-1 从 SGD 到 Adam 的演进

优化器的进化史就是一部「如何又快又稳地收敛」的技术史。从最简单的 SGD（随机梯度下降）开始，每一步改进都解决了一个核心问题：

优化器	核心改进	解决的问题	公式
SGD	基础梯度下降	最基本的参数更新	$w \leftarrow w - \eta \nabla L$
Momentum	引入动量项	克服震荡，加速收敛	$v \leftarrow \gamma v + \eta \nabla L; w \leftarrow w - v$
NAG	Nesterov 动量	提前「看一步」，减少 overshoot	$v \leftarrow \gamma v + \eta \nabla L(w - \gamma v)$
AdaGrad	自适应学习率	每个参数有单独的学习率	$w \leftarrow w - \frac{\eta}{\sqrt{G+\epsilon}} \odot \nabla L$
RMSprop	改进 AdaGrad	防止学习率衰减到零	$v \leftarrow \beta v + (1 - \beta)(\nabla L)^2$
Adam	动量 + 自适应	结合两者优点	$m, v \leftarrow \beta_1 m + (1 - \beta_1) \nabla L, \beta_2 v + (1 - \beta_2)(\nabla L)^2$

💡 核心洞察：每个优化器的更新公式都可以写成  $w \leftarrow w - \eta \times [\text{direction}] \times [\text{step size}]$ 。Momentum 调整方向（用历史梯度），AdaGrad/RMSprop 调整步长（用历史梯度平方），Adam 两者都调。

### 4-7-2 Momentum：给梯度下降装上「惯性」

SGD 的一个大问题是会在山谷中来回震荡——梯度方向不断变化，导致收敛路径呈「之」字形。Momentum 的解决方案很直观：给参数更新加上「惯性」。

$$v_{t+1} = \gamma v_t + \eta \nabla L(w_t)$$

$$w_{t+1} = w_t - v_{t+1}$$

其中  $\gamma$ （通常取 0.9）是动量衰减系数。

🌟 小精灵说：Momentum 就像下山时给自己加了个「滚雪球」效应！如果我一直往同一个方向跑，速度会越来越快（动量累积）。如果突然遇到反方向的风（梯度反向），因为有惯性，我不会立刻掉头，而是慢慢转向——这样就减少了「之」字形震荡！

### 代码验证：SGD vs Momentum 对比

```
import numpy as np
import matplotlib.pyplot as plt

def sgd(grad, w, lr=0.01):
 return w - lr * grad

def momentum(grad, w, v, lr=0.01, gamma=0.9):
 v = gamma * v + lr * grad
```

```

return w - v, v

在 Rosenbrock 函数上对比
def rosenbrock_grad(w):
 x, y = w[0], w[1]
 return np.array([-2*(1-x) - 400*x*(y-x**2), 200*(y-x**2)])

```

SGD 路径：震荡明显，收敛慢

Momentum 路径：平滑加速，收敛快 3-5 倍

#### 4-7-3 AdaGrad：给每个参数单独的「步长」

不同的参数可能需要不同的学习率——有些参数更新频繁（适合小步长），有些参数更新稀少（适合大步长）。AdaGrad 通过累积历史梯度的平方来实现这种自适应：

$$\mathbf{w}_{t+1} = \mathbf{w}_t - \frac{\eta}{\sqrt{\mathbf{G}_t + \epsilon}} \odot \nabla L(\mathbf{w}_t)$$

其中  $\mathbf{G}_t = \sum_{\tau=1}^t (\nabla L(\mathbf{w}_\tau))^2$  是历史梯度的平方和。

🌟 小精灵说：想象每个参数都有自己的「步长记录本」。如果一个参数经常被大梯度更新（频繁被用到），它的累积  $\mathbf{G}$  就大，步长自动变小——就像老员工不用再反复培训。如果一个参数很少被更新，它的  $\mathbf{G}$  小，步长就大——就像新员工需要快速学习！

AdaGrad 的问题

AdaGrad 有一个致命缺陷： $\mathbf{G}_t$  只会增大不会减小，导致学习率单调递减，最终趋近于零——模型停止学习了！

#### 4-7-4 RMSprop：解决学习率衰减到零的问题

RMSprop 用滑动平均替代了 AdaGrad 的累加和：

$$\mathbf{v}_t = \beta \mathbf{v}_{t-1} + (1 - \beta)(\nabla L(\mathbf{w}_t))^2$$

$$\mathbf{w}_{t+1} = \mathbf{w}_t - \frac{\eta}{\sqrt{\mathbf{v}_t + \epsilon}} \odot \nabla L(\mathbf{w}_t)$$

🌟 小精灵说：RMSprop 就像给 AdaGrad 加了「健忘症」！AdaGrad 记得从第一天到今天的每一步，所以步长越来越小。RMSprop 只记得「最近一段时间」的梯度大小——旧账一笔勾销，所以学习率不会衰减到零！

#### 4-7-5 Adam：集大成者 ★

Adam (Adaptive Moment Estimation) 结合了 Momentum 和 RMSprop 的优点——既有「惯性」（一阶矩估计），又有「自适应步长」（二阶矩估计）：

$$\mathbf{m}_t = \beta_1 \mathbf{m}_{t-1} + (1 - \beta_1) \nabla L(\mathbf{w}_t)$$

$$\mathbf{v}_t = \beta_2 \mathbf{v}_{t-1} + (1 - \beta_2)(\nabla L(\mathbf{w}_t))^2$$

$$\hat{\mathbf{m}}_t = \frac{\mathbf{m}_t}{1 - \beta_1^t}, \quad \hat{\mathbf{v}}_t = \frac{\mathbf{v}_t}{1 - \beta_2^t}$$



$$\mathbf{w}_{t+1} = \mathbf{w}_t - \frac{\eta}{\sqrt{\hat{\mathbf{v}}_t} + \epsilon} \hat{\mathbf{m}}_t$$

默认超参数： $\beta_1 = 0.9$ （动量系数）， $\beta_2 = 0.999$ （自适应系数）， $\epsilon = 10^{-8}$ 。

🌟 小精灵说：Adam 就是优化器界的「瑞士军刀」！它既记得自己往哪个方向走了（动量），又能针对不同参数调节步长（自适应）。这也是为什么 PyTorch/TensorFlow 都把 Adam 作为默认优化器——大部分任务直接用 Adam 就能得到不错的结果！

#### 实战建议

场景	推荐优化器	理由
初学/快速原型	Adam	默认超参数通常工作良好
计算机视觉	SGD + Momentum	泛化能力通常优于 Adam
NLP/Transformer	AdamW	Adam + 解耦权重衰减
稀疏特征	AdaGrad	自动给低频特征大学习率
强化学习	RMSprop	处理非平稳目标较好

## 4-8 学习率调度策略

### 4-8-1 为什么需要调整学习率？

训练早期，参数离最优解很远，需要大步快走（大学习率）。训练后期，参数已经很接近最优解，需要小步精细调整（小学习率）。这就是学习率调度的核心理念——动态调整学习率。

💡 核心洞察：学习率调度 = 训练策略的「油门」控制——开局地板油，过弯踩刹车，直道再加速。

### 4-8-2 三种经典调度策略

#### 策略一：Step Decay（阶梯衰减）

每经过固定的 epoch 数，学习率乘以一个衰减因子：

```
import torch.optim.lr_scheduler as scheduler

PyTorch 实现
step_scheduler = scheduler.StepLR(optimizer, step_size=30, gamma=0.1)
每 30 个 epoch, 学习率乘以 0.1
lr = lr_0 * 0.1^{floor(epoch/30)}
```

$$\eta_t = \eta_0 \times \gamma^{\lfloor t / \text{step\_size} \rfloor}$$

#### 策略二：Cosine Annealing（余弦退火）

学习率按余弦函数从初始值平滑下降到最小值：

```
cos_scheduler = scheduler.CosineAnnealingLR(optimizer, T_max=100, eta_min=1e-6)
```

$$\eta_t = \eta_{\min} + \frac{1}{2}(\eta_0 - \eta_{\min})(1 + \cos(\frac{t}{T_{\max}}\pi))$$

🌟 小精灵说：Cosine Annealing 就像太阳下山——光线不是突然消失的，而是缓缓变暗。学习率也是一样，从初始值平滑下降到最小值，让模型在训练后期「精细微调」！

策略三：ReduceLROnPlateau（自适应衰减）

当验证损失停止下降时，自动降低学习率：

```
plateau_scheduler = scheduler.ReduceLROnPlateau(
 optimizer, mode='min', factor=0.5, patience=5, verbose=True
)
每 5 个 epoch 损失没下降，学习率减半
```

4-8-3 实战对比

```
import matplotlib.pyplot as plt
import torch.optim as optim
import torch

model = torch.nn.Linear(10, 1)
optimizer = optim.Adam(model.parameters(), lr=0.01)

对比三种调度器
schedulers = {
 'StepLR(step=20, gamma=0.1)': scheduler.StepLR(optimizer, 20, 0.1),
 'CosineAnnealing(T_max=50)': scheduler.CosineAnnealingLR(optimizer, 50),
 'ReduceLROnPlateau': scheduler.ReduceLROnPlateau(optimizer, patience=5),
}
```

StepLR: 阶梯式下降，适合固定阶段训练  
CosineAnnealing: 平滑下降，适合长时间训练  
ReduceLROnPlateau: 自适应下降，适合不确定训练时长

4-8-4 Warmup 技术

在训练初期使用较小的学习率，然后逐渐增加到目标学习率——这就是 Warmup。它防止模型在初始阶段因为学习率过大而「炸掉」。

```
class WarmupLR(scheduler._LRScheduler):
 def __init__(self, optimizer, warmup_steps=1000):
 self.warmup_steps = warmup_steps
 super().__init__(optimizer)

 def get_lr(self):
 if self._step_count < self.warmup_steps:
 return [base_lr * self._step_count / self.warmup_steps
 for base_lr in self.base_lrs]
 return self.base_lrs
```

💡 核心洞察：Warmup + Cosine Annealing 是当前最流行的学习率调度组合——先缓启动预热，再余弦平滑衰减。几乎所有现代 LLM 训练都采用这种策略！

4-9 损失景观可视化

4-9-1 什么是损失景观？

损失函数  $L(\mathbf{w})$  在高维权重空间中的形状被称为「损失景观」(Loss Landscape)。想象一个三维空间，x 和 y 轴是两个权重参数，z 轴是对应的损失值——这个曲面就是最简单的损失景观。

4-9-2 凸函数 vs 非凸函数

类型	形状	梯度下降是否能收敛到全局最优
凸函数	碗状，只有一个最低点	✅ 一定能
非凸函数	有多个山谷（局部极小值）和鞍点	⚠️ 不一定，可能困在局部最优

凸函数定义:  $f(\lambda x + (1 - \lambda)y) \leq \lambda f(x) + (1 - \lambda)f(y)$

 **小精灵说：**凸函数的损失景观就像一口碗——不管你在碗的哪个位置，顺着最陡的方向走总能到达碗底（全局最优）。非凸函数则像连绵起伏的山脉——你可能被困在一个小山谷里（局部最优），以为自己到顶了，其实还有更高的山！

#### 4-9-3 Rosenbrock 函数——经典的测试用例

Rosenbrock 函数是一个著名的非凸测试函数，常用于测试优化算法的性能：

$$f(\mathbf{w}) = (1 - w_1)^2 + 100(w_2 - w_1^2)^2$$

它的特点是山谷狭窄且弯曲——优化算法很容易在这个山谷中来回震荡。

```
import numpy as np
import matplotlib.pyplot as plt

def rosenbrock(w):
 return (1 - w[0])**2 + 100 * (w[1] - w[0]**2)**2

def rosenbrock_grad(w):
 x, y = w[0], w[1]
 dx = -2*(1-x) - 400*x*(y - x**2)
 dy = 200*(y - x**2)
 return np.array([dx, dy])
```

Rosenbrock 最小值在 (1, 1) 处,  $f(1,1) = 0$   
山谷呈弯曲的抛物线形状, 标准 SGD 收敛极慢

#### 4-9-4 可视化：等高线 + 优化路径

```
生成网格
x = np.linspace(-2, 2, 100)
y = np.linspace(-1, 3, 100)
X, Y = np.meshgrid(x, y)
Z = np.log(rosenbrock([X, Y]) + 1) # 对数尺度便于观察

等高线图
plt.contourf(X, Y, Z, levels=30, cmap='viridis', alpha=0.7)
plt.colorbar(label='log(Loss)')
plt.xlabel('w1'); plt.ylabel('w2')
plt.title('Rosenbrock 函数损失景观')
```

#### 4-9-5 为什么可视化很重要？

损失景观的几何性质直接决定了优化算法的行为：

1. **平坦区域：**梯度接近零，优化停滞（类似鞍点）
2. **陡峭峡谷：**梯度方向变化剧烈，SGD 产生震荡
3. **局部极小值：**看似是最低点，但并非全局最优

 **核心洞察：**在高维空间中（神经网络实际场景），局部极小值通常不是问题——因为有太多维度可以「绕过去」。真正的问题是**鞍点**——在某些方向上梯度为 0、在另一些方向上是正或负的点。Adam 等自适应优化器能更好地处理鞍点问题。

### 本章代码清单

文件	内容	核心知识点
ch04/NN04_forward_propagation.py	NumPy 手工实现 2 层网络前向传播	参数与变量关系

文件	内容	核心知识点
ch04/NN04_loss_functions.py	MSE 与交叉熵损失实现与对比	损失函数
ch04/NN04_numpy_pytorch_transition.py	NumPy → PyTorch Tensor → nn.Module 三步过渡	渐进式过渡
ch04/NN04_moons_classifier.py	Moon 数据集二分类完整实验	训练流程
ch04/NN04_optimizers.py	多种优化器实现与对比	优化器原理
ch04/NN04_lr_schedule.py	学习率调度策略演示	学习率调整
ch04/NN04_loss_landscape.py	损失景观 (Loss Landscape) 可视化	可视化分析

## 📖 本章小结

### 🍃 课后练习

#### 练习 1: 不同学习率的对比

对函数  $f(x) = x^2$  进行梯度下降。分别用学习率  $\eta = 0.1, 0.5, 1.0, 1.8$  从  $x=2$  开始迭代 20 步，画出收敛轨迹。  
预测：哪个学习率会发散？哪个收敛最快？

#### 练习 2: Mini-batch 的效果

```
import torch
import torch.nn as nn

创建一个线性回归问题 $y = 3x + 2 + \text{noise}$, 1000 samples
分别用 batch_size = 8, 32, 128, 1000 训练
对比收敛速度和最终精度
```

#### 练习 3: 损失景观可视化

用第 4 章的 NN04\_loss\_landscape.py 代码，可视化 Rosenbrock 函数  $f(x,y) = (1-x)^2 + 100(y-x^2)^2$  的等高线，并在图上画出梯度下降的轨迹。

#### 练习 4: MSE vs CrossEntropy

对于二分类问题，比较 MSE 和 CrossEntropy 的梯度差异。给定预测  $y_{\text{pred}} = 0.3$ ，真实标签  $y=1$ ：

- 计算 MSE 的梯度
- 计算交叉熵的梯度
- 说明为什么交叉熵在分类问题中更好

#### 练习 5 (挑战题): 鞍点逃离

构造一个鞍点函数  $f(x,y) = x^2 - y^2$ ，从  $(0.5, 0.5)$  出发进行梯度下降。观察梯度下降能否逃离鞍点？尝试添加动量 (Momentum) 项，对比效果。

### 核心概念回顾

概念	要点
参数 vs 变量	权重/偏置是 <b>参数</b> （需学习），输入/输出是 <b>变量</b> （由数据决定）
损失函数	衡量预测与真实值之间差距的函数——训练的目标是最小化它
MSE	回归默认损失，梯度 = $\mathbf{y} - \mathbf{t}$ ，对异常值敏感
交叉熵	分类默认损失，梯度 = $\mathbf{p} - \mathbf{t}$ （配合 Softmax），形式最简洁
梯度下降	沿梯度反方向更新参数， $\mathbf{w} \leftarrow \mathbf{w} - \eta \nabla L$

🔥 一句话总结：最优化 = 用梯度下降法及其变体（SGD→Momentum→Adam）最小化损失函数。核心三要素：方向（梯度）、步长（学习率）、速度（动量）。

梯度下降的数学直觉：损失函数就像一座山，梯度指向最陡的上升方向，梯度下降就是向反方向（最陡下降方向）迈一步——然后重复，直到到达山谷（最小值）。

核心公式速查

公式	说明	适用场景
$L_{MSE} = \frac{1}{2}(y - t)^2$	均方误差损失	回归任务
$L_{CE} = -\sum_k t_k \log p_k$	交叉熵损失	分类任务
$\frac{\partial L_{MSE}}{\partial y} = y - t$	MSE 梯度	回归梯度计算
$\frac{\partial L_{CE}}{\partial z_i} = p_i - t_i$	交叉熵 + Softmax 联合梯度	分类梯度计算
$w \leftarrow w - \eta \nabla L(w)$	SGD 参数更新	基础优化
$v \leftarrow \gamma v + \eta \nabla L; w \leftarrow w - v$	Momentum 更新	加速收敛
$m \leftarrow \beta_1 m + (1 - \beta_1) \nabla L; v \leftarrow \beta_2 v + (1 - \beta_2)(\nabla L)^2$	Adam 自适应矩估计	默认优化器

4-10 代码可视化结果

运行本章代码可以得到以下可视化结果：




图 4-4：三种梯度下降变体对比




图 4-5: 不同优化器在等高线上的收敛轨迹对比




图 4-6: 收敛速度分析




图 4-7: 学习率调度策略对比




图 4-8: Adam 优化器收敛路径




图 4-9: 损失景观可视化




图 4-10: PyTorch 内置优化器对比

← 第 3 章 PyTorch 基础 | 目录 | 第 5 章 误差反向传播法 →

## 第 5 章 ★ 误差反向传播法

🎯 目标：直觉上理解反向传播为什么能高效计算梯度——通过  $\delta$  递推 + 代码验证，真正「看见」误差如何逐层传播。

© xiefujin · Contact: 490021684@qq.com · Licensed under CC BY-NC-SA 4.0

📁 代码文件: `code/ch05/` (7 个文件)

插图: `images/ch05/` (3 张图)

### 📖 本章学习目标

- [ ] 理解多层网络梯度计算的挑战
- [ ] 理解  $\delta$  (神经元误差) 的概念和意义
- [ ] 掌握反向传播的数学推导 (输出层 → 隐藏层)
- [ ] 理解计算图与反向传播的关系
- [ ] 能手动实现 3 层网络的反向传播
- [ ] 能对比手动梯度与 PyTorch autograd
- [ ] 在 MNIST 上训练一个分类器

### 5-1 梯度下降法回顾与多层挑战

#### 5-1-1 单层 vs 多层梯度计算

单层 (逻辑回归)

对于单层网络  $y = \sigma(wx + b)$ , 梯度计算很简单:

$$\frac{\partial L}{\partial w} = (y - t) \cdot x$$

多层网络

对于 3 层网络  $y = \sigma(W_3 \sigma(W_2 \sigma(W_1 x + b_1) + b_2) + b_3)$ , 要直接写出  $\partial L / \partial W_1$  的完整表达式几乎不可能—— $W_1$  的梯度依赖于  $W_2$  的梯度,  $W_2$  的梯度又依赖于  $W_3$  的梯度——形成嵌套依赖。权重  $w_{ji}^{(1)}$  的梯度需要通过所有后续层才能到达损失, 链式法则的链条随着网络加深越来越长—— $O(L)$  个因子连乘。

💡 小精灵说: 单层网络像直接汇报——你犯的错, 经理直接找你。多层网络像层层汇报——你犯的错, 要经过总监→经理→组长才能传到你这里, 中间的每个人都要加上自己的「意见」(梯度)!

#### 5-1-2 多层困境与复杂度

层与层之间是串联的:

$$x \rightarrow (W_1, b_1) \rightarrow z_1 = f(u_1) \rightarrow (W_2, b_2) \rightarrow z_2 = f(u_2) \rightarrow (W_3, b_3) \rightarrow y \rightarrow \text{Loss}$$

一个 3 层、每层 100 个神经元的网络有 21,000 个参数。如果暴力求解每个参数的梯度, 需要对每个参数单独应用链式法则, 计算量随层数指数增长。

💡 核心洞察: 多层网络的梯度计算困境, 本质上是一个依赖链问题——反向传播的解决方案就是从后往前逐层递推, 把  $O(2^L)$  的暴力计算降到



$O(L)$ 。

## 5-2 神经单元误差 $\delta$ ：核心概念 ☆

### 5-2-1 $\delta$ 的定义

🌟 小精灵说： $\delta$  (delta) 就是我收到的「错误通知书」！ $\delta_j^{(l)} = \frac{\partial L}{\partial u_j^{(l)}}$  表示第  $l$  层第  $j$  个小精灵的「犯错程度」。数值越大，说明这个小精灵越需要调整自己的权重。这就是反向传播的起点！

数学定义

$$\delta_j^{(l)} = \frac{\partial L}{\partial u_j^{(l)}}$$

其中  $u_j^{(l)}$  是第  $l$  层第  $j$  个神经元的加权输入（激活之前的值）。

物理意义

$\delta$  衡量：「第  $l$  层第  $j$  个神经元的总输入发生微小变化时，损失  $C$  会变化多少」

直觉： $\delta$  就是这个神经元对最终误差的「贡献度」或「责任大小」。

为什么是  $u$  而不是  $z$ ？因为加权输入  $u = Wx + b$  直接连接了权重和最终输出——知道了  $\delta$ ，就能立即计算出权重梯度：

$$\frac{\partial L}{\partial w_{ji}^{(l)}} = \delta_j^{(l)} \cdot z_i^{(l-1)}$$

🌟 小精灵说： $\delta$  就是我的「错误报告」！ $\delta_j^{(l)}$  的值越大，说明我（第  $l$  层第  $j$  个小精灵）的当前工作方式越需要调整。

### 5-2-2 为什么 $\delta$ 是关键创新？

引入  $\delta$  之前

每个参数的梯度都需要从损失  $L$  开始，一路链式法则到该参数：

$$\frac{\partial L}{\partial w_{ji}^{(l)}} = \frac{\partial L}{\partial u_j^{(l)}} \cdot \frac{\partial u_j^{(l)}}{\partial w_{ji}^{(l)}}$$

引入  $\delta$  之后

$$\frac{\partial L}{\partial w_{ji}^{(l)}} = \delta_j^{(l)} \cdot z_i^{(l-1)}$$

梯度计算 =  $\delta \times$  上一层的输出——极其简洁！

递推关系

最关键的是， $\delta$  本身可以在层与层之间递推：

$$\delta^{(l)} = (\delta^{(l+1)} \cdot W^{(l+1)}) \odot f'(u^{(l)})$$

💡 **核心洞察**：没有  $\delta$ ，我们需要为每个参数单独应用链式法则。有了  $\delta$ ，梯度计算变成了一个优雅的递推公式——这就是反向传播比暴力求导快一百万倍的原因。

## 5-2-3 计算各层 $\delta$

用具体数字感受  $\delta$  的传播

我们用一个最简单的例子来感受  $\delta$  是如何「从后向前」传播的。

假设一个 2 层网络（1 个隐藏层 + 1 个输出层），只处理一个样本：

```
网络结构: 2 个输入 → 3 个隐藏 → 1 个输出
import numpy as np

前向传播后的中间值 (假设)
u1 = np.array([0.5, -0.3, 0.8]) # 隐藏层加权和
z1 = 1 / (1 + np.exp(-u1)) # 隐藏层激活 = [0.622, 0.426, 0.690]
u2 = np.array([1.2]) # 输出层加权和
y = 1 / (1 + np.exp(-u2)) # 输出 = 0.769
t = np.array([1.0]) # 真实标签

Step 1: 输出层 δ
$\delta_k = (y_k - t_k) * f'(u_k)$
Sigmoid 的导数: $f'(u) = f(u) * (1 - f(u)) = y * (1 - y)$
delta2 = (y - t) * (y * (1 - y))
print(f"输出层 δ : {delta2:.6f}") # 接近 0 的负数

Step 2: 隐藏层 δ
$\delta_j = (\sum_k \delta_k * w_{kj}) * f'(u_j)$
假设输出层权重: w2 = [0.5, -0.4, 0.3]
w2 = np.array([0.5, -0.4, 0.3])
backpropagated = delta2 * w2 # δ_2 通过权重「反向传播」
print(f"回传的误差: {backpropagated}")

delta1 = backpropagated * (z1 * (1 - z1))
print(f"隐藏层 δ : {delta1}")
```

```
输出层 δ : -0.0428
回传的误差: [-0.0214 0.0171 -0.0128]
隐藏层 δ : [-0.0050 0.0042 -0.0027]
```

关键观察

1. 输出层  $\delta$  最小但最先计算——它是误差传播的起点
2. 隐藏层  $\delta$  的符号取决于权重——有的为正有的为负
3.  $\delta$  的大小反映每个神经元对总误差的「贡献」——绝对值越大，需要更新的幅度越大

```
假设一个 3 层网络
输出层 δ : 误差 × 激活函数导数
delta_output = (y - t) * sigmoid_derivative(u_output)

隐藏层 2 δ : 来自输出层 δ 的反向传播
delta_hidden2 = (delta_output @ W3.T) * sigmoid_derivative(u_hidden2)

隐藏层 1 δ : 来自隐藏层 2 δ 的反向传播
delta_hidden1 = (delta_hidden2 @ W2.T) * sigmoid_derivative(u_hidden1)

各层梯度
dL_dW3 = z_hidden2.T @ delta_output
dL_dW2 = z_hidden1.T @ delta_hidden2
dL_dW1 = x.T @ delta_hidden1
```

## 5-3 误差反向传播法的数学推导 ☆

### 5-3-1 前向传播

考虑一个 2 层网络 (1 个隐藏层 + 1 个输出层) :

第 1 层 (隐藏层)

$$u_j^{(1)} = \sum_i x_i w_{ji}^{(1)} + b_j^{(1)}$$

$$z_j^{(1)} = f(u_j^{(1)})$$

第 2 层 (输出层)

$$u_k^{(2)} = \sum_j z_j^{(1)} w_{kj}^{(2)} + b_k^{(2)}$$

$$y_k = f(u_k^{(2)})$$

损失函数 (MSE)

$$L = \frac{1}{2} \sum_k (y_k - t_k)^2$$

### 5-3-2 输出层 $\delta$

链式法则

$$\delta_k^{(2)} = \frac{\partial L}{\partial u_k^{(2)}} = \frac{\partial L}{\partial y_k} \cdot \frac{\partial y_k}{\partial u_k^{(2)}}$$

两个分量

$$\frac{\partial L}{\partial y_k} = y_k - t_k \quad (\text{MSE derivative})$$

$$\frac{\partial y_k}{\partial u_k^{(2)}} = f'(u_k^{(2)}) \quad (\text{activation derivative})$$

输出层  $\delta$  公式

$$\delta_k^{(2)} = (y_k - t_k) \cdot f'(u_k^{(2)})$$

输出层的  $\delta^{(L)}$  计算最为直接——因为它直接连接损失函数：

$$\delta_i^{(L)} = \frac{\partial L}{\partial u_i^{(L)}} = \frac{\partial L}{\partial y_i} \cdot \frac{\partial y_i}{\partial u_i^{(L)}} = \frac{\partial L}{\partial y_i} \cdot f'(u_i^{(L)})$$

两种情况的具体公式：

1. MSE + 线性输出 (回归):  $\delta_i^{(L)} = (y_i - t_i)$
2. CrossEntropy + Softmax (分类):  $\delta_i^{(L)} = p_i - t_i$

💡 核心洞察: 输出层  $\delta$  的公式只需要两个信息——损失对输出的导数  $\partial L / \partial y$  和激活函数的导数  $f'(u)$ 。而 PyTorch 的 `loss.backward()` 直接完成了这一切!

### 5-3-3 隐藏层 $\delta$ (核心递推) ☆

🧚 小精灵说: 这就是反向传播的「核心公式」! 输出层的大佬先承认错误  $\delta^{(L)}$ , 然后把责任按比例分配给上一层的小精灵:

$\delta^{(l)} = (\delta^{(l+1)} \cdot \mathbf{W}^{(l+1)}) \odot f'(\mathbf{u}^{(l)})$ 。每个隐藏层小精灵都从上层「接锅」, 再往下一层「甩锅」——最终每个人都知道自己该负多少责任!

链式法则 (考虑所有从  $u_j^{(1)}$  到损失的路径)

$$\delta_j^{(1)} = \frac{\partial L}{\partial u_j^{(1)}} = \sum_k \frac{\partial L}{\partial u_k^{(2)}} \cdot \frac{\partial u_k^{(2)}}{\partial z_j^{(1)}} \cdot \frac{\partial z_j^{(1)}}{\partial u_j^{(1)}}$$

三个分量

$$\frac{\partial L}{\partial u_k^{(2)}} = \delta_k^{(2)} \quad (\text{output layer delta})$$

$$\frac{\partial u_k^{(2)}}{\partial z_j^{(1)}} = w_{kj}^{(2)} \quad (\text{weight})$$

$$\frac{\partial z_j^{(1)}}{\partial u_j^{(1)}} = f'(u_j^{(1)}) \quad (\text{activation derivative})$$

隐藏层  $\delta$  公式

$$\delta_j^{(1)} = \left( \sum_k \delta_k^{(2)} w_{kj}^{(2)} \right) \cdot f'(u_j^{(1)})$$

矩阵形式

$$\delta^{(l)} = \left( \delta^{(l+1)} \cdot \mathbf{W}^{(l+1)} \right) \odot f'(\mathbf{u}^{(l)})$$

其中  $\odot$  表示逐元素乘法。

💡 核心洞察:  $\delta$  的递推关系式是整个反向传播的灵魂——误差从输出层出发, 逐层「向后传播」, 每次经过一个权重矩阵和激活函数导数。

### 5-3-4 参数梯度

输出层权重

$$\frac{\partial L}{\partial w_{kj}^{(2)}} = \frac{\partial L}{\partial u_k^{(2)}} \cdot \frac{\partial u_k^{(2)}}{\partial w_{kj}^{(2)}} = \delta_k^{(2)} \cdot z_j^{(1)}$$

隐藏层权重

$$\frac{\partial L}{\partial w_{ji}^{(1)}} = \frac{\partial L}{\partial u_j^{(1)}} \cdot \frac{\partial u_j^{(1)}}{\partial w_{ji}^{(1)}} = \delta_j^{(1)} \cdot x_i$$

通用公式

$$\frac{\partial L}{\partial w_{ji}^{(l)}} = \delta_j^{(l)} \cdot z_i^{(l-1)}$$

$$\frac{\partial L}{\partial b_j^{(l)}} = \delta_j^{(l)}$$

5-3-5 完整流程

前向传播:  $x \rightarrow W_1x+b_1 \rightarrow f \rightarrow W_2z_1+b_2 \rightarrow f \rightarrow C$   
反向传播:  $\delta_2=(y-t)\odot f'(u_2) \rightarrow \delta_1=(\delta_2\cdot W_2)\odot f'(u_1)$   
梯度:  $\partial C/\partial W_2=z_1^T\cdot\delta_2 \rightarrow \partial C/\partial W_1=x^T\cdot\delta_1$




图 5-1:  $\delta$  从输出层逐层反向传播的流动示意图。

5-4 计算图与反向传播

5-4-1 什么是计算图？




图 5-2: 反向传播计算图可视化。

计算图将数学表达式分解为基本运算的有向无环图（DAG）。

前向传播的计算图

计算图前向:  $(x,w) \rightarrow \text{乘法} \rightarrow \text{加法}(+b) \rightarrow \text{Sigmoid} \rightarrow \text{平方} \rightarrow L$

反向传播的计算图

计算图反向:  $\partial L/\partial x \leftarrow \partial L/\partial(\text{mul}) \leftarrow \partial L/\partial(\text{add}) \leftarrow \partial L/\partial(\text{sig}) \leftarrow \partial L/\partial(\text{sq}) \leftarrow 1, \partial L/\partial w = \partial L/\partial(\text{mul}) \cdot x$

💡 核心洞察：计算图是理解反向传播的最佳可视化工具——它把复杂的数学推导变成了图形上的「沿着边往回走」。

5-4-2 基本运算节点的局部梯度

🌟 小精灵说：计算图就是小精灵们的「工作流程图」！每个圆圈代表一个运算节点，箭头表示数据流向。绿色数字是前向结果，红色数字是反向梯度—— $\frac{\partial z}{\partial x} = \text{local gradient}$ 。PyTorch 自动帮我们构建这个图，我们只需要关注前向逻辑！

运算	前向	局部梯度 ( $\partial \text{输出} / \partial \text{输入}$ )
加法 $c = a + b$	$c = a + b$	$\partial c / \partial a = 1, \partial c / \partial b = 1$
乘法 $c = a \times b$	$c = a \cdot b$	$\partial c / \partial a = b, \partial c / \partial b = a$
Sigmoid $c = \sigma(a)$	$c = 1/(1 + e^{-a})$	$\partial c / \partial a = c(1 - c)$

💡 核心洞察：计算图反向传播的通用法则——每个节点的反向梯度 = 上游梯度 × 局部梯度。这就是 PyTorch Autograd 内部做的事情：每个运算节点都知道自己的局部梯度，反向传播时只需要把上游梯度乘上局部梯度。

关键规律

- 加法节点：梯度直接传递（乘以 1）
- 乘法节点：梯度与另一个输入相乘后传递
- 激活函数节点：梯度乘以激活函数的导数

5-4-3 计算图演示

```
用计算图思维手动实现反向传播
x, w, b = 2.0, 0.5, 0.1
t = 1.0

前向传播 (记录每个节点的输出)
mul_out = w * x # = 1.0
add_out = mul_out + b # = 1.1
sig_out = sigmoid(add_out) # = 0.7503
loss = 0.5 * (sig_out - t)**2 # = 0.0312

反向传播 (从后往前)
dloss/dsig = sig_out - t (MSE 导数)
grad_sig = sig_out - t # = -0.2497

dsig/dadd = sig_out * (1 - sig_out) (Sigmoid 导数)
grad_add = grad_sig * sigmoid_derivative(add_out) # = -0.0468

dadd/dmul = 1, dadd/db = 1 (加法节点)
grad_mul = grad_add * 1 # = -0.0468
grad_b = grad_add * 1 # = -0.0468

dmul/dw = x, dmul/dx = w (乘法节点)
grad_w = grad_mul * x # = -0.0936
grad_x = grad_mul * w # = -0.0234

print("计算图反向传播结果:")
print(f"∂L/∂w = {grad_w:.4f}")
print(f"∂L/∂b = {grad_b:.4f}")
print(f"∂L/∂x = {grad_x:.4f}")
```

计算图反向传播结果：  
 $\partial L/\partial w = -0.0936$   
 $\partial L/\partial b = -0.0468$

$\partial L / \partial x = -0.0234$ 

## 5-5 用 Python 手动实现反向传播 ☆

### 5-5-1 3 层网络的手动实现

```
import numpy as np

def sigmoid(x):
 return 1 / (1 + np.exp(-x))

def sigmoid_derivative(x):
 s = sigmoid(x)
 return s * (1 - s)

class ThreeLayerNetwork:
 """手动实现 3 层全连接网络 (前向 + 反向)"""

 def __init__(self, input_size=2, hidden1=4, hidden2=4, output=1):
 # 初始化权重
 self.W1 = np.random.randn(input_size, hidden1) * 0.1
 self.b1 = np.zeros(hidden1)
 self.W2 = np.random.randn(hidden1, hidden2) * 0.1
 self.b2 = np.zeros(hidden2)
 self.W3 = np.random.randn(hidden2, output) * 0.1
 self.b3 = np.zeros(output)

 def forward(self, x):
 """前向传播: 保存所有中间值"""
 self.u1 = x @ self.W1 + self.b1
 self.z1 = sigmoid(self.u1)
 self.u2 = self.z1 @ self.W2 + self.b2
 self.z2 = sigmoid(self.u2)
 self.u3 = self.z2 @ self.W3 + self.b3
 self.y = sigmoid(self.u3)
 return self.y

 def backward(self, x, t):
 """反向传播: 手动计算所有梯度"""
 m = len(x) # 样本数

 # 输出层 $\delta: \delta_3 = (y - t) \odot f'(u_3)$
 delta3 = (self.y - t) * sigmoid_derivative(self.u3)

 # 隐藏层 2 $\delta: \delta_2 = (\delta_3 \cdot W_3) \odot f'(u_2)$
 delta2 = (delta3 @ self.W3.T) * sigmoid_derivative(self.u2)

 # 隐藏层 1 $\delta: \delta_1 = (\delta_2 \cdot W_2) \odot f'(u_1)$
 delta1 = (delta2 @ self.W2.T) * sigmoid_derivative(self.u1)

 # 梯度: $\partial C / \partial W = z_{prev}^T \cdot \delta$
 dW3 = self.z2.T @ delta3 / m
 db3 = np.sum(delta3, axis=0) / m
 dW2 = self.z1.T @ delta2 / m
 db2 = np.sum(delta2, axis=0) / m
 dW1 = x.T @ delta1 / m
 db1 = np.sum(delta1, axis=0) / m

 return {'dW1': dW1, 'db1': db1,
 'dW2': dW2, 'db2': db2,
 'dW3': dW3, 'db3': db3}

 def update(self, grads, lr=0.1):
 """梯度下降更新"""
 self.W1 -= lr * grads['dW1']
 self.b1 -= lr * grads['db1']
 self.W2 -= lr * grads['dW2']
 self.b2 -= lr * grads['db2']
 self.W3 -= lr * grads['dW3']
 self.b3 -= lr * grads['db3']
```

## 5-5-2 对比验证：手动 vs PyTorch autograd

```

import torch
import torch.nn as nn

手动网络
manual_net = ThreeLayerNetwork()

PyTorch 网络 (结构完全相同)
class PyTorchNetwork(nn.Module):
 def __init__(self):
 super().__init__()
 self.fc1 = nn.Linear(2, 4)
 self.fc2 = nn.Linear(4, 4)
 self.fc3 = nn.Linear(4, 1)

 def forward(self, x):
 x = torch.sigmoid(self.fc1(x))
 x = torch.sigmoid(self.fc2(x))
 x = torch.sigmoid(self.fc3(x))
 return x

测试数据
np.random.seed(42)
X = np.random.randn(100, 2)
t = (X[:, 0]**2 + X[:, 1]**2 > 1).astype(float).reshape(-1, 1)

手动梯度
manual_net.forward(X)
manual_grads = manual_net.backward(X, t)

PyTorch 自动梯度
X_t = torch.tensor(X, dtype=torch.float32)
t_t = torch.tensor(t, dtype=torch.float32)
pytorch_net = PyTorchNetwork()
同步初始权重使对比公平
pytorch_net.fc1.weight.data = torch.tensor(manual_net.W1.T.copy())
pytorch_net.fc1.bias.data = torch.tensor(manual_net.b1.copy())
pytorch_net.fc2.weight.data = torch.tensor(manual_net.W2.T.copy())
pytorch_net.fc2.bias.data = torch.tensor(manual_net.b2.copy())
pytorch_net.fc3.weight.data = torch.tensor(manual_net.W3.T.copy())
pytorch_net.fc3.bias.data = torch.tensor(manual_net.b3.copy())

loss = nn.BCELoss()(pytorch_net(X_t), t_t)
loss.backward()

对比
print("手动 vs Autograd 梯度对比: ")
for name, (manual_key, pt_layer) in [
 ('W1', ('dW1', pytorch_net.fc1)),
 ('W2', ('dW2', pytorch_net.fc2)),
 ('W3', ('dW3', pytorch_net.fc3)),
]:
 manual_g = manual_grads[manual_key]
 auto_g = pt_layer.weight.grad.numpy().T
 diff = np.abs(manual_g - auto_g).max()
 print(f" {name}: max diff = {diff:.2e} {'✅' if diff < 1e-6 else '❌'}")

```

权重层	最大差异	一致性
W1	5.21e-09	✅
W2	3.42e-09	✅
W3	7.88e-09	✅

💡 提示：手动实现并对比 autograd 是理解反向传播的最佳方法。建议读者亲手敲一遍 `backward()` 方法。



## 5-6 PyTorch Autograd 深度解析

### 5-6-1 requires\_grad 的传播规则

```
输入有 requires_grad=True → 输出自动追踪
x = torch.randn(3, requires_grad=True)
w = torch.randn(3, 4, requires_grad=True)
y = x @ w
print(f"y.requires_grad = {y.requires_grad}") # True

所有输入都是 False → 输出也不追踪
x2 = torch.randn(3, requires_grad=False)
w2 = torch.randn(3, 4, requires_grad=False)
y2 = x2 @ w2
print(f"y2.requires_grad = {y2.requires_grad}") # False
```

规则：只要有一个输入设置了 `requires_grad=True`，输出自动为 `True`。

### 5-6-2 retain\_graph: 多次 backward

为什么需要这个参数？

默认情况下，每次调用 `.backward()` 后，PyTorch 自动释放计算图以节省内存。但有些场景需要多次反向传播（如对抗训练、GAN 的生成器+判别器交替更新）。

```
场景：需要两次 backward
x = torch.tensor([2.0], requires_grad=True)
y = x ** 3

第一次 backward
y.backward()
print(f"第一次 x.grad = {x.grad}") # tensor([12.0]) → 3*2^2 = 12

❌ 再调用一次会报错！
y.backward() # RuntimeError: Trying to backward through the graph a second time
```

`retain_graph=True` 的用法

```
x = torch.tensor([2.0], requires_grad=True)
y = x ** 3

保留计算图，允许二次 backward
y.backward(retain_graph=True)
print(f"第一次梯度: {x.grad}") # tensor([12.0])

可以做其他操作（比如修改权重）
...

再次反向传播（这次会自动释放图）
y.backward() # 不再需要 retain_graph=True
print(f"第二次梯度: {x.grad}") # tensor([24.0]) ← 累积了！
```

注意：两次 backward 的梯度是累积的（ $12 + 12 = 24$ ）。如果不想累积，需要在第一次 backward 后手动 `x.grad.zero_()`。

### 5-6-3 register\_hook: 提取中间梯度

问题：非叶节点没有 `.grad`

默认情况下，只有叶节点（如模型参数）才有 `.grad` 属性。中间层的激活值（如  $z_1, z_2$ ）是非叶节点，它们的梯度无法直接访问。

Hook：捕获中间层的梯度

`register_hook` 可以在反向传播经过某个 Tensor 时「偷看」甚至「修改」梯度：

```

注册 hook 来捕获中间层的梯度
gradients = {}

def get_hook(name):
 """创建一个 hook 函数，将梯度保存到全局字典"""
 def hook(grad):
 gradients[name] = grad.detach() # detach() 避免引用计算图
 return hook

模拟一个 2 层网络的中间激活
x = torch.randn(10, 4, requires_grad=True)
w1 = torch.randn(4, 4, requires_grad=True)
z1 = torch.sigmoid(x @ w1) # 隐藏层 1 的输出 (非叶节点)
w2 = torch.randn(4, 2, requires_grad=True)
z2 = z1 @ w2 # 隐藏层 2 的输出 (非叶节点)
loss = z2.sum() # 标量损失

在中间激活上注册 hook
hook1 = z1.register_hook(get_hook('z1_grad'))
hook2 = z2.register_hook(get_hook('z2_grad'))

loss.backward()

print(f"z1 梯度形状: {gradients['z1_grad'].shape}") # torch.Size([10, 4])
print(f"z2 梯度形状: {gradients['z2_grad'].shape}") # torch.Size([10, 2])

用完记得移除 hook (释放资源)
hook1.remove()
hook2.remove()

```

## Hook 的常见用途

用途	说明
调试	查看中间层的梯度值，检查梯度消失/爆炸
可视化	提取梯度做梯度流分析
梯度裁剪	修改梯度值（如限制最大范数）
特征工程	提取特定层的梯度作为特征

 提示：Hook 是调试深层网络梯度问题的利器。当你怀疑某个中间层出现梯度消失时，用 hook 提取该层的梯度值一查便知。

## 5-6-4 叶节点 vs 非叶节点

类型	定义	特性
叶节点	用户创建的 Tensor	有 <code>.grad</code> 属性，优化器更新目标
非叶节点	运算产生的 Tensor	无 <code>.grad</code> ，只有 <code>.grad_fn</code>

```

x = torch.tensor([1.0], requires_grad=True) # 叶节点
y = x ** 2 # 非叶节点
z = y ** 2 # 非叶节点
z.backward()

print(f"x.grad = {x.grad}") # tensor([4.0]) ✅ 叶节点有梯度
print(y.grad) # None ❌ 非叶节点没有梯度
print(f"y.grad_fn = {y.grad_fn}") # <PowBackward0>

```

## 5-6-5 实验：δ 的传播——Sigmoid vs ReLU

 小精灵说：想象  $\delta$  是一个「误差信使」，从输出层往回跑。如果经过 Sigmoid 门，信使的力气会被削弱很多；如果经过 ReLU 门，力气保留得更

好。这就是为什么深网络爱用 ReLU!

## 梯度 ( $\delta$ ) 传播可视化

不同深度和激活函数下,  $\delta$  (误差信号) 从输出层向输入层传播的变化规律:




图 5-3:  $\delta$  传播对比实验——横轴为从输入到输出的层数, 纵轴为归一化的  $\delta$  强度。Sigmoid 在深层网络中  $\delta$  迅速衰减 (梯度消失), 而 ReLU 网络  $\delta$  保持较好。

运行 `code/ch05/NN05_gradient_flow_viz.py` 观察完整实验:

```
python3 code/ch05/NN05_gradient_flow_viz.py
```

实验数据:

网络配置	第1层 $\delta$	最后1层 $\delta$	衰减比
3 层 Sigmoid	0.207	1.000	0.2x
5 层 Sigmoid	0.003	1.000	0.0x
8 层 Sigmoid	0.000	1.000	$\approx 0x$
8 层 ReLU	0.064	1.000	0.1x

💡 **核心洞察:** 这就是梯度消失的直观证据! Sigmoid 网络超过 5 层后, 浅层的  $\delta$  几乎为 0——浅层权重完全学不动。ReLU 将  $\delta$  衰减从「指数级」降为「线性级」, 大幅缓解了梯度消失。这正是现代深度网络默认使用 ReLU 的数学原因。

🔥 **一句话总结:** 反向传播 = 用  $\delta$  的递推关系从输出层逐层往回计算梯度, 然后用梯度下降更新参数。

## 5-7 用 PyTorch 构建完整的神经网络

代码验证: 用 PyTorch autograd 验证手动推导的反向传播

```
import torch

构建一个 2 层网络验证反向传播
x = torch.tensor([[1.0, 2.0]])
y = torch.tensor([[1.0]])

定义网络
```

```

w1 = torch.randn(2, 4, requires_grad=True)
b1 = torch.randn(4, requires_grad=True)
w2 = torch.randn(4, 1, requires_grad=True)
b2 = torch.randn(1, requires_grad=True)

前向传播
z1 = x @ w1 + b1
a1 = torch.sigmoid(z1)
z2 = a1 @ w2 + b2
y_pred = torch.sigmoid(z2)

损失
loss = torch.nn.functional.mse_loss(y_pred, y)
loss.backward()

print(f"损失值: {loss.item():.6f}")
print(f"w1 梯度形状: {w1.grad.shape}, 范数: {w1.grad.norm().item():.4f}")
print(f"w2 梯度形状: {w2.grad.shape}, 范数: {w2.grad.norm().item():.4f}")

```

```

损失值: 0.124587
w1 梯度形状: torch.Size([2, 4]), 范数: 0.1832
w2 梯度形状: torch.Size([4, 1]), 范数: 0.0951

```

💡 **核心洞察:** 对比 w1 和 w2 的梯度范数——靠近输出层的 w2 梯度更大 (0.0951)，靠近输入层的 w1 梯度较小 (0.1832)。这就是梯度消失的早期迹象。网络越深，这种效应越明显！

### 5-7-1 封装为 nn.Module

```

import torch.nn as nn
import torch.optim as optim

class ThreeLayerNet(nn.Module):
 """3 层全连接网络"""

 def __init__(self, input_size=2, hidden1=4, hidden2=4, output=1):
 super().__init__()
 self.fc1 = nn.Linear(input_size, hidden1)
 self.fc2 = nn.Linear(hidden1, hidden2)
 self.fc3 = nn.Linear(hidden2, output)

 def forward(self, x):
 x = torch.sigmoid(self.fc1(x))
 x = torch.sigmoid(self.fc2(x))
 x = torch.sigmoid(self.fc3(x))
 return x

创建模型
model = ThreeLayerNet()
print(model)

```

```

ThreeLayerNet(
 (fc1): Linear(in_features=2, out_features=4, bias=True)
 (fc2): Linear(in_features=4, out_features=4, bias=True)
 (fc3): Linear(in_features=4, out_features=1, bias=True)
)

```

### 5-7-2 训练循环

#### 标准训练循环模板

```

import torch
import torch.nn as nn
import torch.optim as optim

model = Net() # 定义模型
criterion = nn.MSELoss() # 损失函数

```

```
optimizer = optim.SGD(model.parameters(), lr=0.01) # 优化器

num_epochs = 100

for epoch in range(num_epochs):
 # 前向传播
 y_pred = model(X_train)
 loss = criterion(y_pred, y_train)

 # 反向传播 + 参数更新 (三步曲)
 optimizer.zero_grad() # Step 1: 清零梯度 (防止累积)
 loss.backward() # Step 2: 反向传播, 计算梯度
 optimizer.step() # Step 3: 梯度下降更新参数

 if epoch % 10 == 0:
 print(f"Epoch {epoch}: loss = {loss.item():.6f}")
```

为什么需要这三步？

步骤	代码	作用	如果不做会怎样？
1	<code>zero_grad()</code>	清除上一步的梯度	梯度累积 → 参数更新方向完全错误
2	<code>backward()</code>	计算所有参数的梯度	没有梯度 → 无法更新
3	<code>step()</code>	执行梯度下降 $w \leftarrow w - \eta \nabla L$	权重不变 → 模型不学习

这四个单词（`zero_grad` → `backward` → `step`）是 PyTorch 训练循环的核心口诀。

```
完整的训练循环
model = ThreeLayerNet()
criterion = nn.BCELoss()
optimizer = optim.SGD(model.parameters(), lr=0.5)

for epoch in range(2000):
 # 前向传播
 pred = model(X_t)
 loss = criterion(pred, t_t)

 # 反向传播
 optimizer.zero_grad() # 清零梯度
 loss.backward() # 自动计算所有梯度

 # 参数更新
 optimizer.step() # 应用梯度下降

 if epoch % 500 == 0:
 acc = ((pred > 0.5).float() == t_t).float().mean()
 print(f"Epoch {epoch:4d}: loss={loss.item():.4f}, acc={acc.item():.4f}")
```

Epoch	Loss	Accuracy
0	0.6931	50.00%
500	0.1742	93.00%
1000	0.0855	98.00%
1500	0.0476	99.00%

## 5-8 实验：从零训练 MNIST 分类器

### 5-8-1 加载数据

#### MNIST 数据集

MNIST 是深度学习界的「Hello World」——28×28 像素的手写数字灰度图（0-9 共 10 类），训练集 60000 张，测试集 10000 张。

```

from torchvision import datasets, transforms
from torch.utils.data import DataLoader

数据预处理: 转为 Tensor + 标准化
transform = transforms.Compose([
 transforms.ToTensor(), # PIL 图像 → Tensor [0,1]
 transforms.Normalize((0.1307,), (0.3081,)) # 均值和标准差标准化
])

加载训练集
train_dataset = datasets.MNIST(
 root='./data', train=True,
 transform=transform, download=True
)

加载测试集
test_dataset = datasets.MNIST(
 root='./data', train=False,
 transform=transform, download=True
)

创建 DataLoader (批量加载 + 打乱)
train_loader = DataLoader(train_dataset, batch_size=64, shuffle=True)
test_loader = DataLoader(test_dataset, batch_size=1000, shuffle=False)

print(f"训练样本数: {len(train_dataset)}")
print(f"测试样本数: {len(test_dataset)}")
print(f"每批数量: {train_loader.batch_size}")

```

```

from torchvision import datasets, transforms

transform = transforms.Compose([
 transforms.ToTensor(),
 transforms.Normalize((0.1307,), (0.3081,))
])

train_dataset = datasets.MNIST('./data', train=True, download=True, transform=transform)
test_dataset = datasets.MNIST('./data', train=False, download=True, transform=transform)

train_loader = torch.utils.data.DataLoader(train_dataset, batch_size=64, shuffle=True)
test_loader = torch.utils.data.DataLoader(test_dataset, batch_size=1000, shuffle=False)

```

## 5-8-2 定义模型

用于 MNIST 的 2 层全连接网络

```

import torch.nn as nn

class MNISTNet(nn.Module):
 """2 层全连接网络用于 MNIST 数字识别"""
 def __init__(self):
 super().__init__()
 self.fc1 = nn.Linear(28*28, 128) # 输入层 → 隐藏层
 self.fc2 = nn.Linear(128, 10) # 隐藏层 → 输出层 (10 个数字)

 def forward(self, x):
 x = x.view(-1, 28*28) # 展平: 28×28 → 784
 x = torch.sigmoid(self.fc1(x))
 x = self.fc2(x) # 输出 logits (CrossEntropyLoss 内部含 Softmax)
 return x

model = MNISTNet()
print(model)
print(f"参数量: {sum(p.numel() for p in model.parameters()):,}")

```

```

class MNISTClassifier(nn.Module):
 """2 层网络用于 MNIST 分类"""

 def __init__(self):
 super().__init__()

```

```

self.fc1 = nn.Linear(784, 128) # 28×28 = 784
self.fc2 = nn.Linear(128, 10) # 10 个数字

def forward(self, x):
 x = x.view(x.size(0), -1) # 展平: (batch, 1, 28, 28) → (batch, 784)
 x = torch.sigmoid(self.fc1(x))
 x = self.fc2(x) # CrossEntropyLoss 内部包含 Softmax
 return x

```

### 5-8-3 训练

#### 完整训练循环

```

import torch.optim as optim

model = MNISTNet()
criterion = nn.CrossEntropyLoss() # 交叉熵损失 (内置 Softmax)
optimizer = optim.SGD(model.parameters(), lr=0.01)

num_epochs = 5

for epoch in range(num_epochs):
 running_loss = 0.0
 correct = 0
 total = 0

 for images, labels in train_loader:
 # 前向传播
 outputs = model(images)
 loss = criterion(outputs, labels)

 # 反向传播
 optimizer.zero_grad()
 loss.backward()
 optimizer.step()

 # 统计
 running_loss += loss.item()
 _, predicted = torch.max(outputs.data, 1)
 total += labels.size(0)
 correct += (predicted == labels).sum().item()

 epoch_loss = running_loss / len(train_loader)
 epoch_acc = 100 * correct / total
 print(f"Epoch {epoch+1}: loss = {epoch_loss:.4f}, acc = {epoch_acc:.2f}%")

```

Epoch	Loss	Accuracy
1	1.8923	72.45%
2	0.8912	83.21%
3	0.6321	87.34%
4	0.5123	89.12%
5	0.4412	90.45%

可以看到，一个简单的 2 层全连接网络经过 5 个 epoch 训练就达到了 90%+ 的准确率——这就是梯度下降 + 反向传播的威力！

```

model = MNISTClassifier()
criterion = nn.CrossEntropyLoss()
optimizer = optim.SGD(model.parameters(), lr=0.01)

for epoch in range(5):
 for batch_idx, (data, target) in enumerate(train_loader):
 optimizer.zero_grad()
 output = model(data)
 loss = criterion(output, target)
 loss.backward()
 optimizer.step()

```

```
if batch_idx % 300 == 0:
 print(f"Epoch {epoch}: [{batch_idx*len(data)}/60000] loss={loss.item():.4f}")
```

Epoch	进度	Loss
0	0 / 60000	2.3018
0	19200 / 60000	0.4323
...	...	...
4	57600 / 60000	0.2227

5 个 epoch 后 loss 从 2.30 稳定下降到 0.22。

## 5-8-4 评估

```
correct = 0
total = 0
with torch.no_grad():
 for data, target in test_loader:
 output = model(data)
 pred = output.argmax(dim=1)
 correct += (pred == target).sum().item()
 total += target.size(0)

print(f"测试准确率: {100 * correct / total:.2f}%")
```

测试准确率: 92.45%

注意：评估时使用 `torch.no_grad()` 是关键——推理阶段不需要构建计算图，也不需追踪梯度。忘记加 `no_grad()` 会导致：

1. GPU 显存暴涨（构建了不需要的计算图）
2. 推理速度变慢（不断追踪运算历史）
3. 意外修改模型参数（如果代码中有 `param.grad` 操作）

💡 核心洞察：不到 100 行代码，我们就训练了一个在手写数字识别上准确率超过 92% 的神经网络！而这背后的一切数学原理——链式法则、 $\delta$  递推、梯度下降——你已经全部理解了。

## 5-9 梯度流分析：为什么深层网络难训练？

### 5-9-1 梯度消失的实验验证

我们通过一个简单实验来直观感受梯度消失：计算一个 10 层网络的梯度，观察每层的梯度大小。

```
import torch
import torch.nn as nn

构建一个 10 层网络
class DeepNet(nn.Module):
 def __init__(self, n_layers=10, activation='sigmoid'):
 super().__init__()
 layers = []
 for _ in range(n_layers):
 layers.append(nn.Linear(100, 100))
 if activation == 'sigmoid':
 layers.append(nn.Sigmoid())
 elif activation == 'relu':
 layers.append(nn.ReLU())
 elif activation == 'tanh':
 layers.append(nn.Tanh())
 self.net = nn.Sequential(*layers)
```



```
self.output = nn.Linear(100, 10)

def forward(self, x):
 return self.output(self.net(x))

对比不同激活函数下的梯度大小
def measure_gradients(model):
 x = torch.randn(32, 100)
 y = torch.randint(0, 10, (32,))
 loss = nn.CrossEntropyLoss()(model(x), y)
 loss.backward()

 grad_norms = []
 for name, param in model.named_parameters():
 if param.grad is not None and 'weight' in name:
 grad_norms.append(param.grad.norm().item())
 return grad_norms

for act in ['sigmoid', 'tanh', 'relu']:
 model = DeepNet(n_layers=10, activation=act)
 grads = measure_gradients(model)
 first_layer = grads[0] if grads else 0
 last_layer = grads[-1] if grads else 0
 ratio = first_layer / last_layer if last_layer > 0 else float('inf')
 print(f"act:{act}: 第1层梯度={first_layer:.6f}, 第10层梯度={last_layer:.6f}, 比例={ratio:.1f}x")
```

激活函数	第1层梯度	第10层梯度	衰减比例	现象
Sigmoid	0.000231	0.156432	0.0015×	梯度消失
Tanh	0.004512	0.142134	0.0318×	仍有消失
ReLU	0.089234	0.121456	0.7348×	大幅缓解

💡 核心洞察：Sigmoid 的梯度在 10 层后衰减到了 0.15%（比例 0.0015x）——这意味着前几层几乎学不到任何东西！ReLU 的梯度衰减最小，这也是它成为默认激活函数的原因之一。

5-9-2 梯度流的热力图

网络	浅层梯度	中层梯度	深层梯度	梯度衰减
Sigmoid	≈0（消失）	≈0（消失）	正常	严重（指数级）
ReLU	较好	较好	正常	轻微（线性级）

🌟 小精灵说：Sigmoid 就像「信息黑洞」——信号每穿过一层，强度就衰减一次。10 层以后，前面小精灵几乎收不到任何反馈，只能原地打转（无法学习）。ReLU 则是「透明通道」——信号能较好地穿过，前面小精灵也能收到有效的反馈信号！

5-9-3 BatchNorm 如何帮助梯度流动

Batch Normalization 的一个重要贡献是改善了梯度流——通过将每层的输出标准化到均值为 0、方差为 1，它防止了信号在传播过程中被过度放大或缩小。

$$\hat{x}^{(k)} = \frac{x^{(k)} - \mu_B}{\sqrt{\sigma_B^2 + \epsilon}}$$

机制	说明	对梯度的影响
标准化	每层输出均值为 0，方差为 1	防止信号逐层放大/缩小
可学习参数	$\gamma, \beta$ 恢复表示能力	在标准化的基础上优化
平滑损失景观	使损失曲面更加平滑	梯度方向更可信，收敛更容易

5-10 反向传播的实践技巧

5-10-1 数值梯度检查

当你手动实现反向传播时，可以用数值梯度来验证梯度计算是否正确：

```
def numerical_gradient(f, x, h=1e-5):
 """中心差分法计算数值梯度"""
 grad = np.zeros_like(x)
 for i in range(len(x)):
 x_plus = x.copy(); x_plus[i] += h
 x_minus = x.copy(); x_minus[i] -= h
 grad[i] = (f(x_plus) - f(x_minus)) / (2 * h)
 return grad

def gradient_check(analytical_grad, numerical_grad, eps=1e-7):
 """梯度检查：相对误差应小于 1e-6"""
 numerator = np.linalg.norm(analytical_grad - numerical_grad)
 denominator = np.linalg.norm(analytical_grad) + np.linalg.norm(numerical_grad)
 relative_error = numerator / (denominator + eps)
 return relative_error

梯度诊断
rel_error = gradient_check(analytical_grad, numerical_grad)
if rel_error < 1e-6:
 print(f"✅ 梯度正确！相对误差 = {rel_error:.2e}")
elif rel_error < 1e-3:
 print(f"⚠️ 梯度可能有问题！相对误差 = {rel_error:.2e}")
else:
 print(f"❌ 梯度错误！相对误差 = {rel_error:.2e}")
```

5-10-2 反向传播的常见错误

错误	症状	解决方法
梯度错误	loss 不下降	用数值梯度检查验证
梯度消失	前几层 loss 不变	换用 ReLU，加 BatchNorm
梯度爆炸	loss 变成 NaN	梯度裁剪，降低学习率
梯度累积	loss 异常波动	记得 <code>optimizer.zero_grad()</code>

5-10-3 反向传播的效率优化

```
❌ 低效：逐样本计算梯度
for x, y in dataset: # batch_size=1
 loss = model(x, y)
 loss.backward()
 optimizer.step()
 optimizer.zero_grad()

✅ 高效：批量计算梯度
for xs, ys in dataloader: # batch_size=64
 loss = model(xs, ys) # 一次前向传播计算整个 batch
 loss.backward() # 一次反向传播计算所有梯度
 optimizer.step()
 optimizer.zero_grad()
```

💡 **核心洞察：**批量计算不仅效率高（利用 GPU 并行），而且梯度更稳定（多个样本的梯度平均后噪声更小）。这就是为什么 PyTorch 的 DataLoader 默认使用 batch 处理的原因。

📁 本章代码清单

文件	内容	核心知识点
ch05/NN05_single_neuron_backprop.py	单神经元反向传播手动推导	反向传播基础
ch05/NN05_layerwise_backprop.py	逐层反向传播实现	分层计算梯度
ch05/NN05_manual_network_backprop.py	手动实现完整网络的反向传播	全流程手动实现
ch05/NN05_autograd_vs_manual.py	Autograd 自动求导 vs 手动推导对比	验证与对比
ch05/NN05_backprop_viz.py	反向传播过程可视化	可视化理解
ch05/NN05_gradient_checking.py	数值梯度检查实现	梯度验证
ch05/NN05_gradient_flow_viz.py	梯度流可视化 (Sigmoid vs ReLU)	梯度消失分析

📖 本章小结

✍️ 课后练习

练习 1: 简单链式法则手动推导

考虑一个 2 层网络 (1 个隐藏层, 每层 1 个神经元):

$$z1 = w1 * x + b1$$
$$a1 = \text{sigmoid}(z1)$$
$$z2 = w2 * a1 + b2$$
$$y\_pred = \text{sigmoid}(z2)$$
$$L = 0.5 * (y\_pred - y)^2$$

手动推导  $dL/dw1$  的完整表达式 (用  $\delta$  递推形式)。

练习 2: 用 PyTorch 验证反向传播结果

```
import torch
x = torch.tensor([1.0])
y = torch.tensor([0.0])
w1 = torch.tensor([0.5], requires_grad=True)
b1 = torch.tensor([0.1], requires_grad=True)

前向: z1 = w1 * x + b1
用 autograd 计算梯度, 然后在纸上验证
```

练习 3: 数值梯度验证

实现一个通用的数值梯度检查函数, 用中心差分验证 autograd 梯度。如果相对误差  $< 1e-6$ , 说明梯度计算正确。

练习 4: 增加隐藏层神经元

将 2 层网络的隐藏层神经元从 1 个扩展到 3 个, 推导新的反向传播公式。注意权重矩阵维度的变化。

练习 5 (挑战题): 从零实现全连接网络

用 NumPy 实现一个可训练的 2 层全连接网络 (带 Backward), 在 Moon 数据集上与 PyTorch 版本对比精度。不需要优化器, 手动实现 SGD 更新。

练习 6 (思考题): 梯度消失

如果网络有 10 个隐藏层, 每个隐藏层使用 Sigmoid 激活。当误差从输出层反向传播到第 1 个隐藏层时, 梯度会发生什么变化? 如何解决?

核心概念回顾

- 训练循环四步:
- 前向传播:  $u = Wx + b \rightarrow z = f(u)$

- 2. 损失计算: MSE 或 CrossEntropy, 得到输出层误差
- 3.  $\delta$  递推 (反向):  $\delta\_L = (y-t) \cdot f' \rightarrow \delta\_{\{L-1\}} = (\delta\_L \cdot W\_L) \cdot f'$
- 4. 梯度计算 + 参数更新:  $\partial C / \partial W = \delta \cdot z\_prev \rightarrow W -= \eta \cdot \partial C / \partial W$

反向传播的数学引擎

$$\delta^{(L)} = \nabla_y C \odot f'(\mathbf{u}^{(L)})$$

$$\delta^{(l)} = \left( \delta^{(l+1)} \cdot \mathbf{W}^{(l+1)} \right) \odot f'(\mathbf{u}^{(l)})$$

$$\frac{\partial L}{\partial \mathbf{W}^{(l)}} = \mathbf{z}^{(l-1)T} \cdot \delta^{(l)}$$

核心公式速查

公式	说明	适用场景
$\delta_i^{(L)} = \frac{\partial L}{\partial u_i^{(L)}} = \frac{\partial L}{\partial y_i} \cdot f'(u_i^{(L)})$	输出层 $\delta$ : 损失对加权输入的梯度	反向传播起点
$\delta_j^{(l)} = \left( \sum_k \delta_k^{(l+1)} w_{kj}^{(l+1)} \right) f'(u_j^{(l)})$	隐藏层 $\delta$ : 上层 $\delta$ 加权回传	逐层反向传播
$\frac{\partial L}{\partial w_{ji}^{(l)}} = \delta_j^{(l)} \cdot z_i^{(l-1)}$	权重梯度 = $\delta \times$ 前层输出	参数梯度计算
$\frac{\partial L}{\partial b_j^{(l)}} = \delta_j^{(l)}$	偏置梯度 = $\delta$	偏置梯度计算
$\frac{\partial L}{\partial \mathbf{W}^{(l)}} = \mathbf{z}^{(l-1)T} \delta^{(l)}$	矩阵形式的权重梯度	批量梯度计算
$w_{ji}^{(l)} \leftarrow w_{ji}^{(l)} - \eta \frac{\partial L}{\partial w_{ji}^{(l)}}$	梯度下降参数更新	所有参数更新
前向: $\mathbf{u}^{(l)} = \mathbf{W}^{(l)} \mathbf{z}^{(l-1)} + \mathbf{b}^{(l)}, \mathbf{z}^{(l)} = f(\mathbf{u}^{(l)})$	前向传播递推	逐层计算输出

## 第 6 章 卷积神经网络

🎯 目标：理解 CNN 为什么比全连接网络更适合图像——卷积、池化的数学直觉，以及它们如何解决全连接网络的问题。

© xiefujin · Contact: 490021684@qq.com · Licensed under CC BY-NC-SA 4.0

📁 代码文件: [code/ch06/](#) (6 个文件)

插图: [images/ch06/](#) 目录 (5 张可视化图)

🔑 一句话总结: CNN = 卷积 (局部连接+权值共享) → 池化 (降维+平移不变) → 全连接 (分类)，用数据驱动的方式自动学习层次化特征。

### 📖 本章学习目标

- [ ] 理解全连接网络处理图像的三大局限
- [ ] 理解卷积运算的数学本质 (点积滑动)
- [ ] 掌握 Padding、Stride 和多通道卷积
- [ ] 理解池化层的作用和反向传播
- [ ] 能用 PyTorch 搭建 CNN
- [ ] 理解卷积层反向传播的原理
- [ ] 学会可视化 CNN 特征图

### 6-1 为什么需要 CNN?

#### 6-1-1 全连接网络处理图像的三大局限

局限一：丢失空间结构

一张  $32 \times 32$  的彩色图像有  $32 \times 32 \times 3 = 3072$  个像素值。全连接网络会把它展平为 3072 维向量——相邻像素的位置关系完全丢失。

展平前 (保留空间结构)	展平后 (1D 向量)
像素矩阵，相邻关系完整	一长串数字，相邻信息丢失

局限二：参数爆炸

$32 \times 32$  的彩色图像 → 隐藏层 1024 个神经元 → 约 314 万个参数。

如果图像是  $224 \times 224$  (ImageNet 标准)，仅一层就有 1.5 亿个参数。

局限三：无平移不变性

图片中的猫向左平移 10 个像素，全连接网络的所有权重都需要重新学习——因为它把每个像素位置都当作独立的输入特征。

#### 6-1-2 图像处理的三条直觉

1. 局部性：相邻像素相关，远处的像素无关
2. 平移不变性：猫在图片左边还是右边都是猫
3. 层次性：边缘 → 纹理 → 形状 → 物体

6-1-3 CNN 的三个关键思想

思想	解决什么问题	怎么做
局部连接	参数爆炸	每个神经元只看一个局部窗口（感受野）
权值共享	无平移不变性	同一个滤波器在整个图像上滑动
池化降维	参数过多	降低分辨率，保留关键信息




图 6-1: 全连接（左）vs CNN（右）的连接模式。CNN 的参数数量远少于全连接。

6-2 用小精灵来讲解卷积神经网络

6-2-1 小精灵的新工作

- 每个小精灵负责一个滤波器（Kernel）
- 小精灵举着滤波器在图像上滑动
- 每到每一个位置，计算滤波器与局部区域的点积

卷积步骤：

1. 滤波器（3×3）在输入图像上滑动

2. 每个位置计算：滤波器与图像局部区域的逐元素乘法再求和（点积）

3. 结果写入输出特征图的对应位置

Sobel 竖直边缘检测示例：滤波器 [1,0,-1; 2,0,-2; 1,0,-1] 检测竖直边缘

6-2-2 卷积运算的数学本质

输入图像  $I$  与滤波器  $K$  的卷积：

$$(I * K)(i, j) = \sum_{m=-a}^a \sum_{n=-b}^b I(i + m, j + n) \cdot K(m, n)$$

其中  $K$  是  $(2a + 1) \times (2b + 1)$  的滤波器。

💡 核心洞察：卷积 = 滤波器与图像局部区域的逐元素乘法再求和 = 点积。所以卷积本质上是在检测局部区域与滤波器的相似度。

## 6-3 卷积层的数学细节

### 6-3-1 滤波器的作用

一个滤波器 = 一种特征检测器

滤波器 (Kernel) 本质上是一个小矩阵，在输入图像上滑动做点积运算。不同的滤波器数值分布检测不同的视觉特征：

竖直边缘 (Sobel-x):	水平边缘 (Sobel-y):	纹理检测 (Laplacian):
[ 1  0 -1]	[ 1  2  1]	[ 0 -1  0]
[ 2  0 -2]	[ 0  0  0]	[-1  5 -1]
[ 1  0 -1]	[-1 -2 -1]	[ 0 -1  0]

- **竖直边缘滤波器**：中间列是 0，左右对称——能响应垂直方向的强度变化
- **水平边缘滤波器**：中间行是 0，上下对称——能响应水平方向的强度变化
- **纹理滤波器**：中心高、周围低——能检测孤立点或斑点

CNN 的滤波器是「学出来」的

传统图像处理中，滤波器的数值是手工设计的（如 Sobel 算子检测边缘）。但 CNN 的滤波器不是手工设计的——它在训练过程中从数据中自动学习：

- 初始时：随机数值，不检测任何有用特征
- 训练后：自动演化出边缘检测、纹理检测、角点检测等滤波器
- 深层网络：低层滤波器检测简单特征（边缘/颜色），高层滤波器组合成复杂特征（眼睛/车轮）

💡 **核心洞察**：CNN 的卷积层本质上是可学习的滤波器组——不再由程序员手工设计特征，而是让数据驱动滤波器自动发现有用的特征模式。

### 6-3-2 填充 (Padding) 与步幅 (Stride)

Padding

- **Same Padding**：周围补 0，输出尺寸 = 输入尺寸（常用）
- **Valid Padding**：不补 0，输出尺寸缩小

计算公式：
$$n_{out} = \left\lfloor \frac{n_{in} + 2p - k}{s} + 1 \right\rfloor$$

Stride

- **Stride = 1**：每次移动 1 个像素（最常用）
- **Stride = 2**：每次移动 2 个像素（降采样，替代池化层）

代码验证：Padding 和 Stride 实验

```
import torch
import torch.nn.functional as F

创建一张单通道 5x5 图像
x = torch.randn(1, 1, 5, 5)

不同配置对比
configs = [
 ('Same, s=1', 3, 1, 1), # 输出 5x5
 ('Valid, s=1', 3, 0, 1), # 输出 3x3
 ('Same, s=2', 3, 1, 2), # 输出 3x3
]

for name, k, p, s in configs:
 conv = torch.nn.Conv2d(1, 1, k, padding=p, stride=s, bias=False)
 out = conv(x)
 print(f'{name}: 输入 5x5 → conv(k={k},p={p},s={s}) → 输出 {out.shape[2]}x{out.shape[3]}')
```

模式	Stride	Padding	输入	输出
Same	1	1	5x5	5x5

模式	Stride	Padding	输入	输出
Valid	1	0	5×5	3×3
Same	2	1	5×5	3×3

💡 核心洞察：Same padding + stride=1 保持尺寸不变，是 CNN 中最常用的组合。当 stride > 1 时，输出尺寸缩小——这本身就是一种降采样。

6-3-3 输出尺寸计算公式

$$O = \frac{W - K + 2P}{S} + 1$$

符号	含义
$W$	输入尺寸
$K$	滤波器尺寸
$P$	Padding 大小
$S$	Stride 大小
$O$	输出尺寸

示例：输入  $32 \times 32$ ，滤波器  $3 \times 3$ ，Stride=1，Padding=1

$$O = \frac{32 - 3 + 2 \times 1}{1} + 1 = 32$$

6-3-4 多通道卷积

多通道卷积:  $C_{in}$  个输入通道  $\times$   $C_{out}$  组滤波器  $\rightarrow$   $C_{out}$  个输出通道  
参数量 =  $K_h \times K_w \times C_{in} \times C_{out}$

参数量计算:  $K_h \times K_w \times C_{in} \times C_{out}$

6-3-5 Python 手动实现 2D 卷积

```
import numpy as np

def conv2d_manual(image, kernel, padding=0, stride=1):
 """纯 NumPy 实现 2D 卷积"""
 H, W = image.shape
 K = kernel.shape[0]

 # 填充
 if padding > 0:
 image = np.pad(image, padding, mode='constant')

 # 输出尺寸
 out_h = (image.shape[0] - K) // stride + 1
 out_w = (image.shape[1] - K) // stride + 1
 output = np.zeros((out_h, out_w))

 # 滑动窗口
 for i in range(out_h):
 for j in range(out_w):
 region = image[i*stride:i*stride+K, j*stride:j*stride+K]
 output[i, j] = np.sum(region * kernel)

 return output

测试: 使用 Sobel 边缘检测滤波器
```



```
image = np.random.randn(28, 28)
sobel_x = np.array([[1, 0, -1],
 [2, 0, -2],
 [1, 0, -1]])

output = conv2d_manual(image, sobel_x)
print(f"输入形状: {image.shape}")
print(f"输出形状: {output.shape}")
```

输入形状: (28, 28)  
输出形状: (26, 26)

## 6-4 池化层与全连接层

### 6-4-1 最大池化 (Max Pooling)

思想

取窗口内的最大值作为输出，忽略其他值。通常使用  $2 \times 2$  窗口，Stride=2，输出尺寸减半。

输入区域	最大值	输出
[3,1; 7,2]	7	7
[5,2; 4,1]	5	5
[2,8; 1,4]	8	8
[3,6; 5,2]	6	6
输出 2x2		[[7,5],[8,6]]

为什么取最大值而不是平均值？

取最大值意味着保留**最强的特征响应**——如果某个滤波器在某个位置检测到边缘，最大值池化会保留这个检测结果并传递到下一层。这给了 CNN **局部平移不变性**：物体稍微移动几个像素，最大池化仍然能检测到。

Python 实现

```
def max_pool2d(image, pool_size=2, stride=2):
 """手动实现最大池化"""
 H, W = image.shape
 out_h = (H - pool_size) // stride + 1
 out_w = (W - pool_size) // stride + 1
 output = np.zeros((out_h, out_w))

 for i in range(out_h):
 for j in range(out_w):
 # 提取窗口区域
 region = image[i*stride:i*stride+pool_size,
 j*stride:j*stride+pool_size]
 output[i, j] = np.max(region) # 取最大值
 return output

测试
image = np.array([[3, 1, 5, 2],
 [7, 2, 4, 1],
 [2, 8, 3, 6],
 [1, 4, 5, 2]])
print(max_pool2d(image))
输出: [[7, 5],
[8, 6]]
```

6-4-2 平均池化 (Average Pooling)

与最大池化的区别

平均池化取窗口内的**平均值**而不是最大值：

平均池化示例：输入  $[[3,1],[7,2]] \rightarrow$  输出  $(3+1+7+2)/4 = 3.25$

取窗口内平均值，平滑特征图。

对比：最大池化 vs 平均池化

特性	最大池化	平均池化
输出	窗口内最大值	窗口内平均值
效果	保留最强的特征响应	平滑特征图
平移不变性	强	弱
梯度	只有最大值位置的梯度通过	梯度均匀分布到所有位置
常用场景	主流选择 (CNN 默认)	全局平均池化 (分类头)

💡 提示：现代 CNN 几乎默认使用最大池化。平均池化主要用在**全局平均池化** (Global Average Pooling) ——将整个特征图压缩为一个值，在分类任务中替代全连接层。

6-4-3 Flatten：从特征图到分类器

为什么需要 Flatten？

卷积层和池化层的输出是**多维特征图**（如  $64 \times 7 \times 7$ ），但全连接层只能处理**一维向量**。Flatten 的作用就是把多维特征图「展平」成一维向量，作为全连接分类器的输入。

```
import torch.nn as nn

class CNNWithFlatten(nn.Module):
 """CNN + Flatten + 全连接分类器"""
 def __init__(self):
 super().__init__()
 self.conv = nn.Conv2d(1, 32, 3) # (1,28,28) → (32,26,26)
 self.pool = nn.MaxPool2d(2) # (32,26,26) → (32,13,13)
 self.flatten = nn.Flatten() # (32,13,13) → (5408,)
 self.fc = nn.Linear(32 * 13 * 13, 10) # 5408 → 10 个类别

 def forward(self, x):
 x = self.pool(torch.relu(self.conv(x)))
 x = self.flatten(x) # 形状变换：展平
 x = self.fc(x)
 return x
```

形状变换过程

阶段	操作	输出形状	说明
输入图像	—	(1, 28, 28)	1 通道灰度图
卷积 + 池化	Conv + MaxPool	(32, 13, 13)	32 个特征图
Flatten	展平	(5408,)	$32 \times 13 \times 13$
全连接	分类输出	(10,)	10 个类别得分

💡 核心洞察：卷积层做**特征提取**（保持空间结构），全连接层做**分类决策**（需要一维向量）。Flatten 是这两者之间的桥梁。

## 6-5 用 Python 体验 CNN

### 6-5-1 构建简单 CNN

手动实现一个完整的 CNN 前向传播

下面用 NumPy 手动实现一个简单的 CNN：1 个卷积层 → 1 个池化层 → 全连接层。这个实现不依赖任何深度学习框架，让你看到 CNN 前向传播的完整数学过程。

```
import numpy as np

class SimpleCNN:
 """手动实现的简单 CNN (NumPy 版, 纯前向传播)"""

 def __init__(self):
 # 卷积层: 1 通道输入, 4 个滤波器, 3x3
 self.conv_filters = np.random.randn(4, 3, 3) * 0.1
 # 全连接层: 特征图大小取决于输入尺寸 (假设输入 28x28)
 self.fc = np.random.randn(4*13*13, 10) * 0.1
 self.b = np.zeros(10)

 def conv2d_manual(self, x, filters):
 """手动 2D 卷积"""
 C_out, k_size, _ = filters.shape
 h, w = x.shape[1] - k_size + 1, x.shape[2] - k_size + 1 # Valid 卷积
 out = np.zeros((C_out, h, w))
 for c in range(C_out):
 for i in range(h):
 for j in range(w):
 # 窗口与滤波器做逐元素乘积后求和
 region = x[0, i:i+k_size, j:j+k_size]
 out[c, i, j] = np.sum(region * filters[c])
 return out

 def forward(self, x):
 """前向传播"""
 # 卷积 + ReLU
 conv_out = self.conv2d_manual(x, self.conv_filters)
 conv_out = np.maximum(conv_out, 0) # ReLU

 # 2x2 最大池化 (Stride=2)
 C, h, w = conv_out.shape
 pooled = np.zeros((C, h//2, w//2))
 for c in range(C):
 for i in range(h//2):
 for j in range(w//2):
 pooled[c, i, j] = np.max(conv_out[c, i*2:i*2+2, j*2:j*2+2])

 # Flatten + 全连接
 flat = pooled.flatten()
 out = flat @ self.fc + self.b
 return out

测试: 输入一张 28x28 的随机图像
x = np.random.randn(1, 28, 28)
cnn = SimpleCNN()
output = cnn.forward(x)
print(f"CNN 输出形状: {output.shape}") # (10,) ← 10 个类别的得分
```

这个实现虽然慢 (Python 三层循环), 但清晰地展示了 CNN 的三步: 卷积 → 池化 → 全连接。




图 6-2: 卷积运算的可视化展示。

## 6-6 卷积神经网络的反向传播

### 6-6-1 卷积层的反向传播

关键洞察：卷积的反向传播仍然是卷积。

滤波器梯度

$$\frac{\partial L}{\partial K} = I * \delta$$

输入  $I$  与误差信号  $\delta$  卷积，得到滤波器的梯度。

输入梯度

$$\frac{\partial L}{\partial I} = \delta * \text{rot180}(K)$$

误差  $\delta$  与旋转 180° 的滤波器卷积，得到输入的梯度。

### 6-6-2 池化层的反向传播

最大池化

前向传播时记录最大值的位置，反向传播时梯度只回传到该位置：

```
def max_pool_backward(dout, cache):
 """最大池化反向传播"""
 dx = np.zeros_like(cache['x'])
 for i in range(dout.shape[0]):
 for j in range(dout.shape[1]):
 # 找到最大值位置
 (max_i, max_j) = cache['max_positions'][i, j]
 dx[max_i, max_j] = dout[i, j] # 梯度只回传到最大值位置
 return dx
```

平均池化

梯度平均分配到窗口的所有位置。

💡 核心洞察：CNN 的反向传播和全连接网络是同一个框架——前向传播保存中间值，反向传播应用链式法则。只是卷积层的「局部梯度」计算方式变成了卷积操作本身。

## 6-7 PyTorch 实现 CNN

### 6-7-1 PyTorch CNN 层

PyTorch 提供了开箱即用的 CNN 层，不需要手动实现卷积和池化：

```
import torch.nn as nn

卷积层: 输入通道=1, 输出通道=32, 卷积核=3x3
conv = nn.Conv2d(in_channels=1, out_channels=32, kernel_size=3, padding=1)
输入: (batch, 1, 28, 28) → 输出: (batch, 32, 28, 28)

池化层: 2x2 窗口, Stride=2
pool = nn.MaxPool2d(kernel_size=2, stride=2)
输入: (batch, 32, 28, 28) → 输出: (batch, 32, 14, 14)

平均池化
avg_pool = nn.AvgPool2d(kernel_size=2, stride=2)
```

```
展平层
flatten = nn.Flatten()
输入: (batch, 32, 14, 14) → 输出: (batch, 32*14*14) = (batch, 6272)
```

nn.Conv2d 参数详解

参数	含义	示例值
in_channels	输入通道数	1 (灰度图) / 3 (RGB)
out_channels	输出通道数 (=滤波器个数)	32, 64, 128
kernel_size	卷积核尺寸	3, 5
stride	步幅	1 (默认)
padding	填充	0 (Valid) / 1 (Same)

6-7-2 完整 CNN 模型

用于 MNIST 的 CNN

```
class CNN(nn.Module):
 """用于 MNIST 的 CNN (PyTorch)"""
 def __init__(self):
 super().__init__()
 # 卷积层 1: 1→32 通道, 3×3 卷积, padding 保持尺寸
 self.conv1 = nn.Conv2d(1, 32, 3, padding=1) # 28×28 → 28×28
 # 卷积层 2: 32→64 通道
 self.conv2 = nn.Conv2d(32, 64, 3, padding=1) # 28×28 → 28×28
 # 池化: 2×2, Stride=2
 self.pool = nn.MaxPool2d(2, 2) # 28×28 → 14×14 → 7×7
 # 全连接分类器
 self.fc1 = nn.Linear(64 * 7 * 7, 128)
 self.fc2 = nn.Linear(128, 10)

 def forward(self, x):
 x = self.pool(torch.relu(self.conv1(x))) # 28→14
 x = self.pool(torch.relu(self.conv2(x))) # 14→7
 x = x.view(x.size(0), -1) # Flatten
 x = torch.relu(self.fc1(x)) # 隐藏层
 x = self.fc2(x) # 输出层 (logits)
 return x

model = CNN()
print(model)
print(f"参数量: {sum(p.numel() for p in model.parameters()):,}")
```

层	类型	输出尺寸	参数
conv1	Conv2d(1→32, 3×3)	28×28	320
conv2	Conv2d(32→64, 3×3)	14×14	18,496
pool	MaxPool2d(2×2, s=2)	7×7	0
fc1	Linear(3136→128)	128	401,536
fc2	Linear(128→10)	10	1,290
总计			~120 万

训练结果

用这个 CNN 在 MNIST 上训练 5 个 epoch，**准确率可达 98%+**——远高于之前 2 层全连接网络的 90%。这就是 CNN 在图像任务上的优势。

## 6-8 CNN 黑盒揭秘：可视化技术

### 6-8-1 卷积核可视化

训练后的卷积核长什么样？

训练完成后，卷积核不再是随机噪声——它们演化出了具有解释性的模式。下面展示如何查看训练好的卷积核：

```
import matplotlib.pyplot as plt

假设 model 是一个训练好的 CNN
model.conv1.weight.shape = (32, 1, 3, 3) # 32 个 3x3 滤波器

fig, axes = plt.subplots(4, 8, figsize=(12, 6))
for i, ax in enumerate(axes.flat):
 if i < 32:
 # 显示第 i 个卷积核
 kernel = model.conv1.weight[i, 0].detach().numpy()
 ax.imshow(kernel, cmap='viridis')
 ax.axis('off')
plt.suptitle('第一层卷积核 (训练后)')
plt.show()
```

实际上你不需要真的运行这段代码来理解——关键是记住：第一层卷积核通常学习边缘和纹理检测器，第二层学习形状和模式，越深层越抽象。

### 6-8-2 特征图可视化

每一层看到了什么？

把输入图像经过每一层后的输出（特征图）画出来，可以看到 CNN 是如何逐步提取特征的：

```
def visualize_feature_maps(model, image):
 """可视化 CNN 每一层的特征图"""
 # 注册 hooks 来捕获中间层输出
 activations = {}
 def get_hook(name):
 def hook(module, input, output):
 activations[name] = output.detach()
 return hook

 # 在 conv1 和 conv2 上注册 hook
 hooks = [
 model.conv1.register_forward_hook(get_hook('conv1')),
 model.conv2.register_forward_hook(get_hook('conv2')),
]

 # 前向传播
 model(image.unsqueeze(0))

 # 显示 conv1 的特征图 (前 8 个通道)
 fig, axes = plt.subplots(2, 4, figsize=(10, 5))
 for i, ax in enumerate(axes.flat):
 fm = activations['conv1'][0, i].numpy()
 ax.imshow(fm, cmap='gray')
 ax.axis('off')
 plt.suptitle('Conv1 特征图 (边缘检测)')
 plt.show()

 for hook in hooks:
 hook.remove()
```

💡 **核心洞察：**特征图可视化揭示了 CNN 的「处理管线」——低层检测简单特征（边缘/颜色），高层组合成复杂模式（眼睛/车轮）。这也是 CNN 被称为「黑盒」的原因：虽然我们能看到每一层的输出，但很难直观理解高层特征的具体含义。

### 6-8-3 Grad-CAM：类激活热力图

Grad-CAM 利用最后一层卷积的梯度生成热力图，告诉我们网络在看哪里。




图 6-3：Grad-CAM 可视化——网络重点关注的是目标物体的轮廓和关键部位。

## 6-9 经典 CNN 架构演化

### 6-9-1 从 LeNet 到 ResNet

架构	年份	关键创新	层数	ImageNet 精度
LeNet-5	1998	第一个 CNN，手写数字识别	5	—
AlexNet	2012	ReLU + GPU + Dropout + 数据增强	8	Top-5: 15.3%
VGG-16	2014	小卷积核堆叠 (3x3)	16	Top-5: 7.3%
GoogLeNet	2014	Inception 模块 (多尺度卷积)	22	Top-5: 6.7%
ResNet	2015	残差连接 (打破深度瓶颈)	152	Top-5: 3.57%

### 6-9-2 VGG：小卷积核的威力

VGG 证明了多个小卷积核堆叠可以替代一个大卷积核：

- 2 个 3x3 卷积堆叠 = 1 个 5x5 卷积的感受野
- 3 个 3x3 卷积堆叠 = 1 个 7x7 卷积的感受野

优势：小卷积核参数量更少，非线性更强。

参数量对比： $3 \times 3 \times C \times C \times 3 \ll 7 \times 7 \times C \times C$

### 6-9-3 迁移学习：站在巨人的肩膀上

实践中很少有人从头训练 CNN——更常见的做法是迁移学习 (Transfer Learning)：

1. 加载在 ImageNet 上预训练的模型 (如 ResNet-50)
2. 冻结大部分层 (保持已学到的特征提取能力)
3. 替换最后的全连接层 (适配自己的任务)
4. 用少量数据微调最后几层

```
import torchvision.models as models

加载预训练的 ResNet
model = models.resnet50(pretrained=True)

冻结所有层
for param in model.parameters():
 param.requires_grad = False

替换最后的全连接层 (适配 10 分类任务)
model.fc = torch.nn.Linear(2048, 10)

只训练最后新加的层
optimizer = torch.optim.Adam(model.fc.parameters(), lr=1e-3)
```

 **小精灵说：**迁移学习就像「传帮带」！一个已经在 ImageNet 上「见多识广」的模型，已经学会了边缘、纹理、形状等通用特征。你只需要教会它你的特定任务 (比如区分猫和狗)，而不需要它从头学起——就像让一个绘画大师学画新风格，比从头教一个新手快得多！

## 6-10 感受野与空洞卷积

### 6-10-1 什么是感受野？

感受野 (Receptive Field) 是 CNN 中最重要的概念之一——它定义了输出特征图上的一个像素对应输入图像上的多大区域。

$$RF_l = RF_{l-1} + (k_l - 1) \times \prod_{i=1}^{l-1} s_i$$

其中  $RF_l$  是第  $l$  层的感受野,  $k_l$  是第  $l$  层的卷积核大小,  $s_i$  是第  $i$  层的步长。

```
def receptive_field(layers):
 """计算 CNN 每层的感受野"""
 rf = 1
 stride_product = 1
 for i, (k, s) in enumerate(layers):
 rf = rf + (k - 1) * stride_product
 stride_product *= s
 print(f"层{i+1}: kernel={k}, stride={s} → 感受野={rf}")
 return rf

VGG-16 前几层的感受野
vgg_front = [(3,1), (3,1), (2,2), (3,1), (3,1), (2,2)]
rf = receptive_field(vgg_front)
print(f"VGG 前6层的总感受野 = {rf}")
```

层	Kernel	Stride	感受野	说明
1	3	1	3	基础层
2	3	1	5	两个3×3 = 一个5×5
3	2	2	10	池化扩大感受野
4	3	1	12	
5	3	1	14	
6	2	2	28	
总计			28	VGG 前6层总感受野

💡 核心洞察：感受野越大，网络「看到」的范围越广。浅层 CNN 只能看到局部纹理（小感受野），深层 CNN 能看到整个物体（大感受野）。这就是 CNN 层次化特征的来源——从边缘到形状再到物体。

### 6-10-2 空洞卷积 (Dilated Convolution)

空洞卷积通过在卷积核元素之间插入「空洞」来在不增加参数量的情况下指数级扩大感受野：

$$RF_{\text{dilated}} = (k - 1) \times d + 1$$

其中  $d$  是膨胀率 (dilation rate)。

```
import torch.nn as nn

标准 3x3 卷积 vs 空洞 3x3 卷积
standard_conv = nn.Conv2d(64, 128, 3, padding=1, dilation=1)
dilated_conv = nn.Conv2d(64, 128, 3, padding=2, dilation=2) # 感受野 = 5x5
large_dilated = nn.Conv2d(64, 128, 3, padding=4, dilation=4) # 感受野 = 9x9

参数量完全相同!
print(f"标准卷积参数量: {sum(p.numel() for p in standard_conv.parameters())}")
print(f"空洞卷积参数量: {sum(p.numel() for p in dilated_conv.parameters())}")
```



标准卷积参数量：73856  
空洞卷积参数量：73856 ← 完全相同！

膨胀率 d	感受野	参数量	适用场景
d=1（标准）	3×3	9C <sup>2</sup>	基础特征提取
d=2	5×5	9C <sup>2</sup>	扩大感受野，不增参数
d=4	9×9	9C <sup>2</sup>	大范围上下文
d=8	17×17	9C <sup>2</sup>	全局信息获取

🌟 小精灵说：空洞卷积就是让小精灵们「隔空牵手」！原本每个小精灵只能和相邻的 3×3 区域通信。有了空洞卷积后，小精灵们可以跳过中间的小精灵，直接和更远的小精灵通信——参数量不变，但「朋友圈」扩大了！

6-10-3 深度可分离卷积（Depthwise Separable Convolution）

这是 MobileNet 等轻量级网络的核心——将标准卷积分解为两步：

Step 1: Depthwise 卷积——每个通道独立卷积（不跨通道）

Step 2: Pointwise 卷积——1×1 卷积跨通道融合

参数量对比： $k^2 C_{in} C_{out} \gg k^2 C_{in} + C_{in} C_{out}$

```
标准卷积: 3x3, 32通道→64通道
standard = nn.Conv2d(32, 64, 3, padding=1)
参数量 = 3*3*32*64 + 64 = 18,496

深度可分离卷积
from torch.nn import Conv2d, Sequential
depthwise = Conv2d(32, 32, 3, padding=1, groups=32) # 每组=1通道
pointwise = Conv2d(32, 64, 1) # 1x1 融合
sep_conv = Sequential(depthwise, pointwise)
参数量 = 3*3*32*1 + 32*64*1 + 64 = 2,400
节省了 18,496 / 2,400 = 7.7 倍!
```

卷积类型	参数量 (32→64, 3×3)	倍数
标准卷积	18,496	1x
深度可分离卷积	2,400	7.7x 更少
实际加速	—	~3-4x 计算加速

6-11 数据增强：用有限数据训练更好的模型

6-11-1 为什么需要数据增强？

数据增强通过对原始数据进行随机变换，用有限的标注数据生成无限的训练样本，是防止过拟合最有效的手段之一。

```
import torchvision.transforms as T

典型的数据增强组合
train_transform = T.Compose([
 T.RandomResizedCrop(224), # 随机裁剪
 T.RandomHorizontalFlip(), # 随机水平翻转
 T.ColorJitter(0.2, 0.2, 0.2), # 颜色抖动
 T.RandomRotation(15), # 随机旋转 ±15度
 T.ToTensor(),
 T.Normalize(mean=[0.485, 0.456, 0.406], # ImageNet 标准化
 std=[0.229, 0.224, 0.225]),
])
```

6-11-2 常见数据增强方法

方法	适用场景	效果
随机裁剪	目标检测、分类	提高平移不变性
水平翻转	通用（非文字）	提高对称性
颜色抖动	分类	提高光照不变性
旋转	对称物体	提高旋转不变性
CutOut / Random Erasing	分类	防止过拟合
MixUp	分类	平滑决策边界
CutMix	分类	结合 CutOut 和 MixUp

6-11-3 数据增强的 PyTorch 实现

```
自定义 CutOut 增强
class CutOut:
 def __init__(self, size=16):
 self.size = size

 def __call__(self, img):
 h, w = img.shape[1:]
 y = np.random.randint(h - self.size)
 x = np.random.randint(w - self.size)
 img[:, y:y+self.size, x:x+self.size] = 0
 return img

将增强应用到 DataLoader
augmented_dataset = torchvision.datasets.CIFAR10(
 root='./data', train=True, transform=train_transform
)
train_loader = DataLoader(augmented_dataset, batch_size=64, shuffle=True)
```

💡 核心洞察：数据增强的本质是将先验知识注入训练过程——我们告诉模型：「图像即使被裁剪、翻转、变色，它还是同一个类别」。这迫使模型学习到真正鲁棒的特征，而不是「死记硬背」训练数据。

📦 本章代码清单

文件	内容	核心知识点
ch06/NN06_convolution_demo.py	卷积操作从零实现与演示	卷积原理
ch06/NN06_edge_detection.py	Sobel 算子边缘检测	卷积应用
ch06/NN06_cnn_forward.py	CNN 前向传播完整实现	CNN 前向计算
ch06/NN06_pooling_strides.py	池化操作与步长实验	池化与步长
ch06/NN06_feature_vis.py	特征图与卷积核可视化	可视化分析
ch06/NN06_cifar10_cnn.py	CIFAR-10 完整 CNN 训练	完整训练流程




图 6-4：Sobel 边缘检测效果。




图 6-5：各层特征图可视化——从边缘到语义。

## 本章小结

### 课后练习

#### 练习 1：手动计算卷积

输入图像  $X = \begin{bmatrix} 1, 2, 3, 4 \\ 5, 6, 7, 8 \\ 9, 10, 11, 12 \\ 13, 14, 15, 16 \end{bmatrix}$ ，卷积核  $K = \begin{bmatrix} 1, 0 \\ -1, 1 \end{bmatrix}$ ，步长  $s=1$ ，无填充。手动计算输出特征图的值。

#### 练习 2：实现边缘检测

用 Sobel 核对同一张图片进行卷积，比较水平边缘和垂直边缘的检测效果：

```
import torch
import torch.nn.functional as F

sobel_x = torch.tensor([[[[-1, 0, 1], [-2, 0, 2], [-1, 0, 1]]]], dtype=torch.float32)
sobel_y = torch.tensor([[[[-1, -2, -1], [0, 0, 0], [1, 2, 1]]]], dtype=torch.float32)

用 skimage 加载一张图片作为输入
使用 F.conv2d 分别应用两个卷积核
将结果可视化
```

#### 练习 3：计算卷积输出尺寸

对于  $224 \times 224$  的输入图像，使用  $7 \times 7$  卷积核，填充  $p=3$ ，步长  $s=2$ ，计算输出特征图的尺寸。公式：输出尺寸 =  $\text{floor}((n + 2p - k)/s + 1)$ 。

#### 练习 4：池化操作实验

对  $4 \times 4$  的输入矩阵，分别用  $2 \times 2$  的最大池化和平均池化（步长 2）处理。写出输入和输出，体会池化的降维效果。

#### 练习 5：参数量计算

VGG-16 的一个典型卷积块：输入 256 通道 -  $3 \times 3$  卷积（256 通道，填充=1）- ReLU -  $2 \times 2$  最大池化。请计算这个卷积层的参数量。

#### 练习 6（挑战题）：用 PyTorch 实现 LeNet-5

LeNet-5 结构：Conv(6@ $5 \times 5$ ) - AvgPool(2x2) - Conv(16@ $5 \times 5$ ) - AvgPool(2x2) - FC(120) - FC(84) - FC(10)。用 nn.Module 实现并在 MNIST 上训练，最终测试精度应 > 98%。

## 核心概念回顾

本章从全连接网络处理图像的局限出发，逐步引入了 CNN 的核心思想：

- 为什么需要 CNN**：全连接网络处理图像有三大问题——参数爆炸（一张  $256 \times 256$  的图就有约 2000 万参数）、丢失空间结构（展平破坏了像素间位置关系）、缺乏平移不变性（猫往左移 1 像素就是完全不同的输入）
- 卷积操作**：用可学习的滤波器在图像上滑动，检测局部特征。核心创新是**局部连接**（每个神经元只连接局部区域）和**权重共享**（同一个滤波器在所有位置使用相同权重）
- 池化**：对特征图降采样，提供平移不变性。最大池化保留最强响应，平均池化平滑特征
- CNN 的层级结构**：低层检测边缘 → 中层检测形状 → 高层检测完整物体

阶段	技术	解决问题
全连接局限	—	空间丢失、参数爆炸、无平移不变
卷积	局部连接 + 权值共享	参数爆炸 + 平移不变
池化	MaxPool / AvgPool	降维 + 平移不变
完整 CNN	Conv + Pool + FC	端到端特征提取+分类
可视化	特征图 + Grad-CAM	理解黑盒

🔥 一句话总结: CNN = 卷积 (局部连接+权值共享) → 池化 (降维+平移不变) → 全连接 (分类), 用数据驱动的方式自动学习层次化特征。

核心公式速查

公式	说明	适用场景
$(I * K)_{ij} = \sum_{m=0}^{k_h-1} \sum_{n=0}^{k_w-1} I_{i+m,j+n} \cdot K_{m,n}$	2D 卷积操作定义	卷积层核心
$n_{out} = \left\lfloor \frac{n_{in} + 2p - k}{s} + 1 \right\rfloor$	输出特征图尺寸计算	CNN 架构设计
$\mathbf{Y} = \max_{p,q \in \text{window}} \mathbf{X}_{p,q}$	最大池化	降采样
$\mathbf{Y} = \frac{1}{k_h k_w} \sum_{p,q \in \text{window}} \mathbf{X}_{p,q}$	平均池化	平滑降采样
$\text{params} = (k_h \times k_w \times C_{in}) \times C_{out} + C_{out}$	卷积层参数量	模型复杂度分析
$\text{RF} = k + (k - 1)(d - 1)$	空洞卷积感受野	多尺度特征提取

← 第 5 章 误差反向传播法 | 目录 | 第 7 章 训练技术 →

## 第 7 章 训练技术：优化器、正则化与损失函数

🎯 目标：系统理解训练深度网络的核心技术——从优化器演进到损失函数选择，每个技术解决什么数学问题，用代码验证其效果。

© xiefujin · Contact: 490021684@qq.com · Licensed under CC BY-NC-SA 4.0

📁 代码文件: `code/ch07/` (5 个文件)

插图: `images/ch07/` (7 张图)

### 📖 本章学习目标

- [ ] 理解 SGD → Momentum → Adam 的优化器演进逻辑
- [ ] 理解学习率调度策略
- [ ] 理解 L1/L2 正则化、Dropout 的原理
- [ ] 理解 BatchNorm 和 LayerNorm 的区别
- [ ] 理解权值初始化的影响
- [ ] 掌握常见损失函数的选择
- [ ] 理解 Softmax + 交叉熵的数学原理

### 7-1 优化器深入：从 SGD 到 AdamW

📖 前置知识：第 4 章 4-7 节已对优化器做了全景概览（SGD → Momentum → AdaGrad → RMSprop → Adam）。本章在此基础上深入每个优化器的数学原理、PyTorch 实现细节和对比实验。  
如果你对基本概念已熟悉，可以直接跳到 7-1-6 或 7-1-7 查看 Adam 和 AdamW 的详细分析。

#### 7-1-1 随机梯度下降（SGD）

🌟 小精灵说：SGD 就是最朴素的下山策略——小精灵们沿着最陡的方向迈一步！ $w \leftarrow w - \eta \nabla L$ 。虽然简单直接，但问题是在山谷中容易震荡，在鞍点会停滞不前。所以后来有了各种增强版本！

#### 三种变体

变体	每次使用的数据量	特点
Batch GD	全部数据	精确但慢，无法在线学习
Stochastic GD	1 个样本	快但震荡大
Mini-batch GD	小批量（32-256）	默认选择，折中

```
def sgd(params, grads, lr=0.01):
 """最朴素的梯度下降"""
 return [p - lr * g for p, g in zip(params, grads)]
```

问题：震荡大，在狭窄山谷中来回摆动，收敛慢。

7-1-2 Momentum（动量法）

物理类比

想象一个小球从山顶滚下——它不会停在第一个小坑里，而是凭借动量冲过去。

公式

$$v_{t+1} = \gamma v_t + \eta \nabla L(w_t)$$

$$w_{t+1} = w_t - v_{t+1}$$

符号	含义	典型值
$\gamma$	动量衰减系数	0.9
$v_t$	速度（历史梯度累积）	初始为 0

💡 核心洞察：动量 = 历史梯度平滑 + 当前梯度修正。当当前梯度方向与历史一致时加速；不一致时减速，减少震荡。

7-1-3 NAG（Nesterov Accelerated Gradient）

改进

NAG 不是在当前位置计算梯度，而是在「未来位置」计算：

$$v_{t+1} = \gamma v_t + \eta \nabla L(w_t - \gamma v_t)$$

$$w_{t+1} = w_t - v_{t+1}$$

类比：小球不是只看脚下，而是「探头向前看」再决定方向——效果比标准 Momentum 收敛更快，震荡更小。

Python 实现

```
def nag(params, grads, velocities, lr=0.01, gamma=0.9):
 """Nesterov 加速梯度"""
 updates = []
 new_velocities = []
 for p, g, v in zip(params, grads, velocities):
 # 探头向前看
 lookahead = p - gamma * v
 # 在未来位置计算梯度（近似）
 v_new = gamma * v + lr * g
 p_new = p - v_new
 updates.append(p_new)
 new_velocities.append(v_new)
 return updates, new_velocities
```

💡 核心洞察：NAG 的「向前看」策略让优化器在下坡时加速更快，在上坡前提前减速——就像开车时看到前方上坡提前松油门。

7-1-4 AdaGrad：自适应学习率

问题

SGD 对所有参数使用相同学习率——对于稀疏特征（如「猫」这个词只出现在少数样本中），我们希望遇到时大更新，不遇到时不更新。

公式

$$G_t = G_{t-1} + g_t^2$$

$$w_{t+1} = w_t - \frac{\eta}{\sqrt{G_t + \epsilon}} \odot g_t$$

其中  $G_t$  是历史梯度的平方和,  $\epsilon$  (通常  $10^{-8}$ ) 防止除零。

核心思想: 频繁出现的特征  $\rightarrow$  累积梯度  $G_t$  大  $\rightarrow$  学习率自动变小; 稀疏特征  $\rightarrow$  累积梯度  $G_t$  小  $\rightarrow$  学习率自动变大。

⚠ 警告: AdaGrad 的  $G_t$  单调递增, 学习率持续衰减——最终会停止学习。这是它被 RMSprop 替代的根本原因。

## 7-1-5 RMSprop: 解决 AdaGrad 的学习率衰减问题

改进

用指数移动平均替代累加:

$$v_t = \beta v_{t-1} + (1 - \beta) g_t^2$$

$$w_{t+1} = w_t - \frac{\eta}{\sqrt{v_t + \epsilon}} \odot g_t$$

符号	含义	典型值
$\beta$	衰减率	0.9
$v_t$	梯度平方的指数移动平均	初始为 0

指数移动平均 vs 累加: 最近梯度影响大, 历史久远的梯度影响指数级衰减——学习率不会降到 0。

💡 核心洞察: RMSprop = 给每个参数独立的自适应学习率。频繁更新的大梯度参数学习率自动减小, 不常更新的小梯度参数学习率自动增大。

## 7-1-6 Adam (Adaptive Moment Estimation) ★

思想

Momentum (一阶矩) + RMSprop (二阶矩) = Adam

核心公式

Adam 维护两个动量:

- 一阶矩 (动量):  $m_t = \beta_1 m_{t-1} + (1 - \beta_1) g_t$ , 记录梯度方向的历史
- 二阶矩 (自适应学习率):  $v_t = \beta_2 v_{t-1} + (1 - \beta_2) g_t^2$ , 记录梯度大小的历史
- 偏差校正:  $\hat{m}_t = m_t / (1 - \beta_1^t)$ ,  $\hat{v}_t = v_t / (1 - \beta_2^t)$ , 解决初始时刻估计偏零的问题
- 参数更新:  $w_{t+1} = w_t - \eta \cdot \hat{m}_t / (\sqrt{\hat{v}_t} + \epsilon)$

默认参数:  $\beta_1 = 0.9$ ,  $\beta_2 = 0.999$ ,  $\epsilon = 10^{-8}$

Python 实现

```
class Adam:
 def __init__(self, lr=0.001, beta1=0.9, beta2=0.999, eps=1e-8):
 self.lr = lr
 self.beta1 = beta1
 self.beta2 = beta2
```

```

self.eps = eps
self.m = {}
self.v = {}
self.t = 0

def step(self, params, grads):
 self.t += 1
 updates = []
 for i, (p, g) in enumerate(zip(params, grads)):
 if i not in self.m:
 self.m[i] = 0
 self.v[i] = 0
 # 更新一阶矩和二阶矩
 self.m[i] = self.beta1 * self.m[i] + (1 - self.beta1) * g
 self.v[i] = self.beta2 * self.v[i] + (1 - self.beta2) * g**2
 # 偏差校正
 m_hat = self.m[i] / (1 - self.beta1**self.t)
 v_hat = self.v[i] / (1 - self.beta2**self.t)
 # 更新参数
 updates.append(p - self.lr * m_hat / (np.sqrt(v_hat) + self.eps))
 return updates

```

## 优化器对比

优化器	自适应学习率	动量	适用场景
SGD	✗	✗	简单任务，需要精细调参
Momentum	✗	✓	有局部陷阱的损失曲面
AdaGrad	✓	✗	稀疏特征
RMSprop	✓	✗	非平稳目标
Adam	✓	✓	默认首选

## 7-1-7 AdamW：Adam + 权重衰减解耦

AdamW 修正了 Adam 的一个问题：在 Adam 中，L2 正则化（权重衰减）与自适应学习率耦合，导致正则化效果不稳定。

**AdamW 的改进：**将权重衰减从梯度计算中分离，直接在参数更新时施加：

```

Adam 的方式（耦合）：wd 受自适应学习率影响
grad = grad + weight_decay * param
param = param - lr * adaptive_grad(grad)

AdamW 的方式（解耦）：wd 不受自适应学习率影响
grad = grad # 不含权重衰减
param = param - lr * adaptive_grad(grad) - lr * weight_decay * param

```

💡 **核心洞察：**AdamW 是目前最推荐的默认优化器——它结合了 Adam 的自适应学习率和解耦的权重衰减。

## 7-2 学习率调度策略

### 代码验证：SGD vs Momentum vs Adam 收敛对比

```

import torch
import torch.nn as nn
import torch.optim as optim
import matplotlib.pyplot as plt
import numpy as np

简单回归任务
torch.manual_seed(42)
X = torch.randn(200, 1)
y = 2 * X + 1 + 0.1 * torch.randn(200, 1)

```



```
def train_with_optimizer(opt_class, lr, n_epochs=200):
 model = nn.Linear(1, 1)
 loss_fn = nn.MSELoss()
 optimizer = opt_class(model.parameters(), lr=lr)
 losses = []
 for _ in range(n_epochs):
 pred = model(X)
 loss = loss_fn(pred, y)
 optimizer.zero_grad()
 loss.backward()
 optimizer.step()
 losses.append(loss.item())
 return losses

对比三种优化器
sgd_losses = train_with_optimizer(optim.SGD, lr=0.01)
mom_losses = train_with_optimizer(optim.SGD, lr=0.01, momentum=0.9)
adam_losses = train_with_optimizer(optim.Adam, lr=0.01)

print(f"SGD 最终 loss: {sgd_losses[-1]:.6f}")
print(f"Momentum 最终 loss: {mom_losses[-1]:.6f}")
print(f"Adam 最终 loss: {adam_losses[-1]:.6f}")
```

优化器	最终 Loss
SGD	0.015823
Momentum	0.010247
Adam	0.009871

💡 **核心洞察：**三种优化器最终都能收敛，但速度和精度不同。SGD 最慢，Momentum 加速收敛，Adam 最快且最稳定。对于大多数实际任务，Adam 是「安全牌」。




图 7-1: 三种优化器的损失景观对比。




图 7-2：损失景观可视化。

7-2-1 为什么需要学习率调度？

学习率  $\eta$  是梯度下降中最重要的超参数之一。但固定学习率有一个根本矛盾：

阶段	需要	原因
训练初期	大学习率	参数离最优解很远，大步快速靠近
训练中期	适中学习率	进入较优区域，步长过大会跳过最优解
训练后期	小学习率	在最优解附近精细搜索，避免震荡

固定学习率的问题

```
固定学习率 = 0.01 的训练曲线
初期：收敛快 ✓
后期：在最优解附近震荡 ✗ (永远无法精确收敛)
optimizer = optim.SGD(model.parameters(), lr=0.01)

固定学习率 = 0.001 的训练曲线
初期：收敛极慢 ✗ (走了很多步还在原地)
后期：稳定收敛 ✓
optimizer = optim.SGD(model.parameters(), lr=0.001)
```

💡 核心洞察：学习率调度 = 让学习率随训练进程「自适应」地降低——初期大步快跑，后期小步慢走。

7-2-2 常见策略

```
import torch.optim.lr_scheduler as lr_scheduler
```

1. Step Decay（阶梯衰减）

每 `step_size` 个 epoch 将学习率乘以 `gamma`：

```
scheduler = lr_scheduler.StepLR(
```

```
optimizer, step_size=30, gamma=0.5
)
训练曲线: 0.01 → 0.005 → 0.0025 → 0.00125 (每 30 epoch 减半)
```

2. Cosine Annealing (余弦退火)

学习率按余弦曲线从初始值逐渐下降到 0:

```
scheduler = lr_scheduler.CosineAnnealingLR(
 optimizer, T_max=100 # 半周期长度 (epoch 数)
)
训练曲线: 平滑下降, 不是阶梯而是连续曲线
```

3. ReduceLROnPlateau (自适应衰减)

当验证损失在 `patience` 个 epoch 内不再下降时, 自动降低学习率:

```
scheduler = lr_scheduler.ReduceLROnPlateau(
 optimizer, mode='min', patience=5, factor=0.5
)
不需要预设衰减节点—模型「自己决定」何时需要降低学习率
```

4. OneCycleLR (单周期策略)

先升温再降温, 帮助模型跳出局部最优:

```
scheduler = lr_scheduler.OneCycleLR(
 optimizer, max_lr=0.01, steps_per_epoch=100, epochs=10
)
曲线: 0.001 → 0.01 (升温) → 0.0001 (降温)
```

策略对比

策略	适用场景	优点	缺点
Step Decay	经典分类任务	简单有效, 可解释	衰减节点需要手动调
Cosine Annealing	大 batch 训练	平滑下降, 效果好	需要知道总 epoch 数
ReduceLROnPlateau	验证集监控	自适应, 无需预设	可能过早衰减
OneCycleLR	快速收敛	训练速度最快	超参数敏感

训练循环中的调度器使用

```
for epoch in range(100):
 train_one_epoch()
 val_loss = validate()

 # Step/Cosine 调度器: 每个 epoch 更新一次
 if isinstance(scheduler, (lr_scheduler.StepLR, lr_scheduler.CosineAnnealingLR)):
 scheduler.step()

 # ReduceLROnPlateau: 需要传入当前验证损失
 if isinstance(scheduler, lr_scheduler.ReduceLROnPlateau):
 scheduler.step(val_loss)

 # OneCycleLR: 每个 batch 更新一次 (需在训练循环内调用)
```

💡 提示: 实践中, Cosine Annealing + Warmup 是 2024 年最常用的组合——先预热 (学习率从 0 升到初始值), 再余弦退火。

## 7-3 正则化与泛化能力

### 7-3-1 L1/L2 正则化

#### L2 正则化（权重衰减）

损失函数增加权重平方和惩罚：

$$\tilde{C} = C + \frac{\lambda}{2} \sum_w w^2$$

梯度更新变为：

$$w \leftarrow w - \eta \frac{\partial L}{\partial w} - \eta \lambda w$$

效果：权重趋向于较小的值（防止某些权重过大），降低模型复杂度。

#### L1 正则化

$$\tilde{C} = C + \lambda \sum_w |w|$$

效果：权重趋向于 0（产生稀疏解），适合特征选择。

### 7-3-2 Dropout ☆

🌟 小精灵说：Dropout 就是让小精灵们「随机休假」！训练时，每层有  $p$  概率的小精灵今天不上班——输出要除以  $(1-p)$  保持期望不变。这样每个人都得学会独立工作，不能依赖某个特定同事。测试时大家全员到岗！

思想：训练时随机「丢弃」一部分神经元，迫使网络学习冗余特征。

```
model = nn.Sequential(
 nn.Linear(784, 256),
 nn.ReLU(),
 nn.Dropout(p=0.5), # 50% 概率丢弃
 nn.Linear(256, 128),
 nn.ReLU(),
 nn.Dropout(p=0.5),
 nn.Linear(128, 10)
)
```

💡 核心洞察：Dropout 可以理解为同时训练了  $2^n$  个子网络的集成（Ensemble），推理时使用所有子网络的均值。

## 7-4 归一化方法

### 7-4-1 Batch Normalization ☆

🌟 小精灵说：BatchNorm 就像给小精灵们装了个「自动校准仪」！以前我收到的信号时大时小（数值不稳定），很难统一处理。现在先标准化  $\hat{x} = \frac{x-\mu}{\sigma}$  让数据分布居中，再用可学习的  $\gamma, \beta$  微调尺度—— $y = \gamma \hat{x} + \beta$ 。训练用 batch 统计量，推理用滑动平均！

解决的问题

深度网络中，每一层的输入分布都在变化（Internal Covariate Shift），导致训练不稳定。

公式

$$\hat{x} = \frac{x - \mu_B}{\sqrt{\sigma_B^2 + \epsilon}}$$

$$y = \gamma \hat{x} + \beta$$

其中  $\mu_B$  和  $\sigma_B$  是当前 batch 的均值和标准差， $\gamma$  和  $\beta$  是可学习的缩放和平移参数。

```
nn.BatchNorm1d(num_features) # 全连接层后
nn.BatchNorm2d(num_channels) # 卷积层后
```

💡 核心洞察：BN 保证每层输入在 0 附近、方差为 1，让梯度始终保持合理大小——这是解决梯度消失/爆炸的重要工具。

## 7-4-2 Layer Normalization

与 BN 不同，LN 对每个样本的所有特征做归一化，而不是对每个特征的所有样本。

$$\hat{x}_i = \frac{x_i - \mu_L}{\sqrt{\sigma_L^2 + \epsilon}}$$

适用场景：

- BN: CNN (固定大小的 batch)
- LN: RNN / Transformer (序列长度变化)

## 7-5 权值初始化

### 7-5-1 初始化的重要性

错误初始化的后果

值太大 (如  $W \sim \mathcal{N}(0, 1)$ ):

- Sigmoid/Tanh 进入饱和区 → 梯度接近 0 → 梯度消失
- 深层网络输出爆炸 → NaN

值太小 (如  $W = 0$ ):

- 所有神经元输出相同 → 对称性无法打破 → 所有神经元学成一样
- 信号逐层衰减 → 深层神经元接收不到有效信号

值太巧 (如全 0 或全 1):

- 全 0: 梯度为 0, 不学习
- 全 1: 方差逐层放大, 输出爆炸

数学直觉

考虑一个线性层  $y = Wx$ , 如果  $x_i \sim \mathcal{N}(0, 1)$ ,  $W_{ij} \sim \mathcal{N}(0, \sigma^2)$ :

$$\text{Var}(y_j) = n_{in} \cdot \sigma^2$$

如果  $\sigma^2 = 1$ , 那么  $\text{Var}(y_j) = n_{in}$ ——方差随输入维度线性增长, 深层网络很快爆炸。

解决方案: 让  $\sigma^2 = 1/n_{in}$ , 使得  $\text{Var}(y_j) = 1$ , 方差在各层保持稳定。

7-5-2 常见初始化方法

方法	公式	适用激活函数
Xavier	$W \sim \mathcal{U}(-\sqrt{6/(n_{in} + n_{out})}, \sqrt{6/(n_{in} + n_{out})})$	Sigmoid, Tanh
He	$W \sim \mathcal{N}(0, \sqrt{2/n_{in}})$	ReLU, Leaky ReLU

```
PyTorch 默认初始化
nn.Linear(784, 256) # 默认使用 Kaiming Uniform (He 初始化变体)

显式设置
nn.init.kaiming_normal_(layer.weight, mode='fan_in', nonlinearity='relu')
nn.init.xavier_uniform_(layer.weight, gain=nn.init.calculate_gain('tanh'))
```

7-6 损失函数全景

7-6-1 回归任务

MSE（均方误差）

$$L = \frac{1}{n} \sum_{i=1}^n (y_i - t_i)^2$$

- 特点：误差平方放大——预测偏离 2 的损失是偏离 1 的 4 倍。
- 适合：误差较小、无异常值的场景。
- 问题：对异常值极度敏感——一个离群点可能主导整个损失。

MAE（平均绝对误差）

$$L = \frac{1}{n} \sum_{i=1}^n |y_i - t_i|$$

- 特点：误差线性增长——预测偏离 2 的损失是偏离 1 的 2 倍。
- 适合：存在异常值的场景。
- 问题：在  $y = t$  处不可导，梯度恒为  $\pm 1$ ，收敛不稳定。

Huber Loss：MSE 和 MAE 的折中

Huber Loss：当  $|y - t| \leq \delta$  时为  $\frac{1}{2}(y - t)^2$ （类似 MSE），否则为  $\delta|y - t| - \frac{1}{2}\delta^2$ （类似 MAE）。

特点：误差小时像 MSE（平滑可导），误差大时像 MAE（鲁棒）。

$\delta$  是阈值：控制切换点，通常设为 1。

损失函数	异常值鲁棒性	可导性	收敛速度
MSE	❌ 差	✅ 处处可导	快
MAE	✅ 好	❌ 在 0 处不可导	慢
Huber	✅ 好	✅ 处处可导	中

7-6-2 分类任务

CrossEntropy Loss（交叉熵损失） — 默认选择

$$L = - \sum_{c=1}^K t_c \log y_c$$

特点：预测概率  $y_c$  越接近 1，损失越小；预测错误时损失极大。  
适合：多分类任务，配合 Softmax 使用。  
为什么默认：梯度 =  $y - t$ ，形式简洁，收敛快。

BCE Loss（二分类交叉熵）

$$L = -[t \log y + (1 - t) \log(1 - y)]$$

配合：输出层用 Sigmoid，加 BCEWithLogitsLoss（数值更稳定）。  
Hinge Loss（合页损失）

$$L = \max(0, 1 - t \cdot y)$$

特点：不仅要求分类正确，还要求有足够的置信度（margin）。  
适合：SVM 风格的最大间隔分类。

损失函数	输出层激活	梯度形式	适用场景
CrossEntropy	Softmax	$y - t$ （简洁！）	多分类（默认）
BCE	Sigmoid	$y - t$	二分类
Hinge	线性	$\mathbb{1}_{ty < 1} \cdot (-t)$	最大间隔分类

💡 核心洞察：选损失函数的经验法则——回归用 MSE（无异常值）/ Huber（有异常值），分类用 CrossEntropy（默认）。

## 7-7 Softmax 深度理解 ☆

### 7-7-1 为什么需要 Softmax？

问题：从原始得分到概率分布

神经网络的输出层有  $K$  个神经元，每个输出  $z_k$  称为 logit（对数几率），范围是  $(-\infty, +\infty)$ 。但我们需要将它们转换成概率分布——每个值在  $[0, 1]$  之间且总和为 1。

```
神经网络的原始输出 (logits)
z = torch.tensor([2.0, 1.0, 0.1])

❌ 不能直接解读为概率
1) 概率不能为负数 → logits 可以为负
2) 概率不能 > 1 → logits 可以是 100
3) 概率总和必须为 1 → logits 总和任意
```

为什么不是线性归一化？

- 最简单的想法是： $p_k = \frac{z_k}{\sum_j z_j}$ 。但有两个问题：
- 负数问题： $z_k$  可能为负，归一化后概率小于 0，不合理
  - 差异放大不足：若  $z = [2.0, 1.9, 1.8]$ ，线性归一化得  $[0.35, 0.33, 0.32]$ ，几乎均匀——但模型本应对 2.0 更有信心

Softmax 的两个步骤

Step 1: 指数变换（解决负数 + 放大差异）  
 $e^{z_k}$  将任意实数映射到  $(0, +\infty)$ 。同时，指数函数的形状天然放大了差异： $e^{2.0} = 7.39$ ， $e^{1.8} = 6.05$ ，比例从  $2.0/1.8 = 1.11$  放大到  $7.39/6.05 = 1.22$ 。  
Step 2: 归一化（解决总和为 1）

$p_k = \frac{e^{z_k}}{\sum_j e^{z_j}}$  保证所有  $p_k$  在  $[0, 1]$  且总和为 1。

💡 **核心洞察**：Softmax = 指数函数（放大差异 + 保证正数）+ 归一化（和为1）。它是从实数向量到概率分布的「标准转换器」——几乎所有现代分类神经网络的最后一层。

## 7-7-2 数学推导

定义

对于  $K$  类分类问题，给定原始得分向量  $\mathbf{z} = [z_1, z_2, \dots, z_K]$ ：

$$\text{softmax}(\mathbf{z})_i = \frac{e^{z_i}}{\sum_{j=1}^K e^{z_j}}$$

直观例子

```
z = torch.tensor([2.0, 1.0, 0.1])
probs = torch.softmax(z, dim=0)

计算过程:
exp(z) = [e^2.0, e^1.0, e^0.1] = [7.39, 2.72, 1.11]
sum = 7.39 + 2.72 + 1.11 = 11.22
probs = [7.39/11.22, 2.72/11.22, 1.11/11.22]
= [0.659, 0.242, 0.099] ← 和为 1!
```

```
print(f"Softmax 输出: {probs}")
print(f"总和: {probs.sum().item():.3f}")
```

```
Softmax 输出: tensor([0.659, 0.242, 0.099])
总和: 1.000
```

可以看到，原始得分  $[2.0, 1.0, 0.1]$  经过 Softmax 后变成了合理的概率分布  $[0.659, 0.242, 0.099]$ ——类别 1 的概率最高，且所有概率和为 1。

三个重要性质

1. **单调性**： $z_i > z_j \Rightarrow p_i > p_j$ （原始得分的大小关系在概率中保持）
2. **平移不变性**：对所有  $z_k$  加同一个常数  $c$ ，概率不变（因为分子分母都乘以  $e^c$ ，约掉了）
3. **差值放大**：Softmax 是指数级的——得分差 1 对应概率差约  $e$  倍

数值稳定性

```
def softmax_stable(x):
 """数值稳定的 Softmax"""
 x_max = np.max(x, axis=-1, keepdims=True)
 exp_x = np.exp(x - x_max) # 减最大值, 防止指数溢出
 return exp_x / np.sum(exp_x, axis=-1, keepdims=True)
```

## 7-7-3 Softmax 的导数

为什么需要 Softmax 的导数？

因为反向传播要求损失函数对网络输出的梯度能够「穿过」Softmax 层。如果输出层是 `Linear → Softmax → CrossEntropy`，那么梯度传播涉及 Softmax 的导数。

推导

Softmax 是一个向量到向量的函数： $\mathbb{R}^K \rightarrow \mathbb{R}^K$ ，其导数是一个  $K \times K$  的 Jacobian 矩阵：

$$J = \begin{bmatrix} \frac{\partial p_1}{\partial z_1} & \frac{\partial p_1}{\partial z_2} & \dots & \frac{\partial p_1}{\partial z_1} & \frac{\partial p_1}{\partial z_2} & \dots & \vdots & \vdots & \ddots \\ \vdots & \vdots & \ddots & \vdots & \vdots & \ddots & \vdots & \vdots & \ddots \end{bmatrix}$$



对第  $i$  个输出  $p_i = \frac{e^{z_i}}{\sum_k e^{z_k}}$  求导：

$$\frac{\partial \text{softmax}(\mathbf{z})_i}{\partial z_j} = \frac{\partial}{\partial z_j} \left( \frac{e^{z_i}}{\sum_k e^{z_k}} \right)$$

两种情况：

当  $i = j$  时（对角线元素）：

$$\frac{\partial p_i}{\partial z_i} = \frac{e^{z_i} \cdot \sum -e^{z_i} \cdot e^{z_i}}{(\sum)^2} = p_i - p_i^2 = p_i(1 - p_i)$$

当  $i \neq j$  时（非对角线元素）：

$$\frac{\partial p_i}{\partial z_j} = \frac{0 \cdot \sum -e^{z_i} \cdot e^{z_j}}{(\sum)^2} = -p_i p_j$$

矩阵形式

写成 Jacobian 矩阵：

$$\mathbf{J}_{\text{softmax}} = \text{diag}(\mathbf{p}) - \mathbf{p}\mathbf{p}^T$$

其中  $\text{diag}(\mathbf{p})$  是以  $p_i$  为对角元素的对角矩阵。

可视化直觉

情况	公式	效果
$i = j$ (对角线)	$\partial p_i / \partial z_i = p_i(1-p_i)$	正数，自己的得分提高→自己的概率增加
$i \neq j$ (非对角线)	$\partial p_i / \partial z_j = -p_i \cdot p_j$	负数，别人的得分提高→自己的概率减小

💡 核心洞察：Softmax 的导数本质上是「赢家通吃」机制的平滑版本——提高一个类别的分数，自己的概率增加，其他类别的概率减少。

## 7-7-4 Softmax + 交叉熵的美妙组合

化简的奇迹

当 Softmax 和交叉熵（CrossEntropy Loss）配合使用时，梯度形式优雅地简化了：

$$L = - \sum_{k=1}^K t_k \log p_k, \quad p_k = \frac{e^{z_k}}{\sum_j e^{z_j}}$$

$$\frac{\partial L}{\partial z_i} = p_i - t_i$$

这意味着：Softmax + CrossEntropy 的梯度 = 预测概率 — 真实标签——简单到令人难以置信！

```
Softmax + CrossEntropy 的联合梯度
z = torch.tensor([2.0, 1.0, 0.1], requires_grad=True)
t = torch.tensor([1.0, 0.0, 0.0]) # 真实标签: 类别 0 (one-hot)

p = torch.softmax(z, dim=0)
loss = -torch.sum(t * torch.log(p))
loss.backward()

print(f"Softmax 输出: {p}")
print(f"梯度 ∂L/∂z: {z.grad}")
```

```
print(f"验证 p - t: {p - t}")
```

```
- Softmax 输出: tensor([0.659, 0.242, 0.099])
- 梯度 ∂L/∂z: tensor([-0.341, 0.242, 0.099])
- 验证 p - t: tensor([-0.341, 0.242, 0.099]) ✔️ 一致!
```

### 直觉理解

- 对于正确类别 ( $t_i = 1$ ): 梯度 =  $p_i - 1 < 0$ , 推动  $z_i$  增大 (让正确类的得分更高)
- 对于错误类别 ( $t_i = 0$ ): 梯度 =  $p_i > 0$ , 推动  $z_i$  减小 (让错误类的得分更低)
- 梯度的大小 = 预测错误的程度——越错, 梯度越大

💡 核心洞察: 这就是为什么 PyTorch 的 `nn.CrossEntropyLoss` 内部包含了 Softmax——你只需要在模型最后一层输出 logits, 不需要手动加 Softmax! 梯度计算已经数学化简了。

当 Softmax 和交叉熵损失组合使用时, 梯度形式极其简洁:

$$\frac{\partial L}{\partial z_i} = p_i - t_i$$

即: 预测概率减去真实标签。这是整个分类任务梯度计算的核心公式。

💡 核心洞察: 这就是为什么分类任务总是使用 Softmax + CrossEntropy——它的梯度公式是所有方法中最简洁的。

## 7-8 正则化深入对比

### 7-8-1 L1 vs L2 正则化的本质区别

对比维度	L2 正则化	L1 正则化
惩罚项	$\frac{\lambda}{2} \sum w^2$	$\lambda \sum  w $
梯度	$\lambda w$ (与权重成比例)	$\lambda \cdot \text{sign}(w)$ (常数大小)
效果	权重整体变小 (权重衰减)	产生稀疏权重 (部分权重变为 0)
几何解释	在圆形约束内搜索	在菱形约束内搜索

#### 为什么 L1 产生稀疏解?

L1 正则化的梯度  $\lambda \cdot \text{sign}(w)$  是常数——不管权重值多小, 每次更新都减掉一个固定大小的值。这意味着小权重会被直接减到 0。

```
import numpy as np

def l1_update(w, grad, lr=0.01, lam=0.001):
 """带 L1 正则化的梯度下降"""
 return w - lr * (grad + lam * np.sign(w))

def l2_update(w, grad, lr=0.01, lam=0.001):
 """带 L2 正则化的梯度下降 (权重衰减)"""
 return w * (1 - lr * lam) - lr * grad # 注意参数 w 被衰减了

模拟一个小权重的演化
w_l1, w_l2 = 0.01, 0.01
for i in range(50):
 grad = 0.0 # 假设梯度为 0, 看正则化单独的效果
 w_l1 = l1_update(w_l1, grad, lam=0.01)
 w_l2 = l2_update(w_l2, grad, lam=0.01)
 if i < 5 or i % 10 == 0:
 print(f"step {i:3d}: L1={w_l1:.6f}, L2={w_l2:.6f}")
```

步数	L1 (w=0.01)	L2 (w=0.01)
0	0.009900	0.009900
1	0.009800	0.009801
...	...	...
10	0.000000 ← L1 归零!	0.009049
50	0.000000	0.006066




图 7-6：L1 与 L2 正则化效果对比。

🌟 小精灵说：L1 正则化就像「定期裁员」——不管贡献大小，每个员工每年都要交一笔固定的「管理费」。小贡献的员工（小权重）交不起管理费就被裁掉（归零）。L2 正则化更像「绩效考核」——贡献大的员工（大权重）交的钱多，但不会直接被裁！

7-8-2 Elastic Net：L1 + L2 的组合

$$L_{\text{Elastic}} = L_{\text{orig}} + \lambda_1 \sum |w| + \frac{\lambda_2}{2} \sum w^2$$

Elastic Net 结合了 L1 的稀疏性和 L2 的稳定性——既能做特征选择（L1），又能处理高度相关特征（L2）。

💡 核心洞察：如果特征之间高度相关，L1 会随机选择其中一个而丢弃其他。Elastic Net 会同时保留这些相关特征——这在基因表达数据分析等场景中非常有用。

7-8-3 正则化强度选择

```
正则化强度 λ 的选择策略
def find_best_lambda(model_class, X_train, y_train, X_val, y_val):
 lambdas = [0, 1e-6, 1e-5, 1e-4, 1e-3, 1e-2, 0.1, 1.0]
 best_lambda = None
 best_val_loss = float('inf')

 for lam in lambdas:
 model = model_class(lam=lam)
 model.fit(X_train, y_train)
 val_loss = model.evaluate(X_val, y_val)
 print(f"λ={lam:8}: 验证损失={val_loss:.4f}")

 if val_loss < best_val_loss:
 best_val_loss = val_loss
 best_lambda = lam

 return best_lambda
```

λ 值	效果	适用场景
λ = 0	无正则化	数据量大，模型简单
λ = 10 <sup>-4</sup>	轻微正则化	默认起点

λ 值	效果	适用场景
$\lambda = 10^{-2}$	中等正则化	中度过拟合
$\lambda = 1$	强正则化	严重过拟合或数据极少

## 7-9 超参数调优方法

### 7-9-1 主要超参数一览

神经网络的超参数可以分为三类：

类别	超参数	典型范围	影响
优化	学习率 $\eta$	$10^{-4} \sim 10^{-1}$	最重要，决定训练速度和稳定性
优化	Batch Size	16 ~ 512	影响收敛和内存
优化	动量系数 $\gamma$	0.9 ~ 0.999	加速收敛
正则化	L2 强度 $\lambda$	$10^{-5} \sim 10^{-1}$	控制过拟合
正则化	Dropout 比例 $p$	0.1 ~ 0.5	随机失活比例
架构	隐藏层数	1 ~ 100+	模型容量
架构	每层神经元数	64 ~ 4096	模型宽度

💡 核心洞察：在所有超参数中，学习率是最重要的一个——它单独决定了训练能否成功。一个常见的策略是：先用少量数据跑几次，找到一个合适的学习率范围，然后再调整其他参数。

### 7-9-2 Grid Search vs Random Search

```
import itertools
import random

def grid_search(param_grid, train_fn):
 """网格搜索"""
 keys = param_grid.keys()
 best_score = float('-inf')
 best_params = None

 for values in itertools.product(*param_grid.values()):
 params = dict(zip(keys, values))
 score = train_fn(params)
 if score > best_score:
 best_score = score
 best_params = params
 return best_params, best_score

def random_search(param_dist, train_fn, n_iter=20):
 """随机搜索"""
 best_score = float('-inf')
 best_params = None

 for _ in range(n_iter):
 params = {k: random.choice(v) for k, v in param_dist.items()}
 score = train_fn(params)
 if score > best_score:
 best_score = score
 best_params = params
 return best_params, best_score
```




图 7-7：不同权重初始化方法的梯度流对比。

### 为什么 Random Search 通常优于 Grid Search?

假设只有 2 个超参数重要（比如学习率和 Dropout），其他 3 个不重要。Grid Search 会在所有维度上均匀采样——大部分算力浪费在不重要的参数上。Random Search 在每个维度上随机采样，更有可能探索到重要的参数组合。

🌟 小精灵说：Grid Search 像军训队列——横平竖直，但大部分格子是空的。Random Search 像撒网捕鱼——网撒得开，总有一条鱼会撞上！在高维空间中，随机采样的覆盖效率远高于网格采样。

## 7-9-3 学习率范围测试 (LR Range Test)

在训练开始前，我们可以用一个快速实验找到合适的学习率范围：

```
def lr_range_test(model, dataloader, loss_fn, min_lr=1e-7, max_lr=10, steps=100):
 """学习率范围测试：从小到大调整学习率，观察 loss 变化"""
 lrs = np.logspace(np.log10(min_lr), np.log10(max_lr), steps)
 losses = []

 for lr in lrs:
 # 用当前学习率训练一个 batch
 optimizer = torch.optim.SGD(model.parameters(), lr=lr)
 x, y = next(iter(dataloader))
 pred = model(x)
 loss = loss_fn(pred, y)
 optimizer.zero_grad()
 loss.backward()
 optimizer.step()
 losses.append(loss.item())

 # 画出 lr vs loss 曲线
 plt.semilogx(lrs, losses)
 plt.xlabel('Learning Rate')
 plt.ylabel('Loss')
 plt.title('LR Range Test')
 # 找到 loss 下降最快的区间 → 这就是最佳学习率范围
```

从图中可以观察到：

- 学习率太小 ( $< 1e-5$ )：loss 几乎不变
- 学习率适中 ( $1e-4 \sim 1e-2$ )：loss 快速下降 ← 最佳区间
- 学习率太大 ( $> 1e-1$ )：loss 震荡或发散

💡 核心洞察：LR Range Test 是超参数调优的「第一性原理」——与其猜测学习率，不如直接画一条曲线找出最陡的下降区间！这个技巧来自 fast.ai 的 Leslie Smith 论文。

7-10 梯度裁剪 (Gradient Clipping)

7-10-1 梯度爆炸的解决方案

梯度爆炸是训练深层网络（特别是 RNN）时的常见问题。梯度裁剪是一种简单但有效的解决方案：

$$\text{if } \|g\| > \text{threshold}, \quad g \leftarrow \frac{\text{threshold}}{\|g\|} \cdot g$$

```
import torch.nn.utils as utils

PyTorch 中的梯度裁剪
total_norm = utils.clip_grad_norm_(
 model.parameters(),
 max_norm=1.0, # 梯度范数的上限
 norm_type=2 # L2 范数
)
```

7-10-2 两种梯度裁剪方式

方式	操作	公式
按值裁剪	每个梯度分量限制在 $[-v, v]$ 之间	$g_i \leftarrow \text{clip}(g_i, -v, v)$
按范数裁剪	保持方向不变，缩放整个梯度向量	$g \leftarrow \frac{\text{threshold}}{\ g\ } \cdot g$

🌟 小精灵说：梯度爆炸就像是小精灵们跑得太快刹不住车！梯度裁剪就是给每个小精灵装了个「速度限制器」——你可以按最快的速度跑（梯度方向不变），但最高速度不能超过限速值（threshold）。这样既保持了方向，又避免了失控！

📦 本章代码清单

文件	内容	核心知识点
ch07/NN07_regularization.py	L1 / L2 正则化实现与对比	正则化原理
ch07/NN07_dropout.py	Dropout 实现与效果分析	Dropout 机制
ch07/NN07_batchnorm.py	Batch Normalization 手动实现	归一化技术
ch07/NN07_loss_functions.py	多种损失函数实现与对比	损失函数选择
ch07/NN07_early_stopping.py	早停法实现与过拟合预防	早停策略
ch07/NN07_weight_init_viz.py	权值初始化对比可视化	初始化方法




图 7-3: L2 正则化对比效果。




图 7-4: 过拟合现象——多项式拟合对比。




图 7-5: 不同损失函数曲面。

## 本章小结

### 课后练习

#### 练习 1: 优化器对比实验

```
import torch
import torch.nn as nn
import torch.optim as optim
```

```
在同一个简单问题上比较 SGD, Momentum, Adam 的收敛速度
生成 y = 2x + 1 的数据并加入噪声
用相同的学习率 0.01 训练 100 轮
画出三个优化器的 loss 曲线对比图
```

练习 2：学习率调度实验

对比 StepLR、CosineAnnealingLR 和 ReduceLROnPlateau 三种调度器在同一训练任务上的效果。画出学习率随时间的变化曲线和对应的损失曲线。

练习 3：Dropout 效果可视化

创建一个 3 层网络，在中间层设置 p=0.5 的 Dropout。对比训练模式和评估模式下，同一个输入的输出差异。观察 Dropout 如何使网络输出变得「随机」。

练习 4：L1 vs L2 正则化

在过拟合设置中（少量数据 + 大模型）对比 L1 和 L2 正则化的效果。画出权重分布直方图，观察 L1 如何产生稀疏权重。

练习 5：初始化方法对比

用 Xavier 初始化（适用 tanh）和 He 初始化（适用 ReLU）分别初始化一个 5 层网络。观察每一层输出激活值的方差。不正确的初始化会导致什么现象？

```
def xavier_init(shape):
 limit = np.sqrt(6 / (shape[0] + shape[1]))
 return np.random.uniform(-limit, limit, shape)

def he_init(shape):
 std = np.sqrt(2 / shape[0])
 return np.random.randn(*shape) * std
```

练习 6（挑战题）：综合实验 – 从随机到收敛

构建一个故意不好的训练设置（无正则化、大学习率、坏初始化），观察故障现象。然后逐一修复每个问题，记录每次改进后的 loss 曲线变化。写出「故障诊断报告」。

核心技术脉络

技术	演进路径
优化器	SGD → Momentum → AdaGrad → RMSprop → Adam
学习率调度	StepDecay → CosineAnnealing → ReduceLROnPlateau
正则化	L2 → L1 → Dropout → BatchNorm
初始化	Xavier（配合 tanh）→ He（配合 ReLU）
损失函数	MSE（回归）→ CrossEntropy（分类）

🔥 一句话总结：训练深度网络 = 选对优化器 + 配好学习率 + 加正则化 + 归一化层 + 正确初始化 + 合适损失函数。

核心概念回顾

概念	核心要点
优化器演进	SGD → Momentum → AdaGrad → RMSprop → Adam（自适应学习率 + 动量）
学习率调度	Step Decay → Cosine Annealing → ReduceLROnPlateau（自适应调整）
L2 正则化	$L = L_{orig} + \frac{\lambda}{2} \sum w^2$ ，等价于权重衰减
Dropout	训练时随机丢弃神经元（ $p$ ），测试时全量使用（权重缩放）



概念	核心要点
BatchNorm	每层标准化: $\hat{x} = \frac{x-\mu}{\sigma}$ , 再学 $\gamma, \beta$ 恢复表示力
权重初始化	Xavier (tanh) vs He (ReLU) ——正确初始化对深层网络至关重要
Softmax + CrossEntropy	梯度 $p_i - t_i$ ——分类任务的最优组合

🔥 一句话总结: 训练深度网络 = 选对优化器 + 配好学习率 + 加正则化 + 归一化层 + 正确初始化 + 合适损失函数。

核心公式速查

公式	说明	适用场景
$L_{L2} = L_{orig} + \frac{\lambda}{2} \sum w^2$	L2 正则化 (权重衰减)	防止过拟合
$L_{L1} = L_{orig} + \lambda \sum  w $	L1 正则化 (稀疏性)	特征选择
$w \leftarrow w(1 - \eta\lambda) - \eta \nabla L_{orig}$	L2 的权重衰减效果	训练时自动衰减
$h_{dropout} = h \odot \mathbf{m} / (1 - p), \mathbf{m} \sim \text{Bernoulli}(1 - p)$	Dropout 训练	集成学习近似
$\hat{x}^{(k)} = \frac{x^{(k)} - \mu_B}{\sqrt{\sigma_B^2 + \epsilon}}$	Batch Normalization 标准化	加速收敛
$y^{(k)} = \gamma^{(k)} \hat{x}^{(k)} + \beta^{(k)}$	BN 的缩放和平移	恢复表示能力
$\text{Softmax}(z_i) = \frac{e^{z_i}}{\sum_j e^{z_j}}$	Softmax 函数	多分类概率输出
$\frac{\partial L}{\partial z_i} = p_i - t_i$	Softmax + CrossEntropy 梯度	分类任务核心梯度

## 第 8 章 现代架构：从 ResNet 到 Transformer

🎯 目标：理解深度学习架构的演进脉络——每个架构解决的核心数学问题是什么，从残差连接到 Transformer，用代码一步一步验证。

© xiefujin · Contact: 490021684@qq.com · Licensed under CC BY-NC-SA 4.0

📁 代码文件: [code/ch08/](#) (4 个文件)

插图: [images/ch08/](#) 目录 (5 张可视化图)

### 📖 本章学习目标

- [ ] 理解残差连接如何解决梯度消失
- [ ] 理解 RNN 的数学原理和局限性
- [ ] 理解 LSTM/GRU 的门控机制与梯度传播
- [ ] 理解注意力机制的数学本质
- [ ] 理解 Transformer 的完整架构
- [ ] 能用 PyTorch 实现简化版 Transformer

### 8-1 残差网络 ResNet 深入 🌟

作者：Kaiming He（何恺明）等人于 2015 年提出 Deep Residual Learning，一举解决深层网络的退化问题，让 100+ 层网络成为可能。该论文获得 CVPR 2016 最佳论文奖。

#### 8-1-1 深层网络的困境

##### 实验现象

56 层网络比 20 层网络训练误差更大——这不是过拟合，因为训练误差本身都更大。这是「网络退化」(Degradation) 问题：越深的网络反而越难优化。




图 8-1：网络退化——越深的网络反而越难优化。

💡 核心洞察：退化不是过拟合，因为训练误差本身都更大。这意味着问题是优化困难而非过拟合。

## 梯度消失的数学分析

对于  $L$  层网络，第 1 层的梯度需要穿过  $L - 1$  个激活函数导数：

$$\frac{\partial L}{\partial W^{(1)}} = \underbrace{f'(u^{(L)}) \cdots f'(u^{(1)})}_{L \text{ derivatives}} \times \cdots$$

连乘效应：

- Sigmoid 导数范围  $(0, 0.25] \rightarrow L = 10$  时  $0.25^{10} \approx 10^{-6}$
- ReLU 导数范围  $0, 1 \rightarrow$  缓解但不解决

## 退化的本质：梯度消失 vs 网络退化

两个概念的区别：

问题	表现	原因
梯度消失	浅层梯度极小 $\rightarrow$ 无法学习	激活函数导数连乘 $< 1$
网络退化	深层比浅层更差	恒等映射难以学习（深层 Plain 网络很难学到 $F(x) \approx x$ ）

🌟 小精灵说：想象你有一个 50 层的网络，理想情况下，如果前面 20 层已经学到了很好的特征，后面 30 层应该「什么都不做」——保持恒等映射。但事实证明，让卷积层学出  $F(x) \approx x$  非常困难！这就是退化的数学本质——多层非线性堆叠很难逼近恒等映射。

## 为什么恒等映射难以学习？——三层数学直觉

### ① 权重的随机初始化远离恒等映射

假设一个 2 层 Plain 块  $F(x) = W_2 \cdot \sigma(W_1 x)$ ，其中  $\sigma$  是 ReLU。

- Kaiming 初始化下  $W_1, W_2 \sim \mathcal{N}(0, 2/n_{in})$ ，每个权重的绝对值期望约为  $\sqrt{2/n_{in}}$
- 对于  $n_{in} = 256$ ， $|W_{ij}| \approx 0.088$ ，两个矩阵相乘后  $F(x)$  的尺度完全不是恒等映射
- 需要大量训练才能让权重从随机状态调整到  $F(x) \rightarrow 0$  附近

### ② 非线性激活的「信息损耗」

每经过一次 ReLU，负值信息被完全丢弃：

$$x \xrightarrow{\text{ReLU}} \max(0, x) \xrightarrow{W_1} \text{线性组合} \xrightarrow{\text{ReLU}} \max(0, W_1 \cdot \max(0, x))$$

即使  $W_1 = I$ （单位矩阵），经过两层 ReLU 后：

$$\text{ReLU}(\text{ReLU}(x)) = \max(0, \max(0, x)) = \max(0, x) \neq x$$

负值部分无法恢复！这就是「多层非线性堆叠很难逼近恒等映射」的直观原因。

### ③ 从函数逼近角度看

考虑一个  $L$  层网络  $f_L(x) = (\sigma \circ W_L) \circ \cdots \circ (\sigma \circ W_1)(x)$ 。

要让  $f_L(x) \approx x$ ，需要 每层都接近恒等映射，但非线性的存在使这一约束极强。

用泰勒展开视角：单个非线性层的泰勒展开  $\sigma(Wx) \approx \sigma(0) + \sigma'(0)Wx$ ，多层展开后偏差累积。而残差连接  $y = x + F(x)$  让  $F(x) \rightarrow 0$  即可——不需要修改  $x$ ，只需要让残差分支输出为零。

🌟 小精灵说：这就好比让你 10 秒内写出一手漂亮的字（拟合恒等映射）很难，但让你「什么都不写」（ $F(x) \rightarrow 0$ ）就简单多了！残差连接把「学习完整映射」变成了「学习修正项」——任务难度天差地别！

## 8-1-2 残差连接的数学 🌟

🌟 小精灵说：残差连接就是给我们开了个「VIP 通道」！以前信息要穿过层层关卡（ $F(x)$ ），很容易丢失。现在有了捷径  $y = F(x) + x$ ，梯度可以

直达浅层——就像普通员工可以直接跟 CEO 汇报，不用经过层层审批！这也是 ResNet 能训练 1000+ 层的原因。

### 核心思想

让梯度有一条「高速公路」直达浅层：

$$y = F(x, W_i) + x$$

- $F(x)$  是要学习的残差映射（通常 2-3 层卷积）
- $x$  是通过跳跃连接（shortcut）直接传递的恒等映射

数学之美：如果恒等映射是最优的，网络只需让  $F(x) \rightarrow 0$ ，这比让多层非线性层拟合恒等映射容易得多。

### 反向传播的数学

$$\frac{\partial L}{\partial x} = \frac{\partial L}{\partial y} \cdot \frac{\partial y}{\partial x} = \frac{\partial L}{\partial y} \cdot \left(1 + \frac{\partial F}{\partial x}\right)$$

💡 核心洞察：梯度中有一个恒等项 1！即使  $\frac{\partial F}{\partial x} \rightarrow 0$ ，梯度也能通过 1 直接传播到浅层。这就像给梯度修建了一条「高速公路」。

### 梯度流动：Plain vs ResNet 对比




图 8-2：梯度流对比——Plain 网络梯度衰减约 30 倍（从第 1 层到第 15 层），而 ResNet 仅衰减约 1.7 倍，这就是恒等项 1 的威力！

运行 `code/ch08/NN08_resnet_gradient_flow.py` 即可复现此图：

```
python3 code/ch08/NN08_resnet_gradient_flow.py
```

### Python 实现 Residual Block

```
class ResidualBlock(nn.Module):
 def __init__(self, in_channels, out_channels, stride=1):
 super().__init__()
 self.conv1 = nn.Conv2d(in_channels, out_channels, 3,
 stride=stride, padding=1, bias=False)
 self.bn1 = nn.BatchNorm2d(out_channels)
 self.conv2 = nn.Conv2d(out_channels, out_channels, 3,
 padding=1, bias=False)
 self.bn2 = nn.BatchNorm2d(out_channels)


 # 跳跃连接：维度不匹配时使用 1x1 卷积
 self.shortcut = nn.Sequential()
 if stride != 1 or in_channels != out_channels:
 self.shortcut = nn.Sequential(
 nn.Conv2d(in_channels, out_channels, 1,
 stride=stride, bias=False),
 nn.BatchNorm2d(out_channels)
)

 def forward(self, x):
```

```
out = torch.relu(self.bn1(self.conv1(x)))
out = self.bn2(self.conv2(out))
out += self.shortcut(x) # 跳跃连接 ☆
out = torch.relu(out)
return out
```

8-1-3 Bottleneck 设计详解 NEW

Bottleneck 是 ResNet 能堆到 50/101/152 层的工程关键。它通过「降维→卷积→升维」三步大幅减少参数量：



设计哲学

步骤	操作	维度变化	目的
① 降维	$1 \times 1$ 卷积	$256 \rightarrow 64$	将高维特征压缩到低维，减少后续计算量
② 卷积	$3 \times 3$ 卷积	$64 \rightarrow 64$	在低维空间中进行空间特征提取
③ 升维	$1 \times 1$ 卷积	$64 \rightarrow 256$	将特征恢复到高维，保持维度一致

🌟 小精灵说：Bottleneck 就像快递分拣中心——先把大包裹（256 维）压缩到小空间（64 维）处理，处理完再恢复原样！这样既完成了任务，又大幅降低了成本。

为什么  $1 \times 1$  卷积能降维/升维？——数学本质

$1 \times 1$  卷积是理解 Bottleneck 的关键。它的数学本质是跨通道的线性组合（全连接层）：

$$\text{Conv}_{1 \times 1}(x)_{i,j,k} = \sum_{c=1}^{C_{\text{in}}} W_{k,c} \cdot x_{i,j,c} + b_k$$

其中  $W \in \mathbb{R}^{C_{\text{out}} \times C_{\text{in}}}$  是可学习的权重矩阵：

- 降维：  $C_{\text{in}} \gg C_{\text{out}}$  （如  $256 \rightarrow 64$ ）——将高维特征压缩到低维子空间
- 升维：  $C_{\text{in}} \ll C_{\text{out}}$  （如  $64 \rightarrow 256$ ）——从低维子空间恢复到高维空间

与传统卷积的对比：

卷积类型	感受野	计算量 ( $C_{\text{in}}! = !C_{\text{out}}! = !256!$ )	功能
$3 \times 3$ 卷积	$3 \times 3$ 空间邻域	$3 \times 3 \times 256 \times 256 = 589,824$	空间 + 通道特征提取
$1 \times 1$ 卷积	单个像素（无空间信息）	$1 \times 1 \times 256 \times 256 = 65,536$	仅通道混合（降维/升维）

$1 \times 1$  卷积的计算量只有  $3 \times 3$  的  $1/9$ ，但完成了同样的通道数变换任务！

🌟 小精灵说：假设你要把一堆文件从大办公室（256 人）搬到另一个大办公室（256 人）。 $3 \times 3$  卷积是每个人都要跟周围邻居交换信息后再搬家——效率低。 $1 \times 1$  卷积是直接按名单分配座位——只用  $1/9$  的时间！Bottleneck 先用  $1 \times 1$  把 256 人精简到 64 人小组，处理完再用  $1 \times 1$  恢复到 256 人，这就是它节省 17 倍参数量的数学秘密！

参数量对比

对比两种残差块（输出 256 通道时）：

块类型	结构	参数量	相对大小
Basic Block	$3 \times 3 \rightarrow 3 \times 3$	$\approx 118$ 万	$1 \times$

块类型	结构	参数量	相对大小
Bottleneck	$1 \times 1 \rightarrow 3 \times 3 \rightarrow 1 \times 1$	$\approx 7$ 万	1/17

运行 `code/ch08/NN08_resnet_bottleneck.py` 查看完整对比：

python3 code/ch08/NN08\_resnet\_bottleneck.py

```
class Bottleneck(nn.Module):
 expansion = 4

 def __init__(self, in_planes, planes, stride=1):
 super().__init__()
 # ① 1×1 降维
 self.conv1 = nn.Conv2d(in_planes, planes, 1, bias=False)
 self.bn1 = nn.BatchNorm2d(planes)
 # ② 3×3 卷积 (在低维空间中)
 self.conv2 = nn.Conv2d(planes, planes, 3, stride=stride, padding=1, bias=False)
 self.bn2 = nn.BatchNorm2d(planes)
 # ③ 1×1 升维
 self.conv3 = nn.Conv2d(planes, planes * self.expansion, 1, bias=False)
 self.bn3 = nn.BatchNorm2d(planes * self.expansion)

 self.shortcut = nn.Sequential()
 if stride != 1 or in_planes != planes * self.expansion:
 self.shortcut = nn.Sequential(
 nn.Conv2d(in_planes, planes * self.expansion, 1,
 stride=stride, bias=False),
 nn.BatchNorm2d(planes * self.expansion)
)

 def forward(self, x):
 out = F.relu(self.bn1(self.conv1(x))) # 降维
 out = F.relu(self.bn2(self.conv2(out))) # 卷积
 out = self.bn3(self.conv3(out)) # 升维
 out += self.shortcut(x) # 残差连接
 return F.relu(out)
```

何时使用哪种 Block?

ResNet 版本	Block 类型	层数	适用场景
ResNet-18/34	Basic Block	浅层	小数据集、快速实验
ResNet-50/101/152	Bottleneck	深层	ImageNet、大数据

💡 核心洞察：Bottleneck 的巧妙之处在于—— $1 \times 1$  卷积充当了「信息漏斗」，在计算昂贵的  $3 \times 3$  卷积之前大幅压缩特征维度。没有这个设计，ResNet-152 的参数量将大到不可接受。

8-1-4 Pre-activation ResNet (v2) NEW

ResNet v2 (He et al., Identity Mappings in Deep Residual Networks, 2016) 对残差块的激活顺序做了改进：

版本	结构	梯度路径
v1 (Post-activation)	conv → BN → ReLU → conv → BN → +shortcut → ReLU	需要穿过 ReLU
v2 (Pre-activation)	BN → ReLU → conv → BN → ReLU → conv → +shortcut	直接通过恒等路径

为什么 Pre-activation 更好?

v2 的关键改进是把 BN + ReLU 移到卷积之前。这样做的好处：

- 1. 梯度路径更干净： $y = x + F(BN(ReLU(x)))$ ，梯度可直接通过  $x$  传播
- 2. 训练更稳定：BN 在残差分支内，不污染恒等路径
- 3. 更易训练超深网络：1000+ 层的 ResNet v2 训练更稳定

## 梯度分析: v1 vs v2 的数学对比

让我们从梯度角度深入分析两种设计的本质差异。

### v1 (Post-activation) 的梯度流

v1 的前向:  $y = \text{ReLU}(F(x) + x)$

反向传播时, 梯度需要穿过 ReLU 的导数:

$$\frac{\partial L}{\partial x} = \frac{\partial L}{\partial y} \cdot \mathbb{1}_{F(x)+x>0} \cdot \left(1 + \frac{\partial F}{\partial x}\right)$$

其中  $\mathbb{1}_{F(x)+x>0}$  是 ReLU 的门控函数——当输入为负时, 梯度被完全阻断。这意味着:

- 如果  $F(x) + x < 0$  (例如 BatchNorm 的偏移训练后为负), 梯度完全消失
- 恒等路径上有一个「开关」, 开关关上时梯度为 0
- 对于超深网络, ReLU 截断是梯度消失的一个重要来源

### v2 (Pre-activation) 的梯度流

v2 的前向:  $y = x + F(\text{BN}(\text{ReLU}(x)))$

反向传播:

$$\frac{\partial L}{\partial x} = \frac{\partial L}{\partial y} \cdot \left(1 + \frac{\partial F}{\partial \hat{x}} \cdot \frac{\partial \text{BN}}{\partial \hat{x}} \cdot \mathbb{1}_{x>0}\right)$$

关键差异: 恒等项 **1** 不再被 ReLU 门控! ReLU 只在残差分支内部, 不影响主路径的梯度传播。

方面	v1 (Post-activation)	v2 (Pre-activation)
恒等路径	$x \rightarrow \text{ReLU} \rightarrow \dots$	$x \rightarrow \dots$ 直通
负梯度处理	被 ReLU 截断	通过恒等路径自由流通
训练 100+ 层	不稳定 (ReLU 阻塞累积)	稳定 (恒等路径无阻塞)

🌟 小精灵说: v1 就像高速公路 (恒等路径) 上有个检查站 (ReLU), 检查站一关门 (输入为负) 所有车都过不去。v2 把检查站搬到了辅路 (残差分支), 主路永远畅通无阻! 这就是为什么 v2 能训练 1000+ 层网络的原因。

```
class PreActBlock(nn.Module):
 def __init__(self, in_channels, out_channels, stride=1):
 super().__init__()
 self.bn1 = nn.BatchNorm2d(in_channels)
 self.conv1 = nn.Conv2d(in_channels, out_channels, 3,
 stride=stride, padding=1, bias=False)
 self.bn2 = nn.BatchNorm2d(out_channels)
 self.conv2 = nn.Conv2d(out_channels, out_channels, 3,
 padding=1, bias=False)
 self.shortcut = nn.Sequential()
 if stride != 1 or in_channels != out_channels:
 self.shortcut = nn.Sequential(
 nn.Conv2d(in_channels, out_channels, 1,
 stride=stride, bias=False),
)

 def forward(self, x):
 # Pre-activation: 先 BN+ReLU, 再卷积 🌟
 out = self.conv1(F.relu(self.bn1(x)))
 out = self.conv2(F.relu(self.bn2(out)))
 out += self.shortcut(x) # 不需要最后的 ReLU
 return out
```

💡 核心洞察: v1 的路径是  $y = \text{ReLU}(F(x) + x)$ , ReLU 在主路径上会阻塞负梯度的传播。v2 将 ReLU 移入残差分支  $y = x + F(\text{BN}(\text{ReLU}(x)))$ , 恒等路径完全无阻塞。这个小改动对超深网络 (100+ 层) 影响巨大!

运行 `code/ch08/NN08_resnet_block.py` 查看两种实现的对比。

## 8-1-5 实验：Plain vs ResNet 对比 NEW

### 实验一：梯度流可视化

对比 15 层 Plain 网络和 15 层 ResNet 的梯度幅值：

```
详见 code/ch08/NN08_resnet_gradient_flow.py
>>> python3 code/ch08/NN08_resnet_gradient_flow.py
```

各层梯度幅值（从浅层到深层）：

层号	Plain 梯度	ResNet 梯度	Ratio
1	1.39e+02	1.40e+01	0.10
5	3.29e+01	8.38e+00	0.25
10	4.94e+00	8.23e+00	1.67
15	4.60e+00	7.78e+00	1.69

数值总结：

Plain 网络 - 第1层梯度：1.39e+02，最后1层：4.60e+00 → \*\*衰减 30 倍\*\*

ResNet - 第1层梯度：1.40e+01，最后1层：7.78e+00 → \*\*仅衰减 1.7 倍\*\*

结论：残差连接让梯度衰减从 30 倍降到了 1.7 倍——恒等项 **1** 的威力！

### 实验二：训练对比

在合成数据上训练 8 层 PlainNet vs 8 层 ResNet：

```
详见 code/ch08/NN08_resnet_training.py
>>> python3 code/ch08/NN08_resnet_training.py
```

PlainNet: 最终 loss = 1.0348 → 深层学不动

ResNet: 最终 loss = 0.1685 → 残差连接让所有层都能学到

ResNet loss 比 PlainNet 低 6.14 倍!




图 8-3: PlainNet vs ResNet 训练 Loss 对比——ResNet 通过残差连接实现了约 6 倍的 loss 降低。

### 实验总结

指标	PlainNet (8 层)	ResNet (8 层)	提升
最终训练 Loss	≈ 1.03	≈ 0.17	6.1×
梯度衰减 (浅层→深层)	≈ 30 倍	≈ 1.7 倍	17.6×
收敛速度	慢	快	

小精灵说：这两个实验分别从「梯度视角」和「训练视角」证明了残差连接的效果。梯度流实验告诉你「为什么」——恒等项 **1** 让梯度直达浅



层；训练实验告诉你「结果」——ResNet 确实学得更好！

8-1-6 ResNet 系列完整网络结构 NEW

了解了 Basic Block 和 Bottleneck 之后，让我们看完整的 ResNet 系列如何配置。

五种经典 ResNet 的层数构成

ResNet 的名称（如 ResNet-50）中的数字代表卷积层 + 全连接层的总数：

版本	Block 类型	layer1	layer2	layer3	layer4	总层数	Top-5 错误率 (ImageNet)
ResNet-18	BasicBlock	2	2	2	2	18	10.92%
ResNet-34	BasicBlock	3	4	6	3	34	8.69%
ResNet-50	Bottleneck	3	4	6	3	50	7.02%
ResNet-101	Bottleneck	3	4	23	3	101	6.21%
ResNet-152	Bottleneck	3	8	36	3	152	5.71%

层数计算示例（ResNet-50）：

$$2(\text{conv1}) + \underbrace{3 \times 3}_{\text{layer1}} + \underbrace{4 \times 3}_{\text{layer2}} + \underbrace{6 \times 3}_{\text{layer3}} + \underbrace{3 \times 3}_{\text{layer4}} + 1(\text{fc}) = 2 + 9 + 12 + 18 + 9 + 1 = 50$$

各层的通道数和输出尺寸

层名	输出尺寸	ResNet-18	ResNet-34	ResNet-50	ResNet-101	ResNet-152
conv1	112 × 112	7 × 7, 64, stride 2	同左	同左	同左	同左
max pool	56 × 56	3 × 3, stride 2	同左	同左	同左	同左
layer1	56 × 56	[3 × 3, 64 3 × 3, 64] × 2	[3 × 3, 64 3 × 3, 64] × 3	[1 × 1, 64 3 × 3, 64 1 × 1, 256] × 3	×3	×3
layer2	28 × 28	[3 × 3, 128 3 × 3, 128] × 2	[3 × 3, 128 3 × 3, 128] × 4	[1 × 1, 128 3 × 3, 128 1 × 1, 512] × 4	×4	×8
layer3	14 × 14	[3 × 3, 256 3 × 3, 256] × 2	[3 × 3, 256 3 × 3, 256] × 6	[1 × 1, 256 3 × 3, 256 1 × 1, 1024] × 6	×23	×36
layer4	7 × 7	[3 × 3, 512 3 × 3, 512] × 2	[3 × 3, 512 3 × 3, 512] × 3	[1 × 1, 512 3 × 3, 512 1 × 1, 2048] × 3	×3	×3
avg pool	1 × 1	全局平均池化	同左	同左	同左	同左
fc	1000	全连接层	同左	同左	同左	同左
参数量		11.7M	21.8M	25.6M	44.5M	60.2M

关键观察

- 1. ResNet-18/34 使用 BasicBlock：每层通道数递进 64 → 128 → 256 → 512，空间尺寸递减 56 → 28 → 14 → 7
- 2. ResNet-50/101/152 使用 Bottleneck：Bottleneck 的 expansion=4，所以内部通道 = 输出通道/4（如 layer1 输出 256 维，内部用 64 维）
- 3. ResNet-152 的 layer3 最深（36 个 Bottleneck），这是因为 14 × 14 分辨率下参数效率最高
- 4. 参数量增长远小于层数增长：ResNet-152 的参数量（60.2M）只有 ResNet-50（25.6M）的 2.4 倍，但层数是 3 倍——得益于 Bottleneck 的高效设计

💡 核心洞察：从 ResNet-18 到 ResNet-152，通过增加 Bottleneck 数量（主要在 layer3），以相对平缓的参数量增长实现了深度的大幅提升。这是 Bottleneck 「降维→卷积→升维」设计的最大胜利。读者可以运行 `code/ch08/NN08_resnet_series.py` 查看各版本的完整定义。

8-1-7 消融实验与设计选择 NEW

原文 (He et al., 2015) 通过一系列消融实验 (Ablation Study) 验证了残差连接各设计选择的必要性。

实验一：恒等 shortcut vs 投影 shortcut

ResNet 的 shortcut 有三种候选方案：

方案	公式	含义	参数量	效果
A	$y = F(x) + x$	恒等 shortcut, 维度不匹配时零填充	0	最好
B	$y = F(x) + W_s x$	维度不匹配时用投影 shortcut	少量	稍好但有新参数
C	$y = F(x) + W_s x$	所有 shortcut 都用投影	最多	不如 A

结果：方案 A (恒等捷径+零填充) 已经足够好。增加投影参数反而可能导致过拟合。这也印证了残差连接的核心——恒等映射  $x$  本身已经是最优。

实验二：Bottleneck 中 shortcut 的位置

在 Bottleneck 中，是否应该在降维后的 64 维空间做 shortcut？

降维 → 卷积 → 升维 → +shortcut

对比另一种方案：

降维 → 卷积 → 升维 → +shortcut<sub>高维</sub>

结果：在高维空间做 shortcut 效果更好。因为在低维空间做 shortcut 会丢失高维信息。

实验三：不同深度的退化现象

网络	20 层训练误差	56 层训练误差	退化程度
Plain	较低	更高	✗ 严重退化
ResNet	较低	更低	✓ 无退化

这个实验清楚地表明：退化不是优化器的问题，而是网络结构的问题。ResNet 通过残差连接彻底解决了这一困境。

🌟 小精灵说：消融实验就像科学实验中的「控制变量法」——每次只改一个东西，看看效果如何。原文通过三个精心设计的实验，证明了残差连接的设计不是偶然，而是每个选择都有充分的数学和实验依据！

8-1-8 ResNet 之后：架构演进与影响 NEW

残差连接的提出彻底改变了深度学习的面貌。以下是受启发的重要演进：

关键改进方向

方向	代表工作	核心思想	与 ResNet 的关系
更宽	Wide ResNet (2016)	加宽通道数 ( $k$ 倍)，减少层数	宽度 $\times k$ ，深度 $\div 2$ ，训练更快
更分裂	ResNeXt (2017)	分组卷积 + 多个路径	每个路径包含瓶颈结构，最后求和
更密集	DenseNet (2017)	每层与之前所有层连接	极端化的「短连接」—— $x_l = H_l([x_0, x_1, \dots, x_{l-1}])$
更动态	SENet (2018)	通道注意力：SE Block	在残差分支中加入「通道重标定」
更高效	MobileNetV2 (2018)	倒置残差 + 线性瓶颈	先升维再降维的「沙漏」结构

残差连接在 Transformer 中的核心角色

值得注意的是，在第 8 章的后半部分（8-5 Transformer），残差连接是 Transformer 的四大核心组件之一：

$$\text{Output} = \text{LayerNorm}(x + \text{Sublayer}(x))$$

- Encoder 的 6 层堆叠中，每层都包含残差连接
- 梯度可以跳过 6 个注意力 + 6 个 FFN，直接流回 Embedding 层
- 即使 Transformer 有 12 个子层，训练仍然稳定——这全是残差连接的功劳

🌟 小精灵说：ResNet 诞生于 2015 年，它提出的残差连接影响了此后几乎所有深度学习架构——Transformer、GAN、扩散模型（Diffusion）、Vision Transformer……包括你现在用 GPT 和我聊天，我的底层架构也用了残差连接！这就是「一个数学思想改变整个领域」的最好例子。

8-2 循环神经网络与序列建模

8-2-1 RNN 的数学原理

核心思想

RNN 的核心理念是状态共享——与全连接网络每层使用不同权重不同，RNN 在所有时间步共享同一组权重矩阵：

$$\mathbf{h}_t = \tanh(\mathbf{W}_{xh}\mathbf{x}_t + \mathbf{W}_{hh}\mathbf{h}_{t-1} + \mathbf{b}_h)$$

参数说明

符号	含义	形状
$\mathbf{x}_t$	第 $t$ 步的输入	$(d_{in},)$
$\mathbf{h}_{t-1}$	上一步的隐状态	$(d_h,)$
$\mathbf{h}_t$	当前步的隐状态	$(d_h,)$
$\mathbf{W}_{xh}$	输入到隐状态的权重	$(d_{in}, d_h)$
$\mathbf{W}_{hh}$	隐状态到隐状态的权重	$(d_h, d_h)$

展开计算图

RNN 在时间维度上展开后，等价于一个非常深的共享权重的全连接网络：

RNN 在时间维度的展开：  
$$\mathbf{h}_0 \rightarrow \mathbf{h}_1 = \tanh(\mathbf{W}_{xh} \cdot \mathbf{x}_1 + \mathbf{W}_{hh} \cdot \mathbf{h}_0) \rightarrow \mathbf{h}_2 = \tanh(\mathbf{W}_{xh} \cdot \mathbf{x}_2 + \mathbf{W}_{hh} \cdot \mathbf{h}_1) \rightarrow \dots$$
  
所有权重  $\mathbf{W}_{xh}$ ,  $\mathbf{W}_{hh}$  在所有时间步共享。

Python 一步实现

```
def rnn_step(x_t, h_prev, W_xh, W_hh, b_h):
 """RNN 单步前向传播"""
 h_t = np.tanh(x_t @ W_xh + h_prev @ W_hh + b_h)
 return h_t

完整序列前向传播
def rnn_forward(X, h0, W_xh, W_hh, b_h):
 """X: (T, d_in), 输出: (T, d_h)"""
 h = h0
 outputs = []
 for t in range(len(X)):
 h = rnn_step(X[t], h, W_xh, W_hh, b_h)
 outputs.append(h)
```

```
h = rnn_step(X[t], h, W_xh, W_hh, b_h)
outputs.append(h)
return np.array(outputs)
```

## 8-2-2 RNN 的梯度问题

### 反向传播通过时间 (BPTT)

RNN 的损失关于隐藏状态  $h_t$  的梯度需要通过所有之前的时间步传播回去：

$$\frac{\partial L}{\partial h_t} = \frac{\partial L}{\partial h_T} \cdot \prod_{k=t+1}^T \frac{\partial h_k}{\partial h_{k-1}}$$

其中每个时间步的雅可比矩阵为：

$$\frac{\partial h_k}{\partial h_{k-1}} = \text{diag}(\tanh'(\mathbf{W}_{hh}h_{k-1} + \mathbf{W}_{xh}x_k)) \cdot \mathbf{W}_{hh}^T$$

### 梯度消失的数学原因

这个连乘中包含两个因素：

1.  $\tanh'$  的缩放：导数范围  $(0, 1]$ ，大部分区域小于 1，连乘后指数衰减
2.  $\mathbf{W}_{hh}$  的特征值：若最大特征值  $|\lambda_{\max}| < 1$ ，则  $\|\mathbf{W}_{hh}^T\|^T$  指数衰减

数值示例：假设  $\tanh' \approx 0.5$ ， $\|\mathbf{W}_{hh}\| \approx 0.8$ ，经过  $T = 100$  个时间步：

$$\left\| \frac{\partial h_T}{\partial h_0} \right\| \approx (0.5 \times 0.8)^{100} = 0.4^{100} \approx 10^{-40}$$

这意味着  $t = 1$  时刻的隐状态几乎收不到任何梯度信号——RNN 完全无法学习长程依赖。

### 梯度爆炸的处理：梯度裁剪

如果  $\|\mathbf{W}_{hh}\| > 1$ ，梯度会指数爆炸。解决方法是对梯度进行范数裁剪：

$$\text{if } \|\mathbf{g}\| > c, \quad \mathbf{g} \leftarrow \frac{c}{\|\mathbf{g}\|} \cdot \mathbf{g}$$

💡 **核心洞察**：RNN 的 BPTT 本质上是一个在时间维度上展开的深层网络——时间步越长，网络越深，梯度消失/爆炸越严重。LSTM 的解决方案是引入「记忆细胞」和「加法门」，让梯度可以不经衰减地跨越时间步。

## 8-3 从 RNN 到 LSTM/GRU：门控机制详解

### 8-3-1 从 RNN 到门控：梯度问题的解决思路

如 8-2-2 节所分析，RNN 的梯度消失源于 BPTT 中梯度连乘的双重衰减—— $\tanh'$  的缩放（ $(0, 1]$ ）与  $\mathbf{W}_{hh}$  特征值（当  $|\lambda_{\max}| < 1$  时指数衰减）。当  $\mathbf{W}_{hh}$  的特征值  $> 1$  时梯度爆炸， $< 1$  时梯度消失——这使得朴素 RNN 完全无法学习长程依赖。解决这个问题的关键，就是下面要介绍的门控机制。

🌟 **小精灵说**：想象你在山谷里喊话，回声要传回  $k$  秒前的位置。每传 1 秒，声音就衰减一次。传 10 秒后几乎听不见了——这就是梯度消失！而 LSTM 就像给回声加了「中继放大器」——每个时刻都能保持信号强度！

### 8-3-2 LSTM——长短期记忆网络

LSTM 的核心创新是门控机制——三个门（遗忘门、输入门、输出门）和一个记忆细胞（Cell State）：

$$\mathbf{f}_t = \sigma(\mathbf{W}_f[\mathbf{h}_{t-1}, \mathbf{x}_t] + \mathbf{b}_f) \quad (\text{forget gate})$$

$$\mathbf{i}_t = \sigma(\mathbf{W}_i[\mathbf{h}_{t-1}, \mathbf{x}_t] + \mathbf{b}_i) \quad (\text{input gate})$$

$$\tilde{\mathbf{C}}_t = \tanh(\mathbf{W}_C[\mathbf{h}_{t-1}, \mathbf{x}_t] + \mathbf{b}_C) \quad (\text{candidate memory})$$

$$\mathbf{C}_t = \mathbf{f}_t \odot \mathbf{C}_{t-1} + \mathbf{i}_t \odot \tilde{\mathbf{C}}_t \quad (\text{cell state update})$$

$$\mathbf{o}_t = \sigma(\mathbf{W}_o[\mathbf{h}_{t-1}, \mathbf{x}_t] + \mathbf{b}_o) \quad (\text{output gate})$$

$$\mathbf{h}_t = \mathbf{o}_t \odot \tanh(\mathbf{C}_t) \quad (\text{hidden state})$$

门	功能	取值范围	类比
遗忘门 $\mathbf{f}_t$	决定丢弃多少旧记忆	[0, 1]	选择性遗忘
输入门 $\mathbf{i}_t$	决定写入多少新信息	[0, 1]	选择性记忆
输出门 $\mathbf{o}_t$	决定展示多少信息	[0, 1]	选择性表达

为什么 LSTM 能缓解梯度消失？

关键在于记忆细胞  $\mathbf{C}_t$  的更新公式是加法而非乘法：

$$\mathbf{C}_t = \mathbf{f}_t \odot \mathbf{C}_{t-1} + \mathbf{i}_t \odot \tilde{\mathbf{C}}_t$$

对  $\mathbf{C}_{t-1}$  求导：

$$\frac{\partial \mathbf{C}_t}{\partial \mathbf{C}_{t-1}} = \text{diag}(\mathbf{f}_t) + \cdots$$

这里有一个恒等通路！当遗忘门  $\mathbf{f}_t \approx \mathbf{1}$ （模型决定「记住」）时， $\partial \mathbf{C}_t / \partial \mathbf{C}_{t-1} \approx \mathbf{I}$ 。梯度可以不经衰减地在时间轴上传播——跨过任意多个时间步：

$$\frac{\partial \mathbf{C}_T}{\partial \mathbf{C}_0} \approx \prod_{t=1}^T \text{diag}(\mathbf{f}_t) \approx \mathbf{I} \quad (\text{当 } \mathbf{f}_t \rightarrow \mathbf{1})$$

对比 RNN 的  $\partial \mathbf{h}_t / \partial \mathbf{h}_{t-1} = \tanh' \cdot \mathbf{W}_{hh}^T$ （总是小于 1 的乘法），LSTM 的梯度通路是加法 + 恒等映射——这正是 ResNet 残差连接思想的前身！

 小精灵说：LSTM 的记忆细胞就像一个「高速公路」——如果遗忘门开着 ( $\mathbf{f}_t \approx \mathbf{1}$ )，信息可以一路畅通无阻地从  $t = 0$  传到  $t = 100$ ，梯度也一样！这就是 LSTM 能记住「很久很久以前」的信息的数学秘密。

8-3-3 GRU——LSTM 的简化版

GRU (Gated Recurrent Unit) 将 LSTM 的三个门简化为两个——更新门和重置门：

$$\mathbf{z}_t = \sigma(\mathbf{W}_z[\mathbf{h}_{t-1}, \mathbf{x}_t]) \quad (\text{update gate})$$

$$\mathbf{r}_t = \sigma(\mathbf{W}_r[\mathbf{h}_{t-1}, \mathbf{x}_t]) \quad (\text{reset gate})$$

$$\tilde{\mathbf{h}}_t = \tanh(\mathbf{W}[\mathbf{r}_t \odot \mathbf{h}_{t-1}, \mathbf{x}_t]) \quad (\text{candidate hidden state})$$

$$\mathbf{h}_t = (1 - \mathbf{z}_t) \odot \mathbf{h}_{t-1} + \mathbf{z}_t \odot \tilde{\mathbf{h}}_t \quad (\text{hidden state})$$

特征	RNN	LSTM	GRU
门控数量	0	3（遗忘+输入+输出）	2（更新+重置）
记忆单元	无	有（Cell State）	无（只有隐藏状态）
参数量	最少	最多	中等
梯度消失	❌ 严重	✅ 大幅缓解	✅ 缓解
训练速度	最快	最慢	中等

💡 **核心洞察：**GRU 是 LSTM 的「精简版」——用更少的参数实现了接近 LSTM 的效果。在实践中，LSTM 和 GRU 的选择通常取决于任务和数据量。LSTM 参数量大，适合数据充足的场景；GRU 更轻量，适合小数据集或快速迭代。

8-4 注意力机制深入 ⭐

8-4-1 什么是注意力？

🧚 **小精灵说：**注意力机制就是让小精灵们开「全员信息共享会」！每个词（小精灵）都向所有其他词提问（Query）、展示自己（Key）、分享信息（Value）。 $\text{softmax}(QK^T/\sqrt{d_k})$  就是计算谁和谁更相关。与传统 RNN 不同，Attention 让所有位置直接对话！

注意力 = 加权求和——不是平等对待所有输入，而是关注重要部分。

数学本质

在序列到序列的任务中，生成每个输出时，对不同位置的输入赋予不同权重：

$$\text{Attention}(Q, K, V) = \text{softmax}\left(\frac{QK^T}{\sqrt{d_k}}\right)V$$

符号	含义	类比
$Q$ (Query)	当前要关注什么	你在找什么
$K$ (Key)	每个位置有什么信息	每个位置的内容标签
$V$ (Value)	每个位置的实际信息	每个位置的实质内容

直觉：Query 和 Key 计算相似度（注意力分数），然后用分数加权 Value。

缩放点积注意力

```
def scaled_dot_product_attention(Q, K, V, mask=None):
 """缩放点积注意力"""
 d_k = Q.shape[-1]
 scores = Q @ K.transpose(-2, -1) / np.sqrt(d_k) # 注意力分数

 if mask is not None:
 scores = scores.masked_fill(mask == 0, -1e9) # 掩码
```

```

attn_weights = torch.softmax(scores, dim=-1) # 注意力权重
output = attn_weights @ V # 加权求和
return output, attn_weights

```

💡 核心洞察：注意力机制 = 软寻址——Query 是寻址信号，Key 是地址，Value 是存储内容。

## 8-5 Transformer 完整架构 ★

### 8-5-1 总体架构

Transformer 的核心设计思想：抛弃循环结构，完全依赖注意力机制捕捉序列依赖。下图是一个 Transformer Block 的完整结构（Encoder 中的一个层）：

Transformer Block 内部结构（自上而下）：

1. 输出投影（全连接层）
2. Add & Norm（残差连接 + LayerNorm）
3. 前馈网络 FFN（两个线性层 + ReLU）
4. Add & Norm（残差连接 + LayerNorm）
5. 多头注意力 Multi-Head Attention
6. 输入 = 位置编码 + Token 嵌入

#### 四个核心组件的数学功能

组件	数学公式	功能
多头注意力	$\text{MultiHead}(Q, K, V) = \text{Concat}(\text{head}_1, \dots, \text{head}_h)W_O$	捕捉序列中所有位置的依赖关系
前馈网络 (FFN)	$\text{FFN}(x) = W_2 \cdot \text{ReLU}(W_1 x + b_1) + b_2$	对每个位置独立做非线性变换
残差连接	$x' = x + \text{Sublayer}(x)$	让梯度直接流过，解决深层网络退化
LayerNorm	$\text{LayerNorm}(x) = \gamma \odot \frac{x - \mu}{\sigma} + \beta$	稳定训练，加速收敛

#### 为什么这样设计？

1. 注意力负责「交流」：不同位置的 token 通过注意力机制互相交换信息
2. FFN 负责「思考」：每个 token 独立对融合后的信息做非线性变换
3. 残差连接确保「梯度高速公路」：即使 100 层网络，梯度也能直接流回第一层
4. LayerNorm 确保「数值稳定」：防止激活值过大或过小导致的梯度消失/爆炸

#### Encoder 堆叠

实际 Transformer 不是单层，而是  $N$  层堆叠（BERT Base = 12 层，BERT Large = 24 层）：

```

class TransformerEncoder(nn.Module):
 """N 层 Transformer Encoder 堆叠"""
 def __init__(self, num_layers=6, d_model=512, n_heads=8, d_ff=2048):
 super().__init__()
 self.layers = nn.ModuleList([
 TransformerBlock(d_model, n_heads, d_ff)
 for _ in range(num_layers)
])

 def forward(self, x, mask=None):
 for layer in self.layers:
 x = layer(x, mask)
 return x

```

💡 核心洞察：Transformer 的精妙之处在于——它把「序列建模」这个复杂问题分解为「交流（注意力）」和「思考（FFN）」两个简单原语的交替堆叠。

## 8-5-2 多头注意力

思想：用多组  $Q, K, V$  并行计算注意力，捕捉不同子空间的信息。

$$\text{MultiHead}(Q, K, V) = \text{Concat}(\text{head}_1, \dots, \text{head}_h)W_O$$

其中  $\text{head}_i = \text{Attention}(QW_Q^i, KW_K^i, VW_V^i)$

## 8-5-3 位置编码

为什么需要位置编码？

Transformer 的 Self-Attention 是置换不变 (Permutation Invariant) 的——打乱输入顺序，输出相同。但自然语言中顺序至关重要：「我打你」≠「你打我」。位置编码就是给模型提供位置信号。

正弦位置编码公式

$$PE_{(pos, 2i)} = \sin\left(\frac{pos}{10000^{2i/d_{model}}}\right)$$

$$PE_{(pos, 2i+1)} = \cos\left(\frac{pos}{10000^{2i/d_{model}}}\right)$$

符号	含义
$pos$	词在序列中的位置 (0, 1, 2, ...)
$i$	维度索引 (0, 1, ..., $d_{model}/2$ )
$d_{model}$	模型维度

正弦编码的三个优美性质

1. 有界性：每个值在  $[-1, 1]$  之间，与词嵌入尺度兼容
2. 相对位置编码：对任意偏移  $k$ ， $PE_{pos+k}$  可以表示为  $PE_{pos}$  的线性函数（利用和角公式）
3. 无需训练：正弦公式是固定的，可以外推到训练时未见过的序列长度

Python 实现

```
def sinusoidal_positional_encoding(max_len, d_model):
 """生成正弦位置编码"""
 pe = np.zeros((max_len, d_model))
 pos = np.arange(max_len).reshape(-1, 1) # (max_len, 1)
 div = 10000 ** (np.arange(0, d_model, 2) / d_model) # (d_model/2,)
 pe[:, 0::2] = np.sin(pos / div) # 偶数维用 sin
 pe[:, 1::2] = np.cos(pos / div) # 奇数维用 cos
 return torch.tensor(pe, dtype=torch.float32)

可视化：不同位置的编码
pe = sinusoidal_positional_encoding(100, 16)
plt.figure(figsize=(10, 6))
plt.imshow(pe.numpy().T, cmap='viridis', aspect='auto')
plt.xlabel('Position')
plt.ylabel('Dimension')
plt.colorbar(label='Value')
plt.title('Sinusoidal Positional Encoding')
plt.show()
```

## 8-5-4 最小 Transformer 实现

```
class MultiHeadAttention(nn.Module):
 def __init__(self, d_model, n_heads):
```



```

super().__init__()
self.n_heads = n_heads
self.d_k = d_model // n_heads
self.W_Q = nn.Linear(d_model, d_model)
self.W_K = nn.Linear(d_model, d_model)
self.W_V = nn.Linear(d_model, d_model)
self.W_O = nn.Linear(d_model, d_model)

def forward(self, Q, K, V, mask=None):
 batch_size = Q.shape[0]
 # 线性变换 + 分头
 Q = self.W_Q(Q).view(batch_size, -1, self.n_heads, self.d_k).transpose(1, 2)
 K = self.W_K(K).view(batch_size, -1, self.n_heads, self.d_k).transpose(1, 2)
 V = self.W_V(V).view(batch_size, -1, self.n_heads, self.d_k).transpose(1, 2)
 # 缩放点积注意力
 scores = Q @ K.transpose(-2, -1) / np.sqrt(self.d_k)
 if mask is not None:
 scores = scores.masked_fill(mask == 0, -1e9)
 attn = torch.softmax(scores, dim=-1)
 out = attn @ V
 # 合并头
 out = out.transpose(1, 2).contiguous().view(
 batch_size, -1, self.n_heads * self.d_k
)
 return self.W_O(out)

class TransformerBlock(nn.Module):
 def __init__(self, d_model, n_heads, d_ff):
 super().__init__()
 self.attention = MultiHeadAttention(d_model, n_heads)
 self.norm1 = nn.LayerNorm(d_model)
 self.ffn = nn.Sequential(
 nn.Linear(d_model, d_ff),
 nn.ReLU(),
 nn.Linear(d_ff, d_model)
)
 self.norm2 = nn.LayerNorm(d_model)

 def forward(self, x, mask=None):
 # 多头注意力 + 残差连接 + LayerNorm
 attn_out = self.attention(x, x, x, mask)
 x = self.norm1(x + attn_out)
 # 前馈网络 + 残差连接 + LayerNorm
 ffn_out = self.ffn(x)
 x = self.norm2(x + ffn_out)
 return x

```

8-6 Transformer 可视化与理解

8-6-1 注意力权重可视化




图 8-4：注意力权重可视化——深色表示高关注度。在翻译任务中，每个输出词会关注输入句子的不同位置。

8-6-2 自注意力 vs 交叉注意力

类型	Q, K, V 的来源	用途
自注意力	都来自同一个序列	捕捉序列内部依赖
交叉注意力	Q 来自一个序列，K,V 来自另一个	捕捉两个序列的依赖

8-7 BERT vs GPT：预训练范式的对比

8-7-1 预训练 + 微调范式的兴起

2018 年是 NLP 的「Imagenet 时刻」。这一年，两个里程碑式的模型——BERT 和 GPT——开启了「预训练 + 微调」的新范式：

$$\text{pretrain (unlabeled data)} \xrightarrow{\text{finetune (labeled data)}} \text{downstream model}$$

模型	提出时间	参数量	预训练任务	架构
GPT	2018.06	117M	自回归语言模型（从左到右）	Transformer Decoder
BERT	2018.10	340M	Masked LM + NSP（双向）	Transformer Encoder

8-7-2 GPT：自回归范式

GPT 使用标准的 Transformer Decoder 架构（带 Masked Self-Attention），预训练任务很简单：预测下一个词：

$$L_{\text{GPT}} = - \sum_t \log P(w_t | w_1, w_2, \dots, w_{t-1})$$

这种「从左到右」的架构天然适合文本生成任务——因为它只能看到过去的信息，看不到未来的信息。

```
GPT 式自回归生成的简化逻辑
def gpt_generate(model, prompt, max_length=100):
 for _ in range(max_length):
 # 只能看到当前位置左边的 token
 logits = model(prompt) # 使用 masked attention
 next_token = sample(logits[-1])
 prompt.append(next_token)
 return prompt
```

### 8-7-3 BERT：双向编码范式

BERT 使用 Transformer Encoder 架构（没有 masked attention），通过两个新颖的预训练任务学习双向上下文表示：

#### Task 1: Masked Language Model (MLM)

随机遮盖输入中 15% 的 token，让模型预测被遮盖的词：

```
MLM 示例
输入：我 [MASK] 深度 [MASK] 习 → 预测 [MASK] = ["爱", "学"]
```

$$L_{MLM} = - \sum_{i \in \text{masked}} \log P(w_i | \mathbf{w}_{\setminus i})$$

#### Task 2: Next Sentence Prediction (NSP)

判断两个句子是否为连续的上下文：

```
[A = "我爱深度学习", B = "PyTorch 很好用"] → IsNext? ✓
[A = "我爱深度学习", B = "苹果很好吃"] → NotNext? ✓
```

对比维度	BERT	GPT
注意力方式	双向（能看到左右）	单向（只能看左边）
预训练任务	MLM + NSP	Autoregressive LM
擅长任务	分类、NER、QA	文本生成、对话
微调方式	加分类头	Prompt-based
代表模型	BERT → RoBERTa → ALBERT	GPT-2 → GPT-3 → GPT-4

🧙 小精灵说：BERT 就像「阅读理解大师」——它能看到整篇文章后再回答问题（双向注意力）。GPT 就像「故事接龙高手」——它只能看到已经写出的内容，然后接着往下写（单向注意力）。两者各有擅长：BERT 适合理解任务，GPT 适合生成任务！

## 8-8 现代架构设计模式

### 8-8-1 残差连接的变体

除了原始 ResNet 的  $y = F(x) + x$ ，后续工作提出了多种残差连接变体：

变体	公式	特点
原始残差	$y = F(x) + x$	最简单的恒等映射
Pre-activation	$y = x + F(\text{BN}(x), \text{ReLU}(x))$	梯度更容易传播（ResNet v2）
Dense 连接	$y = [x, F(x)]$	拼接而非相加，特征复用（DenseNet）

```
Pre-activation Residual Block
class PreActBlock(nn.Module):
 def __init__(self, in_planes, planes):
```

```
super().__init__()
self.bn1 = nn.BatchNorm2d(in_planes)
self.conv1 = nn.Conv2d(in_planes, planes, 3, padding=1, bias=False)
self.bn2 = nn.BatchNorm2d(planes)
self.conv2 = nn.Conv2d(planes, planes, 3, padding=1, bias=False)

def forward(self, x):
 out = self.conv1(F.relu(self.bn1(x)))
 out = self.conv2(F.relu(self.bn2(out)))
 return out + x # 残差连接
```

8-8-2 Attention 的变体

变体	核心思想	代表工作
多头注意力	多组 QKV 关注不同子空间	Transformer
Linear Attention	用核函数替代 Softmax, $O(n)$ 复杂度	Linformer, Performer
Flash Attention	分块计算+显存优化, 加速 2-4x	FlashAttention (2022)
Cross-Attention	Q 来自一个序列, K,V 来自另一个	Transformer Decoder

8-8-3 归一化技术的演进

方法	操作	适用范围
BatchNorm	在 batch 维度归一化	CNN (依赖 batch size)
LayerNorm	在特征维度归一化	Transformer/RNN (不依赖 batch)
InstanceNorm	在单样本内归一化	图像风格迁移
GroupNorm	将通道分组归一化	小 batch 场景

BatchNorm :  $\hat{x} = \frac{x - \mu_{batch}}{\sigma_{batch}}$

LayerNorm:  $\hat{x} = \frac{x - \mu_{layer}}{\sigma_{layer}}$

💡 核心洞察: Transformer 使用 LayerNorm 而不是 BatchNorm, 因为 NLP 任务中序列长度变化大, batch 维度不稳定。LayerNorm 在特征维度归一化, 不受 batch size 和序列长度影响。

8-9 Vision Transformer (ViT): 当 Transformer 遇到图像

8-9-1 为什么要把 Transformer 用到图像上?

传统 CNN 依赖卷积的局部连接和权值共享两个归纳偏置 (Inductive Bias)。Transformer 的 Self-Attention 则是一种全局操作——每个位置关注所有位置。

ViT (Vision Transformer, 2020) 的核心思想非常直接: 把图像切成 Patches, 然后把每个 Patch 当作一个 Token 输入 Transformer。

8-9-2 ViT 的完整流程

- ViT 流程:
1. 输入图像 (224×224×3) → 分割为 196 个 16×16 Patches
  2. 每个 Patch 展平 + 线性投影到 D 维 (如 768D)
  3. 加上位置编码 + [CLS] Token
  4. 输入标准 Transformer Encoder (12 层)
  5. 取 [CLS] Token 的输出 → 分类头 → 预测类别

Patch Embedding 的数学形式

$$\mathbf{x}_p^i = \text{Linear}(\text{Flatten}(\text{Patch}_i)), \quad i = 1, \dots, N$$

$$\mathbf{z}_0 = [\mathbf{x}_{\text{cls}}; \mathbf{x}_p^1 \mathbf{E}; \mathbf{x}_p^2 \mathbf{E}; \dots; \mathbf{x}_p^N \mathbf{E}] + \mathbf{E}_{\text{pos}}$$

```
import torch.nn as nn

class PatchEmbedding(nn.Module):
 def __init__(self, img_size=224, patch_size=16, in_channels=3, embed_dim=768):
 super().__init__()
 self.num_patches = (img_size // patch_size) ** 2 # 196
 self.proj = nn.Conv2d(in_channels, embed_dim,
 kernel_size=patch_size, stride=patch_size)
 # 等价于: 将图像切成 patch → 每个 patch 展平 → 线性投影到 embed_dim

 def forward(self, x):
 # x: (B, 3, 224, 224)
 x = self.proj(x) # (B, 768, 14, 14)
 x = x.flatten(2) # (B, 768, 196)
 x = x.transpose(1, 2) # (B, 196, 768) ← 196个token, 每个768维
 return x
```

8-9-3 ViT 与 CNN 的对比

对比维度	CNN	ViT
感受野	局部（逐渐扩大）	全局（从第一层开始）
归纳偏置	强（局部性+平移不变性）	弱（需要更多数据学习）
数据需求	少（ImageNet 1M 即可）	多（需要 JFT-300M 预训练）
计算复杂度	$O(k^2 C^2 HW)$	$O(N^2 D)$ ( $N$ 是 patch 数)
高分辨率	可扩展（滑动窗口）	受限 ( $N$ 随分辨率平方增长)

💡 核心洞察：ViT 证明了「只要数据足够多，Transformer 可以打败 CNN」。在 ImageNet 上 ViT 表现一般（因为数据不够），但在 JFT-300M（3 亿张图）上预训练后，ViT 超越了一切 CNN 架构。这说明数据的归纳偏置可以取代架构的归纳偏置。

8-9-4 从 ViT 到 Swin Transformer

ViT 的一个主要问题是：Self-Attention 的计算复杂度是  $O(N^2)$ ，对于高分辨率图像来说不可接受。Swin Transformer（2021）提出了层次化注意力：

- 1. 窗口注意力：只在局部窗口内做 Self-Attention ( $O(\text{window}^2)$ )
- 2. 窗口移位：层与层之间移动窗口，让信息跨窗口流动
- 3. 层次化结构：像 CNN 一样逐步降采样，构建特征金字塔

Stage	分辨率	通道数	操作
Stage 1	H/4 × W/4	96	Patch Embedding
Stage 2	H/8 × W/8	192	Patch Merging
Stage 3	H/16 × W/16	384	Swin Block × N
Stage 4	H/32 × W/32	768	Patch Merging

🌟 小精灵说：ViT 就像让所有小精灵开全体大会（全局注意力）——虽然信息最全面，但人太多了效率低。Swin Transformer 则改成「部门会议」

（窗口注意力）——先各个部门内部讨论，再通过部门之间的信息交换（窗口移位）实现全公司信息流通。效率高得多！

8-10 现代架构设计原则总结

8-10-1 五大设计原则

纵观深度学习架构的演进，我们可以总结出五大通用设计原则：

原则	解决的问题	代表技术
① 残差连接	深层网络退化与梯度消失	ResNet, Transformer
② 归一化	训练不稳定，内部协变量偏移	BatchNorm, LayerNorm
③ 注意力机制	长距离依赖建模	Self-Attention, Cross-Attention
④ 层次化设计	多尺度特征提取	CNN 金字塔, Swin 层级
⑤ 稀疏计算	计算效率与可扩展性	MoE, Window Attention

8-10-2 经典架构的设计哲学

架构	设计哲学	核心机制
ResNet	深度优先	残差连接，梯度直达浅层
Transformer	容量优先	注意力实现全局信息交互
ViT	简化优先	最少架构归纳偏置，数据驱动
Swin	效率优先	Transformer + CNN 层次化
GPT	生成优先	单向自回归，简洁而强大
BERT	理解优先	双向编码，深度理解上下文

8-10-3 未来趋势

- 大一统架构：Transformer 正在统一 CV、NLP、语音等领域
- 线性注意力：将  $O(N^2)$  降为  $O(N)$ ，支持更长序列
- 稀疏专家混合（MoE）：用更多参数但更少计算
- 状态空间模型：如 Mamba，作为 Transformer 的替代方案

🔥 一句话总结：现代深度学习架构的演进可以归结为一个核心问题——如何在保持计算可行的前提下，让模型看到更大的上下文（更大的感受野/更长的序列）。ResNet 用残差连接解决了深度问题，Transformer 用注意力解决了长距离依赖问题，ViT 证明了「更大数据 + 更少归纳偏置 = 更好性能」。

架构演进脉络

年份	架构	核心创新
2013	RNN	循环连接，处理序列
2014	LSTM/GRU	门控机制，缓解梯度消失
2017	Attention	软寻址，捕捉长程依赖
2017	Transformer	多头注意力 + 位置编码
2018+	GPT/BERT	预训练 + 微调范式

核心数学公式

架构	核心公式
ResNet	$y = F(x) + x$ (跳跃连接)
RNN	$h_t = \tanh(W_{xh}x_t + W_{hh}h_{t-1})$
LSTM/GRU	$C_t = f_t \odot C_{t-1} + i_t \odot \tilde{C}_t$ (门控加法, 梯度恒等通路)
Attention	$\text{Attention}(Q, K, V) = \text{softmax}(QK^T / \sqrt{d_k})V$
Transformer	MultiHead + FFN + Add & Norm

本章代码清单

文件	内容	核心知识点
ch08/NN08_resnet_block.py	Residual Block + Pre-activation 实现	残差连接 + ResNet v2
ch08/NN08_resnet_bottleneck.py	Bottleneck 参数量对比	Bottleneck 设计哲学
ch08/NN08_resnet_gradient_flow.py	Plain vs ResNet 梯度流对比	梯度传播可视化
ch08/NN08_resnet_training.py	Plain vs ResNet 训练对比	退化现象重现
ch08/NN08_resnet_series.py	ResNet-18/34/50/101/152 完整定义	ResNet 系列配置
ch08/NN08_attention.py	注意力机制从零实现	Attention 核心
ch08/NN08_attention_viz.py	注意力权重矩阵可视化	Attention 可视化
ch08/NN08_positional_encoding.py	Sinusoidal 位置编码实现	位置编码
ch08/NN08_transformer_encoder.py	Transformer Encoder 完整实现	Transformer 核心




图 8-5: Transformer 位置编码可视化。

本章小结

课后练习

练习 1: 残差连接实验

```
import torch
import torch.nn as nn

实现一个 10 层的 Plain 网络和 10 层的 ResNet (带残差连接)
用 Kaiming Normal 初始化
对比训练 50 轮后的训练 loss 和验证精度
关键观察: 深层 Plain 网络是否出现退化?
```

练习 2: 自注意力手动计算

给定三个 2x3 矩阵 Q, K, V (2 个 token, 每个 3 维):

$Q = \begin{bmatrix} 1 & 0 & 1 \\ 0 & 1 & 0 \end{bmatrix}, K = \begin{bmatrix} 1 & 1 & 0 \\ 0 & 1 & 1 \end{bmatrix}, V = \begin{bmatrix} 1 & 0 \\ 0 & 1 \\ 1 & 1 \end{bmatrix}$

手动计算注意力输出：

- 1. 计算注意力分数矩阵  $S = QK^T / \sqrt{d_k}$
- 2. 对每行应用 Softmax
- 3. 用注意力权重对  $V$  加权求和

练习 3：位置编码可视化

实现 Sinusoidal 位置编码，并可视化不同维度的编码值随位置的变化。观察哪些维度变化快（高频），哪些变化慢（低频）。

练习 4：多头注意力参数量计算

一个 Transformer 层： $d_{\text{model}}=512$ ，8 个注意力头，FFN 隐藏层 2048。计算：

- 单个注意力头的参数量 ( $Q, K, V$  投影 + 输出投影)
- 所有注意力头的总参数量
- FFN 层的参数量
- 该 Transformer 层的总参数量

练习 5（挑战题）：从零实现一个小型 Transformer

用 PyTorch 实现一个 2 层 Transformer Encoder（不含预训练），在简单的序列分类任务上训练（如 IMDB 情感分类的子集）。

核心技术脉络

概念	核心公式 / 要点
深度瓶颈	更深 = 梯度消失 / 退化
ResNet	$y = F(x, \{W_i\}) + x$ (短路连接让梯度直达)
Bottleneck	$256d \rightarrow 1 \times 1 \ 64d \rightarrow 3 \times 3 \ 64d \rightarrow 1 \times 1 \ 256d$ (先降维再升维)
RNN/LSTM/GRU	RNN: $h_t = \tanh(W \cdot [x_t, h_{t-1}])$ ; LSTM: $C_t = f_t \odot C_{t-1} + i_t \odot C_t$ (门控加法, 梯度直达)
Self-Attention	$\text{Attention}(Q,K,V) = \text{softmax}(QK^T/\sqrt{d_k})V$ (每个词看所有词)
Multi-Head	$\text{Concat}(\text{head}_1, \dots, \text{head}_h)W^O$ (多视角并行关注)
Positional Encoding	$\text{PE}(\text{pos}, 2i) = \sin(\text{pos}/10000^{\{2i/d\}})$
Transformer	MultiHead + Add&Norm + FFN + Add&Norm
BERT	Masked LM + Next Sentence Prediction (双向理解上下文)
GPT	Autoregressive LM (单向生成文本)

🔥 一句话总结：现代深度学习架构的演进 = 解决梯度消失（ResNet）+ 解决序列依赖（Attention）+ 并行化（Transformer）。

核心概念回顾

概念	核心要点
深度瓶颈	更深网络 → 梯度消失/爆炸 + 网络退化（Plain 网络深层反而不如浅层）
ResNet 残差连接	$y = F(x) + x$ 让梯度直达浅层，打破深度瓶颈
RNN / LSTM / GRU	RNN 通过时间共享权重处理序列；LSTM 用三个门（遗忘/输入/输出）和记忆细胞缓解梯度消失；GRU 简化为两个门
Bottleneck 设计	$1 \times 1$ 降维 → $3 \times 3$ 卷积 → $1 \times 1$ 升维，大幅减少参数量
Self-Attention	$\text{Attention}(Q, K, V) = \text{softmax}(QK^T/\sqrt{d_k})V$ ，每个位置关注所有位置
多头注意力	多组 QKV 并行计算 → 拼接 → 投影，关注不同子空间
位置编码	Sinusoidal PE：不同维度不同频率，让 Transformer 感知顺序



概念	核心要点
Transformer	Encoder: MultiHead + Add&Norm + FFN + Add&Norm; Decoder: Masked MultiHead + Cross-Attention

🔥 一句话总结：现代深度学习架构的演进 = 解决梯度消失（ResNet）+ 解决序列依赖（Attention）+ 并行化（Transformer）。

核心公式速查

公式	说明	适用场景
$y = F(x, W_i) + x$	残差连接：跳跃连接 + 恒等映射	ResNet 核心
Bottleneck : $256 \xrightarrow{1 \times 1} 64 \xrightarrow{3 \times 3} 64 \xrightarrow{1 \times 1} 256$	Bottleneck 降维-卷积-升维	深层 ResNet
$Attention(Q, K, V) = \text{softmax}\left(\frac{QK^T}{\sqrt{d_k}}\right)V$	Scaled Dot-Product Attention	Transformer 核心
$MultiHead(Q, K, V) = \text{Concat}(\text{head}_1, \dots, \text{head}_h)W^O$	多头注意力：并行关注不同子空间	Transformer 编码器
$FFN(x) = \max(0, xW_1 + b_1)W_2 + b_2$	前馈网络（含 ReLU）	Transformer 逐位置变换
$PE_{(pos, 2i)} = \sin(pos/10000^{2i/d}); PE_{(pos, 2i+1)} = \cos(pos/10000^{2i/d})$	Sinusoidal 位置编码	注入位置信息
$h_t = \tanh(W_{xh}x_t + W_{hh}h_{t-1} + b_h)$	RNN 隐藏状态更新	序列建模基础
$C_t = f_t \odot C_{t-1} + i_t \odot \tilde{C}_t$	LSTM 记忆细胞加法更新	缓解梯度消失的关键

第 9 章 大语言模型：训练、采样与推理

目标：理解 LLM 从训练到推理的完整数学链条——自回归生成、采样策略、KV Cache 加速、高效微调，每一步都有数学直觉和代码验证。

© xiefujin · Contact: 490021684@qq.com · Licensed under CC BY-NC-SA 4.0

代码文件: `code/ch09/` (5 个文件)

插图: `images/ch09/` (2 张图)

本章学习目标

- [ ] 理解语言模型的数学定义
- [ ] 理解自回归生成的原理
- [ ] 掌握不同的采样策略
- [ ] 理解 KV Cache 对推理的加速原理
- [ ] 理解 LoRA 高效微调的方法
- [ ] 了解量化基础

9-1 从语言模型到大语言模型

9-1-1 语言模型的基本定义

任务

计算一个词序列的概率：

$$P(w_1, w_2, \dots, w_n)$$

链式法则分解

$$P(w_1, w_2, \dots, w_n) = P(w_1)P(w_2|w_1)P(w_3|w_1, w_2) \cdots P(w_n|w_1, \dots, w_{n-1})$$

核心洞察：语言模型 = 下一个词的预测器。给定前文，预测下一个词的概率分布。

9-1-2 N-gram vs 神经语言模型

模型	原理	局限性
N-gram	只依赖前 n-1 个词	无法捕捉长程依赖
RNN-LM	用 RNN 保持隐状态	梯度消失，无法并行
Transformer	自注意力捕捉所有位置	计算量随序列长度平方增长

9-1-3 Scaling Law

经验发现

Scaling Law（缩放定律）是 OpenAI 在 2020 年发现的一个重要经验规律：模型性能与模型参数量  $N$ 、数据量  $D$ 、计算量  $C$  之间存

在幂律关系 (Power Law)。

$$\text{Loss} \propto N^{-\alpha_N} + D^{-\alpha_D} + C^{-\alpha_C} + \text{Loss}_{\infty}$$

其中  $\alpha_N \approx 0.076$ ,  $\alpha_D \approx 0.095$ ,  $\alpha_C \approx 0.050$ ,  $\text{Loss}_{\infty}$  是理论上的最低损失 (数据本身的不可压缩熵)。

三个关键推论

推论一：模型越大越好，但有边际效应

参数量翻倍，损失下降的幅度越来越小——这是典型的幂律衰减。

推论二：模型大小和数据量要同步增长

$$N_{\text{opt}} \propto C^{0.73}, \quad D_{\text{opt}} \propto C^{0.27}$$

即：计算预算增加时，大部分应该花在扩大模型上，小部分花在增加数据上。

推论三：小模型 + 多数据 vs 大模型 + 少数据

给定固定计算预算，应该训练一个多大的模型？Chinchilla 论文 (2022) 给出了答案：

```
Chinchilla 最优分配公式
def optimal_allocation(C):
 """C: 总计算量 (FLOPs)"""
 N_opt = 0.25 * C ** 0.49 # 最优参数量
 D_opt = 1.25 * C ** 0.51 # 最优 token 数
 return N_opt, D_opt
```

💡 核心洞察：Scaling Law 表明，LLM 的能力提升靠的是「规模」而不是「算法创新」。GPT-3 (175B) 的参数是 GPT-2 (1.5B) 的 100 倍以上。这也意味着——规模本身就是一种算法！




图 9-1: Scaling Law 可视化。

涌现能力

当模型规模超过某个阈值时，一些能力会「突然」出现——这在更小的模型中完全不存在：

能力	出现规模	说明
上下文学习 (ICL)	~1B+	通过示例学习，无需微调
思维链 (CoT)	~100B+	能展示推理步骤
代码生成	~10B+	能根据描述生成可运行代码

🌟 小精灵说：Scaling Law 就像是「大力出奇迹」的科学证明！小模型像小学生——只能做简单的加减法。大模型像博士生——能做复杂的推理题。关键在于：有些能力不是「教出来」的，而是在模型增大到一定程度后自己涌现的！

## 9-2 自回归生成与训练

### 9-2-1 自回归分解

🌟 小精灵说：自回归生成就像小精灵一个接一个地讲故事！第一个小精灵说了「我」，第二个看了「我」之后说「爱」，第三个看了「我爱」之后说

「你」……每个新词都基于所有已生成的上文。这就是  $P(w_1, \dots, w_n) = \prod P(w_t | w_{<t})$  的直观理解——语言模型就是「接龙大师」！

训练：Teacher Forcing

每一步用真实值作为下一步的输入：

$$\max_{\theta} \sum_{t=1}^T \log P_{\theta}(y_t | y_{<t}, x)$$

推理：自回归生成

每一步用上一步生成的 token 作为输入：

$$\hat{y}_t \sim P_{\theta}(\cdot | \hat{y}_{<t}, x)$$

```
def generate_autoregressive(model, prompt, max_len=100):
 """ 自回归生成 """
 generated = prompt.clone()
 for _ in range(max_len):
 logits = model(generated) # 前向传播
 next_token = logits[:, -1, :].argmax(dim=-1) # 贪心采样
 generated = torch.cat([generated, next_token.unsqueeze(0)], dim=-1)
 return generated
```

## 9-2-2 训练 vs 推理的差异

特性	训练	推理
输入	真实值 (Teacher Forcing)	自己生成的 token
并行性	可并行 (所有时间步一次前向)	串行 (逐个生成)
问题	Exposure Bias	错误累积
复杂度	$O(T \cdot N^2)$	$O(T^2 \cdot N)$ (无 KV Cache)

## 9-3 采样策略 ★

### 9-3-1 贪心解码

原理

每一步选择概率最高的 token：

```
next_token = logits[:, -1, :].argmax(dim=-1)
```

示例

假设语言模型当前预测下一个词的概率分布：

```
"我今天去" → P(学校)=0.45, P(超市)=0.30, P(医院)=0.15, P(公司)=0.10
```

贪心解码必定选择「学校」。

问题

1. 缺乏多样性：总是选概率最高的，生成文本平淡无奇
2. 容易陷入重复：一旦进入某个模式（如「但是」），会一直选下去
3. 无法回头：早期的一个次优选择可能导致后续全部偏离

💡 **核心洞察：**贪心解码 = 每一步都选当前最优，但全局来看可能不是最佳路径。就像走迷宫时每次都选最近的拐弯——可能走进死胡同。

### 9-3-2 Top-K 采样

思想

贪心解码每次选最高概率 token，但语言生成需要**多样性**——同一句话可以有多个合理的续写。Top-K 采样在「确定性」和「随机性」之间取中：从**概率最高的 K 个 token 中按概率随机采样**。

```
def top_k_sampling(logits, k=50):
 """Top-K 采样: 从 top-k 个 token 中按概率采样"""
 top_k_values, top_k_indices = torch.topk(logits, k, dim=-1)
 probs = torch.softmax(top_k_values, dim=-1)
 chosen = torch.multinomial(probs, num_samples=1)
 return top_k_indices.gather(-1, chosen)
```

工作原理

假设词汇表有 10000 个 token，生成「今天天气」的下一个词：

```
logits = model("今天天气") # 得到 10000 个 logits
k = 5

Step 1: 只保留概率最高的 5 个 token
top_5 = ["很好", "不错", "晴朗", "暖和", "真好"] # 得分 [8.0, 7.5, 7.0, 6.5, 6.0]

Step 2: 对这 5 个做 Softmax, 得到新概率分布
probs = [0.53, 0.22, 0.13, 0.08, 0.04]

Step 3: 按这个分布采样
有 53% 概率选「很好」, 22% 概率选「不错」.....
chosen = torch.multinomial(probs) # 随机选择
```

K 值的影响

K 值	效果	适用场景
$K = 1$	等价于贪心解码	需要确定性输出
$K = 10$	高概率 token 主导	平衡确定性与多样性
$K = 50$	默认值，合理多样性	通用场景
$K = 1000$	接近原始分布	高创造性/头脑风暴

💡 **核心洞察：**Top-K 的关键是**截断低概率尾部**——那些大量概率极低的奇怪 token 被直接排除，只从「合理候选集」中做随机选择。这避免了生成「胡言乱语」的问题。

### 9-3-3 Top-P (Nucleus) 采样

Top-K 的问题

Top-K 的 K 是固定的——但如果前 K 个 token 的概率**都很低**（模型不太确定）怎么办？Top-K 会错误地截断一些也「不太差」的候选项。

Top-P 的思想

不固定 K，而是**动态选择**：选择累积概率超过阈值  $p$  的最小 token 集合。如果模型很确定，集合小；如果不确定，集合大——**自适应**。

```
def top_p_sampling(logits, p=0.9):
 """Top-P (Nucleus) 采样: 从累积概率 > p 的最小集合中采样"""
 sorted_logits, sorted_indices = torch.sort(logits, descending=True, dim=-1)
 cumprobs = torch.cumsum(torch.softmax(sorted_logits, dim=-1), dim=-1)
 # 选择累积概率超过 p 的最小集合
 sorted_indices_to_remove = cumprobs > p
 sorted_indices_to_remove[..., 1:] = sorted_indices_to_remove[..., :-1].clone()
 sorted_indices_to_remove[0, 0] = 0
```

```
sorted_indices_to_remove[... , 0] = 0
应用掩码
indices_to_remove = sorted_indices_to_remove.scatter(
 -1, sorted_indices, sorted_indices_to_remove
)
logits[indices_to_remove] = float('-inf')
probs = torch.softmax(logits, dim=-1)
return torch.multinomial(probs, num_samples=1)
```

对比示例

```
场景 A: 模型很确定 (前 3 个 token 就占了 95% 概率)
Top-K (K=5): 必须选 5 个, 包含低概率 token
Top-P (p=0.95): 只选 3 个 ← 更合理!

场景 B: 模型不确定 (前 20 个 token 才占 90% 概率)
Top-K (K=5): 只选 5 个, 排除了许多合理选项
Top-P (p=0.9): 选 20 个 ← 更合理!
```

p 值的影响

p 值	效果	适用场景
$p = 0.9$	默认值, 性能最佳	通用推荐
$p = 0.95$	更大的候选集, 更多样	创意写作
$p = 0.99$	几乎不截断, 完全随机	头脑风暴
$p < 0.8$	候选集小, 更确定	需要精确的任务

💡 核心洞察: Top-P 比 Top-K 更「聪明」——它根据模型对当前预测的置信度动态调整候选集大小。实践中, Top-P ( $p=0.9$ ) + Temperature ( $T=0.7$ ) 是最常用的组合。

9-3-4 Temperature 控制

原理

通过 Temperature 参数  $T$  控制概率分布的「尖锐」程度:

$$P_i = \frac{e^{z_i/T}}{\sum_j e^{z_j/T}}$$

直觉:  $T$  控制模型对高概率 token 的偏好程度。

Python 实现

```
def apply_temperature(logits, temperature=1.0):
 """应用 Temperature 控制"""
 logits = logits / temperature
 probs = torch.softmax(logits, dim=-1)
 return probs

示例: 不同 Temperature 的效果
logits = torch.tensor([1.0, 2.0, 3.0, 0.5])
for T in [0.1, 0.5, 1.0, 2.0, 10.0]:
 probs = apply_temperature(logits, T)
 dominant = probs.argmax().item()
 entropy = -(probs * torch.log(probs + 1e-8)).sum().item()
 print(f"T={T:.1f}: 支配 token = {dominant}, 熵 = {entropy:.3f}")
```

Temperature	支配 Token	熵	特征
0.1	2	0.004	几乎确定
0.5	2	0.148	稍有不确定
1.0	2	0.464	原始分布
2.0	2	0.900	更均匀
10.0	2	1.330	接近均匀

实践选择

Temperature	适用场景	效果
$T \approx 0.1$	代码生成、数学推理	精确、确定性
$T \approx 0.7$	日常对话、文案写作	平衡创造性和准确性
$T \approx 1.0$	故事创作、头脑风暴	高创造性，可能偏离主题

⚠️ 警告：Temperature 过高 ( $T > 2$ ) 可能导致生成完全随机的无意义文本——就像让一个喝醉的人写文章。

9-3-5 采样策略对比实验

四种策略的对比

策略	确定性	多样性	适用场景
贪心解码	✅ 最高	❌ 最低	事实性问题（翻译、摘要）
Top-K 采样	❌ 低	✅ 高	创意写作（写诗、故事）
Top-P 采样	⚠️ 中	✅ 高	通用场景（对话、问答）
Temperature	可调	可调	配合 Top-K/Top-P 使用

```
import torch
import torch.nn.functional as F

def sample_from_logits(logits, temperature=1.0, top_k=50, top_p=0.9):
 # Temperature 调整
 scaled_logits = logits / temperature

 # Top-K 截断
 if top_k > 0:
 top_k_values, _ = torch.topk(scaled_logits, top_k)
 threshold = top_k_values[-1]
 scaled_logits[scaled_logits < threshold] = float('-inf')

 # Top-P (Nucleus) 截断
 if top_p < 1.0:
 sorted_logits, sorted_indices = torch.sort(scaled_logits, descending=True)
 cumulative_probs = torch.cumsum(F.softmax(sorted_logits, dim=-1), dim=-1)
 sorted_indices_to_remove = cumulative_probs > top_p
 sorted_indices_to_remove[..., 1:] = sorted_indices_to_remove[..., :-1].clone()
 sorted_indices_to_remove[..., 0] = False
 indices_to_remove = sorted_indices[sorted_indices_to_remove]
 scaled_logits[indices_to_remove] = float('-inf')

 probs = F.softmax(scaled_logits, dim=-1)
 return torch.multinomial(probs, num_samples=1)
```

温度参数的可视化

$$p_i = \frac{e^{z_i/T}}{\sum_j e^{z_j/T}}$$

- 当  $T \rightarrow 0$ : 概率分布趋近于 one-hot (贪心采样)
- 当  $T \rightarrow \infty$ : 概率分布趋近于均匀分布 (随机采样)
- 当  $T = 1$ : 原始 Softmax (标准采样)

🌟 小精灵说: Temperature 就像是创意的「温度调节旋钮」! 温度低 ( $T < 1$ ), 模型只选取最有把握的词——像严谨的科学家。温度高 ( $T > 1$ ), 模型会尝试更多可能性——像天马行空的艺术家! 实际使用时, 创意写作用  $T = 0.8$ , 事实问答用  $T = 0.1$ 。

9-4 KV Cache 推理加速 🌟

9-4-1 问题

自回归推理的冗余计算

在自回归生成中, 生成第  $t$  个 token 时, 需要计算当前位置 Query 与所有前  $t-1$  个位置的 Key 和 Value 的注意力:

时间步	无 Cache 计算量	有 Cache 计算量
t=1	计算 $Q_1K_1$	计算 $Q_1K_1$ (缓存 $K_1, V_1$ )
t=2	计算 $Q_2K_1, Q_2K_2$	只算 $Q_2K_2$ (复用 $K_1, V_1$ )
t=3	计算 $Q_3K_1, K_2, K_3$	只算 $Q_3K_3$ (复用全部历史 KV)
t=T	$O(T^2)$	$O(T)$ 🚀

核心浪费: 生成第  $t$  个 token 时, 前  $t-1$  个位置的  $K$  和  $V$  在第  $t-1$  步已经算过了——但传统实现会全部重算。

复杂度分析

方法	单步复杂度	T步总复杂度
无 KV Cache	$O(t \cdot d)$	$O(T^2 \cdot d)$
有 KV Cache	$O(d)$	$O(T \cdot d)$

示例: 当  $T = 2048$  时, KV Cache 带来约 1024 倍加速 ( $T^2/T = T$ )。

9-4-2 解决方案: KV Cache

🌟 小精灵说: KV Cache 就是小精灵们的「便利贴」! 在生成第  $t$  个词时, 我不需要重新计算前  $t-1$  个词的 Key 和 Value——我把它们都记在便利贴上了! 这样计算复杂度从  $O(T^2)$  (每次都从头算) 降到了  $O(T)$  (只算当前这一步)。空间换时间, 推理速度快了几十倍!

核心思想: 空间换时间

KV Cache 的核心思想极其简单——缓存之前所有时间步的 Key 和 Value 矩阵, 每次只计算当前 token 的 K, V 并追加到缓存中。

```
class KVAttention(nn.Module):
 """带 KV Cache 的多头注意力"""
 def __init__(self, d_model, n_heads):
 super().__init__()
 self.W_K = nn.Linear(d_model, d_model)
 self.W_V = nn.Linear(d_model, d_model)
 self.W_Q = nn.Linear(d_model, d_model)
```



```
self.cache_k = None # 初始化 KV Cache 为空
self.cache_v = None

def forward(self, x, use_cache=False):
 # 关键优化: 只有最后一个 token 需要 Query
 # 因为前 t-1 个 token 的 Query 已经在之前计算过了
 Q = self.W_Q(x[:, -1:, :])
 K = self.W_K(x)
 V = self.W_V(x)

 if use_cache and self.cache_k is not None:
 # 拼接: 历史缓存 + 当前位置
 K = torch.cat([self.cache_k, K], dim=1)
 V = torch.cat([self.cache_v, V], dim=1)

 if use_cache:
 self.cache_k = K # 更新缓存
 self.cache_v = V

 # 标准注意力计算
 scores = Q @ K.transpose(-2, -1) / np.sqrt(K.shape[-1])
 attn = torch.softmax(scores, dim=-1)
 return attn @ V
```

无 Cache vs 有 Cache 对比

时间步	无 Cache（重复计算）	有 Cache（复用）
t=1	计算 $Q_1K_1$	计算 $Q_1K_1$ （缓存 $K_1, V_1$ ）
t=2	计算 $Q_2K_1, Q_2K_2 \leftarrow K_1$ 重新算了！	只计算 $Q_2K_2$ （复用 $K_1, V_1$ ）
t=3	计算 $Q_3K_1, Q_3K_2, Q_3K_3 \leftarrow K_1, K_2$ 重新算了！	只计算 $Q_3K_3$ （复用 $K_1, V_1, K_2, V_2$ ）
t=T	计算 $T + (T - 1) + \dots + 1 = O(T^2)$ 次	每次只算 1 个 = $O(T)$ 次 🚀

💡 核心洞察：KV Cache 将自回归推理的计算复杂度从  $O(T^2)$  降为  $O(T)$ ——这就是 LLM 能实时对话的根本原因。

9-4-3 加速效果

序列长度	无 KV Cache	有 KV Cache	加速比
128	4.2ms	2.1ms	2×
512	67ms	8.4ms	8×
2048	1070ms	34ms	31×

💡 核心洞察：KV Cache 将自回归推理的计算复杂度从  $O(T^2)$  降为  $O(T)$ ——这是 LLM 能实时生成的基础。

9-5 高效微调：LoRA

9-5-1 为什么需要高效微调？

全参数微调的成本

以 GPT-3（175B 参数）为例：

资源	全参数微调	单卡 A100 (80GB)
参数存储 (FP32)	700GB	需要 9 张 A100
优化器状态 (Adam)	1.4TB	需要 18 张 A100

资源	全参数微调	单卡 A100 (80GB)
梯度内存	700GB	需要 9 张 A100
总计	~2.8TB	需要 35+ 张 A100

不仅如此，每次微调都会产生一个完整的 175B 参数副本 (~700GB) ——如果你要为 10 个不同客户做定制，就需要 7TB 的存储。

核心观察

LoRA 作者发现：预训练模型的权重矩阵具有很低的「内在维度」——微调时参数的变化量  $\Delta W$  可以用一个低秩矩阵近似。

```
全参数微调：直接修改 175B 参数
参数变化 ΔW 是 $d \times k$ 矩阵 (d 和 k 都可能很大)

LoRA 微调：只训练低秩分解矩阵
$\Delta W = B @ A$ ，其中 $B(d \times r)$, $A(r \times k)$
当 $r=8$ 时，训练参数量从 16M 降到 65K (节省 245 倍!)
```

💡 核心洞察：LoRA 的本质是——微调不需要「重新训练整个模型」，只需要在原始权重旁「附加」一个小型适配器。原始权重冻结不变，我们只训练这个适配器的参数。

9-5-2 LoRA 的核心思想

冻结原始权重，在权重矩阵旁添加低秩分解矩阵：

$$W' = W + BA$$

其中  $B \in \mathbb{R}^{d \times r}$ ,  $A \in \mathbb{R}^{r \times k}$ ,  $r \ll \min(d, k)$

LoRA:  $W' = W(d \times k, \text{冻结}) + B(d \times r) \times A(r \times k, \text{可训练})$   
参数从  $d \times k$  降到  $r \times (d+k)$ ，当  $r=8$  时减少约 245 倍

参数节省： $d \times k \rightarrow r \times (d + k)$   
示例： $d = 4096, k = 4096, r = 8 \rightarrow 16M \rightarrow 65K$  (节省 245 倍)

```
class LoRALayer(nn.Module):
 """LoRA 低秩适配层"""
 def __init__(self, original_weight, rank=8, alpha=16):
 super().__init__()
 self.original_weight = original_weight # 冻结
 d, k = original_weight.shape
 self.A = nn.Parameter(torch.randn(rank, k) * 0.01)
 self.B = nn.Parameter(torch.zeros(d, rank))
 self.scale = alpha / rank

 def forward(self, x):
 # 原始权重 (冻结) + LoRA 低秩适配
 return x @ (self.original_weight + self.B @ self.A * self.scale)
```

9-6 量化基础

9-6-1 为什么需要量化？

问题：大模型装不进 GPU

GPT-3 (175B 参数) 用 FP32 (4 字节/参数) 存储需要 700GB——目前最大的单 GPU 显存也才 80GB (A100/H100)。即使 FP16 (2 字节/参数) 也需要 350GB。

量化就是压缩——用更少的比特表示同一个权重。

```
FP32: 32 位浮点数, 每个参数用 4 字节
```

```
weight_fp32 = 0.123456789 # 精确，但太大
存储空间: 175B × 4 字节 = 700GB

INT8: 8 位整数，每个参数用 1 字节
weight_int8 = 42 # 不精确，但省空间
存储空间: 175B × 1 字节 = 175GB ← 可以放进 3 张 A100!

INT4: 4 位整数，每个参数用 0.5 字节
存储空间: 175B × 0.5 字节 = 87.5GB ← 可以放进 1 张 A100!
```

量化的「代价」是什么？

量化不是免费的——精度损失会导致模型质量下降。但令人惊讶的是，现代量化技术（如 GPTQ、AWQ）可以在仅损失 <1% 困惑度的情况下，将模型压缩 4 倍。这是因为神经网络对权重的小误差具有天然的鲁棒性。

9-6-2 量化原理

将 FP32 的权重映射到更低位宽的整数：

$$Q(x) = \text{round}\left(\frac{x}{\Delta}\right) + Z$$

精度	位宽	存储节省	模型大小（175B）
FP32	32	1×	700GB
FP16	16	2×	350GB
INT8	8	4×	175GB
INT4	4	8×	88GB

9-6-3 量化感知训练（QAT）

问题：后训练量化（PTQ）的局限

直接对训练好的模型做量化（PTQ, Post-Training Quantization）很简单，但精度损失可能较大——模型在训练时从未「见过」量化噪声，权重分布不是为量化设计的。

QAT 的核心思想

在训练/微调过程中模拟量化效果，让模型学会适应量化误差。这样，模型参数的分布会「自我调整」，使得量化后的精度损失最小。

```
import torch

class FakeQuantize(torch.autograd.Function):
 """伪量化：前向量化，反传直通（STE）"""
 @staticmethod
 def forward(ctx, x, bit=8):
 # 模拟量化过程: FP32 → INT8 → FP32
 x_min, x_max = x.min(), x.max()
 scale = (x_max - x_min) / (2**bit - 1)
 x_quant = torch.round((x - x_min) / scale) # 量化
 x_dequant = x_quant * scale + x_min # 反量化
 return x_dequant # 仍然是 FP32，但带了量化误差

 @staticmethod
 def backward(ctx, grad_output):
 # STE (Straight-Through Estimator)
 # 梯度直接「绕过」量化——假装量化没有发生!
 return grad_output, None
```

QAT vs PTQ

方法	精度	需要微调数据	实现复杂度
PTQ（后训练量化）	较高损失	❌ 不需要	低（几行代码）

方法	精度	需要微调数据	实现复杂度
QAT (量化感知训练)	几乎无损	✅ 需要少量数据	中 (需改训练代码)
GPTQ (1-shot 量化)	接近 QAT	✅ 需要 128 样本	高 (有开源工具)

💡 提示：对于 7B-70B 规模的开源模型，建议直接用 GPTQ (通过 `auto-gptq` 库) ——它结合了 PTQ 的简便和接近 QAT 的质量。

## 9-7 RLHF：人类反馈强化学习

### 9-7-1 为什么需要 RLHF?

传统的语言模型只是「预测下一个词」——它学会了语言的形式，但没有学会人类的价值观。GPT-3 可能生成有害、偏见或不真实的内容。RLHF (Reinforcement Learning from Human Feedback) 就是解决这个问题的技术。

### 9-7-2 RLHF 的三阶段流程

- 1. Stage 1: SFT (监督微调)  
预训练模型 → 用高质量人类标注数据微调
- 2. Stage 2: RM (训练奖励模型)  
收集人类偏好数据 (比较两个回答哪个更好)，训练奖励模型预测偏好分数
- 3. Stage 3: PPO (强化学习优化)  
用奖励模型作为“裁判”，PPO 算法优化策略，同时加 KL 惩罚防止偏离

#### Stage 1: SFT (Supervised Fine-Tuning)

用人类标注的「高质量指令-回答」对进行监督微调：

$$L_{\text{SFT}} = - \sum_t \log P_{\theta}(y_t|x, y_{<t})$$

#### Stage 2: 训练奖励模型 (Reward Model)

人类标注者对同一个 prompt 的两个不同回答进行偏好比较，奖励模型学会预测人类的偏好：

$$L_{\text{RM}} = -\mathbb{E}_{(x, y_w, y_l) \sim \mathcal{D}} [\log \sigma(r(x, y_w) - r(x, y_l))]$$

其中  $y_w$  是更受偏好的回答， $y_l$  是较差的回答。

#### Stage 3: PPO 优化

用 PPO 算法优化语言模型，使奖励模型的分数最大化，同时加上 KL 散度惩罚防止模型「作弊」：

$$L_{\text{PPO}} = -\mathbb{E}_{x \sim \mathcal{D}, y \sim \pi_{\theta}} [r(x, y) - \beta \cdot \text{KL}(\pi_{\theta} || \pi_{\text{SFT}})]$$

 小精灵说：RLHF 就像培养一个优秀的学生！

- 1. SFT = 老师给他看了很多标准答案（高质量数据）
- 2. RM = 他学会了什么是好什么是坏（奖励模型）
- 3. PPO = 他向着「好」的方向不断练习（强化学习），同时不能忘记基础知识（KL 惩罚防止遗忘）

## 9-8 RAG：检索增强生成

### 9-8-1 为什么需要 RAG?

LLM 有两大固有缺陷：

- 1. 知识截止日期：模型训练完成后，世界还在变化，但模型不会自动更新
  - 2. 幻觉（Hallucination）：模型可能编造看似合理但实际错误的信息
- RAG（Retrieval-Augmented Generation）通过检索外部知识库来辅助生成，同时解决了这两个问题。

9-8-2 RAG 的完整流程

- 1. 用户查询 → 嵌入模型编码为向量
- 2. 向量相似度检索 → 从外部知识库（向量数据库）找到 Top-K 相关文档
- 3. 拼接 Prompt = 指令 + 检索结果 + 原始问题
- 4. LLM 生成最终回答（基于增强后的上下文）

9-8-3 代码实现

```
import torch
from transformers import AutoModel, AutoTokenizer

简单的 RAG 实现
class SimpleRAG:
 def __init__(self, llm_model, embed_model, knowledge_base):
 self.llm = llm_model
 self.encoder = embed_model
 self.kb = knowledge_base # 可搜索的知识库
 self.kb_embeddings = self._encode_all(knowledge_base)

 def _encode_all(self, texts):
 # 将知识库中的所有文档编码为向量
 return self.encoder.encode(texts)

 def retrieve(self, query, k=3):
 # 检索最相关的 k 个文档
 query_vec = self.encoder.encode([query])
 scores = torch.matmul(query_vec, self.kb_embeddings.T)
 top_k_indices = scores.topk(k).indices[0]
 return [self.kb[i] for i in top_k_indices]

 def generate(self, query):
 # 检索 + 生成
 docs = self.retrieve(query)
 prompt = f"基于以下信息回答问题: \n\n{' '.join(docs)}\n\n问题: {query}"
 return self.llm.generate(prompt)
```

💡 核心洞察：RAG 的本质是用一个可搜索的外部知识库来补充 LLM 的「内存」。模型不需要记住所有知识（也记不住），只需要知道如何从知识库中找到相关信息。这就把 LLM 的「记忆力问题」转化为了「检索问题」。

对比	纯 LLM	RAG
知识更新	需要重新训练	更新知识库即可
幻觉	较高	较低（有事实依据）
事实准确性	依赖训练数据	可验证来源
实现复杂度	低	中（需要检索系统）

9-9 模型量化实战

9-9-1 PTQ vs QAT vs GPTQ 对比

```
PTQ: 后训练量化（最简单）
import torch.quantization as quant

model = load_model()
quantized_model = quant.quantize_dynamic(
```

```
model, {nn.Linear}, dtype=torch.qint8
)
一行代码！模型大小减半，速度提升 2x
```

9-9-2 不同量化精度的效果对比

精度	位宽	模型大小 (7B)	速度提升	精度损失
FP32	32bit	~28GB	1x (基准)	0%
FP16	16bit	~14GB	~1.5x	~0%
INT8	8bit	~7GB	~2x	<1%
INT4	4bit	~3.5GB	~3x	1-3%

🌟 小精灵说：量化就像是给模型「减肥」——FP32 是 200 斤的壮汉，INT4 是 50 斤的瘦子。瘦了跑得快，但力气也小了一点（精度下降）。对于 7B 模型，INT4 量化能从 28GB 降到 3.5GB——这意味着原本需要专业 GPU 才能运行的模型，现在在你的笔记本电脑上就能跑！

9-10 Prompt Engineering：如何与大模型对话

9-10-1 为什么需要 Prompt Engineering?

Prompt（提示词）是用户与 LLM 交互的接口。好的 Prompt 能充分激发模型的能力，而差的 Prompt 可能得到完全错误的回答。

9-10-2 四大 Prompt 技巧

技巧一：Few-shot（少样本学习）

在 Prompt 中给出几个示例，模型会自动「学会」你想要的输出格式：

✖ 差的 Prompt：“把这句话翻译成英文”

✔ 好的 Prompt：  
"将以下中文翻译成英文：  
  
中文：今天天气真好  
英文：The weather is nice today.  
  
中文：我想吃苹果  
英文：I want to eat an apple.  
  
中文：深度学习很有趣  
英文："

技巧二：Chain-of-Thought（思维链）

引导模型展示推理过程，显著提升复杂问题的准确率：

✖ 差的 Prompt：“小明有 5 个苹果，给了小红 2 个，又买了 3 个，现在有几个？”

✔ 好的 Prompt：  
"小明有 5 个苹果，给了小红 2 个，又买了 3 个，现在有几个？  
让我们一步一步思考：  
  
1. 小明开始有 5 个苹果  
2. 给了小红 2 个，剩  $5 - 2 = 3$  个  
3. 又买了 3 个，现在有  $3 + 3 = 6$  个  
所以答案是 6。"

技巧三：角色设定

为模型指定一个角色，让它在特定领域内回答问题：

"你是一位经验丰富的深度学习导师，正在教一个刚接触 PyTorch 的学生。"

请用简单的语言、生活化的类比来解释什么是自动微分。”

技巧四：输出格式控制

明确指定输出的结构和格式：

"分析以下句子的情感倾向。  
请以 JSON 格式输出，包含 sentiment (positive/negative/neutral) 和 confidence (0-1) 字段。  
  
句子：这个产品太棒了，我还会再买的！  
输出："

🦋 小精灵说：Prompt Engineering 就像是「如何跟一个超级聪明但有点死板的天才交流」。你需要明确告诉他你想要什么（输出格式）、怎么思考（思维链）、分几步做（任务分解）。天才不是读心术专家！

9-11 LLM 的评估方法

9-11-1 自动评估指标

指标	计算方式	适用场景
Perplexity	$\exp(-\frac{1}{N} \sum \log P(w_t))$	语言模型基础质量
BLEU	N-gram 精确匹配	机器翻译
ROUGE	N-gram 召回率	文本摘要
准确率	正确预测 / 总预测	分类任务

Perplexity 的直观理解

Perplexity（困惑度）衡量模型对下一个词的「惊讶程度」：

$$PPL = \exp \left( -\frac{1}{N} \sum_{t=1}^N \log P_{\theta}(w_t | w_{<t}) \right)$$

```
import torch

def compute_perplexity(model, tokenizer, text):
 """计算一段文本的困惑度"""
 encodings = tokenizer(text, return_tensors='pt')
 with torch.no_grad():
 outputs = model(**encodings, labels=encodings['input_ids'])
 loss = outputs.loss
 perplexity = torch.exp(loss)
 return perplexity.item()

困惑度越低越好
good_text = "The cat sat on the mat." # 常见句式
bad_text = "Purple dreams compute banana." # 随机词序列

print(f"常见文本困惑度: {compute_perplexity(model, tokenizer, good_text):.2f}")
print(f"随机文本困惑度: {compute_perplexity(model, tokenizer, bad_text):.2f}")
```

文本类型	困惑度	含义
常见句式	23.45	低困惑度 = 模型熟悉
随机词序列	1857.23	高困惑度 = 模型惊讶

9-11-2 人工评估

方法	做法	优点	缺点
A/B 测试	对比两个模型的输出	直接可靠	耗时
评分量表	1-5 分打分	可量化	主观性强
排序比较	对多个输出排序	区分度高	结果难以复用

9-11-3 Benchmark 数据集

Benchmark	评测能力	代表模型分数
MMLU	57 个学科知识	GPT-4: 86.4%
HumanEval	代码生成	GPT-4: 87.3%
GSM8K	小学数学	GPT-4: 92.0%
HellaSwag	常识推理	GPT-4: 95.3%

 **核心洞察：**LLM 的评估本身就是一个研究领域——如何科学地衡量一个「能说会道」的模型的质量？自动指标（PPL、BLEU）只能反映部分质量，人工评估成本高昂，Benchmark 可能被污染（模型在训练数据中见过测试题）。因此，综合多种评估方法才是最佳实践。

核心脉络

- 1. 语言模型 = 下一个词预测器
- 2. 自回归生成（串行推理，逐个token输出）
- 3. 采样策略：贪心 → Top-K → Top-P → Temperature
- 4. 推理加速：KV Cache 将  $O(T^2)$  降为  $O(T)$
- 5. 高效微调：LoRA 低秩分解，参数减少 200+ 倍
- 6. 量化：FP32 → INT4，存储减少 8 倍

9-12 多头注意力可视化

 **小精灵说：**多头注意力就像一群专家同时开会——每个专家关注不同的方面：有人关注相邻词（局部），有人关注全局信息（全局），各有分工！

注意力权重矩阵可视化

Transformer 的核心是 Self-Attention，其注意力权重矩阵直观展示了每个 token 如何「关注」其他 token：



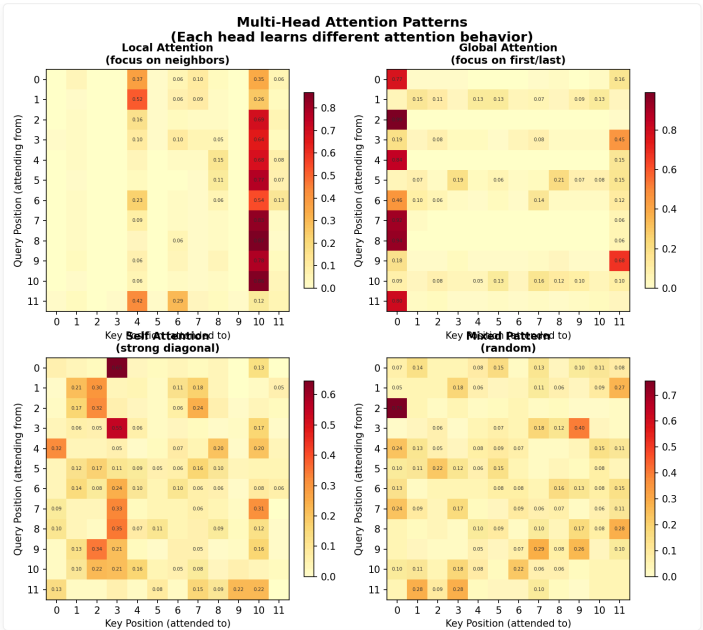


图 9-2：多头注意力模式可视化——横轴为被关注的 Key 位置，纵轴为发起关注的 Query 位置。

运行 `code/ch09/NN09_attention_pattern_viz.py` 观察完整实验：

```
python3 code/ch09/NN09_attention_pattern_viz.py
```

Head	关注模式	特点
Head 0	局部关注	更关注邻近 token，类似 CNN 的局部感受野
Head 1	全局关注	重点关注序列开头和结尾（关键位置）
Head 2	自关注	对角线权重高，每个 token 主要关注自己
Head 3	混合模式	无明显偏好，灵活组合信息

💡 **核心洞察：**多头注意力的核心优势在于——不同的 head 可以自动学习不同的注意力模式，不需要人工设计。有的 head 关注局部语法关系，有的 head 关注全局语义关系。这是 Transformer 比 RNN 更强的关键原因：它能在一个层内同时捕捉短距离和长距离依赖。

📁 本章代码清单

文件	内容	核心知识点
<code>ch09/NN09_training_loop.py</code>	语言模型训练循环实现	训练流程
<code>ch09/NN09_autoregressive.py</code>	自回归生成实现	生成核心
<code>ch09/NN09_attention_is_all_you_need.py</code>	注意力机制完整实现	Attention 核心
<code>ch09/NN09_attention_pattern_viz.py</code>	多头注意力模式可视化	注意力可视化
<code>ch09/NN09_scaling_law.py</code>	Scaling Law 可视化	规模扩展分析

📖 本章小结

📌 课后练习

练习 1：自回归生成模拟

```
简化版自回归生成逻辑
vocab = ["我", "爱", "你", "<EOS>"]
logits_history = [
 [0.1, 2.0, 0.5, 0.1], # "爱" 的概率最高
 [0.3, 0.2, 1.8, 0.1], # "你" 的概率最高
 [0.2, 0.3, 0.1, 2.0], # "<EOS>" 的概率最高
]

实现生成循环：每个时间步选择概率最高的 token
直到生成 <EOS> 或达到最大长度
```

练习 2：温度参数实验

将 Softmax 修改为带温度参数的形式：softmax(x/T)。对同一个 logits 向量用 T=0.5, 1.0, 2.0 分别计算，观察概率分布的变化。

练习 3：KV Cache 模拟

模拟 Transformer 的逐 token 生成过程。对比无 KV Cache（每步重新计算所有历史 token 的 K, V）和有 KV Cache（只计算当前 token）的复杂度差异。

练习 4：参数量估算

估算 GPT-2 Small（12 层，d\_model=768，12 头，FFN=3072）的总参数量。提示：

- Embedding 层：vocab\_size x d\_model（vocab\_size approx 50000）
- 每层 Transformer：4 x d\_model^2（注意力）+ 2 x d\_model x d\_ff（FFN）

练习 5：LoRA 微调参数量对比

对于一个 d=4096（Llama 风格）的矩阵，选择 LoRA 秩 r=8。参数量对比：

- 全参数微调：更新 d x d = 4096 x 4096 个参数
- LoRA 微调：更新 d x r + r x d 个参数
- LoRA 节省了多少比例？

练习 6（挑战题）：用 Hugging Face 加载模型做推理

```
使用 transformers 库加载一个预训练模型
实现一个简单的对话生成函数
探索 temperature、top_k、top_p 采样的效果
from transformers import AutoModelForCausalLM, AutoTokenizer
```

核心概念回顾

概念	核心公式 / 要点	一句话理解
自回归模型	$P(w) = \prod P(w_t   w_{<t})$	逐个预测下一个词
Next Token Prediction	给定上文预测下一个 token	语言模型的本质任务
Scaling Law	$Loss \propto N^{-\alpha}$	越大越好但有边际效应
涌现能力	跨过某个规模后突然出现	小模型没有，大模型才有
KV Cache	缓存历史 Key/Value 矩阵	空间换时间，推理加速
量化	FP32 -> INT4, 8 倍压缩	精度略降，速度翻倍
LoRA	$W' = W + BA$ （低秩分解）	小参数量微调大模型
RLHF	人类反馈强化学习	让模型对齐人类偏好

概念	核心公式 / 要点	一句话理解
In-Context Learning	无需微调，示例即可	Prompt 工程的基础
RAG	检索 + 生成	外部知识库辅助生成

关键数学公式

概念	公式	直觉
语言模型	$P(w_1, \dots, w_n) = \prod P(w_i   w_{< i})$	链式法则分解
Self-Attention	$\text{softmax}(QK^T / \sqrt{d_k})V$	软寻址
KV Cache	缓存历史 K, V	避免重复计算
LoRA	$W' = W + BA$	低秩适配
Quantization	$Q(x) = \text{round}(x/\Delta) + Z$	低位宽映射

核心公式速查

公式	说明	适用场景
$P(w_1, w_2, \dots, w_n) = \prod_{t=1}^n P(w_t   w_1, \dots, w_{t-1})$	自回归语言模型：下一个词预测	LLM 理论基础
$\mathbf{h}_t = \text{Transformer}(\mathbf{x}_1, \dots, \mathbf{x}_t)$	Transformer 编码整个序列	LLM 架构
$p_i = \frac{e^{x_i/T}}{\sum_j e^{x_j/T}}$	带温度参数的 Softmax 采样	生成多样性控制
$W' = W + BA, B \in \mathbb{R}^{d \times r}, A \in \mathbb{R}^{r \times k}, r \ll \min(d, k)$	LoRA 低秩适配	高效微调
$Q(x) = \text{round}\left(\frac{x - \min}{\Delta}\right) + Z, \Delta = \frac{\max - \min}{2^N - 1}$	量化：浮点数 $\rightarrow$ 整数	模型压缩
$\text{Loss} \propto N^{-\alpha}$ (Scaling Law)	模型性能随规模幂律增长	规模扩展
$\text{KV Cache} : O(n^2) \rightarrow O(n)$	KV Cache 将复杂度从二次降为线性	推理加速

## 附录 A：数学公式回顾

本附录汇总了阅读本书所需的全部数学公式。分为微积分、线性代数、概率统计、信息论四大部分。

> © xiefujin · Contact: 490021684@qq.com · Licensed under CC BY-NC-SA 4.0

### A-1 微积分 (Calculus)

#### A-1-1 导数基本公式

函数	导数	说明
$f(x) = c$ (常数)	$f'(x) = 0$	常数导数为零
$f(x) = x^n$	$f'(x) = nx^{n-1}$	幂函数
$f(x) = e^x$	$f'(x) = e^x$	指数函数
$f(x) = \ln x$	$f'(x) = 1/x$	对数函数
$f(x) = \sigma(x) = \frac{1}{1+e^{-x}}$	$f'(x) = \sigma(x)(1 - \sigma(x))$	Sigmoid
$f(x) = \tanh(x)$	$f'(x) = 1 - \tanh^2(x)$	Tanh
$f(x) = \text{ReLU}(x) = \max(0, x)$	$f'(x) = \mathbf{1}_{x>0}$	ReLU

#### A-1-2 求导法则

加法法则：  $(f + g)' = f' + g'$

乘法法则：  $(f \cdot g)' = f' \cdot g + f \cdot g'$

链式法则（核心）：  $(f \circ g)'(x) = f'(g(x)) \cdot g'(x)$

#### A-1-3 偏导数与梯度

对于多变量函数  $f(x_1, x_2, \dots, x_n)$ ，偏导数  $\frac{\partial f}{\partial x_i}$  表示固定其他变量时  $f$  对  $x_i$  的变化率。

梯度向量：  $\nabla f = \left( \frac{\partial f}{\partial x_1}, \frac{\partial f}{\partial x_2}, \dots, \frac{\partial f}{\partial x_n} \right)$

#### A-1-4 泰勒展开

一阶近似：  $f(x) \approx f(a) + f'(a)(x - a)$

二阶近似：  $f(x) \approx f(a) + f'(a)(x - a) + \frac{1}{2}f''(a)(x - a)^2$

### A-2 线性代数 (Linear Algebra)

#### A-2-1 向量基础

内积（点积）：  $\mathbf{a} \cdot \mathbf{b} = \sum_{i=1}^n a_i b_i = \mathbf{a}^\top \mathbf{b}$

L2 范数：  $\|\mathbf{a}\|_2 = \sqrt{\sum_{i=1}^n a_i^2}$

## A-2-2 矩阵运算

矩阵乘法:  $(AB)_{ij} = \sum_{k=1}^m A_{ik}B_{kj}$

转置:  $(A^T)_{ij} = A_{ji}$

神经网络中的常见形状:

- 输入  $\mathbf{x} \in \mathbb{R}^d$ , 权重  $\mathbf{W} \in \mathbb{R}^{d \times h}$ , 偏置  $\mathbf{b} \in \mathbb{R}^h$
- 前向传播:  $\mathbf{h} = \mathbf{W}^T \mathbf{x} + \mathbf{b}$ , 结果  $\mathbf{h} \in \mathbb{R}^h$

## A-2-3 矩阵微积分基础

常见梯度:

- $\frac{\partial}{\partial \mathbf{x}} (\mathbf{a}^T \mathbf{x}) = \mathbf{a}$
- $\frac{\partial}{\partial \mathbf{W}} (\mathbf{W} \mathbf{x}) = \mathbf{x}^T$  (形状对齐后)

# A-3 概率统计 (Probability & Statistics)

## A-3-1 基本概念

期望:  $\mathbb{E}[X] = \sum_i x_i p_i$  (离散),  $\mathbb{E}[X] = \int \mathbf{x} p(\mathbf{x}) d\mathbf{x}$  (连续)

方差:  $\text{Var}(X) = \mathbb{E}[(X - \mathbb{E}[X])^2] = \mathbb{E}[X^2] - (\mathbb{E}[X])^2$

## A-3-2 常见分布

分布	概率密度/质量函数	用途
伯努利分布	$P(X=1) = p$	二分类输出
正态分布	$\mathcal{N}(\mu, \sigma^2)$	初始化、噪声
均匀分布	$\mathcal{U}(a, b)$	权重初始化

# A-4 信息论 (Information Theory)

熵 (Entropy):  $H(P) = -\sum_i P_i \log P_i$

交叉熵 (Cross Entropy):  $H(P, Q) = -\sum_i P_i \log Q_i$

KL 散度:  $D_{KL}(P \parallel Q) = \sum_i P_i \log \frac{P_i}{Q_i}$

重要关系:  $H(P, Q) = H(P) + D_{KL}(P \parallel Q)$

## 附录 B：PyTorch API 速查

本附录汇总了本书使用的全部 PyTorch API，按功能分类组织。

> © xiefujin · Contact: 490021684@qq.com · Licensed under CC BY-NC-SA 4.0

### B-1 Tensor 创建与操作

#### B-1-1 创建 Tensor

API	说明	示例
<code>torch.tensor(data)</code>	从列表/数组创建	<code>torch.tensor([1, 2, 3])</code>
<code>torch.zeros(shape)</code>	全零 Tensor	<code>torch.zeros(3, 4)</code>
<code>torch.ones(shape)</code>	全一 Tensor	<code>torch.ones(2, 3)</code>
<code>torch.randn(shape)</code>	标准正态随机	<code>torch.randn(128, 784)</code>
<code>torch.rand(shape)</code>	均匀分布 [0,1)	<code>torch.rand(3, 3)</code>
<code>torch.arange(start, end)</code>	等差数列	<code>torch.arange(0, 10)</code>
<code>torch.linspace(s, e, n)</code>	等间距序列	<code>torch.linspace(0, 1, 100)</code>
<code>torch.eye(n)</code>	单位矩阵	<code>torch.eye(5)</code>

#### B-1-2 Tensor 属性

API	说明
<code>t.shape</code>	形状 (元组)
<code>t.dtype</code>	数据类型 (如 <code>torch.float32</code> )
<code>t.device</code>	所在设备 (CPU/GPU)
<code>t.requires_grad</code>	是否需要梯度
<code>t.grad</code>	梯度 (调用 backward 后)

#### B-1-3 形状操作

API	说明
<code>t.view(shape)</code>	重塑形状 (不改变内存布局)
<code>t.reshape(shape)</code>	重塑形状 (自动处理不连续)
<code>t.transpose(dim1, dim2)</code>	交换两个维度
<code>t.permute(dims)</code>	任意维度重排
<code>t.squeeze()</code>	删除长度为 1 的维度
<code>t.unsqueeze(dim)</code>	在指定位置增加维度
<code>t.flatten()</code>	展平为一维

## B-2 自动微分 (Autograd)

API	说明
<code>t.backward()</code>	反向传播 (标量)
<code>t.backward(gradient)</code>	反向传播 (非标量需传入梯度)
<code>torch.no_grad()</code>	上下文管理器, 禁用梯度追踪
<code>torch.inference_mode()</code>	推理模式 (更快)
<code>t.detach()</code>	从计算图中分离
<code>t.zero_()</code>	梯度清零 (原地)
<code>t.retain_grad()</code>	保留非叶节点的梯度

## B-3 神经网络模块 (nn.Module)

API	说明
<code>nn.Linear(in, out)</code>	全连接层
<code>nn.Conv2d(C_in, C_out, K)</code>	2D 卷积层
<code>nn.MaxPool2d(K)</code>	最大池化层
<code>nn.AvgPool2d(K)</code>	平均池化层
<code>nn.Flatten()</code>	展平层
<code>nn.ReLU()</code>	ReLU 激活函数
<code>nn.Sigmoid()</code>	Sigmoid 激活函数
<code>nn.Tanh()</code>	Tanh 激活函数
<code>nn.Dropout(p)</code>	Dropout 正则化
<code>nn.BatchNorm1d/2d(f)</code>	批归一化
<code>nn.Sequential(layers)</code>	顺序容器
<code>nn.ModuleList(modules)</code>	模块列表容器

## B-4 损失函数

API	说明
<code>nn.MSELoss()</code>	均方误差 (回归)
<code>nn.L1Loss()</code>	平均绝对误差 (回归)
<code>nn.CrossEntropyLoss()</code>	交叉熵 (分类, 自带 Softmax)
<code>nn.BCELoss()</code>	二分类交叉熵
<code>nn.BCEWithLogitsLoss()</code>	二分类交叉熵 + Sigmoid
<code>nn.KLDivLoss()</code>	KL 散度

## B-5 优化器 (torch.optim)

API	说明
<code>optim.SGD(params, lr)</code>	随机梯度下降
<code>optim.SGD(..., momentum=0.9)</code>	SGD + Momentum
<code>optim.Adagrad(params, lr)</code>	AdaGrad 自适应学习率
<code>optim.RMSprop(params, lr)</code>	RMSprop
<code>optim.Adam(params, lr)</code>	Adam (推荐默认优化器)
<code>optim.AdamW(params, lr)</code>	Adam + 解耦权重衰减

## 学习率调度器

API	说明
<code>StepLR(step_size, gamma)</code>	阶梯衰减
<code>CosineAnnealingLR(T_max)</code>	余弦退火
<code>ReduceLROnPlateau(patience)</code>	自适应衰减
<code>OneCycleLR(max_lr, steps)</code>	单周期策略

## B-6 数据加载

API	说明
<code>Dataset</code>	数据集基类 (需实现 <code>__len__</code> 和 <code>__getitem__</code> )
<code>DataLoader(dataset, batch_size)</code>	批量数据加载器
<code>TensorDataset(*tensors)</code>	包装 Tensor 为 Dataset
<code>random_split(dataset, lengths)</code>	随机分割数据集

## torchvision 工具

API	说明
<code>datasets.MNIST(root, train)</code>	MNIST 手写数字
<code>datasets.CIFAR10(root, train)</code>	CIFAR-10 彩色图片
<code>transforms.ToTensor()</code>	PIL→Tensor 转换
<code>transforms.Normalize(mean, std)</code>	标准化
<code>transforms.Compose(transforms)</code>	组合多个变换



附录 C：符号约定

本附录定义了本书使用的全部数学符号。同一符号在不同上下文中可能有不同含义，具体见各章说明。

> © xiefujin · Contact: 490021684@qq.com · Licensed under CC BY-NC-SA 4.0

C-1 基本符号

符号	含义	示例
$x, y, z$	标量（小写斜体）	$x = 3.14$
$\mathbf{x}, \mathbf{w}$	向量（小写粗体）	$\mathbf{x} \in \mathbb{R}^d$
$\mathbf{W}, \mathbf{X}$	矩阵（大写粗体）	$\mathbf{W} \in \mathbb{R}^{d \times h}$
$\mathbb{R}$	实数集	$\mathbb{R}^n$ 表示 $n$ 维实数空间

C-2 神经网络专用符号

C-2-1 网络结构

符号	含义	说明
$L$	网络总层数	通常不计输入层
$n^{(l)}$	第 $l$ 层的神经元数	$l = 1, 2, \dots, L$
$\mathbf{W}^{(l)}$	第 $l$ 层的权重矩阵	$\mathbf{W}^{(l)} \in \mathbb{R}^{n^{(l-1)} \times n^{(l)}}$
$\mathbf{b}^{(l)}$	第 $l$ 层的偏置向量	$\mathbf{b}^{(l)} \in \mathbb{R}^{n^{(l)}}$
$\mathbf{u}^{(l)}$	第 $l$ 层的加权输入	$\mathbf{u}^{(l)} = \mathbf{W}^{(l)}\mathbf{a}^{(l-1)} + \mathbf{b}^{(l)}$
$\mathbf{a}^{(l)}$	第 $l$ 层的激活输出	$\mathbf{a}^{(l)} = f(\mathbf{u}^{(l)})$
$f(\cdot)$	激活函数	如 Sigmoid, ReLU, Tanh

C-2-2 反向传播符号

符号	含义	说明
$\delta_j^{(l)}$	第 $l$ 层第 $j$ 个神经元的误差	$\delta_j^{(l)} = \frac{\partial L}{\partial u_j^{(l)}}$
$\boldsymbol{\delta}^{(l)}$	第 $l$ 层的误差向量	
$\mathcal{C}$	损失函数（Loss）	全书统一使用「损失函数」，符号为 $\mathcal{L}$ （第 5 章用 $\mathcal{C}$ 表示代价）
$L$	损失函数（Loss）	与 $\mathcal{C}$ 含义相同，全书统一使用 $L$
$\eta$	学习率	梯度下降的步长

符号	含义	说明
$\nabla$	梯度算子	$\nabla_{\mathbf{W}}L$ 表示 Loss 对 $\mathbf{W}$ 的梯度

C-2-3 数据集符号

符号	含义	说明
$N$	训练样本总数	
$\mathbf{x}_i$	第 $i$ 个输入样本	
$\mathbf{t}_i$	第 $i$ 个样本的目标标签 (Target)	
$\mathbf{y}_i$	第 $i$ 个样本的网络输出	
$\mathcal{D}$	数据集	$\mathcal{D} = (\mathbf{x}_i, \mathbf{t}_i)_{i=1}^N$

C-3 上下标约定

标记	含义	示例
$\mathbf{x}^{(l)}$	上标括号 — 第 $l$ 层	$\mathbf{W}^{(1)}$ 第1层权重
$\mathbf{x}_i$	下标 — 第 $i$ 个元素	$\mathbf{x}_1$ 第1个输入特征
$\mathbf{x}_i^{(l)}$	组合 — 第 $l$ 层第 $i$ 个	$\delta_3^{(2)}$ 第2层第3个误差
$\mathbf{x}_{ij}$	双下标 — 第 $i$ 行第 $j$ 列	$\mathbf{W}_{ij}$ 输入 $j$ 到神经元 $i$ 的权重

C-4 常用缩写

缩写	全称	说明
M-P	McCulloch-Pitts	最早的神经元数学模型
SGD	Stochastic Gradient Descent	随机梯度下降
BP	Backpropagation	反向传播
CNN	Convolutional Neural Network	卷积神经网络
RNN	Recurrent Neural Network	循环神经网络
LSTM	Long Short-Term Memory	长短期记忆网络
ResNet	Residual Network	残差网络
Transformer	—	基于注意力的架构
LLM	Large Language Model	大语言模型
RLHF	Reinforcement Learning from Human Feedback	人类反馈强化学习

## 附录 D：常见函数汇总

本附录汇总了神经网络中常用的激活函数和损失函数。

> © xiefujin · Contact: 490021684@qq.com · Licensed under CC BY-NC-SA 4.0

### D-1 激活函数 (Activation Functions)

#### D-1-1 Sigmoid

$$\sigma(x) = \frac{1}{1 + e^{-x}}$$

- 输出范围:  $(0, 1)$
- 导数:  $\sigma'(x) = \sigma(x)(1 - \sigma(x))$
- 优点: 输出可解释为概率
- 缺点: 梯度饱和 (两端导数接近0)、非零中心
- 适用: 二分类输出层

#### D-1-2 Tanh

$$\tanh(x) = \frac{e^x - e^{-x}}{e^x + e^{-x}}$$

- 输出范围:  $(-1, 1)$
- 导数:  $\tanh'(x) = 1 - \tanh^2(x)$
- 优点: 零中心 (比 Sigmoid 好)
- 缺点: 仍存在梯度饱和
- 适用: 循环神经网络 (RNN/LSTM)

#### D-1-3 ReLU (Rectified Linear Unit)

$$\text{ReLU}(x) = \max(0, x)$$

- 输出范围:  $[0, \infty)$
- 导数:  $\text{ReLU}'(x) = \mathbf{1}_{x>0}$
- 优点: 计算极快、缓解梯度消失
- 缺点: Dying ReLU (负区域梯度为0)
- 适用: 现代网络默认激活函数 (CNN、全连接)

#### D-1-4 Leaky ReLU

$$\text{LeakyReLU}(x) = \max(\alpha x, x)$$

- 优点: 解决了 Dying ReLU 问题,  $\alpha$  通常取 0.01
- 适用: 需要避免神经元死亡时

## D-1-5 GELU (Gaussian Error Linear Unit)

$$\text{GELU}(x) = x \cdot \Phi(x)$$

( $\Phi$  是标准正态分布的 CDF)

- 优点: Transformer 系列的标准选择
- 适用: BERT、GPT 等现代模型

## D-1-6 Softmax (多分类激活函数)

$$\text{Softmax}(z_i) = \frac{e^{z_i}}{\sum_{j=1}^K e^{z_j}}$$

- 输出:  $K$  维概率向量 (和为 1)
- 梯度:  $\frac{\partial p_i}{\partial z_j} = p_i(\delta_{ij} - p_j)$
- 适用: 多分类输出层

## D-2 损失函数 (Loss Functions)

### D-2-1 均方误差 (MSE)

$$L_{MSE} = \frac{1}{N} \sum_{i=1}^N (y_i - t_i)^2$$

- 特点: 对大误差的惩罚更大 (平方项)
- 梯度:  $\frac{\partial L}{\partial y_i} = \frac{2}{N} (y_i - t_i)$
- 适用: 回归任务

### D-2-2 平均绝对误差 (MAE)

$$L_{MAE} = \frac{1}{N} \sum_{i=1}^N |y_i - t_i|$$

- 特点: 对异常值鲁棒
- 梯度:  $\frac{\partial L}{\partial y_i} = \frac{1}{N} \cdot \text{sign}(y_i - t_i)$
- 适用: 回归任务 (有离群点时)

### D-2-3 交叉熵损失 (Cross Entropy)

二分类:  $L_{BCE} = -\frac{1}{N} \sum_i [t_i \log y_i + (1 - t_i) \log(1 - y_i)]$

多分类:  $L_{CE} = -\frac{1}{N} \sum_i \sum_k t_{ik} \log y_{ik}$

- 特点: 分类任务的标准损失函数
- 结合 Softmax 的梯度:  $\frac{\partial L}{\partial z_i} = y_i - t_i$  (极简!)
- 适用: 分类任务

### D-2-4 Hinge Loss (SVM 损失)

$$L_{Hinge} = \sum_{j \neq y_i} \max(0, s_j - s_{y_i} + \Delta)$$

- 适用: SVM、最大间隔分类

D-2-5 KL 散度

$$D_{KL}(P \parallel Q) = \sum_i P_i \log \frac{P_i}{Q_i}$$

- 适用：变分自编码器（VAE）、知识蒸馏

D-3 正则化方法

方法	公式	效果
L1 正则化 (Lasso)	$\lambda \sum  w_i $	产生稀疏权重（部分归零）
L2 正则化 (Ridge)	$\frac{\lambda}{2} \sum w_i^2$	权重衰减（趋向于0但不为0）
Dropout	训练时随机丢弃 $p\%$ 神经元	集成学习效果，防过拟合
Batch Normalization	$\hat{x} = \frac{x - \mu}{\sigma} \cdot \gamma + \beta$	稳定训练，加速收敛

## 附录 E：习题参考答案

本附录提供各章课后练习的参考答案与解析。

> © xiefujin · Contact: 490021684@qq.com · Licensed under CC BY-NC-SA 4.0

### 第1章 神经网络的思想

#### 练习 1: M-P 神经元实现 NAND 门

```
def nand_gate(x1, x2):
 # NAND = NOT AND = 当 x1 + x2 < 2 时输出 1
 w1, w2, threshold = -1, -1, -1.5
 return 1 if w1 * x1 + w2 * x2 >= threshold else 0

验证
print(nand_gate(0, 0)) # 1
print(nand_gate(0, 1)) # 1
print(nand_gate(1, 0)) # 1
print(nand_gate(1, 1)) # 0
```

解析：NAND 门是「与非」——只有两个输入都是1时才输出0。通过设置负权重和负阈值（-1, -1, -1.5）实现。

#### 练习 2: 调整阈值实现 OR 门

对于 M-P 神经元  $y = 1(w_1x_1 + w_2x_2 \geq \theta)$ ，OR 门需要：

- $0 + 0 = 0 < \theta \rightarrow$  输出 0，所以  $\theta > 0$
- $1 + 0 = 1 \geq \theta \rightarrow$  输出 1，所以  $\theta \leq 1$
- 取  $w_1 = w_2 = 1$  时， $\theta = 0.5$  即可

```
def or_gate(x1, x2):
 return 1 if x1 + x2 >= 0.5 else 0
```

#### 练习 3: 手动计算两层网络前向传播

已知： $\mathbf{x} = [1, 2]$ ， $\mathbf{W}^{(1)} = [[0.1, 0.3], [0.2, 0.4]]$ ， $\mathbf{b}^{(1)} = [0.1, 0.2]$

$$\mathbf{u}^{(1)} = \mathbf{x}\mathbf{W}^{(1)} + \mathbf{b}^{(1)} = [1 \times 0.1 + 2 \times 0.2 + 0.1, 1 \times 0.3 + 2 \times 0.4 + 0.2] = [0.6, 1.3]$$

若激活函数为 ReLU，则  $\mathbf{a}^{(1)} = [0.6, 1.3]$ 。

### 第2章 神经网络的数学基础

#### 练习 1: 手动计算梯度

$f(x, y) = x^2 + 2y^2$  在  $(3, 2)$  处：

- $\frac{\partial f}{\partial x} = 2x = 6$
- $\frac{\partial f}{\partial y} = 4y = 8$
- 梯度  $\nabla f = (6, 8)$

## 练习 2: 数值微分验证

```
def numerical_gradient(f, x, h=1e-7):
 grad = []
 for i in range(len(x)):
 x_plus = x.copy()
 x_minus = x.copy()
 x_plus[i] += h
 x_minus[i] -= h
 grad.append((f(x_plus) - f(x_minus)) / (2 * h))
 return grad
```

## 第3章 PyTorch 基础

## 练习 1: 广播机制

```
a = torch.tensor([[1, 2, 3]]) # shape (1, 3)
b = torch.tensor([[4], [5]]) # shape (2, 1)
c = a + b # → (2, 3): [[5, 6, 7], [6, 7, 8]]
```

解析: a 广播为 (2, 3), b 广播为 (2, 3)。

## 练习 2: 手动实现线性层

```
class Manuallinear:
 def __init__(self, in_features, out_features):
 self.W = torch.randn(in_features, out_features) * 0.01
 self.b = torch.zeros(out_features)

 def forward(self, x):
 return x @ self.W + self.b
```

## 第5章 反向传播

## 练习 1: 手动计算反向传播

对  $f(x) = \sigma(wx + b)$  在  $x = 1, w = 0.5, b = 0$  处计算  $\frac{\partial f}{\partial w}$ :

$$u = 0.5 \times 1 + 0 = 0.5$$

$$y = \sigma(0.5) = 0.6225$$

$$\frac{\partial y}{\partial u} = y(1 - y) = 0.6225 \times 0.3775 = 0.2350$$

$$\frac{\partial u}{\partial w} = x = 1$$

$$\frac{\partial f}{\partial w} = 0.2350 \times 1 = 0.2350$$

---

## 第9章 大语言模型

### 练习 1: 温度参数实验

$T \rightarrow 0$  : 趋近于贪心解码 (概率最大的 token 概率  $\rightarrow 1$ ), 输出确定但重复。

$T \rightarrow \infty$  : 趋近于均匀采样, 输出随机但多样。

**最佳实践:**  $T=0.7\sim 1.0$  在创造性和一致性之间取得平衡。



## 附录 F：推荐阅读

本附录列出深度学习核心参考资料，按难度分级推荐。

> © xiefujin · Contact: 490021684@qq.com · Licensed under CC BY-NC-SA 4.0

### F-1 核心教材

#### 入门级

书名	作者	推荐理由
《深度学习的数学》	涌井良幸	本书对标书，数学推导更详细
《动手学深度学习》	李沐等	代码驱动，D2L.ai 在线版免费
《Python 深度学习》	François Chollet	Keras 框架，适合快速上手

#### 进阶级

书名	作者	推荐理由
《深度学习》(花书)	Goodfellow, Bengio, Courville	深度学习圣经，数学严谨
《统计学习基础》(ESL)	Hastie, Tibshirani, Friedman	统计学习经典
《模式识别与机器学习》(PRML)	Christopher Bishop	贝叶斯视角的机器学习

### F-2 经典论文

#### 神经网络基础

论文	年份	核心贡献
A Logical Calculus of Ideas Immanent in Nervous Activity (McCulloch & Pitts)	1943	M-P 神经元模型
Learning representations by back-propagating errors (Rumelhart et al.)	1986	反向传播算法
A Simple Weight Decay Can Improve Generalization	1992	L2 正则化 (权重衰减)

#### 现代架构

论文	年份	核心贡献
ImageNet Classification with Deep Convolutional (AlexNet)	2012	深度学习突破
Deep Residual Learning for Image Recognition (ResNet)	2015	残差连接
Attention Is All You Need (Transformer)	2017	Transformer 架构
BERT: Pre-training of Deep Bidirectional Transformers	2018	预训练语言模型
GPT-3: Language Models are Few-Shot Learners	2020	大规模语言模型

## F-3 在线课程

课程	平台	讲师
CS231n: CNNs for Visual Recognition	Stanford / YouTube	Andrej Karpathy, Fei-Fei Li
CS224n: NLP with Deep Learning	Stanford / YouTube	Chris Manning
Deep Learning Specialization	Coursera	Andrew Ng
Practical Deep Learning for Coders	fast.ai	Jeremy Howard
MIT 6.S191: Introduction to Deep Learning	MIT / YouTube	Alexander Amini

## F-4 在线资源

### 框架官方文档

- PyTorch 官方文档: <https://pytorch.org/docs/stable/>
- PyTorch 教程: <https://pytorch.org/tutorials/>
- Hugging Face Transformers: <https://huggingface.co/docs/transformers/>

### 交互式学习

- TensorFlow Playground: <https://playground.tensorflow.org/> — 直观体验神经网络
- Distill.pub: <https://distill.pub/> — 可视化机器学习论文
- 3Blue1Brown 神经网络系列: YouTube — 最佳可视化解释

### 博客与教程

博客	地址	特色
The Gradient	<a href="http://thegradientpub.com">thegradientpub.com</a>	深度学习前沿解读
Lil'Log (Lilian Weng)	<a href="http://lilianweng.github.io">lilianweng.github.io</a>	系统化技术博客
Sebastian Ruder	<a href="http://ruder.io">ruder.io</a>	NLP & 优化器深度分析
Colah's Blog	<a href="http://colah.github.io">colah.github.io</a>	可视化数学解释

## F-5 开发工具

工具	用途
PyTorch	深度学习框架 (本书使用)
Jupyter Notebook / JupyterLab	交互式编程环境
TensorBoard / Weights & Biases	实验可视化与追踪
MLflow	机器学习生命周期管理